

上海财经大学

研究生申请学位论文开题报告表

姓名	吴优	学院	统计与数据科学学院
学号	2025213385	导师姓名	张吕欧
专业	应用统计	培养层次	专业硕士
同意开题		导师签字：	

论文题目	基于去随机化 Model-X Knockoff 的电商 GMV 多粒度受控维度选择研究
开题时间	开题地点：
与会专家姓名、 单位（3-5 人）	
开题报告情况	专家主要意见：
开题结果（划 圈）	开题通过，同意进入论文写作阶段。 / 开题未通过，不同意进入论文写作阶段。 开题报告会专家组组长签名： 导师签名：年 月 日

注：填写本表 1 份，申请开题须经导师签字同意；开题结果由开题报告会专家组组长及导师签署并签字；交研究生秘书进入教学管理信息系统录入开题结果。附：上海财经大学研究生学位论文开题报告书（见下页），打印 3-5 份交学院安排开题。

上海财经大学

研究生学位论文开题报告书

论文题目：基于去随机化 **Model-X Knockoff** 的
电商 **GMV** 多粒度受控维度选择研究

姓 名： 吴优

学 号： 2025213385

院系所： 统计与数据科学学院

专 业： 应用统计

培养层次： 专业硕士

导师姓名： 张吕欧

二〇二六年九月

1、选题背景、研究问题、理论意义与实用价值

电商平台能够连续记录获客、下单、支付、发货、送达和评价等经营过程。企业通常以 GMV 作为核心经营指标，并围绕交易规模、价格成本、供给、支付、履约、口碑、地域和营销建立多维监控看板。随着业务发展，指标数量持续增加，订单数、件数和顾客数等高度相关变量容易重复表达同一经营状态，管理者难以在有限时间内判断哪些维度真正具有独立信息。若使用边际相关或逐项显著性检验筛选指标，还会因多重比较累积假阳性；若仅依赖 XGBoost 等机器学习重要性，则只能得到相对排序，无法控制入选集合的误选比例。

本文拟研究的核心问题是：给定卖家在当前周期的 31 项经营维度，哪些变量在控制其余候选信息后，仍包含下一周期 GMV 的增量预测信息，并值得进入持续监控体系。月度主分析的条件零假设为

$$H_{0j} : Y_{s,t+1} \perp X_{j,s,t} \mid X_{-j,s,t},$$

其中 $Y_{s,t+1}$ 为卖家 s 次月的 $\log(1 + \text{GMV})$ ， $X_{j,s,t}$ 为本月第 j 项候选维度。拒绝该假设表示变量具有条件预测信息，但不表示主动改变该变量必然改变 GMV。

理论上，本文把经营看板选维转化为 Model-X Knockoff 框架下的多重检验问题，以仿制变量作为负对照，并通过多轮 e-value 聚合控制目标错误发现率。研究同时讨论面板组内相关、共线业务组、非高斯联合分布和时间聚合粒度对选择结果的影响。

实践上，研究将统计确认与页面展示分开。统计程序先形成可控误选的确认真集，再由参数 K 确定首页展示 4 项、8 项、10 项或完整集合。月度分析负责稳定确认，周度分析负责短期预警和粒度复核，从而为指标准入、下钻和退出提供可复核依据。

本文围绕四个具体问题展开：

1. 如何从十张不同自然粒度的业务表构造金额可对账、主键不重复的卖家面板；
2. 如何在 31 项混合且高度相关的候选变量中控制目标错误发现率；
3. 如何在不改变统计确认集合的前提下，通过参数 K 控制页面展示数量；
4. 月度结论在周度、卖家内变化、业务组竞争和非线性模型下是否保持稳定。

2、国内外研究现状与发展趋势

Benjamini 和 Hochberg 提出错误发现率控制方法，使多重检验能够在保留发现能力的同时约束错误发现比例 [1]。Barber 和 Candès 提出 Knockoff 过滤器，Candès 等将其扩展到 Model-X 设定，通过构造与真实变量成对可交换的仿制变量实现受控变量选择 [2, 3]。与 Lasso 等以预测误差为目标的稀疏估计不同，Knockoff 直接针对发现集合的错误比例。

Knockoff 生成具有随机性。Ren 和 Barber 将单轮结果表示为 e-value，并通过 e-BH 聚合多轮 Knockoff，从而降低随机种子对最终集合的影响 [5]。Wang 和 Ramdas 证明 e-BH 可在任意依赖的 e-values 下控制 FDR [6]。Spector 和 Janson 提出最小可重构性准则，以改善相关变量场景下的功效 [9]。对于共线变量，Dai 和 Barber 给出 Group Knockoff，使统计竞争从单列扩展到预定义业务组 [12]。

复杂非高斯数据推动了深度 Knockoff 研究。Romano 等使用深度生成网络逼近可交换联合分布 [11]。然而，边际分布接近并不足以保证联合交换性。Liu 等提出的深度核两样本检验能够提高高维分布差异的检测能力 [13]，适合用作生成器准入诊断。本文据此将深度模型的生成能力与统计有效性分开评价。

机器学习方法常用于销售预测和特征排序。Lasso 和 Elastic Net 提供稀疏基线 [14, 15]，随机森林和梯度提升能够表达非线性 [16, 17]，XGBoost 进一步提供适合大规模稀疏表格数据的实现 [18]。TreeSHAP 可以一致地分解树模型预测贡献 [19, 20]。但机器学习重要性不等于条件独立检验，也不提供因果效应。面板固定效应能够控制卖家不随时间变化的异质性 [21]，仍可能受到未观测时变混杂影响。

现有方法分别覆盖多重检验、预测、解释或面板建模，但较少将受控发现、随机稳定性、可调展示数量和月周粒度复核纳入同一经营指标治理流程。本文拟在该交叉问题上形成完整实证框架。

3、数据来源、变量与研究设计

3.1 原始数据与连接原则

本文使用 Olist 公开的订单、商品明细、支付、评价、商品、卖家、顾客、地理和营销漏斗数据。支付和评价先聚合至订单级，地理数据按邮编前缀聚合，再与商品明细连接，以避免多对多连接造成 GMV 膨胀。独立顾客数使用跨订单唯一顾客标识计算。

月度面板包含 14,677 个卖家-月、2,793 个卖家和 19 个月，下一月零成交率为 25.86%；周度面板包含 33,190 个卖家-周、2,834 个卖家和 83 周，下一周零成交率为 40.46%。32 项候选维度中，申报月收入对数因零方差排除，31 项进入模型。

分析口径	面板行数	卖家数	期间数	下一期零值率
月度主分析	14,677	2,793	19 个月	25.86%
周度稳健性	33,190	2,834	83 周	40.46%

3.2 候选维度与业务概念

业务概念	列数	主要变量
价格成本	2	平均商品价格、平均运费
商品物理属性	4	重量、长度、高度、宽度
商品内容	3	图片数、标题长度、描述长度
支付与口碑	7	分期、序列、四种支付方式占比、评价得分
履约	4	送达、审核、承运、预计偏差
交易规模	4	件数、订单数、品类数、独立顾客数
市场覆盖	4	买家州数、最大州占比、跨州占比、距离
卖家与营销	3	卖家州频率、营销来源频率、成交线索匹配

3.3 目标、时间切分与评价

月度目标为 $Y_{s,t+1} = \log(1 + \text{GMV}_{s,t+1})$ ，周度目标相应替换为下一周。若卖家当前期活跃而下一期无成交，则目标标记为零。月度预测使用 2017 年训练、2018 年 1–4 月验证、2018 年 5–7 月测试；周度使用相同自然时间边界。主要评价指标为

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad \text{WAPE} = \frac{\sum_i |g_i - \hat{g}_i|}{\sum_i g_i}.$$

4、核心统计方法

4.1 随机化秩高斯与二阶 Knockoff

首先对连续变量进行分位缩尾、偏态变换、中位数插补和标准化，再使用随机化秩高斯变换处理并列值：

$$Z_{ij} = \Phi^{-1} \left(\frac{r_{ij} - 0.5}{n} \right).$$

设 $\widehat{\Sigma}$ 为 Ledoit-Wolf 收缩协方差。仿制变量需要满足

$$(X, \tilde{X})_{\text{swap}(S)} \stackrel{d}{=} (X, \tilde{X}), \quad \tilde{X} \perp Y \mid X.$$

在潜在高斯空间中，按 MVR 准则确定对角矩阵 S ，条件采样分布为

$$\tilde{Z} \mid Z \sim \mathcal{N} \left(Z - Z\widehat{\Sigma}^{-1}S, 2S - S\widehat{\Sigma}^{-1}S \right).$$

4.2 Lasso 竞争统计量与 Knockoff+

将 $[Z, \tilde{Z}]$ 共同输入 Lasso，构造反对称统计量

$$W_j = |\hat{\beta}_j| - |\hat{\beta}_{j+p}|.$$

Knockoff+ 阈值为

$$T(q) = \min \left\{ t > 0 : \frac{1 + \#\{j : W_j \leq -t\}}{\#\{j : W_j \geq t\} \vee 1} \leq q \right\}, \quad \widehat{S} = \{j : W_j \geq T(q)\}.$$

若真实变量持续胜过对应仿制变量，则 W_j 倾向于为正；负向统计量用于估计正向发现中的错误数量。

4.3 去随机化 e-value

主分析独立生成 $M = 60$ 组 Knockoff。第 m 轮变量 j 的 e-value 定义为

$$e_j^{(m)} = p \frac{\mathbf{1}\{W_j^{(m)} \geq T^{(m)}\}}{1 + \sum_{k=1}^p \mathbf{1}\{W_k^{(m)} \leq -T^{(m)}\}}, \quad \bar{e}_j = \frac{1}{M} \sum_{m=1}^M e_j^{(m)}.$$

本文以 $\alpha_{\text{kn}} = 0.10$ 形成单轮 e-value, 并在最终 $\alpha_{\text{eBH}} = 0.20$ 下实施 e-BH。将 $\bar{e}_j$ 从大到小排列, 取满足

$$\bar{e}_{(k)} \geq \frac{p}{\alpha_{\text{eBH}} k}$$

的最大 k 形成正式确认集合。单轮频率只作为随机稳定性描述。

5、参数化展示与稳健性分支

5.1 参数 K

确认集合 S_{FDR} 固定后, 使用训练期 XGBoost 和验证集 TreeSHAP 得到排序 π :

$$S(K) = \{\pi_1, \dots, \pi_K\}, \quad K^* = \min \{K : C_K \geq 90\%, \text{RMSE}_K \leq 1.005 \text{RMSE}_{\min}\}.$$

K 仅改变页面展示长度, 不重新计算 FDR。

5.2 卖家间/内与业务组

面板结构按

$$X_{s,t} = \bar{X}_s + (X_{s,t} - \bar{X}_s)$$

拆分为卖家间长期位置与卖家内短期离差。31 项变量另划为 12 个业务组, 组级统计量定义为

$$W_g = \|\hat{\beta}_g\|_2 - \|\hat{\beta}_{\bar{g}}\|_2.$$

5.3 深度联合诊断与非线性重要性

深度生成器使用多比例 swap-MMD、边际、协方差、交叉对称和可重构性损失。有效性由边际 KS、协方差误差、深度核 MMD 和分类器两样本检验共同决定。未通过联合交换性诊断的生成器不进入 FDR 结论。非线性重要性使用配对竞争 MLP, 并在二维正则路径上累计真实与仿制入口活跃度之差。

5.4 预测与解释

预测模型包括 Ridge、Lasso、Extra Trees、XGBoost 和 MLP。测试集不参与参数选择。TreeSHAP 用于确认集合内部排序; 双向固定效应控制卖家和周期效应, 标准误按卖家聚类。两者均为预测或条件关联证据, 不解释为因果效应。

6、月度确认性实证结果

Copula-MVR 的平均边际 KS 为 0.013, 原始高斯为 0.200, 因此正式分析采用 Copula-MVR。最终 FDR 水平 0.20 下入选 14 项; 其中 10 项单轮频率不低于 90%。

排序	维度	平均 W	单轮频率	平均 e-value
1	成交订单数	0.144	95.0%	28.675
2	平均商品价格	0.142	95.0%	28.675
3	独立顾客数	0.140	95.0%	28.675
4	成交件数	0.117	95.0%	28.675
5	买家州数量	0.097	95.0%	28.675
6	平均审核至承运天数	0.053	95.0%	28.675
7	平均运费	0.027	95.0%	28.675
8	活跃品类数	0.023	95.0%	28.675
9	平均预计提前送达天数	0.021	95.0%	28.675
10	平均商品标题长度	0.022	91.7%	27.642
11	平均商品高度	0.013	80.0%	24.025
12	卖家所在州频率	0.014	76.7%	22.992
13	平均商品描述长度	0.009	50.0%	14.725
14	平均下单至送达天数	0.007	41.7%	12.142

在 $q = 0.10$ 时严格集合为空, $q = 0.20$ 和 $q = 0.30$ 均为 14 项。该跳跃来自 $p = 31$ 时 Knockoff+ 阈值的离散性, 因此本文不通过事后调整 q 来获得任意长度列表。

7、参数 K 与时间外预测结果

档位	K	累计贡献	验证 RMSE	测试 RMSE
极简	4	72.1%	2.335	2.388
均衡	8	87.1%	2.341	2.389
默认推荐	10	92.6%	2.343	2.385
完整确认集	14	100.0%	2.343	2.384

默认 $K = 10$ 包括独立顾客数、成交订单数、平均商品价格、平均审核至承运天数、平均预计提前送达天数、买家州数量、平均下单至送达天数、成交件数、平均运费和平均商品标题长度。

模型	RMSE(log)	MAE(log)	R^2	WAPE
XGBoost	2.388	1.914	0.291	67.2%
Ridge	2.389	1.949	0.291	73.1%
Lasso	2.389	1.949	0.290	73.1%
Extra Trees	2.390	1.914	0.290	65.9%
XGBoost (确认集合)	2.391	1.914	0.289	67.2%
残差 MLP	2.414	1.927	0.276	71.8%
MLP	2.429	1.947	0.267	74.5%
本月 GMV 基线	2.895	1.981	-0.042	79.2%

最佳月度模型为 XGBoost，较朴素基线 RMSE 改善 17.5%。默认 $K = 10$ 的测试 RMSE 为 2.385，与全 31 维 XGBoost 基本一致，说明压缩展示数量未明显损失预测信息。MLP 和残差 MLP 未优于树模型，表明当前样本下模型复杂度本身不能保证泛化收益。

8、周度粒度与结构稳健性结果

周度分析在相同流程下入选 18 项，其中 13 项单轮频率不低于 90%。月度 14 项与周度 18 项共同入选 11 项，Jaccard 系数为 0.524。周度特有项主要涉及商品物理、支付结构和营销标记，应作为观察层而非直接升级为确认指标。

场景	重复数	严格数	与周度主集重合
周度主分析	60	18	18
原始高斯生成	40	12	12
同周 GMV 对照	40	29	17
截尾时间窗	40	20	16
下一周客单价	40	15	15
测试期前样本	40	14	13
XGBoost 统计量	25	16	15

周度模型	RMSE(log)	MAE(log)	R^2	WAPE
Extra Trees	2.416	2.146	0.254	78.0%
XGBoost	2.420	2.160	0.251	79.6%
XGBoost (18 项)	2.421	2.157	0.251	79.2%
Lasso	2.433	2.189	0.244	82.7%
Ridge	2.434	2.185	0.243	82.8%
MLP	2.443	2.167	0.238	81.0%
本周 GMV 基线	3.401	2.600	-0.478	110.8%

月度降低低频卖家的偶发噪声，适合作为确认性分析；周度提供更多时间点，但零膨胀和相关代理更强，适合作为短期预警和粒度复核。

9、生成器诊断、组级结果与负结果

生成器	平均 KS	协方差误差	深度核拒绝率	分类 AUC
Copula-MVR	0.026	0.091	0%	0.777
基础深度生成器	0.018	0.166	100%	0.902
最坏 swap 深度生成器	0.019	0.188	100%	0.937

两类深度生成器虽然边际 KS 较小，但深度核 MMD 在所有交换比例下均拒绝，分类 AUC 显著高于 0.5，因此不作 FDR 声明。该负结果说明边际匹配不能替代联合交换性。

分支	月度	周度	解释
卖家间层 $q = .20$	16 项	12 项	长期卖家差异包含主要信号
卖家内层 $q = .20$	0 项	0 项	当前序列不足以支持严格动态发现
业务组 $q = .20$	0 组	10 组	周度组级信息更强
轨迹重要性 $q = .20$	0 项	0 项	主水平未恢复非线性发现

真实特征矩阵上的稀疏模拟中，去随机化 e-BH 平均 FDP 为 0、平均功效为 0；单轮 Knockoff+ 平均 FDP 为 0.197、功效为 1.000。低维且仅 5 个真信号时，聚合程序受到离散门槛限制。本文保留这一结果，作为方法功效边界而非删除不利证据。

10、创新、可行性、范围与计划

10.1 研究创新与方法主线

本文不是把多个算法并列叠加，而是围绕“如何形成可信、精简且可复核的 GMV 监控维度”建立一条确认性主线：Copula-MVR Model-X Knockoff 负责生成负对照，Lasso 反对称统计量度量真实变量相对优势，60 轮 e-value 与 e-BH 形成正式确认集合。其余方法不参与改写正式发现，只回答主结论是否依赖共线结构、面板层级、非线性生成器或时间粒度。

研究创新主要体现在三个方面：第一，将随机 Knockoff 运行转化为 e-value 证据并进行正式聚合，避免用任意稳定频率替代错误率控制；第二，将 FDR 确认与参数 K 展示分离，使页面容量不反向决定统计结论；第三，建立“月度确认—周度复核—结构与生成诊断”的分层证据体系，并规定未通过交换性诊断的深度生成器不得用于 FDR 声明。

严格而言，上述贡献属于面向经营指标治理的应用统计研究设计创新，而不是提出新的 Knockoff 定理。论文的价值在于把已有统计工具组织成具有明确职责、否决规则和解释边界的统一流程；不能将每个辅助分支分别包装成算法创新。

10.2 可行性证据与范围限制

可行性由已完成的实证结果直接支持：月度程序得到 14 项确认集合，默认 $K = 10$ 的测试 RMSE 为 2.385；周度得到 18 项并与月度重合 11 项；深度生成器未通过联合交换性诊断时被明确否决。该结果表明流程能够同时输出确认集合、压缩路径和失效诊断，而不是仅给出无法复核的变量排名。

研究目标是下一期 GMV 的条件预测信息，不是因果效应。公开数据缺少曝光、广告、库存、促销和竞争强度；卖家面板存在组内相关；周度物流与评价变量采用最终结果回溯归属，不等同于实时部署。实际应用需要按字段真实可见时间重构并滚动回测。

10.3 写作计划

时间	主要任务
2026 年 9 月	完成开题、数据审计和完整实证结果整理
2026 年 10 月	完善理论、模拟、组级和深度诊断说明
2026 年 11 月	统一月度与周度结果、图表和文献
2026 年 12 月	完成论文初稿并根据导师意见修改
2027 年 1 月	完成格式终检、查重和答辩材料

论文拟分为绪论、理论基础、数据与设计、统一方法、实证结果、讨论与应用、结论与展望七章。若深度生成器未通过诊断，则坚持 Copula 主线；若周度零膨胀过强，则坚持月度确认、周度稳健性的预设分工。

11、主要参考文献

- [1] Benjamini Y, Hochberg Y. Controlling the false discovery rate[J]. JRSS B, 1995, 57(1): 289–300.
- [2] Barber R F, Candès E J. Controlling the false discovery rate via knockoffs[J]. Annals of Statistics, 2015, 43(5): 2055–2085. DOI:10.1214/15-AOS1337.
- [3] Candès E, Fan Y, Janson L, Lv J. Panning for gold: Model-X knockoffs[J]. JRSS B, 2018, 80(3): 551–577. DOI:10.1111/rssb.12265.
- [4] Barber R F, Candès E J, Samworth R J. Robust inference with knockoffs[J]. Annals of Statistics, 2020, 48(3): 1409–1431. DOI:10.1214/19-AOS1852.
- [5] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for FDR control[J]. JRSS B, 2024, 86(1): 122–154.
- [6] Wang R, Ramdas A. False discovery rate control with e-values[J]. JRSS B, 2022, 84(3): 822–852. DOI:10.1111/rssb.12489.
- [7] Vovk V, Wang R. E-values: calibration, combination and applications[J]. Annals of Statistics, 2021, 49(3): 1736–1754.
- [8] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. Journal of Multivariate Analysis, 2004, 88(2): 365–411.
- [9] Spector A, Janson L. Powerful knockoffs via minimizing reconstructability[J]. Annals of Statistics, 2022, 50(1): 252–276.
- [10] Bates S, Candès E, Janson L, Wang W. Metropolized knockoff sampling[J]. JASA, 2021, 116(535): 1413–1427.
- [11] Romano Y, Sesia M, Candès E. Deep knockoffs[J]. JASA, 2020, 115(532): 1861–1872.
- [12] Dai R, Barber R F. The knockoff filter for FDR control in group-sparse regression[C]//ICML. 2016: 1851–1859.
- [13] Liu F, Xu W, Lu J, et al. Learning deep kernels for non-parametric two-sample tests[C]//ICML. 2020: 6316–6326.
- [14] Tibshirani R. Regression shrinkage and selection via the lasso[J]. JRSS B, 1996, 58(1): 267–288.
- [15] Zou H, Hastie T. Regularization and variable selection via the elastic net[J]. JRSS B, 2005, 67(2): 301–320.
- [16] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5–32.
- [17] Friedman J H. Greedy function approximation: a gradient boosting machine[J]. Annals of Statistics, 2001, 29(5): 1189–1232.
- [18] Chen T, Guestrin C. XGBoost: a scalable tree boosting system[C]//KDD. 2016: 785–794. DOI:10.1145/2939672.2939785.
- [19] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]//NeurIPS. 2017, 30.
- [20] Lundberg S M, Erion G, Chen H, et al. From local explanations to global understanding with explainable AI for trees[J]. Nature Machine Intelligence, 2020, 2: 56–67.
- [21] Wooldridge J M. Econometric analysis of cross section and panel data[M]. 2nd ed. MIT Press, 2010.
- [22] Little R J A, Rubin D B. Statistical analysis with missing data[M]. 3rd ed. Wiley, 2019.
- [23] Hyndman R J, Athanasopoulos G. Forecasting: principles and practice[M/OL]. 3rd ed. OTexts, 2021.
- [24] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle, 2018.
- [25] Olist. Marketing Funnel by Olist[DB/OL]. Kaggle, 2018.