

应用统计硕士论文 · 通俗完整介绍

基于去随机化 Model-X Knockoff 的电商 GMV 多粒度受控维度选择研究

从“几十个指标看不过来”出发，解释数据怎么构造、假变量怎么生成、14项如何选出、参数K如何控制展示，以及开题报告和开题汇报分别讲了什么。

研究生

吴优 · 2025213385

指导教师

张吕欧

学院

统计与数据科学学院

01 研究到底要做什么

企业以GMV为核心指标，但周围可能有几十个价格、交易、履约、口碑、地域和营销维度。论文希望用历史数据筛出少数真正值得持续监控的维度，同时减少重复指标和偶然误选。

这篇论文的最终目的不是做一个“预测最准”的GMV模型，而是完成预测型维度选择：用下一期GMV作为评价标准，判断本期某个指标在已经知道其他指标以后，是否仍然提供额外信息。

业务问题

订单数、件数、顾客数经常同时变化；价格、运费和商品结构也相互关联。只看相关系数，容易把同一类信息重复放进看板。

统计问题

同时检查31个指标会累积误报。论文需要的不只是重要性排序，还需要一个针对发现集合的目标错误率口径。

论文中“最好”的含义

评价维度	通俗含义	论文中的证据
增量信息	其他30项已知后，该指标是否仍有用	真实变量与Knockoff竞争
误选控制	不希望为了找得多而混入大量无效指标	e-value与e-BH
稳定性	随机过程稍变，具体名单不要大幅改变	多轮生成与后续统一重抽样
信息保留	减少指标后，预测能力不要明显下降	时间外RMSE等指标
业务可用	数量可控、含义清晰、可以准入和退出	参数K与分层看板

02 数据与31项经营维度

研究使用巴西Olist公开电商数据，覆盖2017年1月至2018年7月，原始数据约10万笔订单。订单、商品明细、支付和评价不能直接平铺连接，否则一笔多商品、多支付订单会造成GMV重复放大，因此先在各自自然粒度聚合，再形成卖家面板。



数据连接原则



31项维度

业务类别	数量	具体指标
价格成本	2	平均商品价格、平均运费
商品物理属性	4	平均重量、长度、高度、宽度
商品内容	3	平均图片数、标题长度、描述长度
支付与口碑	7	分期期数、支付序列、信用卡/Boleto/代金券/借记卡占比、评价得分
履约	4	下单至送达、下单至审核、审核至承运、预计提前送达天数
交易规模	4	成交件数、订单数、活跃品类数、独立顾客数
市场覆盖	4	买家州数量、第一大州占比、跨州交易占比、买卖家距离
卖家与营销	3	卖家所在州频率、营销来源频率、是否匹配营销成交线索

为什么删除第32项：申报月收入在分析面板中全部为0，没有任何区分能力，因此不进入模型。

03 为什么使用下一期GMV

$$Y_{s,t+1} = \log(1 + \text{GMV}_{s,t+1})$$

例如，用卖家A在6月份的31项经营指标判断7月份GMV。若7月GMV为10,000，则模型使用的目标约为 $\log(10001)=9.21$ ；预测完成后可以通过 $\exp(9.21)-1$ 转回GMV。

为什么不是当期GMV

当期GMV与当期件数、订单数、平均价格存在机械定义关系。改用下一期，可以把问题从“重复计算GMV”变为“是否具有前瞻监控信息”。

为什么取对数

加1可以处理GMV为0；对数可以压缩极少数超大卖家的影响，使模型更关注相对变化而不是只追随最大卖家。

边界：能帮助预测下一期GMV，不等于主动改变该指标一定会改变GMV。本文识别的是条件预测信息，不是因果效应。

04 Knockoff: 给每个真实指标安排一个假双胞胎

普通重要性模型只比较真实变量之间的大小，Knockoff则为每个真实指标生成一个外表相似、但不应包含额外GMV信息的负对照变量。

真实订单数

保留真实业务信息，与顾客数、件数、价格等变量存在真实相关结构。

VS

假订单数

模仿订单数的分布和相关结构，但只根据真实特征生成，不读取下一期GMV。

一个极简生成例子

假设订单量为 [1, 3, 5, 10]，先按排名映射为近似正态尺度 [-1.15, -0.32, 0.32, 1.15]。在单变量简化情况下，若MVR得到的参数为 $s=0.6$ ，则可以写成：

$$\tilde{Z} = 0.4Z + \sqrt{0.84} \times \varepsilon, \quad \varepsilon \sim N(0,1)$$

假变量一部分参考真实值，一部分加入随机扰动。理论上其均值和方差与真实变量相同；有限样本中不必逐项精确相等，但整体应当接近。真实研究有31维，生成时还要同时保持订单数与顾客数、件数、价格等变量的相关结构。

S矩阵控制什么

$$\text{Cov}(Z_j, \tilde{Z}_j) = 1 - s_j$$

参数情况	真假变量关系	影响
s 较小	真假变量非常相似	模型难以判断谁更有用，筛选功效较低

参数情况	真假变量关系	影响
s 适中	保持分布合法，同时形成差异	更适合公平竞争
s 过大	可能破坏联合协方差合法性	不能随意设置

MVR、SDP和等相关方法，本质上是三种确定S矩阵的方式。论文主线选择MVR，是因为它专门降低真实变量与Knockoff之间的可重构性，适合高度相关的经营指标。

05 从31项维度到确认集合的完整流程



每轮如何竞争

$$W_j = |\beta_j| - |\hat{\beta}_{j+p}|$$

31个真实变量和31个假变量共同进入Lasso。若真实订单数的系数绝对值为0.30、假订单数为0.05，则 $W=0.25$ ；若真实评价得分为0.06、假评价得分为0.09，则 $W=-0.03$ 。负向统计量用于估计正向发现中可能混入的错误数量。

60轮不是平均选出多少项

真实数据和GMV始终不变，每轮同时重新生成31个假双胞胎。最后针对每个具体变量分别平均60个e-value，再在最终目标水平0.20下实施e-BH。正式14项是具体名称，不是“每轮平均选出14项”。

准确理解：使用前1、5、10、20、40轮时，发现数为12、16、15、17、16；使用全部60轮得到14项。60轮与正式集合一致是定义结果，真正的信息是较少轮数时名单仍有波动，不能据此证明60轮已经理论收敛。

06 月度预分析结果与参数K

当前完整月度样本在最终e-BH目标水平0.20下形成14项候选确认集合，其中10项在单轮程序中的出现频率不低于90%。

1	成交订单数	2	平均商品价格
3	独立顾客数	4	成交件数
5	买家州数量	6	平均审核至承运天数
7	平均运费	8	活跃品类数
9	平均预计提前送达天数	10	平均商品标题长度
11	平均商品高度	12	卖家所在州频率
13	平均商品描述长度	14	平均下单至送达天数

参数K如何控制展示数量


展示档位	K	累计验证贡献	初步测试RMSE	用途
极简	4	72.1%	2.388	高层快速总览
均衡	8	87.1%	2.389	日常经营首页
默认推荐	10	92.6%	2.385	信息与容量平衡
完整确认集	14	100%	2.384	完整复核页面

当前证据口径：14项使用完整样本形成，默认K及其RMSE属于预分析结果。后续将严格隔离选维、验证和测试信息，重新确认时间外性能。

07 与标准方法的比较

为避免“选得越多越容易预测”的不公平比较，基准实验只使用2018年4月及以前的数据选维，并统一为12项预算、相同XGBoost预测器和相同测试期。

方法	测试RMSE	报告稳定性	主要解释
XGBoost-SHAP	2.383	0.686	纯预测误差最低
影子变量树模型	2.387	0.832	非线性影子变量筛选
稳定性选择	2.390	0.814	有竞争力的经验基线
Elastic Net	2.390	0.873	配对稳定性均值最高
去随机化Knockoff	2.392	0.855	提供目标FDR解释



统一稳定性结论：30组完全相同的70%卖家子样本下，Elastic Net与Knockoff的平均稳定性分别为0.873和0.855，配对差异的95%区间包含0，不能认定二者存在明确差异。固定数据只更换仿制变量得到的0.969仅作为Knockoff算法随机性诊断。

08 消融实验与已知真值模拟

消融：一次更换一个零件

检查内容	设定	重复数	严格数	与主集Jaccard
S矩阵	MVR	30	16	0.875
S矩阵	SDP	30	16	0.765
S矩阵	等相关	30	12	0.857
重复次数	M=1 / 10 / 60	1 / 10 / 60	12 / 15 / 14	0.857 / 0.933 / 1.000
边际处理	原始高斯-MVR-Lasso	40	12	0.733
统计量	Copula-MVR-XGBoost	25	0	0.000

S矩阵三种方法使用相同30轮，可以直接比较；重复次数也使用同一批结果的不同前缀。原始高斯和XGBoost分支的重复数不同，更准确地属于组件敏感性分析。

模拟：先出一份知道答案的考试

从真实特征矩阵抽取4,000行，人工规定10项是真信号，其余21项为假信号，再加入随机噪声生成20套人工目标。因为标准答案已知，可以计算FDP和Power。

FDP：选中的指标里错了多少

$$\text{FDP} = \text{错误入选数} \div \text{全部入选数}$$

例如选12项，其中3项是假变量，FDP就是25%。越低越好。

Power：真指标找回了多少

$$\text{Power} = \text{正确入选数} \div \text{全部真变量数}$$

10个真变量找回9个，Power就是90%。越高越好。

方法	平均FDP	FDP>0.20概率	Power	平均发现数
去随机化Knockoff	0.054	10%	1.000	10.65
单次Knockoff	0.145	35%	1.000	12.05

方法	平均FDP	FDP>0.20概率	Power	平均发现数
Elastic Net	0.644	100%	1.000	28.15
稳定性选择	0.090	5%	1.000	11.05
影子变量树模型	0.566	100%	1.000	23.10

模拟边界：20次模拟、10个线性真信号仍较有限；全部方法Power为1说明当前信号较强。后续将扩展弱信号、不同稀疏度、非线性和更多重复次数。

09 周度、卖家结构与负结果

18项 周度目标FDR水平0.20 下入选	11项 月度与周度共同入选	0.524 月周集合Jaccard	2.421 周度18项XGBoost RMSE
-----------------------------	------------------	----------------------	-------------------------------

$$\text{Jaccard} = \text{共同11项} \div (\text{月度14} + \text{周度18} - \text{共同11}) = 11 \div 21 = 0.524$$

全31维周度模型RMSE为2.420，18项模型为2.421，差距只有0.001，说明压缩后信息基本保留。但周度下一期零成交率为40.46%，高于月度的25.86%，因此周度不替代月度主分析。

卖家间与卖家内

分析层次	月度结果	周度结果	含义
卖家间长期位置	16项	12项	主要信号来自不同卖家的长期规模和经营差异
同一卖家时间变化	0项	0项	当前序列不足以支持严格的短期动态发现

业务解释：当前结果更适合筛选长期监控和卖家分层指标，不能直接解释为“同一卖家改变某指标就会导致GMV改变”。

为什么保留失败结果

深度生成器虽然边际分布接近，但深度核MMD和分类器仍能识别交换后的样本，因此不进入FDR结论。主Copula生成器也存在联合诊断差异，后续需继续校准。否决失败生成器是研究设计的一部分，而不是隐藏不利结果。

10 研究创新点、边界与后续工作

研究创新主要体现为面向电商核心指标治理的一套可实施方法流，而不是提出新的Knockoff定理。

创新点

- 1. 把多轮随机Knockoff转化为可聚合的e-value证据。
- 2. 把FDR确认与参数K展示分离。
- 3. 构建月度确认、周度复核、结构与生成诊断的分层证据。
- 4. 统一窗口和预算比较标准方法，并结合消融与已知真值模拟。

可迁移价值

流程可以迁移到GMV、活跃用户数、留存率及其他核心经营指标：先确认具有增量预测信息的候选维度，再按业务容量形成分层展示，通过滚动复核管理指标准入、观察和退出。

仍需完成的验证

- 严格时间隔离
按字段真实可见时间重构物流与评价指标，避免回溯信息进入预测。
- 严格时间外复核
在训练期完成选维、验证期确定参数K，测试期只用于最终评价。
- 扩展模拟
增加弱信号、不同稀疏度、非线性和更多Monte Carlo重复。
- 滚动时间窗口
区分长期核心指标、阶段性指标和观察指标。

主要技术风险

风险	为什么存在	后续处理
联合分布近似	Copula不能无条件保证全部高阶依赖	加强交换性诊断与生成器校准
面板与时间口径	同一卖家重复观测，部分字段产生较晚	簇级处理、真实可见时间和滚动回测

风险	为什么存在	后续处理
样本时间较短	19个月不足以覆盖大量经营阶段	扩展数据或使用更长企业面板

11 16页开题报告讲了什么

开题报告是正式书面材料，重点是证明选题有意义、数据可获得、方法可执行、已有预分析支持可行性，同时明确后续验证任务。

页码	主要内容	目的
1	开题申请表、个人信息、导师签名	完成学校申请格式
2	开题报告书封面	题目、姓名、学号、导师
3	背景、研究问题、理论与实践价值	说明为什么需要受控维度选择
4	国内外研究现状	交代FDR、Model-X、MVR、e-value和机器学习文献
5	数据来源、面板与31项指标	证明数据口径可对账
6 – 7	核心统计方法和参数K	给出假变量、W、e-value和e-BH公式
8	基准、消融与模拟设计	说明如何验证方法价值
9 – 10	月度14项、K路径和预测初步结果	展示选题可行性
11 – 12	统一基准、组件敏感性和模拟	比较预测、稳定性与错误发现
13 – 14	周度、结构、生成器和负结果	限定结论适用范围
15	研究创新点、待验证结论、风险和计划	说明贡献和后续工作
16	25条主要参考文献	建立理论和方法依据

12 20页开题汇报讲了什么

开题汇报比书面报告更强调叙事节奏：先提出经营看板的维度过载，再说明为什么需要Knockoff，随后用结果证明方法可运行，最后说明创新与计划。

- 1-2 封面与提纲
题目、汇报人、学号、导师和六部分结构。
- 3-5 背景、问题与文献
为什么相关、逐项检验和普通重要性排序不够。
- 6-7 数据与目标
Olist样本、31项指标和下一期GMV。
- 8-10 主方法
统一流程、Copula-MVR、真假变量竞争、e-value、e-BH与参数K。
- 11-12 验证设计
面板、组级、深度诊断、统一基准和消融协议。
- 13-15 核心预分析
月度14项、默认K=10、基准预测和模拟FDP/Power。
- 16-17 周度与负结果
18项周度集合、月周交集、卖家内0项和深度生成器否决。
- 18-20 创新、计划和文献
应用统计方法流、后续验证安排及主要参考文献。

汇报主线：维度太多 → 普通方法缺少误选控制 → 用假双胞胎建立公平竞争 → 多轮聚合形成确认池 → 参数K控制展示 → 基准、模拟和周度分析说明价值与边界。

13 最后怎样理解整篇论文

数据 正确拼接多表并构造卖家面板	目标 用本期指标判断下一期GMV	竞争 真实变量与假双胞胎比较	确认 多轮e-value与e-BH控制准入	展示 参数K形成不同容量看板	复核 基准、模拟、周度和滚动验证
----------------------------	----------------------------	--------------------------	---------------------------------	--------------------------	----------------------------

一句话：本研究利用下一期GMV定义指标的监控价值，通过去随机化Model-X Knockoff从31项候选指标中形成目标错误率明确的确认集合，再以参数K控制展示数量，并通过基准、模拟、周度和结构诊断检验其适用边界。

内容依据当前开题报告、开题汇报及实际计算结果整理。所有结果属于现阶段预分析证据；正式论文将继续完成严格时间隔离、统一重抽样、扩展模拟和滚动窗口验证。