

交换对称成对损失：方法原型与完整实测

1 研究定位

本轮没有将模型改名当作原创，而是构造了一个固定预测器上的成对损失统计量，要求任意真假列交换时，被交换统计量反号、其他统计量不变。它是候选方法原型，不是已发表新算法，也尚未完成原创性系统检索。

研究已完成 111 个 Olist 开发样本实验、800 份全新种子的模拟数据，每份都计算 14 种方法或消融，共 1554 个真实方法结果和 11200 个模拟方法结果。网络使用三个训练种子；未用旧模拟结果替代新计算。模型权重、日志、协议、数据摘要及失败检查可复现。

与此前不同，基础预测器不能用评分期响应早停。训练/早停完成后固定预测器，再在独立评分期产生排名。因此即使方法名称相同，本表也不能直接与旧实验未重新计算的 RMSE 混排。

2 算法具体变化

1. 在每个真假数值对内取 min/max，按固定随机掩码生成八组不区分真假的背景。
2. 对特征 j 分别放入真实值和 Knockoff 值，计算平方预测损失差；其他变量始终使用相同的对称背景。
3. 对背景、卖家内观测及卖家平均，形成 W ；标准化版再除以卖家均值标准误加常数。
4. 使用既有 Knockoff+ 阈值产生原生名单，同时单独报告 Top-12/Top-8 预算名单。

本轮拆分普通替换、中点背景、随机对称背景、标准化四种评分，并分别接入同一批已训练 XGBoost 和官方 TabM。另有 SHAP、普通置换、Deep Lasso、评分集成对 Lasso，以及使用同样训练样本的线性预测器。标准化不是 t 检验。

完整代数证明、先行文献以及独立样本/精确生成器前提见后附方法说明。符号翻转验证误差为零；这不证明 Olist 生成器精确。

3 公平设计与解释边界

所有真实方法共享同一卖家清单：30 组互补 50% 样本、20 次 70%、20 次 80%，另 10 组种子变化及完整参考。固定预算 $K=12$ ，敏感性 $K=8$ 。最终预测统一特征列顺序、模型参数、种子和时间窗口，相同变量集合复用相同预测。

真实面板共 13,754 行、2,723 个卖家、31 项指标；train/tune/rank/test 分别为 6,567/1,831/1,943/3,413 行。响应为下一自然月签收确认商品金额的 $\log 1p$ ，不含运费，不是按购买月回溯的最终送达 GMV。RMSE、MAE 和 R^2 在 $\log 1p$ 尺度计算，WAPE 在金额尺度计算。静态卖家/商品信息的历史可见性仍有假设，不能将其包装为已经部署的实时预测系统。

新模拟 800 份分为八场景各 100 次， $n=2000$ 、 $p=31$ ；训练 1200 行、评分 400 行、最终预测测试 400 行。七场景使用已知分布下的精确 Knockoff， t 错误场景故意使用不正确的高斯生成器。各场景和失败结果不按有利程度筛除。

成对 Lasso 只在评分样本拟合，其 400 行标签预算与基础模型在前 1200 行拟合的方式不同。所以主要还要看同样使用 1200 行训练、相同评分器的线性预测器对照。原生 $q=0.20$ ， $q=0.10$ 敏感性在同一个 W 上重算。

真实数据存在估计 Copula 失配及同卖家跨期依赖，原生名单只称“名义阈值发现”，不得说实际 FDR 已被证明受控。2018 年测试期曾多次查看，结果属探索性，不是独立外部确认。普通替换损失差不满足本轮要求的完整符号翻转，对它应用名义 Knockoff 阈值只是压力对照，不是 CPI 文献正式检验的复现。

4 同预算总览

方法	XGB-RMSE	TabM-RMSE	半样本 J	Nogueira	FDP@12	Power@12	真实原生数
评分集成对 Lasso	1.9488	1.9765	0.3569	0.2067	0.5203	0.6590	0
线性预测器 + 标准化对称差	2.0784	2.0687	0.4046	0.2352	0.4860	0.7002	0
XGBoost-SHAP	1.8466	1.8571	0.7682	0.7439	0.2629	0.9678	无原生规则
XGBoost-置换	1.8478	1.8612	0.7853	0.7666	0.2514	0.9817	无原生规则
TabM-置换	1.8458	1.8586	0.7288	0.6841	0.2594	0.9720	无原生规则
Deep Lasso	1.8468	1.8567	0.8394	0.8012	0.2678	0.9620	无原生规则
XGB-普通损失差	1.9286	1.9479	0.4237	0.2188	0.2669	0.9630	0
XGB-中点对称差	1.9286	1.9479	0.4308	0.2269	0.2719	0.9570	0
XGB-随机对称差	1.9286	1.9479	0.4300	0.2353	0.2697	0.9597	0
XGB-标准化对称差	1.9323	1.9621	0.3387	0.1016	0.3171	0.9028	0
TabM-普通损失差	2.0271	2.0294	0.3740	0.1947	0.2728	0.9560	0
TabM-中点对称差	1.8577	1.8776	0.3934	0.2009	0.2769	0.9510	0
TabM-随机对称差	1.8577	1.8776	0.3912	0.1993	0.2739	0.9547	0
TabM-标准化对称差	2.0964	2.0886	0.3249	0.1248	0.3214	0.8977	0

FDP@12 和 Power@12 仅为六个精确生成器非零信号场景的等权平均；全无效和生成器错设另列。固定 K 时二者相关，不当作两份独立成功证据。真实原生发现为 0 也保留，预测采用常数均值作为空集基线。

5 预定主候选与线性对照

场景	TabM-FDP	TabM-Power	线性-Power	Power 差	Holm p
linear_sparse	0.1955	0.9700	1.0000	-0.0300	0.666
nonlinear_strong	0.1668	0.7940	0.0870	+0.7070	1.11e-42
nonlinear_weak	0.1636	0.4310	0.0750	+0.3560	3.447e-15
pure_interactions	0.1528	0.9340	0.0030	+0.9310	5.535e-77
high_correlation	0.1772	0.5840	0.8590	-0.2750	4.367e-12
mixed_copula	0.1506	0.8030	0.1750	+0.6280	3.782e-34

已得到的判断。主候选在强非线性场景的 Power 为 0.794，匹配线性对照为 0.087，同时平均 FDP 为 0.167；纯交互场景的 Power 为 0.934 对 0.003。这支持利用非线性预测器发现线性评分遗漏的变量，但不证明优于所有已有非线性 Knockoff 方法。

标准化改动没有获得支持。同一 TabM 预测器的未标准化随机对称差在强非线性场景 Power 为 0.965，高于预定标准化版本。标准化版本在高相关线性场景为 0.584，低于匹配线性对照的 0.859。多个差异通过同场景 Holm 校正，不能把标准化描述成普遍提升检出率的创新。

真实应用未形成优势。主实验 Top-12、统一 XGB 评价下，主候选 RMSE 为 2.0964，SHAP 为 1.8466；半样本 J 分别为 0.3249 和 0.7682。主候选在这两个指标上均更差，不能以模拟 Power 的进步替代真实预测和稳定性的失败。

Holm 校正在同场景、同指标、同规则的预定比较族内进行；不覆盖跨所有场景择优的结论。FDR 是平均 FDP 的总体期望，单次 FDP 不必小于 q。100 次模拟只提供带 Monte Carlo 误差的估计，不是理论证明。

6 全部原生发现结果

6.1 global_null

方法	FDP	MCSE	Power	发现数	非空比例	名单 RMSE
评分集成对 Lasso	0.0300	0.0171	不定义	0.18	0.03	0.9992
线性预测器 + 标准化对称差	0.0100	0.0100	不定义	0.05	0.01	0.9989
XGB-普通损失差	0.0600	0.0239	不定义	0.54	0.06	0.9996
XGB-中点对称差	0.0600	0.0239	不定义	0.34	0.06	0.9998
XGB-随机对称差	0.0400	0.0197	不定义	0.24	0.04	0.9992
XGB-标准化对称差	0.0600	0.0239	不定义	0.43	0.06	0.9996
TabM-普通损失差	0.0600	0.0239	不定义	0.36	0.06	0.9997
TabM-中点对称差	0.0500	0.0219	不定义	0.32	0.05	0.9997
TabM-随机对称差	0.0300	0.0171	不定义	0.24	0.03	0.9990
TabM-标准化对称差	0.0500	0.0219	不定义	0.35	0.05	0.9998

6.2 linear_sparse

方法	FDP	MCSE	Power	发现数	非空比例	名单 RMSE
评分集成对 Lasso	0.1639	0.0213	1.0000	6.65	1.00	0.7438
线性预测器 + 标准化对称差	0.1798	0.0182	1.0000	6.50	1.00	0.7438
XGB-普通损失差	0.1845	0.0203	1.0000	6.72	1.00	0.7446
XGB-中点对称差	0.1632	0.0196	1.0000	6.51	1.00	0.7442
XGB-随机对称差	0.1865	0.0215	1.0000	6.80	1.00	0.7452
XGB-标准化对称差	0.1903	0.0202	0.9980	6.78	1.00	0.7449
TabM-普通损失差	0.2334	0.0229	1.0000	7.40	1.00	0.7450
TabM-中点对称差	0.2013	0.0213	1.0000	6.94	1.00	0.7442
TabM-随机对称差	0.1850	0.0219	1.0000	6.86	1.00	0.7447
TabM-标准化对称差	0.1955	0.0205	0.9700	6.73	0.97	0.7584

6.3 nonlinear_strong

方法	FDP	MCSE	Power	发现数	非空比例	名单 RMSE
评分集成对 Lasso	0.0981	0.0182	0.1180	2.03	0.26	1.1743
线性预测器 + 标准化对称差	0.0760	0.0169	0.0870	1.44	0.20	1.1842
XGB-普通损失差	0.1946	0.0157	0.9980	12.97	1.00	0.8528
XGB-中点对称差	0.1619	0.0135	0.9990	12.31	1.00	0.8533
XGB-随机对称差	0.1879	0.0149	0.9990	12.78	1.00	0.8539
XGB-标准化对称差	0.1701	0.0151	0.9240	11.72	1.00	0.8693
TabM-普通损失差	0.1765	0.0159	0.9670	12.33	1.00	0.8585
TabM-中点对称差	0.1808	0.0151	0.9570	12.20	1.00	0.8599
TabM-随机对称差	0.1732	0.0155	0.9650	12.19	1.00	0.8589
TabM-标准化对称差	0.1668	0.0166	0.7940	10.26	0.95	0.9021

6.4 nonlinear_weak

方法	FDP	MCSE	Power	发现数	非空比例	名单 RMSE
评分集成对 Lasso	0.0512	0.0171	0.0390	0.83	0.10	1.7252
线性预测器 + 标准化对称差	0.0742	0.0177	0.0750	1.39	0.17	1.7212
XGB-普通损失差	0.1784	0.0164	0.9160	11.81	1.00	1.5172
XGB-中点对称差	0.1817	0.0156	0.9030	11.61	1.00	1.5204
XGB-随机对称差	0.1733	0.0164	0.9020	11.63	0.99	1.5217
XGB-标准化对称差	0.1926	0.0185	0.5540	8.04	0.77	1.5930
TabM-普通损失差	0.1944	0.0185	0.7490	10.30	0.94	1.5428
TabM-中点对称差	0.1823	0.0187	0.7580	10.34	0.94	1.5397

方法	FDP	MCSE	Power	发现数	非空比例	名单 RMSE
TabM-随机对称差	0.1826	0.0174	0.7610	10.23	0.93	1.5411
TabM-标准化对称差	0.1636	0.0189	0.4310	6.44	0.63	1.6157

6.5 pure_interactions

方法	FDP	MCSE	Power	发现数	非空比例	名单 RMSE
评分集成对 Lasso	0.0639	0.0221	0.0090	0.45	0.08	1.2239
线性预测器 + 标准化对称差	0.0155	0.0109	0.0030	0.13	0.02	1.2233
XGB-普通损失差	0.1793	0.0157	0.9830	12.57	1.00	1.0245
XGB-中点对称差	0.1471	0.0128	0.9310	11.25	1.00	1.0306
XGB-随机对称差	0.1690	0.0148	0.9370	11.75	1.00	1.0292
XGB-标准化对称差	0.1620	0.0165	0.7090	9.34	0.88	1.0792
TabM-普通损失差	0.1517	0.0145	1.0000	12.25	1.00	1.0125
TabM-中点对称差	0.1565	0.0151	0.9980	12.31	1.00	1.0137
TabM-随机对称差	0.1545	0.0144	0.9970	12.22	1.00	1.0157
TabM-标准化对称差	0.1528	0.0149	0.9340	11.58	0.98	1.0279

6.6 high_correlation

方法	FDP	MCSE	Power	发现数	非空比例	名单 RMSE
评分集成对 Lasso	0.1549	0.0156	0.7730	9.85	0.89	0.8352
线性预测器 + 标准化对称差	0.1746	0.0115	0.8590	10.75	0.95	0.8088
XGB-普通损失差	0.1851	0.0170	0.7280	9.82	0.89	0.8412
XGB-中点对称差	0.1712	0.0163	0.7020	9.34	0.85	0.8613
XGB-随机对称差	0.1779	0.0171	0.7290	9.77	0.89	0.8418
XGB-标准化对称差	0.1514	0.0204	0.3700	5.65	0.53	1.0223
TabM-普通损失差	0.1662	0.0165	0.8480	11.01	0.95	0.8086
TabM-中点对称差	0.1617	0.0163	0.8440	10.87	0.96	0.8059
TabM-随机对称差	0.1686	0.0163	0.8510	11.04	0.97	0.8000
TabM-标准化对称差	0.1772	0.0197	0.5840	8.46	0.73	0.9239

6.7 mixed_copula

方法	FDP	MCSE	Power	发现数	非空比例	名单 RMSE
评分集成对 Lasso	0.1177	0.0211	0.1640	2.78	0.33	1.1642
线性预测器 + 标准化对称差	0.0903	0.0172	0.1750	2.56	0.33	1.1590
XGB-普通损失差	0.1680	0.0147	0.9980	12.48	1.00	0.8517
XGB-中点对称差	0.1750	0.0154	0.9940	12.56	1.00	0.8523
XGB-随机对称差	0.1849	0.0161	0.9940	12.80	1.00	0.8526
XGB-标准化对称差	0.1684	0.0169	0.8940	11.55	0.97	0.8799
TabM-普通损失差	0.1888	0.0162	0.9810	12.69	1.00	0.8546
TabM-中点对称差	0.1612	0.0163	0.9640	12.10	1.00	0.8572
TabM-随机对称差	0.1518	0.0144	0.9630	11.78	1.00	0.8573
TabM-标准化对称差	0.1506	0.0146	0.8030	10.00	0.97	0.8999

6.8 misspecified_t

方法	FDP	MCSE	Power	发现数	非空比例	名单 RMSE
评分集成对 Lasso	0.1546	0.0286	0.0790	2.12	0.24	1.2047
线性预测器 + 标准化对称差	0.0755	0.0208	0.0370	1.00	0.13	1.2168
XGB-普通损失差	0.0968	0.0152	0.5060	6.36	0.69	1.0530
XGB-中点对称差	0.1382	0.0167	0.5090	6.80	0.70	1.0509
XGB-随机对称差	0.1163	0.0154	0.4990	6.42	0.68	1.0497
XGB-标准化对称差	0.1419	0.0189	0.3660	5.35	0.57	1.0911
TabM-普通损失差	0.1574	0.0198	0.4060	5.63	0.69	1.0560
TabM-中点对称差	0.1390	0.0192	0.3710	5.02	0.67	1.0655
TabM-随机对称差	0.1551	0.0202	0.3970	5.52	0.69	1.0580
TabM-标准化对称差	0.1783	0.0228	0.2740	4.49	0.53	1.1149

全无效场景 Power 没有定义;其 FDR 等于选出非空集合的概率。准确二项区间在 simulation_summary.csv 中报告, 不把 100 次全未发现说成真实错误率必为 0。发现数不同的原生名单与强制 12 项名单不混比。

主候选全无效场景为 100 次中 5 次非空, 估计 FDR=0.050, 准确 95% 区间为 [0.016, 0.113]。线性稀疏场景的 TabM 中点平均 FDP 略超过 0.20, 仍须连同 Monte Carlo 标准误如实保留, 不能宣称每个有限模拟均值都严格低于目标。

6.9 同一主候选的阈值敏感性

场景	q=.2 FDP	q=.2 Power	q=.1 FDP	q=.1 Power	q=.1 发现数
global_null	0.0500	不定义	0.0100	不定义	0.11
linear_sparse	0.1955	0.9700	0.0167	0.0300	0.34
nonlinear_strong	0.1668	0.7940	0.0607	0.2740	3.45
nonlinear_weak	0.1636	0.4310	0.0399	0.0900	1.37
pure_interactions	0.1528	0.9340	0.0588	0.5260	5.96
high_correlation	0.1772	0.5840	0.0477	0.1880	2.54
mixed_copula	0.1506	0.8030	0.0602	0.3270	3.96
misspecified_t	0.1783	0.2740	0.0325	0.0440	0.82

这些是相同 W 的不同阈值, 不是重新训练的模型。q=.1 至少需要 10 个正发现才可能非空, 稀疏信号场景可能因此损失 Power。t 错设行只有经验意义, 即使平均 FDP 低于目标也不能恢复不存在的理论保证。

7 真实生成器诊断

交换比例	卖家隔离 AUC
0.25	0.9514
0.5	0.6470
1.0	0.8998

分类训练与测试按卖家分离, 原样本及交换样本成对划入同一侧。该 AUC 仅为工程诊断, 不提供检验 p 值; 接近 0.5 也不是交换性证明。因为评分所用卖家可能出现在模型训练历史中, 独立样本理论不能直接外推。

8 怎样评价论文可行性

有明确研究问题、算法定义、代数性质、机制消融和完整数据实测，比不断拼接网络更具可讨论性。但是否足以成为学位论文方法贡献，需要分别判断：原创性是否与先行文献区分、目标场景是否真实改善、真实数据是否有可使用结果。不能用大批训练次数替代任何一项。

本轮的明确判断是：可以作为“模型无关损失评分的对称化、非线性检出及生成器敏感性”方法研究原型，但尚不能作为“已证明原创且在电商数据上全面改进”的定稿成果。预定标准化版本不宜成为成功创新的核心叙事；简单对称化是否与 CPI、Semi-knockoffs 等文献实质不同，还需逐公式对照，并补足近期非线性受控筛选基线和第二个未使用过的真实数据集。

可以讨论的暂定题目是《面向电商经营指标筛选的交换对称损失统计量及其稳健性研究》。这个题目描述研究问题，不承诺方法优于一切基线。当前不能保证其创新程度满足学位要求，更不能保证答辩通过。

8.1 计算成本与复现审计

运行范围	完成案例	每案例秒数中位数	案例耗时合计/小时
real	111	48.2	1.75
simulations	800	15.4	3.27
real_mvr	111	57.9	1.88

每案例同时训练和计算多种共享预测器/统计量。案例耗时合计是各进程计时之和，不是整轮墙钟耗时或 CPU 核心小时，不能拆算为某方法独有成本。本轮未保存逐评分方法的独立计时，因此不提供虚构的速度排名。

审计对预测 RMSE、MAE、R²、WAPE 从逐行预测重算，并检查样本哈希、两种原生阈值、有限分数和相同集合预测一致性。50% 稳定性区间按 30 组互补样本计算，不把 60 个半样本当独立重复。完整补充指标、配对区间及代码摘要保存在 results 目录；生成报告没有重调模型参数或改动冻结协议。

逐行预测最初含 float32 输出，CSV 重读后按 float64 复算金额指数函数会产生约 2e-8 的差异；核对采用 rtol=2e-7、atol=1e-9，不影响报告四位小数。NumPy/BLAS 矩阵乘法警告保留在运行记录中，不通过关闭警告隐藏。附加的 10 万行精确高斯检查同时核验随机背景协方差，并用不调用 BLAS 的显式 einsum 交叉核对采样矩阵乘法；它不是真实 Olist 生成器合格证明。

9 事后追加：MVR 生成器敏感性

主协议的真实等相关 S 约 0.00334，约 49.4% 的真假数值完全相同，比较信息很弱。一次参考样本检查已看到 MVR 的名义发现数及测试 RMSE 变化，随后才制定 mvr_extension_protocol.json，追加相同 111 个真实案例及两种评价器的 Top-12 分析，不改动前述主表。追加动机受到已见结果启发；不能把“未搜索生成器参数或修改 q”误写成“生成器选择完全未受测试表现影响”。

方法	XGB-RMSE	TabM-RMSE	半样本 J	Nogueira	名义发现数	半样本空集率
评分集成对 Lasso	1.8941	1.8790	0.5216	0.3650	0	0.317
线性预测器 + 标准化对称差	1.8825	1.8849	0.6017	0.4680	10	0.367
XGBoost-SHAP	1.8466	1.8571	0.7682	0.7439	无	不适用
XGBoost-置换	1.8478	1.8612	0.7853	0.7666	无	不适用
TabM-置换	1.8458	1.8586	0.7288	0.6841	无	不适用
Deep Lasso	1.8468	1.8567	0.8394	0.8012	无	不适用
XGB-普通损失差	1.8484	1.8577	0.5515	0.4225	6	0.067
XGB-中点对称差	1.8662	1.8727	0.4982	0.4660	5	0.333
XGB-随机对称差	1.8521	1.8668	0.5119	0.4541	6	0.117
XGB-标准化对称差	1.8479	1.8680	0.4817	0.3451	10	0.250
TabM-普通损失差	1.8899	1.8974	0.4875	0.4268	5	0.167
TabM-中点对称差	1.8431	1.8575	0.4988	0.4509	6	0.100

方法	XGB-RMSE	TabM-RMSE	半样本 J	Nogueira	名义发现数	半样本空集率
TabM-随机对称差	1.8630	1.8732	0.4874	0.4675	6	0.100
TabM-标准化对称差	1.8493	1.8645	0.4696	0.3947	9	0.083

交换比例	卖家隔离 AUC
0.25	0.8782
0.5	0.9139
1.0	0.9467

这是观察主实验结果后追加的诊断，不是预先注册确认。MVR 为既有方法，不列为本轮原创；相同样本、基础模型、阈值保持不变，四项不使用 Knockoff 的基线排名逐案例与主实验一致。只重新检验真实样本，不把前述精确等相关模拟结果误写成 MVR 实测 FDR。发现数增加不证明原生 FDR 正确；估计 Copula 及跨期卖家依赖的限制依然存在。

主候选在 MVR 下的 XGB 评价 RMSE 为 1.8493，半样本 J 为 0.4696；TabM 中点版本分别为 1.8431 和 0.4988。中点版本只属于已登记的机制消融，不能事后改称预定主候选。主实验、追加实验不能各抽一个最好的指标拼成“总体最优方法”。

为避免把小幅数值差当成确定收益，另对追加实验全部六个普通/中点/随机背景版本补算相对 SHAP 的配对区间，标记为事后诊断，不改变主比较族。中点 TabM 相对 SHAP 的 XGB 评价 RMSE 差为-0.0035，卖家簇 Bootstrap 点态 95% 区间为 [-0.0118, +0.0053]。这不是新测试集上的确认性检验；区间包含 0 时不能声称已证实优于 SHAP，也不能声称两者已证明等价。

10 附录：方法定义与证明边界

10.1 研究问题

在训练好的预测模型之外，能否构造一个不依赖网络权重解释、直接比较预测损失、同时满足 Knockoff 完整符号翻转性质的变量筛选统计量？

这是本轮实际研究的问题，不是“找一个更大的网络打败 XGBoost”。候选方法简称 SCPL (swap-canonical paired loss)。名称只是工程标识，不构成原创性证明。本轮独立编写的部分是对称背景、成对损失、固定模型评分及标准化之间的具体组合与验证；Knockoff、条件预测重要性、反对称统计量和集成网络本身均来自既有工作。

10.2 与既有方法的关系

真实文献	核心内容	本轮不能冒称为原创的部分
Candès 等, Panning for gold: Model-X knockoffs for high dimensional controlled variable selection, JRSS B, 2018, DOI 10.1111/rssb.12265	Model-X 条件独立、交换性、Knockoff+	错误率控制框架
Lu 等, DeepPINK: reproducible feature selection in deep neural networks, NeurIPS 2018, arXiv:1809.01185	成对输入与深度选择	真假特征进入同一深度模型
Watson 和 Wright, Testing Conditional Independence in Supervised Learning Algorithms, Machine Learning 110:2107–2129, 2021, DOI 10.1007/s10994-021-06030-6	条件预测影响 CPI 与损失差	用 Knockoff 替换输入后比较预测损失

真实文献	核心内容	本轮不能冒称为原创的部分
Oh 和 Lee, DeepPIG, Scientific Reports 14:15582, 2024, DOI 10.1038/s41598-024-66061-6	成对层、随机门与 Knockoff	成对输入加门控这一方向
Gorishniy 等, TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling, ICLR 2025, arXiv:2410.24210	参数高效表格集成	TabM 预测架构
Zou 和 Tian, GRIP2: A Robust and Powerful Deep Knockoff Method for Feature Selection, arXiv:2602.00218, 2026 预印本	对正则化曲面上的特征活动聚合	深度统计量和轨迹聚合已有相邻研究
Reyero-Lobo 等, Semi-knockoffs: a model-agnostic conditional independence testing method with finite-sample guarantees, ICML 2026, arXiv:2601.23124v2	对预训练模型的条件独立检验	模型无关的受控筛选已有近期研究

上述来源已通过期刊/会议页或 arXiv 作者摘要核验。这里只进行了针对性先行研究排查，没有完成足以证明“此前无人提出”的系统检索。本文没有冒充复现 DeepPIG、GRIP2 或 Semi-knockoffs；它们是必须讨论的相邻文献，而非已完成实证基线。

10.3 数据分离

先用训练数据 A 拟合预测器 f，内部早停后在 A 内固定轮次重拟合。随后在不参与训练、早停或调参的评分数据 B 上生成 Knockoff 并计算统计量。最终测试数据 C 只计算名单的下游预测表现。

在模拟中，A 有 1200 行，其中前 1000 行训练、后 200 行选轮次，B 有 400 行，C 有 400 行。Olist 沿用 train/tune/rank/test 时间切分，rank 期只评分，不参与基础预测器的早停。

Olist 同一卖家跨期相关，所以 A 与 B 不满足理论中的独立样本假设。真实数据分析只能是经验探索；用卖家抽样不能消除这一理论缺口。

10.4 对称背景与损失对比

对 B 中每个观测 i 和特征 j，有真实值 x 与 Knockoff 值 $\tilde{x}$ 。先取：

低值 $L_{ij} = \min(x_{ij}, \tilde{x}_{ij})$
高值 $U_{ij} = \max(x_{ij}, \tilde{x}_{ij})$

生成四组与响应无关的随机 0/1 掩码及其补掩码，共八个背景 C。每个背景对每个变量从低值、高值中选一个。这个背景只依赖无序数值对，不依赖哪一个被命名为“真实”。

评价特征 j 时，其他变量使用背景值，分别把第 j 列设为真实值与 Knockoff 值：

dij = 八个背景下的平均 [使用Knockoff第j列的平方误差 - 使用真实第j列的平方误差]

正值表示：在这些对称背景中，真实第 j 列比其 Knockoff 对应值更有利于预测。

首先在每个卖家内平均 d，再对卖家平均形成 W。标准化版以 W 除以卖家均值的标准误加固定正数。模拟每行是独立组，因此退化为普通行平均。

“标准误”在此仅用于无量纲排序，不进行 Student t 检验，不宣称统计量服从 t 分布。用卖家聚合不会自动赋予面板 FDR 保证。

10.5 符号翻转的代数命题

命题（固定预测器下的路径级符号翻转）。假定 f 、预处理、分组、掩码和任何超参数在交换评分数据的真假变量之前已固定。对任意变量集合 S ，交换每个 j 属于 S 的真实列与对应 Knockoff 列，则：

$$W_j([X, \tilde{X}]_{\text{swap}(S)}, Y) = \begin{cases} -W_j([X, \tilde{X}], Y), & j \in S, \\ W_j([X, \tilde{X}], Y), & j \notin S. \end{cases}$$

证明。交换不改变任意行任意列的 min/max，因此所有背景不变。对于 j 不在 S 中，比较时自身真假值未变，其他列仍使用相同背景，两次预测及其差均不变。对于 j 在 S 中，自身两次预测的输入相互交换，因此每行、每背景的损失差反号。卖家内及卖家间平均保留反号。标准化版的组间标准差在整体反号时不变，所以比值也只反号。证毕。

这一证明不要求 f 正确拟合真实响应函数。它证明的是统计量的对称性，而不是预测精度、检出率、模型收敛或新生成器正确性。min/max 背景也可替换为其他对交换不变的背景；本轮另跑中点背景作为消融。

补充性质（精确生成器下随机背景的边际分布）。对独立同分布观测，若每行真假变量满足精确逐坐标交换性，且对掩码随机性取平均，则任一随机 min/max 背景的整行边际分布与原 X 相同。原因是给定真假数值，每坐标以各一半概率取 min/max，等价于以各一半概率取真实值/Knockoff 值。因此背景分布是全部坐标交换子集的等权混合；每个交换子集下的原侧向量都与 X 同分布，其混合也同分布。补掩码不改变各背景的边际分布，但背景之间不独立。

这一性质需要对掩码随机性平均，不能说任一固定 min/max 取值都来自原联合分布，也不说明有限八背景没有 Monte Carlo 误差。它只涉及输入边际，不意味着背景与 Y 的关系不变，不证明 Power 最优。中点背景通常没有这个性质。Olist 的估计 Copula 失配时同样不能套用。该性质是对现有实现的理论说明，不是看结果后改变算法，也不主张这一群对称化思想的优先权。

10.6 可以调用的既有 FDR 结论

还必须另外假设：

1. 条件于 A 、 B 中的样本来自目标分布并满足所用 Model-X 框架所需的样本条件；
2. B 的 Knockoff 与响应在给定 X 及 A 时条件独立；
3. B 的联合真假分布满足所需的精确交换性；
4. f 及评分超参数不使用 B 的响应训练或选优；
5. 掩码独立产生，统计量满足上面的完整符号翻转。

在这些条件下，可调用既有 Knockoff+ 结果，在目标水平 q 控制 FDR。这里不是新提出一个 FDR 定理，而是把本轮统计量代入既有定理的一项充分条件检查。

反对称性不能补救错误的 Knockoff 生成器。在 Olist 的估计 Copula 和跨期卖家依赖中，上述假设未被证明。本轮故意加入 t 分布数据配高斯生成器，检验错误时可能出现的风险，不会将其平均 FDP 也标为理论保证。

10.7 普通替换为何不能直接套同一结论

普通损失差把其他列固定为“真实列”。交换某一个变量后，该列也进入其他特征的比较背景，其他 W 可能随之改变。因此，“自己那一列的差反号”不够，还要保证其他统计量不变。

本轮普通替换版本仅作为数值和预测比较的对照。若对它使用名义 Knockoff+ 阈值，结果必须明确标记“假设未获保证的压力测试”，不是论文 CPI 原检验的完整复现，也不能据此否定 CPI 文献中的其他检验程序。

10.8 代价、弱点与预算

- 中点背景可能落在训练分布外；随机背景在精确生成器下具有上面的边际同分布性质，但改变了与响应的关系，有限背景近似也有误差。生成器错设时随机背景仍可能失配；符号翻转成立不意味着检出率更高。
- 原生成器准确性仍是难点；没有创造“任意分布都有效”的假变量。
- 需要独立评分样本，牺牲可用于模型训练的数据量。
- 推断计算约需 $2 \times \text{特征数} \times \text{背景数次批预测}$ ；本轮八背景为固定预算，不因结果好坏改动。
- 成对 Lasso 只在 B 中拟合，和利用 A 训练的模型信息用法不同。额外的线性预测器使用同样 A 并用同样评分规则，避免把 A 的额外信息单独归给非线性改动。
- 本轮原生 $q=0.20$ ，同时报告 $q=0.10$ 。Knockoff+ 至少需要 $\text{ceil}(1/q)$ 个发现才可能非空：不能把放宽 q 带来的 Power 变化写成算法创新。
- Top-K 只是预算名单，不继承原生 FDR 保证。全无效变量场景没有 Power，必须记缺失而非人为填零。

10.9 成为论文方法贡献之前

本轮比单纯拼接更明确的一点，是有一个可检查的统计量设计问题、公式、代数性质、对称性反例和拆分消融。但这不自动等于原创性已经成立。仍需要更完整的相关方法比较、生成器稳健性分析，以及新的真实数据验证。

用户需要的是可辩护的研究，而不是“自称独创”。如果实际结果不支持 Power、预测或稳定性改进，就按失败或有边界的结果报告。