

近期模型算法改动的完整配对实验

1 结论性质与范围

本研究是已观察 V7 结果之后的探索，不是外部预注册验证。新改动均完整执行，不能把一次改动的局部收益说成世界首创或跨数据集普遍优势。V7 原论文、CSV、模型和失败记录没有覆盖。

新增十个方法/消融配置，各完成 111 个主预算真实案例、一个 8 项参考案例及 600 个模拟案例，合计 1,120 个新真实选择案例、6,000 个新模拟案例、40 组初始预测文件。旧八方法的选择结果作为历史基线读取，不冒充选择器重新训练。所有 18 种方法与全维基线随后共同按规范列顺序重评，形成 74 组预测文件。完整原始表构建的 13,754 行卖家月面板未抽小；外层抽样是评价的一部分。

2 四条模型改动

1. **Deep Lasso-Jacobian**: 原梯度分数同时乘有残差，容易使误差大的样本支配重要性。改为预测函数 Jacobian 的按列 RMS 稀疏目标，并用相同 Jacobian 排序。另做“只改排序”和“改训练但保留原排名”两项消融。导数正则已有长期文献，不能称为首次提出。
2. **TabM-预算门**: 在官方 8 成员 TabM 前加入共享的精确 K 硬门，反向传播使用约束 sigmoid 软门的直通梯度；15 轮全变量预热后开始预算训练。解决训练看 31 项、最终只留 K 项的不一致。输入门与直通估计均有先例，本实现是局部预算约束适配。
3. **EntryPrune-刷新/环境波动惩罚**: 原发布代码记住候选历史最高进入分数。刷新版用三个训练时间块的当前梯度均分并重置再生列 Adam 动量，波动版再扣除环境间标准差。刷新版和波动版共享除波动项之外的改动；这不是具有覆盖保证的置信下界。回归输出和对齐最佳检查点是共同适配，不列为创新。
4. **VTFS-固定 K/成对损失**: 固定 K 语料与定长唯一 token 解码消除不同长度和任意前缀造成的预算偏差；新增按效用差加权的成对 logistic 排序损失。用同样 128 次子集查询的随机搜索检验 Transformer 是否带来额外收益。固定 K 修复本身不冒称原论文的新发现。

官方组件: Deep Lasso 官方正则与 V7 MLP; TabM 0.0.3; EntryPrune 锁定 commit; VTFS 官方编码/解码骨干（仍保留 $\epsilon=1$ ）。所有路径与摘要见 `source_manifest.json`。

3 公平条件与限制

各方法使用同一 30 组互补 50% 卖家、20 个 70%、20 个 80% 样本，另有 10 组固定数据种子变化。半样本区间以 30 组计算。拟合与排序行摘要逐项核对，选择器不读测试 X 或 Y。模型新增参数在 2017 年训练、2018 年 1 月早停/排序、2 月评价后冻结；最终名单以训练加调参期拟合、3 至 4 月排序。

模型家族	选定参数	选择依据
deep	0.001	1 月排序; 2 月 XGB 误差
gate	0.05	1 月排序; 2 月 XGB 误差
entry	0.25	1 月排序; 2 月 XGB 误差
subset	None	协议固定

主比较 $K=12$; $K=8$ 仅完整参考与预测敏感性，门控、EntryPrune 和 VTFS 独立按 8 项训练。XGBoost 和 TabM 评价器配置、三个训练种子与全开发窗口重拟合对所有名单一致。方法自身计算量并不完全相等。冻结的 V7 架构参数、局部有限搜索不代表每一种模型的充分调参性能上界。

所有新方法只输出排名/固定预算名单，不提供原生 FDR 保证。FDP 与 Power 在模拟真值下计算；固定 K 和真信号数时二者一一对应，不能当作两份独立成功证据。六场景各 100 次等权汇总只用于总览，逐场景表必须同时阅读。

执行审计发现两项 Deep Lasso 排名消融的完整样本 Top-12 与原版相同，但不同列顺序会影响随机列抽样和网络初始化。为消除伪差异，本报告最终预测统一按特征编号排序后重算，初始预测保留。该修订不改变选择名单、参数、FDP、Power 或稳定性。相同集合在相同评价器中必须给出相同预测，并已纳入断言。参数仍沿用原先冻结的开发者期选择，不因重评结果调整。

模拟下游预测也统一使用标准化表示和规范列顺序，保留各方法原名单。这同时纠正了历史 Copula 模拟评价器使用秩高斯表示的问题；新评价保存在 canonical_simulation_evaluation，不覆盖 V7，也不计为新增选择算法案例。

4 主预算总览

方法	XGB-RMSE	TabM-RMSE	50% Jaccard	Nogueira	FDP@12	Power@12
Copula-MVR	1.8650	1.8967	0.7355	0.6798	0.3218	0.8305
Elastic Net	1.8625	1.8806	0.7244	0.6185	0.3251	0.8265
稳定性选择	1.8937	1.8885	0.5827	0.4788	0.3383	0.8107
影子变量树	1.8611	1.8612	0.9388	0.9210	0.3361	0.8261
XGBoost-SHAP	1.8466	1.8571	0.7682	0.7439	0.2315	0.9403
Deep Lasso	1.8450	1.8594	0.8230	0.7754	0.2687	0.8947
TabM-置换	1.8458	1.8586	0.7505	0.7304	0.2656	0.8981
VTFS-定额适配	1.8622	1.8783	0.4068	0.2733	0.5306	0.5876
Deep	1.8461	1.8600	0.8618	0.7889	0.2657	0.8978
Lasso-Jacobian						
Jacobian 训练 + 原排名	1.8450	1.8594	0.7722	0.7591	0.2686	0.8943
原 Deep	1.8450	1.8594	0.8147	0.7994	0.2656	0.8986
Lasso+Jacobian 排名						
TabM-预算门	1.8450	1.8594	0.8071	0.7172	0.2793	0.8826
EntryPrune-回归适配	1.8812	1.8744	0.6271	0.4893	0.2869	0.8729
EntryPrune-刷新	2.0418	2.0350	0.4596	0.2742	0.5203	0.6107
EntryPrune-环境波动惩罚	1.8706	1.8897	0.4498	0.2726	0.5074	0.6263
VTFS-固定 K	1.8676	1.8921	0.4540	0.3047	0.4593	0.6815
VTFS-固定 K+ 成对损失	1.8653	1.8949	0.4333	0.3167	0.4531	0.6901
等预算随机子集搜索	1.8661	1.8926	0.4368	0.2835	0.4911	0.6412

RMSE 越低越好，Jaccard/Nogueira/Power 越高越好，FDP 越低越好。Jaccard 是相对各自完整开发名单；算法种子稳定性另存，不与样本稳定性混用。平均低 FDP 不代表实际 Olist 错误率已控。

4.1 各改动的实际判断

1. **Deep Lasso-Jacobian**：有局部价值，尚非全面提升。相对完整名单的半样本 Jaccard 从原版 0.8230 升至 0.8618，但相对父方法的互补半样本增量区间跨 0，参考 Jaccard 增量经族内校正后也跨 0。相对 SHAP 的两种 Jaccard 差异较明确；其平均 FDP 为 0.2657、Power 为 0.8978，仍弱于 SHAP 的 0.2315 和 0.9403。适合跟进稳定性取舍，不支持全面优胜或新定理。
2. **TabM 预算门**：不支持综合改善。参考 Jaccard 从 0.7505 升至 0.8071，但互补一致性和 Nogueira 没有同步提高，模拟 FDP 从 0.2656 升至 0.2793。不能只选参考 Jaccard 作为成功标准。

- 3. **EntryPrune** 刷新与波动惩罚：本实现不宜作为提升主线。波动版相对回归父实现的参考 Jaccard 从 0.6271 降至 0.4498，Power 从 0.8729 降至 0.6263。即使一个评价器的误差点估计更低，也不能掩盖选择质量恶化。刷新涉及分数与动量两项变化，不能将失败单独归因于其中一项。
- 4. **VTFS**：预算匹配有模拟收益，成对损失独立证据较弱。原适配、固定 K、固定 K 加成对损失的平均 FDP 依次为 0.5306、0.4593、0.4531，Power 依次为 0.5876、0.6815、0.6901。主要收益来自预算修正；成对损失较固定 K 版本仅小幅增量。二者真实数据预测与稳定性尚未形成优势，修复旧适配不应包装成原创模型成功。

结论：没有发现同时在预测、两类样本稳定性与模拟检出方面全面超过强基线的新算法。计算完成和某项指标变好，都不能自动证明论文原创性。

5 对父方法的配对差异

下表差为“改动减对照”，RMSE 差负数有利于改动。卖家簇 Bootstrap 5,000 次，以三个已观察测试月份为条件。校正区间覆盖预先列出的比较对与两个评价器；不能解读为独立外部确认。尾部分位数仍有 Monte Carlo 误差。

改动	父/对照	评价器	RMSE 差	点区间 95%	族内校正区间
Deep	Deep Lasso	xgboost	+0.0010	[-0.0009, 0.0030]	[-0.0021, 0.0042]
Lasso-Jacobian					
Deep	Deep Lasso	tabm	+0.0006	[-0.0022, 0.0035]	[-0.0042, 0.0054]
Lasso-Jacobian					
Jacobian 训练 + 原排名	Deep Lasso	xgboost	+0.0000	[0.0000, 0.0000]	[0.0000, 0.0000]
Jacobian 训练 + 原排名	Deep Lasso	tabm	+0.0000	[0.0000, 0.0000]	[0.0000, 0.0000]
原 Deep	Deep Lasso	xgboost	+0.0000	[0.0000, 0.0000]	[0.0000, 0.0000]
Lasso+Jacobian 排名					
原 Deep	Deep Lasso	tabm	+0.0000	[0.0000, 0.0000]	[0.0000, 0.0000]
Lasso+Jacobian 排名					
TabM-预算门	TabM-置换	xgboost	-0.0008	[-0.0057, 0.0042]	[-0.0084, 0.0074]
TabM-预算门	TabM-置换	tabm	+0.0008	[-0.0029, 0.0046]	[-0.0054, 0.0068]
EntryPrune-刷新	EntryPrune-回归适配	xgboost	+0.1606	[0.1298, 0.1924]	[0.1137, 0.2072]
EntryPrune-刷新	EntryPrune-回归适配	tabm	+0.1606	[0.1322, 0.1895]	[0.1135, 0.2075]
EntryPrune-环境波动惩罚	EntryPrune-回归适配	xgboost	-0.0106	[-0.0237, 0.0022]	[-0.0323, 0.0098]
EntryPrune-环境波动惩罚	EntryPrune-回归适配	tabm	+0.0152	[-0.0015, 0.0326]	[-0.0098, 0.0441]
VTFS-固定 K	VTFS-定额适配	xgboost	+0.0054	[-0.0085, 0.0193]	[-0.0168, 0.0279]
VTFS-固定 K	VTFS-定额适配	tabm	+0.0139	[-0.0053, 0.0330]	[-0.0156, 0.0464]
VTFS-固定 K+ 成对损失	VTFS-固定 K	xgboost	-0.0023	[-0.0107, 0.0063]	[-0.0170, 0.0116]
VTFS-固定 K+ 成对损失	VTFS-固定 K	tabm	+0.0027	[-0.0034, 0.0088]	[-0.0072, 0.0122]
等预算随机子集搜索	VTFS-定额适配	xgboost	+0.0039	[-0.0094, 0.0177]	[-0.0159, 0.0286]
等预算随机子集搜索	VTFS-定额适配	tabm	+0.0144	[-0.0035, 0.0325]	[-0.0159, 0.0444]

不能因为点区间跨 0 就宣称等价；1% 容忍度只是预设的工程参考。即便优于较弱父方法，仍需与 XGBoost-SHAP、影子树等强基线比较，并查看检出率及稳定性代价。

预测 Bootstrap 条件于当前已拟合的三种子集成，不包含重新训练、重调参数或换到新时间环境的不确定性。TabM 门控试验同时改变了预热和预算训练日程，因此即使发现收益，也不能在缺少额外日程消融时把全部效果只归功于门本身。

6 逐场景模拟

6.1 linear_sparse

方法	平均 FDP	FDP MCSE	Power	XGB-RMSE
Copula-MVR	0.5833	0.0000	1.0000	0.6371
Elastic Net	0.5833	0.0000	1.0000	0.6358
稳定性选择	0.5833	0.0000	1.0000	0.6356
影子变量树	0.5875	0.0018	0.9900	0.6399
XGBoost-SHAP	0.5833	0.0000	1.0000	0.6386
Deep Lasso	0.5833	0.0000	1.0000	0.6381
TabM-置换	0.5833	0.0000	1.0000	0.6364
VTFS-定额适配	0.6767	0.0072	0.7760	0.7120
Deep Lasso-Jacobian	0.5833	0.0000	1.0000	0.6367
Jacobian 训练 + 原排名	0.5833	0.0000	1.0000	0.6372
原 Deep Lasso+Jacobian 排名	0.5833	0.0000	1.0000	0.6379
TabM-预算门	0.5833	0.0000	1.0000	0.6380
EntryPrune-回归适配	0.5833	0.0000	1.0000	0.6363
EntryPrune-刷新	0.6167	0.0046	0.9200	0.6577
EntryPrune-环境波动惩罚	0.6092	0.0042	0.9380	0.6543
VTFS-固定 K	0.6083	0.0038	0.9400	0.6514
VTFS-固定 K+ 成对损失	0.6033	0.0036	0.9520	0.6483
等预算随机子集搜索	0.6350	0.0044	0.8760	0.6709

6.2 linear_medium

方法	平均 FDP	FDP MCSE	Power	XGB-RMSE
Copula-MVR	0.1667	0.0000	1.0000	1.0727
Elastic Net	0.1667	0.0000	1.0000	1.0724
稳定性选择	0.1675	0.0008	0.9990	1.0715
影子变量树	0.3292	0.0063	0.8050	1.0956
XGBoost-SHAP	0.1742	0.0024	0.9910	1.0740
Deep Lasso	0.1700	0.0016	0.9960	1.0723
TabM-置换	0.1692	0.0019	0.9970	1.0721
VTFS-定额适配	0.5325	0.0112	0.5610	1.1557
Deep Lasso-Jacobian	0.1667	0.0000	1.0000	1.0724
Jacobian 训练 + 原排名	0.1667	0.0000	1.0000	1.0723
原 Deep Lasso+Jacobian 排名	0.1700	0.0016	0.9960	1.0723
TabM-预算门	0.1983	0.0046	0.9620	1.0756
EntryPrune-回归适配	0.1675	0.0008	0.9990	1.0715
EntryPrune-刷新	0.4967	0.0111	0.6040	1.1437
EntryPrune-环境波动惩罚	0.4792	0.0116	0.6250	1.1354
VTFS-固定 K	0.4308	0.0093	0.6830	1.1210
VTFS-固定 K+ 成对损失	0.4167	0.0088	0.7000	1.1163
等预算随机子集搜索	0.4633	0.0087	0.6440	1.1318

6.3 linear_weak

方法	平均 FDP	FDP MCSE	Power	XGB-RMSE
Copula-MVR	0.1867	0.0041	0.9760	1.8831
Elastic Net	0.1842	0.0036	0.9790	1.8829
稳定性选择	0.2083	0.0066	0.9500	1.8851
影子变量树	0.3583	0.0077	0.7700	1.9023
XGBoost-SHAP	0.2208	0.0058	0.9350	1.8873
Deep Lasso	0.2483	0.0068	0.9020	1.8882
TabM-置换	0.2275	0.0064	0.9270	1.8848
VTFS-定额适配	0.5400	0.0097	0.5520	1.9339
Deep Lasso-Jacobian	0.2125	0.0063	0.9450	1.8841
Jacobian 训练 + 原排名	0.2108	0.0062	0.9470	1.8834
原 Deep Lasso+Jacobian 排名	0.2458	0.0067	0.9050	1.8879
TabM-预算门	0.2400	0.0066	0.9120	1.8881
EntryPrune-回归适配	0.1950	0.0051	0.9660	1.8830
EntryPrune-刷新	0.5517	0.0106	0.5380	1.9405
EntryPrune-环境波动惩罚	0.5300	0.0116	0.5640	1.9357
VTFS-固定 K	0.4917	0.0092	0.6100	1.9232
VTFS-固定 K+ 成对损失	0.4850	0.0097	0.6180	1.9209
等预算随机子集搜索	0.5142	0.0090	0.5830	1.9255

6.4 linear_dense

方法	平均 FDP	FDP MCSE	Power	XGB-RMSE
Copula-MVR	0.0000	0.0000	0.8000	1.0984
Elastic Net	0.0000	0.0000	0.8000	1.1012
稳定性选择	0.0000	0.0000	0.8000	1.1019
影子变量树	0.2033	0.0083	0.6373	1.1177
XGBoost-SHAP	0.0225	0.0042	0.7820	1.0962
Deep Lasso	0.0083	0.0025	0.7933	1.0942
TabM-置换	0.0017	0.0012	0.7987	1.0959
VTFS-定额适配	0.3942	0.0112	0.4847	1.1635
Deep Lasso-Jacobian	0.0000	0.0000	0.8000	1.0981
Jacobian 训练 + 原排名	0.0000	0.0000	0.8000	1.0987
原 Deep Lasso+Jacobian 排名	0.0083	0.0025	0.7933	1.0940
TabM-预算门	0.0167	0.0036	0.7867	1.0929
EntryPrune-回归适配	0.0083	0.0025	0.7933	1.0927
EntryPrune-刷新	0.3758	0.0110	0.4993	1.1534
EntryPrune-环境波动惩罚	0.3542	0.0109	0.5167	1.1524
VTFS-固定 K	0.3150	0.0091	0.5480	1.1338
VTFS-固定 K+ 成对损失	0.3158	0.0089	0.5473	1.1354
等预算随机子集搜索	0.3625	0.0078	0.5100	1.1458

6.5 nonlinear

方法	平均 FDP	FDP MCSE	Power	XGB-RMSE
Copula-MVR	0.5125	0.0106	0.5850	1.2440
Elastic Net	0.5108	0.0088	0.5870	1.2338
稳定性选择	0.5325	0.0104	0.5610	1.2366
影子变量树	0.2642	0.0068	0.8830	1.1721
XGBoost-SHAP	0.1967	0.0048	0.9640	1.1717

方法	平均 FDP	FDP MCSE	Power	XGB-RMSE
Deep Lasso	0.3075	0.0079	0.8310	1.1751
TabM-置换	0.2975	0.0081	0.8430	1.1752
VTFS-定额适配	0.5125	0.0087	0.5850	1.2234
Deep Lasso-Jacobian	0.3242	0.0089	0.8110	1.1784
Jacobian 训练 + 原排名	0.3308	0.0093	0.8030	1.1798
原 Deep Lasso+Jacobian 排名	0.2975	0.0073	0.8430	1.1748
TabM-预算门	0.3150	0.0080	0.8220	1.1767
EntryPrune-回归适配	0.3858	0.0093	0.7370	1.1976
EntryPrune-刷新	0.5392	0.0095	0.5530	1.2243
EntryPrune-环境波动惩罚	0.5242	0.0094	0.5710	1.2189
VTFS-固定 K	0.4592	0.0082	0.6490	1.2006
VTFS-固定 K+ 成对损失	0.4483	0.0084	0.6620	1.1979
等预算随机子集搜索	0.4875	0.0078	0.6150	1.2094

6.6 nonlinear_panel

方法	平均 FDP	FDP MCSE	Power	XGB-RMSE
Copula-MVR	0.4817	0.0104	0.6220	1.2160
Elastic Net	0.5058	0.0113	0.5930	1.2099
稳定性选择	0.5383	0.0111	0.5540	1.2095
影子变量树	0.2742	0.0075	0.8710	1.1437
XGBoost-SHAP	0.1917	0.0042	0.9700	1.1418
Deep Lasso	0.2950	0.0075	0.8460	1.1453
TabM-置换	0.3142	0.0081	0.8230	1.1466
VTFS-定额适配	0.5275	0.0098	0.5670	1.1970
Deep Lasso-Jacobian	0.3075	0.0081	0.8310	1.1483
Jacobian 训练 + 原排名	0.3200	0.0088	0.8160	1.1493
原 Deep Lasso+Jacobian 排名	0.2883	0.0073	0.8540	1.1450
TabM-预算门	0.3225	0.0086	0.8130	1.1546
EntryPrune-回归适配	0.3817	0.0104	0.7420	1.1686
EntryPrune-刷新	0.5417	0.0098	0.5500	1.1989
EntryPrune-环境波动惩罚	0.5475	0.0101	0.5430	1.1988
VTFS-固定 K	0.4508	0.0080	0.6590	1.1728
VTFS-固定 K+ 成对损失	0.4492	0.0084	0.6610	1.1713
等预算随机子集搜索	0.4842	0.0083	0.6190	1.1808

7 组件是否真正贡献

方法	600 模拟神经候选胜出比例	模拟平均开发效用增益	真实完整样本神经候选胜出
VTFS-固定 K	0.737	0.023210	True
VTFS-固定 K+ 成对损失	0.805	0.027291	True

“神经候选胜出”只是该次有限搜索中的来源标签，不自动证明相对全局随机搜索或样本外目标有优势。Deep Lasso 的训练/排名交叉消融、EntryPrune 扣波动前后比较、VTFS 成对损失和等查询随机对照均保留于配对统计文件。

8 复现与剩余研究

本轮仍然是一个电商数据集和预设模拟，未声称第二数据集验证。已有测试期被查看过，报告有利结果不能消除选择偏差。正式论文本体采纳某条改动之前，需要独立时间或数据集、相关先行研究对比及足够的理论/机制说明，不能以“跑赢”替代原创性判断。

结果文件：coverage.csv、audit.json、prediction_summary.csv、prediction_paired.csv、stability_summary.csv、stability_paired.csv、simulation_summary.csv、simulation_paired.csv、vtfs_decoder_diagnostic.csv。逐样本结果及参考模型权重均保留。

9 附录：文献与新颖性

本轮不是证明所有改动“此前无人提出”。检索支持的是下列文献真实存在，以及所试验机制与既有研究的关系。未完成系统查重前，不使用“首创”“首次解决”等措辞。

文献	核验入口	与本轮关系
Cherepanova 等, A Performance-Driven Benchmark for Feature Selection in Tabular Deep Learning, NeurIPS Datasets and Benchmarks 2023	https://openreview.net/forum?id=v4PMCdSaAT	Deep Lasso 父方法，输入损失梯度组惩罚
Gorishniy 等, TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling, ICLR 2025	https://github.com/yandex-research/tabm	官方参数高效集成网络；门控是本轮附加机制
Ying 等, Feature Selection as Deep Sequential Generative Learning, ACM TKDD 18(9), Article 221, 2024	https://doi.org/10.1145/3687485	VTFS 父方法，Transformer 编码、效用预测与解码
Zimmer 等, EntryPrune: Neural Network Feature Selection using First Impressions, arXiv:2410.02344v4, 2025	https://arxiv.org/abs/2410.02344	历史进入分数、动态输入层和随机再生；不擅自标为已发表顶会
Yamada 等, Feature Selection using Stochastic Gates, ICML 2020, PMLR 119:10648-10659	https://proceedings.mlr.press/v119/yamada20a.html	说明神经网络可学习输入门已有先例，不是本轮发明
Gregorová 等, Structured Nonlinear Variable Selection, UAI 2018	https://auai.org/uai2018/proceedings/papers/17.pdf	说明以函数偏导数构造稀疏正则已有先例，并非更换梯度就获得原创性

9.1 可以检验的机制问题

1. 对平方损失，输入损失梯度是预测 Jacobian 与残差的乘积。较大残差样本可能放大某列分数。Jacobian 稀疏/排名试验检验去除这一权重的收益与代价，不能先验保证其错误发现率更低。
2. 普通 TabM 在全部 31 项上训练，再删除多数特征。固定 K 共享门把预算嵌入训练，检验减少训练与使用阶段不一致是否有收益。直通估计是有偏梯度近似，不能说本轮精确求解非凸最优子集。
3. EntryPrune 的历史最大分数可能受到偶然梯度高分影响。刷新与波动惩罚尝试控制这一问题，但反复对同一批数据打分不产生独立统计证据，均值减标准差不是有效置信下界。
4. 固定 K 语料首先纠正 VTFS 适配的预算不匹配；成对效用差损失尝试让连续表示更关注子集优劣。学习排序也是已有思想，必须以“固定 K 版本”作父对照，不能把修复带来的收益归给新增成对损失。

9.2 哪些不足以支撑论文创新

- 调大网络、改学习率、换一个随机种子；
- 把已有正则、门控、相关聚类简单合并并另起名字；
- 修复当前实现问题后只与有问题的旧实现比较；

- 只报告一种指标、一个 K 或最有利模拟场景；
- 某次预测点估计较好，就声称稳定性或 FDR 理论也成立。

9.3 进入正式论文的条件

机制必须有独立动机、相邻工作辨析、拆分消融和稳定的样本外证据。优于较弱父方法还不够，需要与 XGBoost-SHAP 等强基线对比。对新的真实数据进行冻结后验证仍是缺口。本轮结果可为“哪些机制值得继续研究”提供证据，不能替代导师对研究贡献与学位要求的判断。