

基于白噪声假设检验的归因分组变量选择研究

——以 H&M 时尚电商交易数据为例

汇报人：吴优

上海财经大学·应用统计学硕士

2026 年 6 月



上海财经大学
Shanghai University of Finance & Economics

① 研究背景与动机

② 数据概览

③ 研究方法：三阶段框架

④ 实证结果

⑤ 方法增益

⑥ 理论支撑

⑦ 预期贡献

⑧ 总结

① 研究背景与动机

② 数据概览

③ 研究方法：三阶段框架

④ 实证结果

⑤ 方法增益

⑥ 理论支撑

⑦ 预期贡献

⑧ 总结

业务痛点：DTU 波动，归因看板变量太多

核心问题

每日 DTU (Daily Transaction Units, 日交易笔数) 波动时，归因看板上铺着 **21** 个候选分组变量，业务方根本看不过来。

21 个候选分组变量（五族）

- **F1 时间衍生**：年/月/星期/季节/是否周末（5 个）
- **F2 交易渠道**：销售渠道/价格区间（2 个）
- **F3 用户画像**：年龄分段/会员状态/时尚资讯频率（3 个）
- **F4 商品层级**：指数组/品类组/品类/部门/区块/服装组等（7 个）

行业现状

- 到底盯哪几个变量，完全依赖经验直觉
- 缺乏数理依据
- 新业务需 6-12 个月人肉摸索

本研究目标

- 以统计假设检验框架筛选核心变量

核心思想：信号—噪声分解

关键观察

子序列只有两种可能：白噪声（无信号）或非白噪声（承载信号）

$$DTU(t) = \sum_{j=1}^{r_k} DTU_j^{(k)}(t), \quad DTU_j^{(k)}(t) = s_j^{(k)}(t) + \varepsilon_j^{(k)}(t)$$

- $s_j^{(k)}(t)$: 信号部分（未知）
- $\varepsilon_j^{(k)}(t)$: 白噪声扰动
- 理想归因变量：多数子序列为信号，且噪声方差远小于信号

例：颜色组 vs 部门

- 颜色组：绝大多数子序列涨跌接近随机扰动 白噪声噪音族
- 部门：Jersey Basic Knitwear 等子序列有稳定结构 信号族

① 研究背景与动机

② 数据概览

③ 研究方法：三阶段框架

④ 实证结果

⑤ 方法增益

⑥ 理论支撑

⑦ 预期贡献

⑧ 总结

数据概览：H&M 电商交易数据

数据来源

- Kaggle 平台：H&M Personalized Fashion Recommendations
- 三表 JOIN 后：**31,788,324** 条交易 $\in$ 35 列
- 时间跨度：**2018-09-20** 至 **2020-09-22**
- 总观测：**734** 天

目标变量

- $Y(t) = DTU(t) =$ 第 t 天总交易笔数
- 日均约 3-5 万笔
- 周末显著高于工作日

21 个候选分组变量（五族）

族	维度	水平数
F1 时间	年/月/星期/季节/是否周末	2-12
F2 渠道	销售渠道/价格区间	2020, S...

1 研究背景与动机

2 数据概览

3 研究方法：三阶段框架

阶段一：白噪声假设检验

阶段二：方差解释比

阶段三：滑动窗口与 Bootstrap

4 实证结果

5 方法增益

6 理论支撑

整体框架：三阶段量化筛选流水线

阶段	回答的问题	统计方法	
一	子序列是噪声还是信号？	Ljung-Box + McLeod-Li + BY-FDR 校正	
二	分组变量的归因价值多大？	信号方差解释比 R_{sig}^2	21
三	价值在不同窗口下是否稳定？	滑动窗口 + MBB	S_{final}

方法定位

- 全部采用经典统计方法（Ljung-Box, McLeod-Li, BY-FDR, MBB）
- 贡献在流程设计与量化指标定义，而非方法本身
- 不引入迁移学习框架（可复用性来自流程本身）

1 研究背景与动机

2 数据概览

3 研究方法：三阶段框架

阶段一：白噪声假设检验

阶段二：方差解释比

阶段三：滑动窗口与 Bootstrap

4 实证结果

5 方法增益

6 理论支撑

阶段一：子序列白噪声假设检验

对每个子序列 $X_j^{(k)}$ 做两类检验：

Ljung-Box 检验（自相关）

$$Q_{LB} = T(T+2) \sum_{h=1}^m \frac{\hat{\rho}_h^2}{T-h} \sim \chi_m^2$$

- $H_0: \rho_1 = \dots = \rho_m = 0$
- 检验均值层面自相关

判定规则：任一检验拒绝 判定为信号

McLeod-Li 检验（ARCH 效应）

- 对平方序列 $\{X_j^{(k)2}(t)\}$ 做 Ljung-Box
- 捕获条件异方差型非线性信号
- 源于 Engle (1982) 的 ARCH 模型族

BY-FDR 多重检验校正 ($q = 0.10$)

- 约 700 个子序列同时检验，需控制假阳性膨胀

1 研究背景与动机

2 数据概览

3 研究方法：三阶段框架

阶段一：白噪声假设检验

阶段二：方差解释比

阶段三：滑动窗口与 Bootstrap

4 实证结果

5 方法增益

6 理论支撑

阶段二：信号方差解释比 R_{sig}^2

定义

$$R_{sig}^2(D_k) = \frac{\text{Var}\left(\sum_{j \in S_k} X_j^{(k)}\right)}{\text{Var}(DTU)} \in [0, +\infty)$$

- S_k : 阶段一判定为信号的子序列集合
- $R_{sig}^2 \rightarrow 1$: 信号子序列解释了 DTU 的全部波动 归因价值高
- $R_{sig}^2 \rightarrow 0$: 信号贡献微弱 归因价值低
- 注意: R_{sig}^2 可超过 1 (当信号子序列与噪声子序列负相关时)

辅助指标

- 全水平方差占比 R_{all}^2 : 不区分信号/噪声, 反映"水分"多少
- 信号集占比 $\pi_{sig}^k = |S_k|/r_k$: 多大比例的水平承载信号

理想亦是 同时具备高 R_{sig}^2 和 π_{sig}^k

1 研究背景与动机

2 数据概览

3 研究方法：三阶段框架

阶段一：白噪声假设检验

阶段二：方差解释比

阶段三：滑动窗口与 Bootstrap

4 实证结果

5 方法增益

6 理论支撑

阶段三：滑动窗口与 Bootstrap 稳定性评估

三套滑动窗口方案（共 **84** 个窗口）

方案	窗口构造	窗口数	设计意图
W1	30 天 vs 前 30 天，步长 30 天	~24	月度环比
W2	30 天 vs 前 30 天，步长 14 天	~50	重叠月度
W3	90 天 vs 前 90 天，步长 30 天	~20	季度对比

最终选维规则（Moving Block Bootstrap, $B = 1000$ ）

$$p_k = \Pr(D_k \in \text{Top-K by } R_{sig}^2)$$

$$S_{final} = \{D_k : p_k \geq 0.80 \text{ 且 } \mu_k > \text{median}(\mu_{1:K})\}$$

- MBB 块长 $L = 4$ ，块数 ≈ 21
- 同时报告 95% BCa 置信区间（二阶精度）

① 研究背景与动机

② 数据概览

③ 研究方法：三阶段框架

④ 实证结果

⑤ 方法增益

⑥ 理论支撑

⑦ 预期贡献

⑧ 总结

实证结果：21 个分组变量按 μ_k 排序

#	分组变量	族	r_k	$\mu_k \pm \sigma_k$	CV_k	p_k
1	星期	F1	7	5.351 $\pm$ 5.878	1.099	0.003
2	是否周末	F1	2	4.485 $\pm$ 4.683	1.044	0.006
3	年	F1	3	1.158 $\pm$ 0.591	0.510	1.000
4	季节	F1	4	1.000 $\pm$ 0.000	0.000	1.000
5	月	F1	12	1.000 $\pm$ 0.000	0.000	1.000
6	会员状态	F3	4	0.687 $\pm$ 0.463	0.673	0.881
7	品类	F4	130	0.603 $\pm$ 0.312	0.517	1.000
8	部门	F4	250	0.577 $\pm$ 0.298	0.516	1.000
9	品类组	F4	19	0.537 $\pm$ 0.341	0.635	0.978
10	时尚资讯频率	F3	4	0.524 $\pm$ 0.419	0.799	0.509

- 时间衍生变量（星期/是否周末） $\mu_k > 4$ 但 $CV > 1$ ——结构对立，不稳定
- 商品层级族（品类/部门/品类组） μ_k 高且稳定
- 颜色族四项 $\mu_k \in [0.26, 0.30]$, $p_k = 0$ ——白噪声噪音族

稳定性验证与最终选维

秩稳定性

- 前后半窗 Spearman $\rho = 0.9740$
- Kendall $\tau \approx 0.89$
- 排名结构高度一致

负对照验证

- 颜色族： $p_k = 0$ 白噪声族
- 星期/是否周末：
 $CV > 1, p_k \leq 0.006$ 被准确剔除

最终选维 S_{final}

$S_{final} = \{\text{会员状态, 品类, 部门, 年, 季}\}$

- **F4** 商品层级：品类、部门（2 项）
- **F1** 时间衍生：年、季节（2 项）
- **F3** 用户画像：会员状态（1 项）
- **F2** 渠道与 **F5** 属性均无入选

业务含义

汇报人：吴优

基于白噪声假设检验的归因分组变量选择研究

上海财经大学·应用统计学硕士



① 研究背景与动机

② 数据概览

③ 研究方法：三阶段框架

④ 实证结果

⑤ 方法增益

⑥ 理论支撑

⑦ 预期贡献

⑧ 总结

方法增益：相比单一基线的优势

三条基线对比

- ① 简单方差占比 R_{all}^2 ：不区分信号与噪声
- ② Cramér's V：列联表关联强度，单窗口排名
- ③ XGBoost gain：梯度提升树特征重要性

本框架的核心增益

- 场景一（假阳性剔除）：星期/是否周末在 R_{all}^2 或 Cramér's V 下因结构对立被错选，本框架通过 $p_k \leq 0.006$ 准确剔除
- 场景二（隐性不稳定识别）：销售渠道 $\mu_k = 0.441$ 排名第 11 看似中等，但 $p_k = 0.047$ 揭示其 Bootstrap 下波动剧烈——单窗口分数无法识别

引入 **Bootstrap** 不确定性量化（阶段三）是把方法从“统计描述”提升为“统计推断”的关键

① 研究背景与动机

② 数据概览

③ 研究方法：三阶段框架

④ 实证结果

⑤ 方法增益

⑥ 理论支撑

⑦ 预期贡献

⑧ 总结

理论支撑：经典文献背书

理论结果	出处	在本框架中的含义
Ljung-Box Q 渐近 χ_m^2	Ljung & Box (1978)	阶段一白噪声判别的零
McLeod-Li 检验	McLeod & Li (1983)	捕获 ARCH 信号，与
ARCH 模型族	Engle (1982)	解释为何对平方序列做
FDR 控制 (PRDS)	Benjamini & Hochberg (1995)	经典 BH 作为对照
FDR 控制 (任意依赖)	Benjamini & Yekutieli (2001)	700 子序列假阳性可控
Block Bootstrap	Künsch (1989)	MBB 方法起源
Bootstrap 一致性	Lahiri (2003)	相依数据下仍一致估计
BCa 置信区间	Efron (1987)	R_{sig}^2 的 95% CI 二阶精
Stability Selection	Meinshausen & Bühlmann (2010)	p_k 作为稳定性证据的理

① 研究背景与动机

② 数据概览

③ 研究方法：三阶段框架

④ 实证结果

⑤ 方法增益

⑥ 理论支撑

⑦ 预期贡献

⑧ 总结

预期贡献与实际价值

① 从经验判断到数理依据

- 将" 分组变量好坏" 转化为可统计检验、可置信区间量化的指标 R_{sig}^2
- 输出" 这 5 个变量在 90% 以上历史窗口中 R_{sig}^2 进 Top-5, $p_k \geq 0.80$ "

② 对新业务的方法可复用性

- 新业务积累 3 个月数据后跑同样流水线 输出核心分组变量清单
- 流程可复用，不涉及跨数据集迁移学习建模

③ 支持数据治理决策

- $p_k \geq 0.80$ 配进看板默认视图
- $p_k < 0.20$ 可考虑从数据治理上下线，节省存储与 ETL 成本

① 研究背景与动机

② 数据概览

③ 研究方法：三阶段框架

④ 实证结果

⑤ 方法增益

⑥ 理论支撑

⑦ 预期贡献

⑧ 总结

总结

核心问题

从 21 个候选分组变量中，筛选出长期承载真实信号的

方法

白噪声检验 + R_{sig}^2 方差分解 + Bootstrap 稳定

结果

$S_{final} = \{\text{会员状态, 品类, 部门, 年, 季节}\}$

贡献

全流程基于经典统计方法，可辩护、可复用、

Thanks!

指导教师：CECE 教授

上海财经大学·统计与管理学院