

上海财经大学
研究生申请学位论文开题报告表

姓 名		学 院	统计与数据科学学院
学 号		导师姓名	
专 业	应用统计	培养层次	专业硕士
		同意开题	导师签字:
论文题目	基于白噪声假设检验的归因分组变量选择研究——以 H&M 时尚电商交易数据为例		
开题时间		开题地点	
与会专家 姓名、单位 3-5 人			
开题报告 情况	专家主要意见:		
开题结果 (划圈)	开题通过, 同意进入论文写作阶段。 / 开题未通过, 不同意进入论文写作阶段。		
	开题报告会专家组组长签名:		
	导师签名: 年 月 日		
注: 填写本表 1 份, 申请开题须经导师签字同意; 开题结果由开题报告会专家组组长及导师签署并签字; 交研究生秘书进入教学管理信息系统录入开题结果。 附: 上海财经大学研究生学位论文开题报告书 (见下页), 打印3-5 份交学院安排开题。			

上海财经大学
研究生学位论文开题报告书

论文题目： 基于白噪声假设检验的归因分组变量选择研究
——以 H&M 时尚电商交易数据为例

姓 名： _____

学 号： _____

院系所： _____ 统计与数据科学学院

专 业： _____ 应用统计

培养层次： _____ 专业硕士

导师姓名： _____

二〇二六年六月

1、选题的背景、研究问题、理论意义、实用价值

互联网电商日常运营的核心北极星指标 DTU(Daily Transaction Units, 每日下单笔数) 不可避免地出现日间波动。当业务方早上看到"昨天 DTU 跌了 8%" 时, 归因看板上往往铺着数十个候选下钻分组变量, 以本研究采用的 H&M 时尚电商公开数据集为例, 共 21 个分组变量分属时间衍生、交易渠道、用户画像、商品多级品类、商品颜色与外观五族[H&M Personalized Fashion Recommendations]。其中大部分分组变量的子序列只是白噪声式的随机波动, 例如颜色组、图形外观等分组变量, 在绝大多数日子里其子 DTU 的涨跌都接近随机扰动, 几乎不携带可解释的归因信息; 真正每次都能稳定承载波动信号的, 通常只有 3 至 5 个分组变量。

本文拟研究的核心问题是: 如何从大量候选分组变量中, 以严格的统计假设检验框架, 自动筛选出长期承载真实波动信号的少数核心分组变量, 给出有统计背书的核心分组变量清单。具体研究内容包括: 其一, 如何将"分组变量好坏" 这一长期靠业务经验的判断, 转化为可统计检验的标量指标; 其二, 如何利用白噪声假设检验把分组变量下的子序列显式分解为信号集与噪声集; 其三, 如何通过滑动窗口与 Block Bootstrap 量化筛选结果在时间维度上的稳定性与不确定性; 其四, 如何针对多重检验导致的假阳性膨胀问题做合理校正。

本文的理论意义在于, 将分组变量选择问题转化为子序列层面的信号—噪声分解问题, 在 Ljung-Box 检验[Ljung & Box (1978)]、McLeod-Li 检验[McLeod & Li (1983)]、Benjamini-Yekutieli FDR 控制[Benjamini & Yekutieli (2001)] 与 Moving Block Bootstrap[Künsch (1989)] 等经典统计方法基础上, 构造一套面向归因看板选维需求的三阶段量化筛选流水线。每一环节均有独立文献辩护基础, 贡献在于流程设计与量化指标定义, 而非新构造单一估计量。

本文的实用价值主要体现在: 对于成熟业务, 框架输出的核心分组变量清单可直接配置为归因看板默认视图, 降低业务方信息过载; 对于新业务, 框架本身可在积累 3 个月数据后复用, 自动给出该业务的核心分组变量, 填补当前完全依靠人肉经验摸索 6-12 个月的空白; Bootstrap 选择概率 p_k 给出 $[0, 1]$ 之间的稳定性打分, $p_k \geq 0.80$ 配进默认视图、 $p_k < 0.20$ 可考虑从数据治理上下线, 直接支持存储与 ETL 成本优化。

2、国内外研究现状与发展趋势

时间序列白噪声检验是本文方法的基础。Ljung 与 Box 在 1978 年改进了 Box 与 Pierce 的 portmanteau 检验, 提出 $Q_{LB} = T(T+2) \sum_{h=1}^m \hat{\rho}_h^2 / (T-h)$ 统计量, 在大样本下渐近 χ_m^2 , 成为时间序列残差自相关诊断的标准工具[Ljung & Box (1978)]。McLeod 与 Li 在 1983 年将该思路推广到平方序列以检验条件异方差型非线性相关结构[McLeod & Li (1983)]; 该思路对应于 Engle 1982 年提出的 ARCH 模型族[Engle (1982)], 即均值层面可能呈白噪声但方差层面存在显著自相关。两类检验在金融时序、宏观经济序列与运营数据诊断中已有广泛应用。

多重检验校正方面, Benjamini 与 Hochberg 1995 年提出 FDR 控制框架[Benjamini & Hochberg (1995)], 改变了多重检验领域过度依赖 Bonferroni 校正的局面; 但 BH 程序要求 p 值满足正回归相依性 (PRDS), 不一定适用于本文中子序列存在共波动的情形。Benjamini 与 Yekutieli 2001 年进一步将 FDR 控制推广至任意依赖结构[Benjamini & Yekutieli (2001)], 代价是检验阈值更保守。本文采用 BY 程序契合 $\sum_k r_k \approx 700$ 个子序列同时检验的实际场景。

时间相依数据的 Bootstrap 方法由 Künsch 1989 年首次提出 Moving Block Bootstrap (MBB), 解决了经典 i.i.d. Bootstrap 在时间相依数据下的不适用问题[Künsch (1989)]; Lahiri 2003 年在专著中系统给出 MBB 的一致性理论与实用块长选择规则[Lahiri (2003)]。置信区间构造方面, Efron 1987 年提出 BCa 置信区间, 在偏态分布下相较百分位法具有二阶精度[Efron (1987)]。Meinshausen 与

Bühlmann 2010 年提出的稳定性选择 (Stability Selection), 通过子样本上的选择频率给出可解释的变量选择评分[Meinshausen & Bühlmann (2010)], 为本文以 Bootstrap 选择频率 p_k 作为稳定性证据提供了理论参照。

分类变量关联强度方面, Cramér 1946 年提出的 Cramér's V 是衡量两个分类变量列联表关联强度的经典指标[Cramér (1946)]; 该指标常被用作业务侧的单窗口分组变量重要性排名。机器学习侧, Chen 与 Guestrin 2016 年提出的 XGBoost 在特征重要性输出方面被广泛用于分组变量筛选[Chen & Guestrin (2016)]。这两类方法将作为本文的基线对照。

总体上, 白噪声检验、FDR 控制、Block Bootstrap、稳定性选择各自的理论基础已经成熟, 但在"工业归因看板分组变量筛选"这一具体问题上的组合应用尚不多见; 主流业务实践仍依赖 Cramér's V 、单窗口方差占比、树模型特征重要性等单一指标, 缺乏对时间稳定性的量化控制。本文工作的定位正是这一空白。

3、研究的基本思路与方法

3.1 核心思想

本文核心思想为: 当按某个分组变量 D_k 把总 DTU 拆成若干子 DTU 时, 子序列只有两种可能——白噪声 (无信号) 或非白噪声 (承载信号)。具体地,

$$\text{DTU}(t) = \sum_{j=1}^{r_k} \text{DTU}_j^{(k)}(t), \quad \text{DTU}_j^{(k)}(t) = s_j^{(k)}(t) + \varepsilon_j^{(k)}(t), \quad (1)$$

其中 $s_j^{(k)}(t)$ 表示信号部分, $\varepsilon_j^{(k)}(t)$ 表示白噪声扰动。理想的归因分组变量应满足两个性质: 其一, 绝大多数子序列均为信号; 其二, 即便存在噪声子序列, 其方差也应远小于信号子序列。

3.2 数学定义与符号

设原始交易明细 $\Omega = \{\omega_1, \dots, \omega_N\}$, 每笔交易 ω 含日期 $t(\omega) \in \mathcal{T}$ 与字段 $X_k(\omega)$ 。对候选分组变量 $D_k \in \mathcal{V} = \{D_1, \dots, D_K\}$ 、水平集 $\mathcal{L}_k = \{1, \dots, r_k\}$, 定义

$$Y_j^{(k)}(t) = |\{\omega \in \Omega : t(\omega) = t, X_k(\omega) = j\}|, \quad Y(t) = \sum_{j=1}^{r_k} Y_j^{(k)}(t) = \text{DTU}(t). \quad (2)$$

将子 DTU 序列记为 $X_j^{(k)} = \{Y_j^{(k)}(t)\}_{t \in \mathcal{T}}$, 设加性分解 $X_j^{(k)}(t) = s_j^{(k)}(t) + \varepsilon_j^{(k)}(t)$, $\varepsilon_j^{(k)} \stackrel{\text{iid}}{\sim} (0, \sigma_{k,j}^2)$ 。当 $s_j^{(k)} \equiv 0$ 时, 子序列退化为纯白噪声。白噪声检验在显著性水平 α (经 BY-FDR 校正) 下, 水平 j 被判为信号的集合为

$$\mathcal{S}_k = \{j \in \mathcal{L}_k : H_0^{(\text{WN})} \text{ 在 } X_j^{(k)} \text{ 上被拒绝}\}, \quad \mathcal{N}_k = \mathcal{L}_k \setminus \mathcal{S}_k. \quad (3)$$

定义分组变量 D_k 的信号方差解释比

$$R_{\text{sig}}^2(D_k) = \frac{\text{Var}\left(\sum_{j \in \mathcal{S}_k} X_j^{(k)}\right)}{\text{Var}(\text{DTU})}. \quad (4)$$

R_{sig}^2 趋于 1 表示该分组变量信号子序列承载了总 DTU 大部分波动信息, 归因价值高; 趋于 0 则归因价值低。当被排除的子序列与信号子序列负相关时 (典型如星期 = 工作日与周末强对立), R_{sig}^2 可能超过 1, 表示子序列间存在强结构对立。

3.3 三阶段量化筛选框架

阶段一：子序列白噪声假设检验。对每个子序列 $X_j^{(k)}$ 采用 Ljung-Box 检验自相关结构, 统计量

$$Q_{LB} = T(T+2) \sum_{h=1}^m \frac{\hat{\rho}_h^2}{T-h}, \quad Q_{LB} \stackrel{H_0}{\sim} \chi_m^2. \quad (5)$$

辅以 McLeod-Li 检验对平方序列 $\{X_j^{(k)2}(t)\}$ 做同样的自相关检验, 以捕获条件异方差型非线性信号。两类检验任一拒绝即判为信号, 检验阶数取 $m = \min(20, T/4)$ 。针对 $\sum_k r_k \approx 700$ 个子序列同时检验, 采用 BY-FDR 程序控制假阳性率, 目标水平 $q = 0.10$ 。

阶段二：信号方差解释比与基准对照。按式 (4) 计算 $R_{sig}^2(D_k)$, 同时报告:(a) 全水平方差占比 $R_{all}^2(D_k) = \sum_j \text{Var}(X_j^{(k)})/\text{Var}(\text{DTU})$, 体现"噪声水平占了多少水分";(b) 信号集占比 $\pi_k^{sig} = |S_k|/r_k$ 。**负对照设计：**颜色族子序列预期接近白噪声, 若被判定为高 R_{sig}^2 则表明假阳性过高。

阶段三：滑动窗口与 Bootstrap 不确定性量化。窗口方案:W1 长 180 天步长 30 天 (月-季稳定性, 约 19 窗),W2 长 90 天步长 7 天 (中短期敏感性, 约 93 窗)。对每个 D_k 在 W 个窗口得 $\{R_{sig,k}^{2,(w)}\}_{w=1}^W$, 计算均值 μ_k 、标准差 σ_k 、变异系数 $CV_k = \sigma_k/\mu_k$ 。Moving Block Bootstrap 以块为单位重抽样 $B = 1000$ 次, 每次独立运行阶段一与二, 统计

$$p_k = \Pr(D_k \in \text{Top-}K \text{ by } R_{sig}^2), \quad K = 5, \quad (6)$$

最终选维子集

$$S_{\text{final}} = \{D_k : p_k \geq 0.80, \mu_k > \text{median}(\mu_{1:K})\}. \quad (7)$$

同时报告每个分组变量 R_{sig}^2 的 95% BCa 置信区间。

3.4 实证数据

本文采用 Kaggle 公开数据集 *H&M Personalized Fashion Recommendations*(2022 年由 H&M 与 Kaggle 联合发布, 数据集名 *h-and-m-personalized-fashion-recommendations*), 三表 JOIN 后约 31,788,324 行 $\times$ 35 列, 覆盖 2018-09-20 至 2020-09-22 共 734 天[H&M Personalized Fashion Recommendations]。21 个候选分组变量分布于五族:F1 时间衍生 (年/月/星期/季节/是否周末,5 个);F2 交易渠道 (销售渠道/价格区间,2 个);F3 用户画像 (年龄分段/会员状态/时尚资讯频率,3 个);F4 商品层级 (指数组/指数子类/品类组/品类/部门/区块/服装组,7 个, 水平数 5-250);F5 商品属性 (颜色组/颜色明度/颜色主色/图形外观,4 个, 水平数 8-50)。

4、论文的创新性尝试

将分组变量优劣转化为可统计检验的标量指标。本文将业务侧长期靠经验判断的"分组变量好坏", 通过白噪声假设检验显式分解为信号子序列集合 S_k 与噪声子序列集合 N_k , 并以信号方差解释比 $R_{sig}^2(D_k)$ 作为标量评分, 使分组变量比较具备统计推断意义, 而非仅描述性排序。

多阶段流水线模块化设计。三阶段流水线中每一环节 (白噪声检验、FDR 校正、Block Bootstrap 不确定性量化) 均可独立替换, 例如 Ljung-Box 可换为 BDS 检验、BY-FDR 可换为 Storey q 值、MBB 可换为 Circular Block Bootstrap。这种模块化设计使方法在面对新业务场景时具有较强的可迁移性, 而无需重新设计全部流程。

以 Bootstrap 选择概率 p_k 量化跨窗口稳定性。与传统单窗口指标 (简单方差占比、Cramér's V 、XGBoost gain) 不同, 本文以 MBB 重抽样得到的选择频率 $p_k \in [0, 1]$ 作为稳定性证据, 与

Meinshausen 与 Bühlmann 的稳定性选择思路相通, 可识别两类典型假信号: 其一为均值高但跨窗口剧烈波动的"伪稳定"变量; 其二为单窗口看似稳定但 Bootstrap 重抽样下方差剧烈的隐性不稳定变量。这一不确定性量化环节将方法从"统计描述"提升为"统计推断"。

5、研究难点与预期成果

本文的研究难点主要集中在三个方面。其一, 水平数差异极大 (5 至 250) 带来的检验功效不平衡: 水平数多的分组变量 (如部门 250 个水平) 在每个水平上的样本量稀薄, Ljung-Box 功效下降, 可能漏判信号; 水平数少的分组变量 (如销售渠道 2 个水平) 又面临子序列高度相关、 $R_{\text{sig}}^2 > 1$ 的边界情形, 需要在指标解释与稳定性筛子上做相应处理。其二, $\sum_k r_k \approx 700$ 个子序列同时检验的假阳性膨胀, 以及子序列之间复杂的共波动结构, 要求 FDR 校正任任意依赖下仍能控制, 这是选用 BY 程序而非 BH 程序的核心原因。其三, Moving Block Bootstrap 块长 L 的选择对时间相依结构敏感, 过短无法保留自相关、过长则重抽样多样性下降, 需结合实证数据的自相关时长经验性选择。

预期成果包括四个层面。理论层面: 建立信号方差解释比 R_{sig}^2 的良定义性、与传统 R_{all}^2 的等价边界、在弱相依条件下的渐近性质。方法层面: 给出三阶段筛选流水线的完整算法、参数推荐 (检验阶数、FDR 水平、窗口长度、块长、Bootstrap 次数) 与适用边界。实证层面: 在 H&M 全 31,788,324 行交易数据上完成完整跑通, 产出 21 个分组变量的 μ_k 、 CV_k 、 p_k 、95% BCa CI 完整结果表, 并以圣诞促销与 COVID 封锁两个外部冲击案例做实战归因对比。可复用层面: 整理成可复用的 Python 流水线代码, 在新数据集上 3 个月数据即可输出该业务核心分组变量清单。

6、研究范围与目前进展情况 (章节安排)

本文的研究范围限定在已知分组变量水平定义的横截面电商交易数据, 重点研究 DTU 这一交易量类指标的结构化下钻分组变量筛选; 不涉及连续型协变量、未观测异质性建模与因果推断中的反事实估计。处理对象为日级粒度的子序列; 周内/月内细粒度时序结构作为辅助参考, 不进入主筛选目标。

目前研究进展: 已完成 H&M 公开数据全量预处理 (31,788,324 条交易、734 天) 与 21 个分组变量的候选清单确认; 已实现三阶段筛选流水线的完整 Python 代码, 并在 $W=84$ 个窗口 (三种切窗模式) 上完成首轮实证, 得到 21 个分组变量的 μ_k 、 CV_k 、 p_k 、95% BCa CI 结果 (详见下节预实验结果)。后续工作主要集中在: 统一长短窗体系下的检验功效校准、扩充至 $W1/W2$ 长窗方案、增加圣诞促销与 COVID 封锁两个案例的归因对比、完善理论部分关于 R_{sig}^2 边界与渐近性质的证明。

论文拟分为六章。第一章为绪论、问题设定与贡献定位, 主要说明业务背景、核心问题、相关文献和本文贡献。第二章为白噪声假设检验框架与子序列分解理论, 建立信号方差解释比的数学定义、良定义性与基本性质。第三章为三阶段筛选流水线, 完整给出阶段一白噪声检验、阶段二方差分解、阶段三 Bootstrap 稳定性量化的算法细节。第四章为 H&M 数据实证分析, 包括 R_{sig}^2 排序、跨窗口稳定性、Bootstrap 选择概率、负对照验证与圣诞/COVID 案例归因。第五章为基线对比与方法增益验证, 与简单方差占比、Cramér's V 、XGBoost gain 三条基线做完整对比。第六章为结论与展望, 总结主要结论、讨论方法适用边界、对新业务冷启动场景的可复用性、对高阶时序结构与高维分组变量的扩展方向进行展望。

预实验结果 (H&M 数据初步实证)

按上述方法论在 H&M 全 31,788,324 条交易、734 天数据上完成首轮实证, 采用月环比 ($W1$: 30 vs 前 30 天步长 30 天)、滚动窗 ($W2$: 30 vs 前 30 天步长 14 天)、季度窗 ($W3$: 90 vs 前 90 天步长 30 天) 三种短窗体系合计 $W = 84$ 个窗口; Block Bootstrap $B = 1000$ 、块长 $L = 4$ 。下表给出 21 个分

组变量按 μ_k 排序的核心结果。

#	分组变量	族	r_k	$\mu_k \pm \sigma_k$	CV_k	p_k	95% BCa CI
1	星期	F1 时间衍生	7	5.351 ± 5.878	1.099	0.003	[4.184, 6.695]
2	是否周末	F1 时间衍生	2	4.485 ± 4.683	1.044	0.006	[3.569, 5.397]
3	年	F1 时间衍生	3	1.158 ± 0.591	0.510	1.000	[1.053, 1.300]
4	季节	F1 时间衍生	4	1.000 ± 0.000	0.000	1.000	[1.000, 1.000]
5	月	F1 时间衍生	12	1.000 ± 0.000	0.000	1.000	[1.000, 1.000]
6	会员状态	F3 用户画像	4	0.687 ± 0.463	0.673	0.881	[0.592, 0.771]
7	品类	F4 商品层级	130	0.603 ± 0.312	0.517	1.000	[0.529, 0.667]
8	部门	F4 商品层级	250	0.577 ± 0.298	0.516	1.000	[0.510, 0.645]
9	品类组	F4 商品层级	19	0.537 ± 0.341	0.635	0.978	[0.452, 0.599]
10	时尚资讯频率	F3 用户画像	4	0.524 ± 0.419	0.799	0.509	[0.440, 0.599]
11	销售渠道	F2 交易渠道	2	0.441 ± 0.290	0.658	0.047	[0.377, 0.499]
12	区块	F4 商品层级	56	0.436 ± 0.284	0.652	0.009	[0.365, 0.498]
13	图形外观	F5 商品属性	30	0.404 ± 0.360	0.893	0.003	[0.324, 0.477]
14	指数子类	F4 商品层级	10	0.346 ± 0.312	0.904	0.000	[0.287, 0.419]
15	服装组	F4 商品层级	21	0.303 ± 0.179	0.590	0.000	[0.271, 0.341]
16	颜色组	F5 商品属性	50	0.297 ± 0.252	0.848	0.000	[0.243, 0.354]
17	指数组	F4 商品层级	5	0.295 ± 0.314	1.062	0.000	[0.234, 0.355]
18	颜色主色	F5 商品属性	20	0.291 ± 0.204	0.700	0.000	[0.244, 0.332]
19	年龄分段	F3 用户画像	6	0.280 ± 0.146	0.522	0.000	[0.245, 0.313]
20	颜色明度	F5 商品属性	8	0.260 ± 0.210	0.810	0.000	[0.215, 0.308]
21	价格区间	F2 交易渠道	5	0.228 ± 0.232	1.017	0.000	[0.183, 0.284]

秩稳定性与负对照:84 个窗口前后两半 Spearman $\rho = 0.974$ 、Kendall $\tau \approx 0.89$, 排序高度稳定。颜色族 (颜色组、颜色明度、颜色主色、图形外观) 四项 $\mu_k \in [0.26, 0.30]$ 且 $p_k = 0$, 符合"白噪声噪音族"预期; 星期与是否周末 μ_k 因结构对立致 > 1 , 但 $CV > 1$ 且 $p_k \leq 0.006$, 被 Bootstrap 稳定性筛子准确剔除, 验证 p_k 准则对"高均值但不稳定"假阳性的有效抑制。

综合筛选: 三方案交叉验证——A($R_{\text{sig}}^2 > Q_3 = 0.687$)5 个; B($p_k \geq 0.5$)8 个; C(综合折中)8 个; 最终取方案 C 中 μ_k 排名前 5 得

$$S_{\text{final}} = \{\text{会员状态, 品类, 部门, 年, 季节}\}.$$

族分布为 F4 商品层级 2 项、F1 时间衍生 2 项、F3 用户画像 1 项; F2 交易渠道与 F5 商品属性均无入选。该结构与业务直觉一致。

7、 论文写作进度时间安排

时间安排	主要任务
2026 年 6 月	完成开题报告与开题汇报材料, 围绕导师与专家组意见进一步凝练研究问题、文献综述与方法框架, 修订开题报告与 PPT。
2026 年 7 月 -8 月	完善第二章白噪声检验框架与子序列分解理论部分, 补全 R_{sig}^2 的良好定义性证明与弱相依条件下的渐近性质, 统一全文符号体系。
2026 年 9 月	完成第三章三阶段筛选流水线完整算法描述, 包括检验阶数、FDR 水平、窗口长度、块长、Bootstrap 次数等参数推荐与适用边界。
2026 年 10 月	完成第四章 H&M 实证分析章节, 从首轮预实验扩展至 W1/W2 长窗方案, 增加圣诞促销与 COVID 封锁两个外部冲击案例的归因对比。
2026 年 11 月	完成第五章基线对比章节, 与简单方差占比、Cramér's V 、XGBoost gain 完整对比; 启动第六章结论与展望撰写, 讨论新业务冷启动场景的可复用性。
2026 年 12 月 -2027 年 1 月	完成论文全文整合与集中修改, 重点检查章节逻辑、证明细节、公式编号、图表编号、参考文献格式与正文-附录一致性; 依据预答辩意见做最终修订并完成定稿、查重与答辩准备。

8、 查阅主要文献 (作者姓名/出版年份/文章标题或书名/卷或页/期刊号或出版社)

[1] LJUNG G M, BOX G E P. On a Measure of Lack of Fit in Time Series Models [J]. *Biometrika*, 1978, 65(2): 297–303. [Ljung & Box (1978)]

[2] MCLEOD A I, LI W K. Diagnostic Checking ARMA Time Series Models Using Squared-Residual Autocorrelations [J]. *Journal of Time Series Analysis*, 1983, 4(4): 269–273. [McLeod & Li (1983)]

[3] ENGLE R F. Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation [J]. *Econometrica*, 1982, 50(4): 987–1007. [Engle (1982)]

[4] BENJAMINI Y, HOCHBERG Y. Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing [J]. *Journal of the Royal Statistical Society, Series B*, 1995, 57(1): 289–300. [Benjamini & Hochberg (1995)]

[5] BENJAMINI Y, YEKUTIELI D. The Control of the False Discovery Rate in Multiple Testing under Dependency [J]. *The Annals of Statistics*, 2001, 29(4): 1165–1188. [Benjamini & Yekutieli (2001)]

[6] KÜNSCH H R. The Jackknife and the Bootstrap for General Stationary Observations [J]. *The Annals of Statistics*, 1989, 17(3): 1217–1241. [Künsch (1989)]

[7] LAHIRI S N. *Resampling Methods for Dependent Data* [M]. New York: Springer Series in Statistics, Springer-Verlag, 2003. [Lahiri (2003)]

[8] EFRON B. Better Bootstrap Confidence Intervals [J]. *Journal of the American Statistical Association*, 1987, 82(397): 171–185. [Efron (1987)]

[9] MEINSHAUSEN N, BÜHLMANN P. Stability Selection [J]. *Journal of the Royal Statistical Society, Series B*, 2010, 72(4): 417–473. [Meinshausen & Bühlmann (2010)]

- [10] CRAMÉR H. *Mathematical Methods of Statistics* [M]. Princeton: Princeton University Press, 1946. [[Cramér \(1946\)](#)]
- [11] CHEN T, GUESTRIN C. XGBoost: A Scalable Tree Boosting System [C] // *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. San Francisco: ACM, 2016: 785–794. [[Chen & Guestrin \(2016\)](#)]
- [12] H&M GROUP, KAGGLE. H&M Personalized Fashion Recommendations [Z]. Kaggle Competition Dataset, 2022. [[H&M Personalized Fashion Recommendations](#)]