

上海财经大学  
研究生申请学位论文开题报告表

|      |            |           |           |
|------|------------|-----------|-----------|
| 姓名   | 吴优         | 学院        | 统计与数据科学学院 |
| 学号   | 2025213385 | 导师姓名      | 张吕欧       |
| 专业   | 应用统计       | 培养层次      | 专业硕士      |
| 同意开题 |            | 导师签字: 张吕欧 |           |

|                       |                                                                             |
|-----------------------|-----------------------------------------------------------------------------|
| 论文题目                  | 基于去随机化 Model-X Knockoff 的电商 GMV 多粒度受控维度选择研究                                 |
| 开题时间                  | 开题地点:                                                                       |
| 与会专家姓名、<br>单位 (3-5 人) |                                                                             |
| 开题报告情况                | 专家主要意见:                                                                     |
| 开题结果 (划<br>圈)         | 开题通过, 同意进入论文写作阶段。 / 开题未通过, 不同意进入论文写作阶段。<br>开题报告会专家组组长签名:<br><br>导师签名: 年 月 日 |

注: 填写本表 1 份, 申请开题须经导师签字同意; 开题结果由开题报告会专家组组长及导师签署并签字; 交研究生秘书进入教学管理信息系统录入开题结果。附: 上海财经大学研究生学位论文开题报告书 (见下页), 打印 3-5 份交学院安排开题。

# 上海财经大学

## 研究生学位论文开题报告书

论文题目：基于去随机化 **Model-X Knockoff** 的  
电商 **GMV** 多粒度受控维度选择研究

姓 名： 吴优

学 号： 2025213385

院系所： 统计与数据科学学院

专 业： 应用统计

培养层次： 专业硕士

导师姓名： 张吕欧

二〇二六年九月

# 1、选题背景、研究问题、理论意义与实用价值

电商平台能够连续记录获客、下单、支付、发货、送达和评价等经营过程。企业通常以 GMV 作为核心经营指标，并围绕交易规模、价格成本、供给、支付、履约、口碑、地域和营销建立多维监控看板。随着业务发展，指标数量持续增加，订单数、件数和顾客数等高度相关变量容易重复表达同一经营状态，管理者难以在有限时间内判断哪些维度真正具有独立信息。若使用边际相关或逐项显著性检验筛选指标，还会因多重比较累积假阳性；若仅依赖 XGBoost 等机器学习重要性，则只能得到相对排序，无法控制入选集合的误选比例。

本文拟研究的核心问题是：给定卖家在当前周期的 31 项经营维度，哪些变量在控制其余候选信息后，仍包含下一周期 GMV 的增量预测信息，并值得进入持续监控体系。月度主分析的条件零假设为

$$H_{0j} : Y_{s,t+1} \perp X_{j,s,t} \mid X_{-j,s,t},$$

其中  $Y_{s,t+1}$  为卖家  $s$  次月的  $\log(1 + \text{GMV})$ ， $X_{j,s,t}$  为本月第  $j$  项候选维度。拒绝该假设表示变量具有条件预测信息，但不表示主动改变该变量必然改变 GMV。

理论上，本文把经营看板选维转化为 Model-X Knockoff 框架下的多重检验问题，以仿制变量作为负对照，并通过多轮 e-value 聚合控制目标错误发现率。研究同时讨论面板组内相关、共线业务组、非高斯联合分布和时间聚合粒度对选择结果的影响。

实践上，研究将统计确认与页面展示分开。统计程序先形成可控误选的确认真集合，再由参数  $K$  确定首页展示 4 项、8 项、10 项或完整集合。月度分析负责稳定确认，周度分析负责短期预警和粒度复核，从而为指标准入、下钻和退出提供可复核依据。

据此，本文的研究设计由数据基础、统计推断、展示决策和稳健性评价四个层面构成。数据层面按照各业务表的自然粒度先聚合后连接，构建金额可对账、主键不重复的卖家面板；推断层面在 31 项混合且高度相关的候选变量中实施错误发现率受控选择；展示层面在不改变确认真集合的前提下，通过参数  $K$  形成不同容量的指标方案；稳健性层面则从周度粒度、卖家间与卖家内变化、业务组竞争以及非线性模型等角度检验结论边界。

在此基础上，本文进一步设置统一信息窗口、变量预算、预测器和测试期，将主方法与标准筛选基线进行比较，并通过边际变换、 $S$  矩阵、竞争统计量和重复次数消融识别各组件对最终结果的影响。该设计使数据处理、统计发现、业务展示和方法评价形成连续且可复核的研究链条。

## 2、国内外研究现状与发展趋势

Benjamini 和 Hochberg 提出错误发现率控制方法，使多重检验能够在保留发现能力的同时约束错误发现比例 [1]。Barber 和 Candès 提出 Knockoff 过滤器，Candès 等将其扩展到 Model-X 设定，通过构造与真实变量成对可交换的仿制变量实现受控变量选择 [2, 3]。与 Lasso 等以预测误差为目标的稀疏估计不同，Knockoff 直接针对发现集合的错误比例。

Knockoff 生成具有随机性。Ren 和 Barber 将单轮结果表示为 e-value，并通过 e-BH 聚合多轮 Knockoff，从而降低随机种子对最终集合的影响 [5]。Wang 和 Ramdas 证明 e-BH 可在任意依赖的 e-values 下控制 FDR [6]。Spector 和 Janson 提出最小可重构性准则，以改善相关变量场景下的功效 [9]。对于共线变量，Dai 和 Barber 给出 Group Knockoff，使统计竞争从单列扩展到预定义业务组 [12]。

复杂非高斯数据推动了深度 Knockoff 研究。Romano 等使用深度生成网络逼近可交换联合分布 [11]。然而，边际分布接近并不足以保证联合交换性。Liu 等提出的深度核两样本检验能够提高高维分布差异的检测能力 [13]，适合用作生成器准入诊断。本文据此将深度模型的生成能力与统计有效性分开评价。

机器学习方法常用于销售预测和特征排序。Lasso 和 Elastic Net 提供稀疏基线 [14, 15]，随机森林和梯度提升能够表达非线性 [16, 17]，XGBoost 进一步提供适合大规模稀疏表格数据的实现 [18]。TreeSHAP 可以一致地分解树模型预测贡献 [19, 20]。但机器学习重要性不等于条件独立检验，也不提供因果效应。面板固定效应能够控制卖家不随时间变化的异质性 [21]，仍可能受到未观测时变混杂影响。

现有方法分别覆盖多重检验、预测、解释或面板建模，但较少将受控发现、随机稳定性、可调展示数量和月周粒度复核纳入同一经营指标治理流程。应用研究还常在不同时间窗口或不同入选数量下比较方法，导致性能差异与变量预算差异混杂。本文拟在该交叉问题上形成统一信息窗口、统一变量预算、统一预测器和统一测试期的完整实证框架。

### 3、数据来源、变量与研究设计

#### 3.1 原始数据与连接原则

本文使用 Olist 公开的订单、商品明细、支付、评价、商品、卖家、顾客、地理和营销漏斗数据。支付和评价先聚合至订单级，地理数据按邮编前缀聚合，再与商品明细连接，以避免多对多连接造成 GMV 膨胀。独立顾客数使用跨订单唯一顾客标识计算。

月度面板包含 14,677 个卖家-月、2,793 个卖家和 19 个月，下一月零成交率为 25.86%；周度面板包含 33,190 个卖家-周、2,834 个卖家和 83 周，下一周零成交率为 40.46%。32 项候选维度中，申报月收入对数因零方差排除，31 项进入模型。

| 分析口径  | 面板行数   | 卖家数   | 期间数   | 下一期零值率 |
|-------|--------|-------|-------|--------|
| 月度主分析 | 14,677 | 2,793 | 19 个月 | 25.86% |
| 周度稳健性 | 33,190 | 2,834 | 83 周  | 40.46% |

#### 3.2 候选维度与业务概念

| 业务概念   | 列数 | 主要变量                |
|--------|----|---------------------|
| 价格成本   | 2  | 平均商品价格、平均运费         |
| 商品物理属性 | 4  | 重量、长度、高度、宽度         |
| 商品内容   | 3  | 图片数、标题长度、描述长度       |
| 支付与口碑  | 7  | 分期、序列、四种支付方式占比、评价得分 |
| 履约     | 4  | 送达、审核、承运、预计偏差       |
| 交易规模   | 4  | 件数、订单数、品类数、独立顾客数    |
| 市场覆盖   | 4  | 买家州数、最大州占比、跨州占比、距离  |
| 卖家与营销  | 3  | 卖家州频率、营销来源频率、成交线索匹配 |

#### 3.3 目标、时间切分与评价

月度目标为  $Y_{s,t+1} = \log(1 + \text{GMV}_{s,t+1})$ ，周度目标相应替换为下一周。若卖家当前期活跃而下一期无成交，则目标标记为零。月度预测使用 2017 年训练、2018 年 1–4 月验证、2018 年 5–7 月测试；周度使用相同自然时间边界。主要评价指标为

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad \text{WAPE} = \frac{\sum_i |g_i - \hat{g}_i|}{\sum_i g_i}.$$

## 4、核心统计方法

### 4.1 随机化秩高斯与二阶 Knockoff

首先对连续变量进行分位缩尾、偏态变换、中位数插补和标准化，再使用随机化秩高斯变换处理并列值：

$$Z_{ij} = \Phi^{-1} \left( \frac{r_{ij} - 0.5}{n} \right).$$

设  $\widehat{\Sigma}$  为 Ledoit-Wolf 收缩协方差。仿制变量需要满足

$$(X, \tilde{X})_{\text{swap}(S)} \stackrel{d}{=} (X, \tilde{X}), \quad \tilde{X} \perp Y \mid X.$$

在潜在高斯空间中，按 MVR 准则确定对角矩阵  $S$ ，条件采样分布为

$$\tilde{Z} \mid Z \sim \mathcal{N} \left( Z - Z\widehat{\Sigma}^{-1}S, 2S - S\widehat{\Sigma}^{-1}S \right).$$

### 4.2 Lasso 竞争统计量与 Knockoff+

将  $[Z, \tilde{Z}]$  共同输入 Lasso，构造反对称统计量

$$W_j = |\hat{\beta}_j| - |\hat{\beta}_{j+p}|.$$

Knockoff+ 阈值为

$$T(q) = \min \left\{ t > 0 : \frac{1 + \#\{j : W_j \leq -t\}}{\#\{j : W_j \geq t\} \vee 1} \leq q \right\}, \quad \hat{S} = \{j : W_j \geq T(q)\}.$$

若真实变量持续胜过对应仿制变量，则  $W_j$  倾向于为正；负向统计量用于估计正向发现中的错误数量。

### 4.3 去随机化 e-value

主分析独立生成  $M = 60$  组 Knockoff。第  $m$  轮变量  $j$  的 e-value 定义为

$$e_j^{(m)} = p \frac{\mathbf{1}\{W_j^{(m)} \geq T^{(m)}\}}{1 + \sum_{k=1}^p \mathbf{1}\{W_k^{(m)} \leq -T^{(m)}\}}, \quad \bar{e}_j = \frac{1}{M} \sum_{m=1}^M e_j^{(m)}.$$

本文以  $\alpha_{\text{kn}} = 0.10$  形成单轮 e-value，并在最终  $\alpha_{\text{eBH}} = 0.20$  下实施 e-BH。将  $\bar{e}_j$  从大到小排列，取满足

$$\bar{e}_{(k)} \geq \frac{p}{\alpha_{\text{eBH}} k}$$

的最大  $k$  形成正式确认集合。单轮频率只作为随机稳定性描述。

## 5、参数化展示与稳健性分支

### 5.1 参数 $K$

确认集合  $S_{\text{FDR}}$  固定后，使用训练期 XGBoost 和验证集 TreeSHAP 得到排序  $\pi$ ：

$$S(K) = \{\pi_1, \dots, \pi_K\}, \quad K^* = \min \{K : C_K \geq 90\%, \text{RMSE}_K \leq 1.005 \text{RMSE}_{\min}\}.$$

$K$  仅改变页面展示长度，不重新计算 FDR。

### 5.2 卖家间/内与业务组

面板结构按

$$X_{s,t} = \bar{X}_s + (X_{s,t} - \bar{X}_s)$$

拆分为卖家间长期位置与卖家内短期离差。31 项变量另划为 12 个业务组，组级统计量定义为

$$W_g = \|\hat{\beta}_g\|_2 - \|\hat{\beta}_{\bar{g}}\|_2.$$

### 5.3 深度联合诊断与非线性重要性

深度生成器使用多比例 swap-MMD、边际、协方差、交叉对称和可重构性损失。有效性由边际 KS、协方差误差、深度核 MMD 和分类器两样本检验共同决定。未通过联合交换性诊断的生成器不进入 FDR 结论。非线性重要性使用配对竞争 MLP，并在二维正则路径上累计真实与仿制入口活跃度之差。

### 5.4 预测与解释

预测模型包括 Ridge、Lasso、Extra Trees、XGBoost 和 MLP。测试集不参与参数选择。TreeSHAP 用于确认集合内部排序；双向固定效应控制卖家和周期效应，标准误按卖家聚类。两者均为预测或条件关联证据，不解释为因果效应。

## 5.5 基准比较、组件消融与模拟

所有方法只使用 2018 年 4 月及以前数据选维，以 12 项为统一变量预算，再将各自集合输入相同参数的 XGBoost，在 2018 年 5–7 月测试。比较去随机化 Knockoff、Elastic Net、稳定性选择、影子变量树模型与 XGBoost-SHAP。集合稳定性采用 30 组配对的卖家子样本：每组对五种方法使用完全相同的 70% 卖家并保留其全部月份，在子样本内完整重算 Top-12，Knockoff 每组聚合 60 轮；以子样本 Top-12 与各方法全样本 Top-12 的 Jaccard 均值及 95% 置信区间评价。组件消融分别替换 Copula 边际、MVR/SDP/等相关  $S$  矩阵、Lasso/XGBoost 统计量以及  $M = 1, 5, 10, 20, 40, 60$  轮聚合。已知真值模拟从真实特征矩阵抽取 4,000 行、设置 10 个真信号并重复 20 次，报告 FDP、FDP 超过 0.20 的概率、Power 与发现数。

## 6、月度确认性预分析结果

Copula-MVR 的平均边际 KS 为 0.013，原始高斯为 0.200，因此后续确认性分析拟继续采用 Copula-MVR。当前预分析在最终 e-BH 目标水平 0.20 下入选 14 项；其中 10 项单轮频率不低于 90%。

| 排序 | 维度         | 平均 $W$ | 单轮频率  | 平均 e-value |
|----|------------|--------|-------|------------|
| 1  | 成交订单数      | 0.144  | 95.0% | 28.675     |
| 2  | 平均商品价格     | 0.142  | 95.0% | 28.675     |
| 3  | 独立顾客数      | 0.140  | 95.0% | 28.675     |
| 4  | 成交件数       | 0.117  | 95.0% | 28.675     |
| 5  | 买家州数量      | 0.097  | 95.0% | 28.675     |
| 6  | 平均审核至承运天数  | 0.053  | 95.0% | 28.675     |
| 7  | 平均运费       | 0.027  | 95.0% | 28.675     |
| 8  | 活跃品类数      | 0.023  | 95.0% | 28.675     |
| 9  | 平均预计提前送达天数 | 0.021  | 95.0% | 28.675     |
| 10 | 平均商品标题长度   | 0.022  | 91.7% | 27.642     |
| 11 | 平均商品高度     | 0.013  | 80.0% | 24.025     |
| 12 | 卖家所在州频率    | 0.014  | 76.7% | 22.992     |
| 13 | 平均商品描述长度   | 0.009  | 50.0% | 14.725     |
| 14 | 平均下单至送达天数  | 0.007  | 41.7% | 12.142     |

在  $q = 0.10$  时严格集合为空， $q = 0.20$  和  $q = 0.30$  均为 14 项。该跳跃来自  $p = 31$  时 Knockoff+ 阈值的离散性，因此本文不通过事后调整  $q$  来获得任意长度列表。

## 7、参数 $K$ 与时间外预测初步结果

| 档位    | $K$ | 累计贡献   | 验证 RMSE | 测试 RMSE |
|-------|-----|--------|---------|---------|
| 极简    | 4   | 72.1%  | 2.335   | 2.388   |
| 均衡    | 8   | 87.1%  | 2.341   | 2.389   |
| 默认推荐  | 10  | 92.6%  | 2.343   | 2.385   |
| 完整确认集 | 14  | 100.0% | 2.343   | 2.384   |

默认  $K = 10$  包括独立顾客数、成交订单数、平均商品价格、平均审核至承运天数、平均预计提前送达天数、买家州数量、平均下单至送达天数、成交件数、平均运费和平均商品标题长度。

| 模型             | RMSE(log) | MAE(log) | $R^2$  | WAPE  |
|----------------|-----------|----------|--------|-------|
| XGBoost        | 2.388     | 1.914    | 0.291  | 67.2% |
| Ridge          | 2.389     | 1.949    | 0.291  | 73.1% |
| Lasso          | 2.389     | 1.949    | 0.290  | 73.1% |
| Extra Trees    | 2.390     | 1.914    | 0.290  | 65.9% |
| XGBoost (确认集合) | 2.391     | 1.914    | 0.289  | 67.2% |
| 残差 MLP         | 2.414     | 1.927    | 0.276  | 71.8% |
| MLP            | 2.429     | 1.947    | 0.267  | 74.5% |
| 本月 GMV 基线      | 2.895     | 1.981    | -0.042 | 79.2% |

最佳月度模型为 XGBoost，较朴素基线 RMSE 改善 17.5%。默认  $K = 10$  的测试 RMSE 为 2.385，与全 31 维 XGBoost 基本一致，说明压缩展示数量未明显损失预测信息。MLP 和残差 MLP 未优于树模型，表明当前样本下模型复杂度本身不能保证泛化收益。

## 8、统一基准、组件消融与模拟初步结果

### 8.1 同预算真实数据基准

| 方法            | 与主集重合 | 配对稳定性 | 95% 区间         | 测试 RMSE |
|---------------|-------|-------|----------------|---------|
| 去随机化 Knockoff | 12    | 0.855 | [0.823, 0.887] | 2.392   |
| Elastic Net   | 10    | 0.873 | [0.845, 0.901] | 2.390   |
| 稳定性选择         | 10    | 0.814 | [0.779, 0.849] | 2.390   |
| 影子变量树模型       | 10    | 0.832 | [0.798, 0.867] | 2.387   |
| XGBoost-SHAP  | 8     | 0.686 | [0.645, 0.726] | 2.383   |

XGBoost-SHAP 取得最低 RMSE; Elastic Net 的配对卖家子抽样稳定性均值最高, 为 0.873, 去随机化 Knockoff 为 0.855。二者配对差异为  $-0.018$ , 95% 置信区间  $[-0.065, 0.028]$  包含 0, 不能认定两者稳定性存在明确差异。Knockoff 相对 XGBoost-SHAP 的稳定性差异为 0.169, 95% 置信区间为  $[0.120, 0.218]$ 。初步结果支持将预测精度、集合稳定性和错误率控制视为不同目标。

### 8.2 关键组件消融

| 消融维度   | 设定                 | 重复数 | 严格数 | 主集 Jaccard |
|--------|--------------------|-----|-----|------------|
| $S$ 矩阵 | MVR                | 30  | 16  | 0.875      |
| $S$ 矩阵 | SDP                | 30  | 16  | 0.765      |
| $S$ 矩阵 | 等相关                | 30  | 12  | 0.857      |
| 重复次数   | $M = 1$            | 1   | 12  | 0.857      |
| 重复次数   | $M = 10$           | 10  | 15  | 0.933      |
| 重复次数   | $M = 60$           | 60  | 14  | 1.000      |
| 边际     | 原始高斯-MVR-Lasso     | 40  | 12  | 0.733      |
| 统计量    | Copula-MVR-XGBoost | 25  | 0   | 0.000      |

严格发现数随重复次数并非单调变化, 只有 60 轮与正式 14 项集合完全一致。原始高斯边际、替代  $S$  矩阵和 XGBoost 竞争统计量均改变结果, 说明 Copula、MVR、Lasso 与多轮聚合在当前数据中分别承担可识别的统计职责。

### 8.3 已知真值模拟

| 方法            | 平均 FDP | FDP > 0.20 概率 | Power | 平均发现数 |
|---------------|--------|---------------|-------|-------|
| 去随机化 Knockoff | 0.054  | 10%           | 1.000 | 10.65 |
| 单次 Knockoff   | 0.145  | 35%           | 1.000 | 12.05 |
| Elastic Net   | 0.644  | 100%          | 1.000 | 28.15 |
| 稳定性选择         | 0.090  | 5%            | 1.000 | 11.05 |
| 影子变量树模型       | 0.566  | 100%          | 1.000 | 23.10 |

去随机化与单次 Knockoff 均保持全部真信号功效，但多轮聚合将平均 FDP 由 0.145 降至 0.054。Elastic Net 和影子变量树模型的高 Power 来自大量选择，平均 FDP 明显偏高。稳定性选择在该模拟中表现良好，是有竞争力的经验基线；但其阈值不提供与当前 Model-X 设定相同的有限样本 FDR 目标保证。20 轮模拟仅用于验证当前稀疏度与相关结构，不能建立普遍方法排名。

## 9、周度粒度与结构稳健性初步结果

周度分析在相同流程下入选 18 项，其中 13 项单轮频率不低于 90%。月度 14 项与周度 18 项共同入选 11 项，Jaccard 系数为 0.524。周度特有项主要涉及商品物理、支付结构和营销标记，应作为观察层而非直接升级为确认指标。

| 场景          | 重复数 | 严格数 | 与周度主集重合 |
|-------------|-----|-----|---------|
| 周度主分析       | 60  | 18  | 18      |
| 原始高斯生成      | 40  | 12  | 12      |
| 同周 GMV 对照   | 40  | 29  | 17      |
| 截尾时间窗       | 40  | 20  | 16      |
| 下一周客单价      | 40  | 15  | 15      |
| 测试期前样本      | 40  | 14  | 13      |
| XGBoost 统计量 | 25  | 16  | 15      |

| 周度模型           | RMSE(log) | MAE(log) | $R^2$  | WAPE   |
|----------------|-----------|----------|--------|--------|
| Extra Trees    | 2.416     | 2.146    | 0.254  | 78.0%  |
| XGBoost        | 2.420     | 2.160    | 0.251  | 79.6%  |
| XGBoost (18 项) | 2.421     | 2.157    | 0.251  | 79.2%  |
| Lasso          | 2.433     | 2.189    | 0.244  | 82.7%  |
| Ridge          | 2.434     | 2.185    | 0.243  | 82.8%  |
| MLP            | 2.443     | 2.167    | 0.238  | 81.0%  |
| 本周 GMV 基线      | 3.401     | 2.600    | -0.478 | 110.8% |

月度降低低频卖家的偶发噪声，适合作为确认性分析；周度提供更多时间点，但零膨胀和相关代理更强，适合作为短期预警和粒度复核。

## 10、生成器诊断、组级结果与负结果分析

| 生成器           | 平均 KS | 协方差误差 | 深度核拒绝率 | 分类 AUC |
|---------------|-------|-------|--------|--------|
| Copula-MVR    | 0.026 | 0.091 | 0%     | 0.777  |
| 基础深度生成器       | 0.018 | 0.166 | 100%   | 0.902  |
| 最坏 swap 深度生成器 | 0.019 | 0.188 | 100%   | 0.937  |

两类深度生成器虽然边际 KS 较小，但深度核 MMD 在所有交换比例下均拒绝，分类 AUC 显著高于 0.5，因此不作 FDR 声明。该负结果说明边际匹配不能替代联合交换性。

| 分支              | 月度   | 周度   | 解释              |
|-----------------|------|------|-----------------|
| 卖家间层 $q = .20$  | 16 项 | 12 项 | 长期卖家差异包含主要信号    |
| 卖家内层 $q = .20$  | 0 项  | 0 项  | 当前序列不足以支持严格动态发现 |
| 业务组 $q = .20$   | 0 组  | 10 组 | 周度组级信息更强        |
| 轨迹重要性 $q = .20$ | 0 项  | 0 项  | 主水平未恢复非线性发现     |

真实特征矩阵上的稀疏模拟中，去随机化 e-BH 平均 FDP 为 0、平均功效为 0；单轮 Knockoff+ 平均 FDP 为 0.197、功效为 1.000。低维且仅 5 个真信号时，聚合程序受到离散门槛限制。本文保留这一结果，作为方法功效边界而非删除不利证据。

## 11、研究创新点、后续验证与研究计划

### 11.1 研究创新点

本文面向电商平台核心指标周边维度数量多、相关代理重复和看板容量有限的问题，构建“受控确认—参数化展示—多粒度复核—比较诊断”的可实施维度选择流程。该流程以 Copula-MVR Model-X Knockoff、Lasso 反对称统计量、多轮 e-value 聚合和 e-BH 构成确认性主线，并将预测排序、稳健性检验和生成器诊断限定在各自的证据层级内。

研究创新主要体现在四个方面。第一，将多轮随机 Knockoff 转化为可聚合的 e-value 证据，使经营维度准入具有明确的目标错误率口径。第二，将统计确认集合与参数  $K$  控制的展示集合分离，使企业能够按页面容量选择指标数量，而不反向改变统计筛选标准。第三，将月度确认、周度复核、卖家间与卖家内分层、业务组竞争及交换性诊断组织为分层证据体系，对不满足准入条件的生成器设置明确否决规则。第四，在统一信息窗口、变量预算、预测器和测试期下比较标准方法，并结合组件消融与已知真值模拟评价预测性能、集合稳定性和错误发现质量。

上述创新形成了一套可迁移至 GMV、活跃用户数及其他核心经营指标的维度治理方法流：先确定具有增量预测信息的候选指标，再按业务容量形成分层展示，并通过跨粒度与滚动复核支持指标的准入、观察和退出。

### 11.2 已有基础、待验证结论与技术风险

现有计算作为开题阶段的可行性证据：月度程序得到 14 项候选确认集合，默认  $K = 10$  时预测性能基本保留；周度得到 18 项并与月度重合 11 项；30 组统一卖家子抽样、基准预测、模拟和生成器诊断均已形成可复核输出。这些结果证明研究流程可以实施。

仍待验证的结论：后续将严格隔离选维、调参与测试信息，进一步扩展模拟和滚动时间窗口，并检验 14 项集合及默认  $K$  对信号强度和经营阶段的敏感性。

主要技术风险：一是 Copula 仅近似混合变量的高阶联合分布；二是卖家面板存在组内相关，物流与评价字段还需按真实可见时间重构；三是 19 个月样本和当前模拟次数对阶段性结论的支持有限。后续分析将围绕交换性诊断、时间口径和滚动复核进行处理。

### 11.3 写作计划

2026 年 9–10 月完成字段可见时间重构与严格时间切分；11 月扩展不同信号强度、稀疏度及滚动窗口实验；12 月完成论文初稿和导师反馈修改；2027 年 1 月完成格式终检、查重与答辩材料。全文仍按七章结构组织，并坚持月度确认、周度稳健性的预设分工。

## 12、主要参考文献

- [1] Benjamini Y, Hochberg Y. Controlling the false discovery rate[J]. JRSS B, 1995, 57(1): 289–300.
- [2] Barber R F, Candès E J. Controlling the false discovery rate via knockoffs[J]. Annals of Statistics, 2015, 43(5): 2055–2085. DOI:10.1214/15-AOS1337.
- [3] Candès E, Fan Y, Janson L, Lv J. Panning for gold: Model-X knockoffs[J]. JRSS B, 2018, 80(3): 551–577. DOI:10.1111/rssb.12265.
- [4] Barber R F, Candès E J, Samworth R J. Robust inference with knockoffs[J]. Annals of Statistics, 2020, 48(3): 1409–1431. DOI:10.1214/19-AOS1852.
- [5] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for FDR control[J]. JRSS B, 2024, 86(1): 122–154.
- [6] Wang R, Ramdas A. False discovery rate control with e-values[J]. JRSS B, 2022, 84(3): 822–852. DOI:10.1111/rssb.12489.
- [7] Vovk V, Wang R. E-values: calibration, combination and applications[J]. Annals of Statistics, 2021, 49(3): 1736–1754.
- [8] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. Journal of Multivariate Analysis, 2004, 88(2): 365–411.
- [9] Spector A, Janson L. Powerful knockoffs via minimizing reconstructability[J]. Annals of Statistics, 2022, 50(1): 252–276.
- [10] Bates S, Candès E, Janson L, Wang W. Metropolized knockoff sampling[J]. JASA, 2021, 116(535): 1413–1427.
- [11] Romano Y, Sesia M, Candès E. Deep knockoffs[J]. JASA, 2020, 115(532): 1861–1872.
- [12] Dai R, Barber R F. The knockoff filter for FDR control in group-sparse regression[C]//ICML. 2016: 1851–1859.
- [13] Liu F, Xu W, Lu J, et al. Learning deep kernels for non-parametric two-sample tests[C]//ICML. 2020: 6316–6326.
- [14] Tibshirani R. Regression shrinkage and selection via the lasso[J]. JRSS B, 1996, 58(1): 267–288.
- [15] Zou H, Hastie T. Regularization and variable selection via the elastic net[J]. JRSS B, 2005, 67(2): 301–320.
- [16] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5–32.
- [17] Friedman J H. Greedy function approximation: a gradient boosting machine[J]. Annals of Statistics, 2001, 29(5): 1189–1232.
- [18] Chen T, Guestrin C. XGBoost: a scalable tree boosting system[C]//KDD. 2016: 785–794. DOI:10.1145/2939672.2939785.
- [19] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]//NeurIPS. 2017, 30.
- [20] Lundberg S M, Erion G, Chen H, et al. From local explanations to global understanding with explainable AI for trees[J]. Nature Machine Intelligence, 2020, 2: 56–67.
- [21] Wooldridge J M. Econometric analysis of cross section and panel data[M]. 2nd ed. MIT Press, 2010.
- [22] Little R J A, Rubin D B. Statistical analysis with missing data[M]. 3rd ed. Wiley, 2019.
- [23] Hyndman R J, Athanasopoulos G. Forecasting: principles and practice[M/OL]. 3rd ed. OTexts, 2021.
- [24] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle, 2018.
- [25] Olist. Marketing Funnel by Olist[DB/OL]. Kaggle, 2018.