

基于去随机化 Model-X Knockoff 的电商 GMV 多粒度受控维度选择研究

统一基准、组件消融与多粒度受控选择

汇报人：吴优 学号：2025213385

上海财经大学·统计与数据科学学院
指导教师：张吕欧

开题报告·2026 年 9 月



上海财经大学
Shanghai University of Finance & Economics

汇报提纲

- ① 研究背景
- ② 数据与设计
- ③ 研究方法
- ④ 预分析结果
- ⑤ 计划与产出
- ⑥ 参考文献

研究背景：经营看板的维度过载

现实问题

GMV 看板同时包含交易规模、价格成本、供给、支付、履约、口碑、地域和营销等大量指标。指标越多，越难判断哪些变量真正提供了独立信息。

常用做法

- 业务经验筛选
- 边际相关与逐项检验
- 树模型重要性排序

主要不足

- 高度相关代理重复入选
- 多重比较累积误报
- 重要性排序缺少错误比例控制

研究目标

在 31 项候选维度中筛选对下一期 GMV 具有增量预测信息的少数指标，并形成可调数量、可复核的监控集合。

研究问题与预期贡献

- ① 如何从多表交易数据构造不重复计算 GMV 的卖家面板?
- ② 如何在混合分布、高度相关变量中控制目标错误发现率?
- ③ 如何在确认集合内通过参数 K 控制最终展示数量?
- ④ 月度结论在周度、卖家内变化、业务组和非线性模型下是否稳定?
- ⑤ 与标准筛选方法相比，主流程的增量价值及各组件作用是什么?

预期贡献

构建“受控确认—公平比较—参数化展示—多粒度复核”的统一框架，严格区分预测精度、选择稳定性、错误率控制与因果结论。

相关研究与方法依据

受控变量选择

- BH 错误发现率控制 [1]
- Knockoff 过滤器 [2]
- Model-X Knockoff [3]
- 去随机化 Knockoff [4]
- e-BH 与 e-value [5]

生成、预测与解释

- MVR 最小可重构性 [6]
- Deep Knockoffs [7]
- 深度核两样本检验 [8]
- XGBoost [9]
- TreeSHAP [10]

研究空白

现有方法较少把受控发现、统一预算基准、组件消融、展示数量和月周粒度复核纳入同一经营指标治理流程。

Olist 数据与样本构造

实际读取 10 张 CSV

- 订单与商品明细
- 支付与评价
- 商品、卖家与顾客
- 地理位置
- 营销线索与成交线索

数据质量原则

- 自然粒度先聚合后连接
- GMV 与明细逐笔对账
- 独立顾客使用唯一顾客标识
- 排除一项零方差变量

口径	面板行	卖家	期间数	下一期零值率
月度主分析	14,677	2,793	19 个月	25.86%
周度稳健性	33,190	2,834	83 周	40.46%

31 项候选维度与前瞻目标

候选信息

- 价格成本：价格、运费
- 商品结构：尺寸、重量、图片、文本
- 支付口碑：分期、支付方式、评分
- 履约：审核、承运、送达、承诺偏差
- 规模覆盖：订单、件数、顾客、品类、地域
- 营销：来源频率、成交线索匹配

预测目标

$$Y_{s,t+1} = \log(1 + \text{GMV}_{s,t+1})$$

- 月度：本月预测次月
- 周度：本周预测下一周
- 下一期无成交时目标标记为 0
- 避免同周期 GMV 定义泄漏

统一方法框架

原始多表数据 → 自然粒度聚合 → 卖家面板 → Copula-MVR Knockoff → 60 轮 e-value → e-BH 确认集合 → 公平基准与参数 K

确认性主线

- 随机化秩高斯 Copula
- Ledoit-Wolf 协方差
- MVR 二阶 Knockoff
- Lasso 反对称统计量

补充验证

- 时间外机器学习预测
- TreeSHAP 与固定效应
- 卖家间/内与业务组
- 深度交换性诊断

Copula-MVR：从混合边际到有效负对照

秩高斯变换

$$Z_{ij} = \Phi^{-1} \left(\frac{r_{ij} - 0.5}{n} \right)$$

二阶条件生成

$$\tilde{Z} \mid Z \sim \mathcal{N} \left(Z - Z\hat{\Sigma}^{-1}S, 2S - S\hat{\Sigma}^{-1}S \right)$$

- $\hat{\Sigma}$: Ledoit-Wolf 收缩协方差
- S : 按 MVR 准则降低真变量与仿制变量可重构性
- 交换要求: $(X, \tilde{X})_{\text{swap}(A)} \stackrel{d}{=} (X, \tilde{X})$

解释边界

$H_{0j}: Y \perp X_j \mid X_{-j}$; 竞争统计量 $W_j = |\hat{\beta}_j| - |\hat{\beta}_{j+p}|$ 。拒绝零假设只表示条件预测信息。

e-value 聚合、e-BH 与参数 K

第 m 轮变量 j 的 e-value

$$e_j^{(m)} = p \frac{\mathbf{1}\{W_j^{(m)} \geq T^{(m)}\}}{1 + \sum_{k=1}^p \mathbf{1}\{W_k^{(m)} \leq -T^{(m)}\}}$$

$$\bar{e}_j = \frac{1}{60} \sum_{m=1}^{60} e_j^{(m)}, \quad \bar{e}_{(k)} \geq \frac{p}{\alpha_{\text{eBH}} k}$$

- 单轮 $\alpha_{\text{kn}} = 0.10$; 最终 $\alpha_{\text{eBH}} = 0.20$
- e-BH 承担正式 FDR 结论, 单轮频率只描述随机稳定性
- $K^* = \min\{K : C_K \geq 90\%, \text{RMSE}_K \leq 1.005 \text{RMSE}_{\min}\}$

稳健性与诊断体系

风险	方法	回答的问题
卖家内相关	均值—离差分层	信号来自跨卖家还是卖家自身变化?
共线代理	12 业务组 Knockoff	哪类业务信息整体有效?
非高斯联合分布	深度生成 + 深度核 MMD	生成器是否满足联合交换性?
非线性重要性	轨迹聚合配对 MLP	非线性竞争能否恢复信号?
粒度依赖	周度完整重跑	月度结论是否依赖聚合尺度?

基准比较与组件消融设计

公平比较协议

- 选维数据截至 2018 年 4 月
- 统一变量预算：12 项
- 统一预测器：同参数 XGBoost
- 统一测试期：2018 年 5–7 月
- 30 组相同的 70% 卖家子样本
- 比较 RMSE、配对 Jaccard 与集合重合

五种方法

- 去随机化 Knockoff、Elastic Net
- 稳定性选择、影子变量树、XGBoost-SHAP


组件消融

- 边际：Copula / 原始高斯
- S 矩阵：MVR / SDP / 等相关
- 统计量：Lasso / XGBoost
- 重复数： $M = 1, 5, 10, 20, 40, 60$

已知真值模拟

- 真实特征协方差， $n = 4000, p = 31$
- 10 个真信号，20 轮响应重复
- FDP、FDP 超标率、Power、发现数

月度确认性结果



$q = 0.20$ 确认 14 项

- 规模：订单数、件数、顾客数、品类数
- 价格：平均价格、平均运费
- 履约：承运、送达、预计偏差
- 内容与覆盖：标题、描述、高度、买家州、卖家州

高稳定项：10 项单轮频率 $\geq 90\%$

阈值现象

$q = 0.10$ 为 0 项、 $q = 0.20$ 为 14 项，说明低维 Knockoff+ 存在离散门槛。


参数 K 与月度预测

默认 $K = 10$

- ① 独立顾客数
- ② 成交订单数
- ③ 平均商品价格
- ④ 审核至承运天数
- ⑤ 预计提前送达天数
- ⑥ 买家州数量
- ⑦ 下单至送达天数
- ⑧ 成交件数
- ⑨ 平均运费
- ⑩ 商品标题长度

时间外结果

- 默认 $K = 10$: RMSE=2.385
- 全 31 维 XGBoost: RMSE=2.388
- 相对变化: -0.097%
- 维度压缩后性能基本保留



统一基准、消融与模拟结果

真实数据：相同 **12** 项预算

方法	RMSE	稳定性
去随机化 Knockoff	2.392	0.855
Elastic Net	2.390	0.873
稳定性选择	2.390	0.814
影子变量树	2.387	0.832
XGBoost-SHAP	2.383	0.686

解释

SHAP 预测略优；Elastic Net 与 Knockoff 稳定性区间重叠，Knockoff 另承担 FDR 解释。


20 轮模拟

方法	FDP	Power
去随机化 Knockoff	0.054	1.000
单次 Knockoff	0.145	1.000
Elastic Net	0.644	1.000
稳定性选择	0.090	1.000
影子变量树	0.566	1.000

消融结论

重复数从 1 到 60 时集合仍有波动；原始高斯、替代 S 矩阵和 XGBoost 统计量均改变结果。

周度稳健性结果



- 周度 $q = 0.20$ 入选 18 项
- 与月度共同入选 11 项
- Jaccard 系数为 0.524
- 周度高稳定项 13 项
- 周度 18 项 XGBoost RMSE=2.421
- 全 31 维 XGBoost RMSE=2.420

跨粒度核心

交易规模、平均价格与运费、承运准备、商品标题和区域覆盖在两种粒度下共同出现。

结构检验与负结果

分支	月度	周度	解释
卖家间层 $q = 0.20$	16 项	12 项	长期卖家差异包含主要信号
卖家内层 $q = 0.20$	0 项	0 项	短期动态证据不足
业务组 $q = 0.20$	0 组	10 组	周度组级信息更强
轨迹重要性 $q = 0.20$	0 项	0 项	主水平未恢复非线性发现

深度生成器准入

边际 KS 较小，但深度核 MMD 拒绝率 100%、分类器 AUC 为 0.902/0.937；因此不作 FDR 声明。

研究创新点与方法主线

- ① 单一确认主线：Copula-MVR、反对称 W 、e-value 与 e-BH 共同承担正式发现。
- ② 确认—展示分离：参数 K 只压缩确认池，不反向改变 FDR 阈值。
- ③ 分层证据：月度确认，周度、业务组、卖家间/内与深度诊断负责复核。
- ④ 明确否决：未通过交换性诊断的深度生成器不得用于 FDR 声明。
- ⑤ 公平评价：统一窗口、预算、预测器与测试期，并用消融和模拟解释组件作用。

后续研究计划

时间	工作内容
2026.09	完成研究设计、数据审计与预分析整理
2026.10	完善理论推导、模拟设计和稳健性讨论
2026.11	统一图表、核对文献与结果叙述
2026.12	完成论文初稿、导师反馈与结构修改
2027.01	完成格式终检、盲审稿与答辩材料

主要参考文献

- ① Benjamini & Hochberg. Controlling the false discovery rate. JRSS B, 1995.
- ② Barber & Candès. Controlling the false discovery rate via knockoffs. AoS, 2015.
- ③ Candès et al. Panning for gold: Model-X knockoffs. JRSS B, 2018.
- ④ Barber et al. Robust inference with knockoffs. AoS, 2020.
- ⑤ Ren & Barber. Derandomised knockoffs. JRSS B, 2024.
- ⑥ Wang & Ramdas. FDR control with e-values. JRSS B, 2022.
- ⑦ Vovk & Wang. E-values: calibration, combination and applications. AoS, 2021.
- ⑧ Ledoit & Wolf. A well-conditioned covariance estimator. JMA, 2004.
- ⑨ Spector & Janson. Powerful knockoffs via minimizing reconstructability. AoS, 2022.
- ⑩ Bates et al. Metropolized knockoff sampling. JASA, 2021.
- ⑪ Romano et al. Deep knockoffs. JASA, 2020.
- ⑫ Dai & Barber. Knockoff filter for group-sparse regression. ICML, 2016.
- ⑬ Liu et al. Learning deep kernels for two-sample tests. ICML, 2020.
- ⑭ Tibshirani. Regression shrinkage and selection via the Lasso. JRSS B, 1996.
- ⑮ Zou & Hastie. Regularization and variable selection via Elastic Net. JRSS B, 2005.
- ⑯ Breiman. Random forests. Machine Learning, 2001.
- ⑰ Friedman. Gradient boosting machine. AoS, 2001.
- ⑱ Chen & Guestrin. XGBoost. KDD, 2016.
- ⑲ Lundberg & Lee. A unified approach to interpreting predictions. NeurIPS, 2017.
- ⑳ Lundberg et al. Explainable AI for trees. Nature MI, 2020.
- ㉑ Wooldridge. Econometric Analysis of Cross Section and Panel Data. MIT, 2010.
- ㉒ Little & Rubin. Statistical Analysis with Missing Data. Wiley, 2019.
- ㉓ Hyndman & Athanasopoulos. Forecasting: Principles and Practice, 2021.
- ㉔ Olist. Brazilian E-Commerce Public Dataset. Kaggle, 2018.
- ㉕ Olist. Marketing Funnel Dataset. Kaggle, 2018.