



学校代码: 10272

学 号: 2025213385

上海财经大学

SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS

硕 士 学 位 论 文

MASTER DISSERTATION

(专 业 硕 士)

论文题目: 面向电商经营指标筛选的
非线性方法与交换对称损失研究

培养院系: 统计与数据科学学院

论文类别: 应用统计硕士专业学位论文

论文作者: 吴优

指导教师: 张吕欧

完成日期: 2026 年 9 月

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本人的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：

日期： 年 月 日

学位论文版权使用授权书

(硕士学位论文用)

本人完全了解上海财经大学关于收集、保存、使用学位论文的规定，即：按照有关要求提交学位论文的印刷本和电子版本。上海财经大学有权保留并向国家有关部门或机构送交本论文的复印件和扫描件，允许论文被查阅和借阅。本人授权上海财经大学可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

论文作者签名：

导师签名：

日期： 年 月 日

日期： 年 月 日

摘 要

电商经营看板的指标选择需要同时考虑预测信息保留、名单维护成本与错误发现风险。相关指标之间的替代、响应的非线性和假变量生成失配，使“预测准确”“名单稳定”和“统计上可确认”成为不同问题。本文以卖家下一自然月签收确认商品金额为目标，在统一业务口径和评价条件下研究非线性特征选择，并构造固定预测器上的交换对称成对损失统计量。

研究使用 Olist 十张原始表，按月末已发生事件构建 13,754 个卖家月观测、2,723 名卖家和 31 项指标。基础比较覆盖稀疏回归、重抽样、树模型、Deep Lasso、TabM 与 VTFS 适配；机制实验进一步研究预测 Jacobian 正则、预算门、动态输入剪枝和固定容量序列损失。所有主比较共享卖家抽样，区分 30 组互补半样本、70% 及 80% 抽样和固定数据随机种子变化；下游预测使用共同 XGBoost 与 TabM，相同集合采用规范列顺序并共享预测。

交换对称损失通过不依赖真假命名的背景比较每个特征与 Knockoff 的预测损失。本文给出其完整符号翻转性质，并说明随机背景在精确生成器下的边际分布性质。800 份八场景模拟区分精确生成、全无效和错设条件；另外依据 Semi-knockoffs 的双侧条件重建思路，检验条件均值与条件尺度扩展。理论说明仅涉及统计量性质及已有定理的条件调用，不将估计生成器、估计条件矩或面板数据直接视为有限样本 FDR 受控。

实测没有显示复杂方法全面领先。基础规范 Top-12 比较中，XGBoost-SHAP 与 Deep Lasso 的 XGBoost 评价 RMSE 分别为 1.8466 与 1.8450；Jacobian 版本的半样本 Jaccard 为 0.8618，但其优势未同时覆盖互补稳定性和模拟发现质量。SCPL 预定标准化 TabM 版本在强非线性与纯交互场景的 Power 分别为 0.794 与 0.934，匹配线性对照分别为 0.087 与 0.003；未标准化版本却往往更强，高相关线性场景也存在明显反例。真实数据主生成器下 SCPL 表现较弱；事后 MVR 诊断改善预测但未形成稳定性优势。

条件矩补充中, 预定 TabM 均值尺度版本的真实 Top-12 RMSE 为 1.8965, 半样本 Jaccard 为 0.4099; 强非线性原生 Power 为 0.8660, 平均 FDP 为 0.1313。这些结果仍需结合估计条件重建的误选风险解释, 不将局部检出增加直接写为有效错误控制。

研究结论支持将预测器能力、评分对称性、生成器有效性和业务适用性分开检验。本文形成了可复核的方法研究原型与负结果证据, 但不主张新颖性优先权已经确立、真实 FDR 已经受控或任何方法无条件最优。

关键词: 电商经营指标; 非线性特征选择; 交换对称损失; 样本稳定性; 错误发现率

Abstract

Selecting indicators for e-commerce monitoring requires a balance between predictive information, selection stability, and false discovery risk. This study investigates nonlinear feature selection for next-month delivered merchandise value and develops swap-canonical paired loss statistics for independently trained predictors.

Ten Olist tables are aggregated with event-time restrictions into 13,754 seller-month observations, 2,723 sellers, and 31 candidate indicators. Statistical and tree baselines are compared with Deep Lasso, TabM permutation ranking, and a documented VTFS adaptation. Mechanism studies examine Jacobian regularization, budget gates, dynamic pruning, and fixed-cardinality sequence losses. Shared seller samples and canonical feature ordering separate predictor quality from selection quality.

The proposed loss statistic compares original and knockoff coordinates against backgrounds invariant to pair swapping. A pathwise sign-flip proposition and an oracle marginal-distribution argument are provided. Eight simulation scenarios with 100 repetitions each include nonlinear responses, pure interactions, global nulls, and generator misspecification. A supplementary study evaluates conditional-mean and conditional-scale adaptations of Semi-knockoffs on the same simulation datasets.

Complexity does not yield consistent improvement. The prespecified studentized TabM statistic has power 0.794 under strong nonlinearity and 0.934 under pure interactions, versus 0.087 and 0.003 for a matched linear predictor. Nevertheless, unstudentized variants often perform better, and highly correlated linear settings favor linear methods. Real-data generator diagnostics reveal substantial

mismatch; a post hoc MVR extension improves prediction but does not establish superior sample stability. Estimated nuisance functions and repeated seller observations do not inherit oracle finite-sample guarantees automatically.

The prespecified conditional-mean-and-scale TabM adaptation achieves power 0.8660 and mean FDP 0.1313 in the strongly nonlinear scenario. However, its real-data Top-12 RMSE is 1.8965 with half-sample Jaccard 0.4099, which does not establish improvement over the strong tree baseline.

The contribution is a reproducible methodological investigation with explicit algebraic properties, component ablations, and limitations. It is not a claim of established priority, unconditional real-data FDR control, or universal superiority.

Keywords: e-commerce indicators; nonlinear feature selection; swap-canonical loss; selection stability; false discovery rate

目 录

摘要	I
Abstract	III
第一章 绪论	1
1.1 业务问题与统计目标	1
1.2 方法研究动机	1
1.3 研究问题	2
1.4 本文工作与边界	2
第二章 相关研究与理论基础	3
2.1 统计与树模型基线	3
2.2 近期非线性特征选择	3
2.3 Knockoff、e-value 与 FDR	4
2.4 损失比较与条件重建	4
2.5 与先行工作的关系	5
第三章 数据与公平实验设计	6
3.1 数据来源与自然连接层级	6
3.2 月末可见性与目标	6
3.3 时间分工与预处理	7
3.4 样本扰动与稳定性	7
3.5 预测与发现质量	8
3.6 实验组与证据权限	8
第四章 基础选择器与模型机制改动	9
4.1 基础方法	9
4.2 从损失梯度到预测 Jacobian	9
4.3 容量门、历史分数与序列效用	10

4.4 真实结果与模拟发现质量	10
第五章 交换对称成对损失统计量	12
5.1 独立预测器与对称背景	12
5.2 完整符号翻转性质	12
5.3 随机背景边际与现有 FDR 结论	13
5.4 八场景模拟设计	13
5.5 模拟结果与机制反例	14
5.6 真实数据及生成器敏感性	15
第六章 双侧条件重建与条件矩扩展	17
6.1 原算法的目标	17
6.2 条件均值与尺度的四种机制	17
6.3 作者代码核验与实现差异	18
6.4 补充结果	18
第七章 讨论、业务含义与局限	23
7.1 为什么没有全面优胜者	23
7.2 指标看板的使用边界	23
7.3 有效性与计算限制	23
7.4 方法贡献的合理表述	24
第八章 结论与后续研究	25
参考文献	26
附录 A 候选指标字典	31
附录 B 完整表与复现	33

第一章 绪论

第一节 业务问题与统计目标

经营看板同时展示价格、交易规模、支付、口碑、履约和市场覆盖等大量指标。指标越多，维护、解释与注意力分配的成本越高；指标越少，遗漏弱信号或非线性信息的风险越大。本文将问题限定为：在固定展示容量下，筛选对下一期签收确认金额具有预测信息的经营指标，并检验名单是否对参与分析的卖家过度敏感。

预测目标提供可计算的信息保留标准。若仅保留若干指标后共同评价器的样本外误差基本不变，说明压缩保留了该评价器能够利用的大部分信息；这并不说明被删除指标在所有模型、所有月份或所有业务问题上无价值。名单稳定性衡量相同方法在不同样本中的选择一致程度，也不能直接理解为指标正确率。

本文不将预测性筛选、描述性分解与因果归因混为一谈。按州或品类拆分当期 GMV 属于金额结构分析；用月末指标预测下一月目标属于监督学习；估计改变物流策略将使 GMV 增加多少属于因果问题。本文只研究第二类问题，不能从重要性排名推导干预效果。

第二节 方法研究动机

线性系数能够直接表达变量作用，但面对对称平方效应或纯交互时可能遗漏真实信号。神经网络与树模型有更强的函数表达能力，却不自动产生可靠的变量发现。输入梯度、置换、SHAP、门控和序列搜索分别度量不同的模型依赖，具有不同的噪声与相关性敏感性。

Knockoff 提供了真假变量竞争的错误控制框架，但其有效性同时依赖生成器和统计量。一个普通的单列损失差即使在交换自身真假值后反号，也可能因其他列进入比较背景而改变其他统计量，不满足完整符号翻转。另一方面，即使统计量代数性质正确，错误生成器仍会破坏推断前提。因此需要研究具体评分

机制，而非只将更复杂预测器接到原有流程后宣称创新。

第三节 研究问题

本文提出四个问题。第一，近期非线性选择方法在相同容量和评价器下是否优于强基线？第二，输入梯度、预算门、历史剪枝分数和序列效用损失的改动是否具有独立增量？第三，固定预测器上的损失比较能否满足完整交换对称性，其收益来自评分规则还是预测器表达能力？第四，联合生成失配或条件矩估计误差会怎样改变真实应用与模拟结果？

评价维度在实验前明确为预测误差、样本稳定性、模拟平均 FDP 和 Power，辅以集合大小、机会校正稳定性、算法随机性与计算成本。不根据某一方法事后表现新增专门使其胜出的总分，也不要求一个有价值的方法在所有指标上同时第一。能够说明目标场景、机制、增量和代价，才构成可讨论的研究证据。

第四节 本文工作与边界

研究首先完成可见性面板和统一比较，其次对多个非线性机制做拆分实验，再构造交换对称成对损失及条件矩扩展。具体工作包括方法公式、性质说明、作者实现核对、公共样本扰动、独立评分设计、生成诊断以及案例级审计。所有结果由实际运行记录生成，退出候选不填零替代。

本文不把已有网络、既有 FDR 定理、普通正则或软件纠错称为原创。候选统计量的精确构造与先行工作的差异仍需更全面的文献比对；非线性模拟收益不自动成为真实电商应用收益。正式结论允许“改动没有得到支持”，不以计算次数或方法数量替代方法贡献。

第二章 相关研究与理论基础

第一节 统计与树模型基线

Lasso 利用绝对值惩罚进行稀疏估计, Elastic Net 加入平方惩罚以缓解相关变量竞争^[1,2]。稳定性选择与互补成对抽样为选择频率和误选界提供理论基础, 但具体控制结论取决于选择量、阈值与假设^[3,4]。本文的经验频率基线不自动继承所有原文保证。

XGBoost 能够表达非线性与交互, SHAP 及 TreeSHAP 提供模型贡献分解^[5-7]。平均绝对贡献可用于排序, 但不等价于条件独立检验。Extra Trees 影子变量比较参考随机树与 Boruta 思想, 本文没有实现 Boruta 全部检验和停止规则, 故只称影子变量树^[8,9]。

第二节 近期非线性特征选择

Deep Lasso 在输入损失梯度上施加组稀疏惩罚^[10]。VTFS 将子集编码为序列并学习潜在效用, 本文使用其官方骨干进行定额适配^[11]。TabM 是参数高效的表格集成预测器, 置换排名是本文另加的评分过程, 不是网络原生的统计检验^[12]。

EntryPrune 以动态稀疏输入层和进入后的相对变化衡量特征^[13]。随机门和以函数偏导构造稀疏惩罚均有先行研究, 因此预算门或 Jacobian 改动不能仅凭名称认定原创^[14,15]。

DeepPINK 与 DeepPIG 分别研究成对输入网络、成对层和随机门^[16,17]。GRIP2 研究二维正则曲面上的特征活动聚合^[18]。本研究核验这些文献的关系, 但没有把未在共同协议下完整实测的方法放入已完成排名。

DeepDRK 是依赖正则的深度 Knockoff 生成方法, TabPFN v2 是预训练表格基础预测器^[19,20]。前者在本地适配的三种子生成诊断中失败, 后者在完整样本 MPS 运行中遇到内存错误。两种退出原因不同, 都不能填入替代数字或解释

为已经完成全部统计性能比较。

第三节 Knockoff、e-value 与 FDR

FDR 定义为选择集合中错误比例的期望，而不是每次错误比例都低于目标^[21]。Knockoff 及 Model-X 通过交换性负对照构造有效竞争统计量^[22,23]。MVR 以最小可重构性改善功效，多轮 e-value 聚合与 e-BH 减少生成随机性，但不修复错误联合分布^[24–26]。

给定候选变量 X 、响应 Y 和 Knockoff $\tilde{X}$ ，需要对适用交换集合满足

$$(X, \tilde{X})_{\text{swap}(S)} \stackrel{d}{=} (X, \tilde{X}), \quad \tilde{X} \perp Y \mid X.$$

还需要统计量满足被交换分量反号、其他分量不变的完整性质。仅检查协方差、边际分布或单个自身反号均不充分。关于生成失败的近期研究特别区分边际同分布和正确配对，提醒不能把简单诊断通过当作联合有效性证明^[27]。

第四节 损失比较与条件重建

CPI 使用条件替换后的预测损失变化衡量变量信息^[28]。普通替换背景不直接满足所有 Knockoff 符号要求，并不否定 CPI 文献中其他检验程序。本文研究的是构造一个可代入标准 Knockoff 阈值的完整对称统计量。

Semi-knockoffs 比较条件于其他变量、以及额外条件于响应的两种重建，能够使用已有预测器^[29]。需要特别区分其 oracle 条件期望已知时的有限样本结论与估计条件期望时的理论：原文另给出稳定性、Wasserstein 距离和双重稳健性讨论，估计统计量符号匹配的部分还以猜想表述。不能仅阅读摘要，就把任意估计器的有限样本 FDR 都说成已获证明。

第五节 与先行工作的关系

表 2-1 方法家族及本研究完成范围

家族	代表	本研究范围
统计/树基线	Elastic Net、稳定性选择、影子树、SHAP	公共样本与预算完整比较
近期深度	Deep Lasso、TabM、VTFS	官方函数/骨干及已披露适配
模型改动	Jacobian、预算门、EntryPrune、序列成对损失	十项配置完整机制实验
对称评分	XGB/TabM 普通、中点、随机、标准化	14 种方法/消融完整实测
条件重建	Semi-KO Ridge 及条件均值/尺度	八项补充适配，作者数值核对
运行后退出	DeepDRK、TabPFN v2	生成诊断失败/内存失败
相邻方法	DeepPINK、DeepPIG、GRIP2、HRT 等	文献比较；不计作完整实测基线

本文对称化的研究对象是评分背景而不是新生成器；条件矩扩展的对象是双侧重建函数而不是新网络。相关公式具有可解释的结构，但仍属于已有条件抽样与群对称思想附近的方法研究。对先行文献的针对性核验不能证明不存在同等构造。

第三章 数据与公平实验设计

第一节 数据来源与自然连接层级

研究使用 Olist 电商与营销漏斗公开数据^[30,31]。十张原始表涵盖订单、商品明细、支付、评价、商品、卖家、顾客、地理位置、营销线索与营销成交。订单表含 99,441 条记录，商品明细含 112,650 条记录。支付与评价先在订单层聚合，地理位置按邮编前缀取经纬度中位数，再按卖家月份汇总，避免多对多连接放大金额。

目标金额来自商品明细价格，不含运费。支付和物流指标在卖家订单层去重后平均，商品属性与部分地域指标按商品明细聚合，二者对应不同业务对象。全源表有送达时间的商品金额对账为 13,220,895.11 巴西雷亚尔，不能误称为最终面板目标总和。

第二节 月末可见性与目标

对于卖家 s 和特征月 t ，目标为

$$G_{s,t+1} = \sum_{i: \text{seller}(i)=s, \text{deliverymonth}(i)=t+1} \text{price}_i, \quad Y_{s,t+1} = \log(1 + G_{s,t+1}).$$

该定义按下一自然月签收确认，不是按购买月回溯最终送达金额，也不是净利润或扣除全部售后的会计收入。物流仅使用月末前发生的事件，评价按回答时间截断，营销按成交日期截断。支付、商品和卖家元数据缺少完整修订历史，其购买时可得性仍是工作假设，不能宣称完全还原生产实时账本。

分析人口是特征月有购买商品明细的卖家，不按未来最终送达状态过滤特征月。下一月无签收记录时目标记零。面板共 18 个特征月份、13,754 行、2,723 名卖家，目标零值率为 17.8784%。不直接外推到全部注册卖家或没有本月购买活动的冷启动人口。

第三节 时间分工与预处理

表 3-1 训练、调参、评分与测试窗口

阶段	目标月份	行数	主要用途
训练	2017-02 至 2017-12	6567	预处理与基础拟合
调参	2018-01 至 2018-02	1831	选参数/轮次后重拟合
评分	2018-03 至 2018-04	1943	协议 A 可早停; 协议 B 固定模型评分
测试	2018-05 至 2018-07	3413	仅评价; 已经历探索

预处理包括预设偏态指标 $\log_{1p}$ 变换、拟合窗口 1% 和 99% 缩尾、训练中位数填补及标准化。各评价窗口只应用冻结参数。缺失可能意味着事件尚未发生，不应把中位数填补解释为已解决缺失机制。候选指标固定 31 项，不为某个方法单独增删变量。

本文包含两类训练协议。基础选择器及其模型内部机制允许排序期参与早停或子集效用；固定预测器损失研究严格限定 train/tune 决定基础模型，rank 只用于评分或已披露的条件重建。二者分别列示，不把同名模型在不同协议下的稳定性当成相同拟合结果。

第四节 样本扰动与稳定性

所有方法使用相同卖家清单：30 组互补 50% 样本、20 个 70% 样本、20 个 80% 样本；同一卖家所有月份共同保留。50% 样本有 60 份，但区间单位是 30 个互补组。另运行 10 组固定数据种子变化及一个完整参考，共 111 个案例。

对集合 A, B ，Jaccard 为 $|A \cap B|/|A \cup B|$ 。本文同时报告与完整参考名单的 Jaccard、互补两半直接比较的 Jaccard 及 Nogueira 机会校正稳定性^[32]。高参考稳定性不代表互补两半同样一致；固定数据更换随机种子也不代表对新卖家稳定。全空集合的形式一致性需结合空集比例解释。

第五节 预测与发现质量

主容量为 12 项，8 项为敏感性；规范化比较将选中列按固定编号排序，相同集合和评价器共享预测。所有名单分别交给共同 XGBoost 和 TabM 重拟合，在 3,413 行测试集评价 log 尺度 RMSE、MAE、 R^2 及金额尺度 WAPE。卖家簇 Bootstrap 重复 5,000 次，其区间只条件于已观察的三个测试月份和已拟合模型。

对于已知真支持集 S_0 ，

$$\text{FDP} = \frac{|\hat{S} \setminus S_0|}{|\hat{S}| \vee 1}, \quad \text{Power} = \frac{|\hat{S} \cap S_0|}{|S_0|}.$$

空发现集合 FDP 为 0；存在真信号时 Power 为 0；全无效场景 Power 不定义。固定 K 与原生名单分别报告。若真信号只有 5 个，Top-12 即使全部检出也至少误选 7 个，不能据此判定原生 FDR 失败。模拟设计、Monte Carlo 误差与配对比较参照规范化模拟研究原则^[33]。

第六节 实验组与证据权限

表 3-2 各实验设计与覆盖，禁止跨设计直接混排

设计	训练/评分	实测规模	主要边界
A 基础与机制	排序期可用于早停/效用	8 基线 +10 改动；600 份模拟	固定配置适配，规范 Top8/12 复算
B SCPL	基础模型不见评分响应	14 评分；111 真实；800 模拟	oracle 与错设分开
B 生成敏感性	同 B，仅换 MVR	111 真实；30 组预测	看过参考结果后追加
B 条件矩	基础模型固定；条件模型使用评分响应	8 评分；111 真实；800 份复算	6,400 方法结果，非新数据

测试期已被多轮探索查看，本研究不将其称为独立确认数据。补充算法与生成器研究保留探索性质。没有采用所有实验中最好的 RMSE、另一实验的稳定性和第三实验的 FDP 拼成一个虚构“最优方法”。

第四章 基础选择器与模型机制改动

第一节 基础方法

Elastic Net 按绝对系数排序；稳定性选择在每个外层样本中再运行 20 组互补 Lasso，采用频率和平均系数打破并列；影子树进行 8 轮真实/打乱变量比较。其经验原生阈值都不是本文新证明的 FDR 规则。XGBoost-SHAP 使用三个模型的平均绝对贡献，TabM 以每列三次置换的误差增量排序。

Copula-MVR 在训练经验分布变换后估计收缩协方差^[34]，使用近似 Lasso 真假系数差，60 组假变量聚合 e-value，再按 e-BH 筛选。单轮 $q=.10$ 、最终 $q=.20$ 与频率 90% 是不同设置。该实现的真实联合分布诊断未通过，因此保留经验比较，不授予真实发现证书。

Deep Lasso 调用官方输入梯度惩罚，使用两层 MLP；TabM 使用官方 8 成员参数高效集成；VTFS 调用官方编码器解码器，但采用有限随机语料和无重复定额序列，公开实现中的常数重参数化行为被明确保留。完整参考名单来自语料回退时，不把收益归功于 Transformer 解码器。

第二节 从损失梯度到预测 Jacobian

对于平方损失，输入损失梯度同时包含预测器偏导与残差权重：

$$\frac{\partial(f(x) - y)^2}{\partial x_j} = 2(f(x) - y) \frac{\partial f(x)}{\partial x_j}.$$

较大残差可能放大某些观测对重要性的影响，因此检验预测 Jacobian 的稀疏惩罚及排名。消融包含同时改变训练与排名、只改变训练、只改变排名。该研究动机不是“复杂化一定更好”，并且函数偏导正则已有先行研究，不能把简单替换称为首创。

第三节 容量门、历史分数与序列效用

TabM 预算门把固定 K 约束引入输入训练，检验训练使用全部变量、最终只保留少量变量之间的差异。直通梯度只是一种有偏近似，不声称精确解决最优子集选择。

EntryPrune 回归适配使用动态输入层；刷新和环境波动惩罚针对历史高分可能被偶然噪声长期保留的问题。均值减标准差仅是算法分数，不是有效统计置信下界。VTFS 首先改为固定 K 语料，再加入成对效用差损失；预算纠正的收益不能归给后续损失。

第四节 真实结果与模拟发现质量

表 4-1 模型机制比较，规范 Top-12 预测与六场景固定 K 模拟

方法	XGB 误差	TabM 误差	半样本 J	FDP@12	Power@12
Copula-MVR	1.8650	1.8967	0.7355	0.3218	0.8305
Elastic Net	1.8625	1.8806	0.7244	0.3251	0.8265
稳定性选择	1.8937	1.8885	0.5827	0.3383	0.8107
影子变量树	1.8611	1.8612	0.9388	0.3361	0.8261
XGBoost-SHAP	1.8466	1.8571	0.7682	0.2315	0.9403
Deep Lasso	1.8450	1.8594	0.8230	0.2687	0.8947
TabM-置换	1.8458	1.8586	0.7505	0.2656	0.8981
VTFS-定额适配	1.8622	1.8783	0.4068	0.5306	0.5876
Deep Lasso-Jacobian	1.8461	1.8600	0.8618	0.2657	0.8978
Jacobian 训练 + 原排名	1.8450	1.8594	0.7722	0.2686	0.8943
原 Deep Lasso+Jacobian 排名	1.8450	1.8594	0.8147	0.2656	0.8986
TabM-预算门	1.8450	1.8594	0.8071	0.2793	0.8826
EntryPrune-回归适配	1.8812	1.8744	0.6271	0.2869	0.8729
EntryPrune-刷新	2.0418	2.0350	0.4596	0.5203	0.6107
EntryPrune-环境波动惩罚	1.8706	1.8897	0.4498	0.5074	0.6263
VTFS-固定 K	1.8676	1.8921	0.4540	0.4593	0.6815
VTFS-固定 K+ 成对损失	1.8653	1.8949	0.4333	0.4531	0.6901
等预算随机子集搜索	1.8661	1.8926	0.4368	0.4911	0.6412

基础规范比较中，SHAP 和 Deep Lasso 的 XGBoost 评价 RMSE 分别为

1.8466 和 1.8450，相差很小。Jacobian 版本的参考 Jaccard 为 0.8618，父方法为 0.8230；但相对父方法的互补稳定性差区间跨零，模拟平均 FDP 变化也没有一致证据。相对 SHAP 的稳定性改善伴随较弱的模拟发现质量，属于权衡而非全面优势。

预算门提高了相对完整参考名单的 Jaccard，却没有同时提高互补稳定性，且模拟 FDP 增加。EntryPrune 刷新显著恶化真实预测和发现质量，波动惩罚未恢复强基线水平。固定 K 修正改善 VTFS 模拟检出，但实际预测未改善；新增成对损失的独立增量更小。

表 4-2 关键配对差异与组件判断

改动减父方法	参考 J 差	互补 J 差	FDP 差	Power 差
Deep Lasso-Jacobian 减 Deep Lasso	0.0388	0.0155	-0.0031	0.0031
TabM-预算门减 TabM-置换	0.0566	-0.0448	0.0137	-0.0155
EntryPrune-刷新减 EntryPrune-回归适配	-0.1675	-0.1133	0.2333	-0.2622
VTFS-固定 K 减 VTFS-定 额适配	0.0472	-0.0339	-0.0712	0.0939
VTFS-固定 K+ 成对损失减 VTFS-固定 K	-0.0208	0.0085	-0.0062	0.0086

只改变 Deep Lasso 排名的部分配置与原方法完整 Top-12 集合相同，因此规范化预测必须完全一致。任何未统一输入列顺序而产生的微小预测差都不能解释成选维改进。此前同月互补卖家梯度一致性探索最终选中 $\gamma=0$ ，其新增惩罚没有得到支持。

第五章 交换对称成对损失统计量

第一节 独立预测器与对称背景

将数据分为基础预测器训练 A、评分 B 和最终预测测试 C。基础模型 f_A 及预处理在 B 的响应被使用前冻结。对 B 内每个数值对定义 $L_{ij} = \min(X_{ij}, \tilde{X}_{ij})$ 、 $U_{ij} = \max(X_{ij}, \tilde{X}_{ij})$ 。四组 Bernoulli 掩码及其补掩码构成八个背景 $C^{(b)}$ ，每坐标从 L 或 U 选值，不依赖真假身份命名。

对第 j 个变量，将背景其他坐标保持不变，分别放入真实值和假值，计算

$$d_{ij} = \frac{1}{B} \sum_{b=1}^B \left[\ell\{Y_i, f_A(C_{i,-j}^{(b)}, \tilde{X}_{ij})\} - \ell\{Y_i, f_A(C_{i,-j}^{(b)}, X_{ij})\} \right].$$

先在卖家内平均，再对卖家平均形成 W_j 。标准化版本除以卖家均值标准误差加 10^{-8} 。该标准化只用于排序，不是 t 检验。模拟中每行一个组。八个背景来自一组 Knockoff，不是八次独立假变量生成。

第二节 完整符号翻转性质

命题。 固定预测器、预处理、掩码、分组和评分超参数，交换任意列对集合 S 后， $j \in S$ 的 W_j 反号， $j \notin S$ 的 W_j 保持不变。

证明。 交换不改变任何 min/max，因此背景逐路径不变。未交换的 j 自身真假值不变，其两次预测输入不变。被交换的 j 两次预测输入互换，损失差反号。组内与组间均值保留反号；标准差在整体反号下不变，标准化版本也成立。证毕。

该命题不要求预测器正确拟合响应函数，但不保证 Power 或预测精度。中点 $(X + \tilde{X})/2$ 也具有交换不变性。普通真实背景在交换其他列后改变，不能直接满足这一完整性质。实际 TabM 的逐列及联合交换检查与代数检查一致。

第三节 随机背景边际与现有 FDR 结论

在独立同分布、精确逐坐标交换的 oracle 条件下，对掩码取平均，每个随机 min/max 背景的输入边际分布与 X 相同。给定真假数值，随机取 min/max 等价于随机取真实/假值，因此分布是所有交换子集的等权混合；每一交换子集下原侧向量均与 X 同分布。补掩码不会使各背景独立，中点背景一般也不具有这一边际性质。

上述性质只涉及输入分布，不保留背景与 Y 的原关联，不消除有限背景误差；错设生成器下不能使用。另以十万行高斯数据核验协方差，并用显式 einsum 核对矩阵采样数值；数值检查不是数学证明或 Olist 合格证。

若 B 满足 Model-X 样本条件，条件于 A 的假变量精确交换、给定 X 后独立于 Y ，且统计量满足上述性质，可调用已有 Knockoff+ 结论：

$$T_q = \min \left\{ t > 0 : \frac{1 + \#\{j : W_j \leq -t\}}{\#\{j : W_j \geq t\} \vee 1} \leq q \right\}, \quad \hat{S} = \{j : W_j \geq T_q\}.$$

无解时 $T_q = \infty$ ，返回空集。本研究 $q=.20$, $q=.10$ 为敏感性。至少需要 $\lceil 1/q \rceil$ 个正发现才可能非空。Top-K 不继承该规则的 FDR 结论，真实同卖家跨期依赖与估计 Copula 也未满足全部 oracle 前提。

第四节 八场景模拟设计

表 5-1 损失评分研究的模拟设置

场景	真信号	相关系数	信噪比	生成条件
全无效	0	0.6	不适用	已知精确
线性稀疏	5	0.6	2.0	已知精确
强非线性	10	0.6	2.0	已知精确
弱非线性	10	0.6	0.5	已知精确
纯交互	10	0.6	2.0	已知精确
高相关线性	10	0.9	2.0	已知精确
已知混合变换	10	0.6	2.0	已知精确
t 生成错设	10	0.6	2.0	故意错设

每份 $n=2000$ 、 $p=31$ ，前 1200 行用于基础模型，其中 1000/200 作训练与选轮次；400 行评分，400 行预测测试。七场景为精确高斯或已知变换后的高斯 Knockoff，t 场景故意使用错误高斯生成。响应信号尺度只由训练部分确定，真支持集不参与选参。成对 Lasso 仅在 400 行评分集拟合，因此另设同 1200 行训练的线性预测器对照。

第五节 模拟结果与机制反例

表 5-2 原生 $q=.20$ 的场景结果，平均 FDP 与 Power

场景	方法	平均 FDP	FDP-MCSE	Power	发现数
全无效	匹配线性对称差	0.0100	0.0100	不定义	0.05
全无效	XGB-中点差	0.0600	0.0239	不定义	0.34
全无效	TabM-中点差	0.0500	0.0219	不定义	0.32
全无效	TabM-随机对称差	0.0300	0.0171	不定义	0.24
全无效	TabM-标准化对称差	0.0500	0.0219	不定义	0.35
线性稀疏	匹配线性对称差	0.1798	0.0182	1.0000	6.50
线性稀疏	XGB-中点差	0.1632	0.0196	1.0000	6.51
线性稀疏	TabM-中点差	0.2013	0.0213	1.0000	6.94
线性稀疏	TabM-随机对称差	0.1850	0.0219	1.0000	6.86
线性稀疏	TabM-标准化对称差	0.1955	0.0205	0.9700	6.73
强非线性	匹配线性对称差	0.0760	0.0169	0.0870	1.44
强非线性	XGB-中点差	0.1619	0.0135	0.9990	12.31
强非线性	TabM-中点差	0.1808	0.0151	0.9570	12.20
强非线性	TabM-随机对称差	0.1732	0.0155	0.9650	12.19
强非线性	TabM-标准化对称差	0.1668	0.0166	0.7940	10.26
弱非线性	匹配线性对称差	0.0742	0.0177	0.0750	1.39
弱非线性	XGB-中点差	0.1817	0.0156	0.9030	11.61
弱非线性	TabM-中点差	0.1823	0.0187	0.7580	10.34
弱非线性	TabM-随机对称差	0.1826	0.0174	0.7610	10.23
弱非线性	TabM-标准化对称差	0.1636	0.0189	0.4310	6.44
纯交互	匹配线性对称差	0.0155	0.0109	0.0030	0.13
纯交互	XGB-中点差	0.1471	0.0128	0.9310	11.25
纯交互	TabM-中点差	0.1565	0.0151	0.9980	12.31
纯交互	TabM-随机对称差	0.1545	0.0144	0.9970	12.22
纯交互	TabM-标准化对称差	0.1528	0.0149	0.9340	11.58
高相关线性	匹配线性对称差	0.1746	0.0115	0.8590	10.75

场景	方法	平均 FDP	FDP-MCSE	Power	发现数
高相关线性	XGB-中点差	0.1712	0.0163	0.7020	9.34
高相关线性	TabM-中点差	0.1617	0.0163	0.8440	10.87
高相关线性	TabM-随机对称差	0.1686	0.0163	0.8510	11.04
高相关线性	TabM-标准化对称差	0.1772	0.0197	0.5840	8.46
已知混合变换	匹配线性对称差	0.0903	0.0172	0.1750	2.56
已知混合变换	XGB-中点差	0.1750	0.0154	0.9940	12.56
已知混合变换	TabM-中点差	0.1612	0.0163	0.9640	12.10
已知混合变换	TabM-随机对称差	0.1518	0.0144	0.9630	11.78
已知混合变换	TabM-标准化对称差	0.1506	0.0146	0.8030	10.00
t 生成错误	匹配线性对称差	0.0755	0.0208	0.0370	1.00
t 生成错误	XGB-中点差	0.1382	0.0167	0.5090	6.80
t 生成错误	TabM-中点差	0.1390	0.0192	0.3710	5.02
t 生成错误	TabM-随机对称差	0.1551	0.0202	0.3970	5.52
t 生成错误	TabM-标准化对称差	0.1783	0.0228	0.2740	4.49

标准化 TabM 在强非线性、弱非线性、纯交互中明显提高相对匹配线性预测器的 Power，说明非线性表达确实有用。但未标准化 TabM 在强非线性下 Power 达到 0.965，高于预定标准化版本 0.794；高相关线性下主候选 0.584，低于线性对照 0.859。不能事后将更强消融改写为预定主方法，也不能把表达能力增益都归于对称化。

全无效场景主候选 100 次中 5 次非空，FDR 估计.05，准确二项 95% 区间约 [.016,.113]；不是总体错误率恰等于.05 的证明。t 错误下平均 FDP 即使低于目标也不能恢复理论保证。线性稀疏的 TabM 中点平均 FDP 略高于.20，必须连同 Monte Carlo 误差保留。

第六节 真实数据及生成器敏感性

表 5-3 SCPL 同预算真实结果，两个生成器条件分别列示

生成条件	方法	XGB 误差	TabM 误差	J	Nogueira
等相关	XGBoost-SHAP	1.8466	1.8571	0.7682	0.7439
等相关	Deep Lasso	1.8468	1.8567	0.8394	0.8012
等相关	TabM-中点差	1.8577	1.8776	0.3934	0.2009

生成条件	方法	XGB 误差	TabM 误差	J	Nogueira
等相关	TabM-随机对称差	1.8577	1.8776	0.3912	0.1993
等相关	TabM-标准化对称差	2.0964	2.0886	0.3249	0.1248
MVR 追加	XGBoost-SHAP	1.8466	1.8571	0.7682	0.7439
MVR 追加	Deep Lasso	1.8468	1.8567	0.8394	0.8012
MVR 追加	TabM-中点差	1.8431	1.8575	0.4988	0.4509
MVR 追加	TabM-随机对称差	1.8630	1.8732	0.4874	0.4675
MVR 追加	TabM-标准化对称差	1.8493	1.8645	0.4696	0.3947

训练估计 Copula 的等相关 S 约.00334, 约 49.4% 真假值完全相同, 评分信息很弱, 完整参考原生规则均为空。主候选 Top-12 的 RMSE 为 2.0964、Jaccard 为.3249, 明显弱于 SHAP。不能以零发现的低 FDP 或形式稳定性美化这一结果。

事后参考样本 MVR 检查已看到预测变化后, 再登记 111 例生成器敏感性分析。MVR 改善主候选 RMSE 至 1.8493, 但 Jaccard 仅.4696; 中点 TabM 的 1.8431 虽低于 SHAP1.8466, 配对差 95% 区间 [-.0118,.0053] 包含零。该追加不是预先确认, MVR 也是既有生成器, 不构成新发明。

表 5-4 真实交换诊断, 按卖家隔离的分类 AUC

条件	25% 交换	50% 交换	100% 交换
等相关	0.9514	0.6470	0.8998
MVR 追加	0.8782	0.9139	0.9467

两套生成器均明显可区分交换前后联合样本。该 AUC 是工程诊断, 不是已校准的面板检验; 接近.5 也不能证明有效。原生发现数增加不能证明真实 FDR 正确。

第六章 双侧条件重建与条件矩扩展

第一节 原算法的目标

Semi-knockoffs 令 $\nu_j(X_{-j}) = E(X_j | X_{-j})$ 、 $\rho_j(X_{-j}, Y) = E(X_j | X_{-j}, Y)$ 。两侧分别重建特征并独立打乱残差，比较共同预测器的损失。零假设下两个条件期望一致，为 oracle 双侧对称提供依据。这些重建不是标准 Model-X 假变量，不能与 SCPL 生成机制混称。

原文实践允许条件模型使用评分响应；本研究明确将 rank 响应提供给条件重建，不提供给基础预测器训练、早停或最终测试预测。条件于 Y 的拟合属于算法定义，不是未披露的基础模型泄漏。估计模型可能过拟合并偏离零假设对称，因此实际 FDR 需要单独检验。

第二节 条件均值与尺度的四种机制

线性条件均值可能无法表达平方效应中的方差信息。因此预先登记四种重建：固定 Ridge 均值；加入平方与响应交互的非线性均值；线性均值加条件尺度；非线性均值与条件尺度联合。每种分别接入同一批 XGBoost 和 TabM，共八项评分，主候选为 TabM 联合扩展。

非线性侧使用原输入及逐坐标平方，条件于 Y 时再加 Y、Y² 及 Y 与其他特征的乘积。不声称这是通用深度条件分布估计。尺度模型对残差平方加稳定常数后取 log 并用相同基函数 Ridge 拟合，指数预测相对残差方差截断在 [.05,20]，再开方；这是一种条件尺度代理而非已证明无偏的方差估计。

$$\tilde{X}_{ij}^{(r)} = \hat{m}_{rj}(Z_{ri}) + \hat{s}_{rj}(Z_{ri}) \left\{ \frac{X_{\pi_r(i),j} - \hat{m}_{rj}(Z_{r,\pi_r(i)})}{\hat{s}_{rj}(Z_{r,\pi_r(i)})} \right\}, \quad r = 1, 2.$$

两侧使用相互独立的置换，所有机制共享置换；不使用 Y 的一侧 $Z_1 = X_{-j}$ ，另一侧 $Z_2 = (X_{-j}, Y)$ 。统计量按行平均平方损失差，不额外标准化。零假设下 oracle 均值及尺度一致时，两侧残差抽样对称，但估计均值尺度不会自动保持这

一性质。这里不提出无条件的新 FDR 定理。

第三节 作者代码核验与实现差异

作者源码锁定
commit `ff51ec239529620300e92efd9988eb69490eb3ac`。在小型样本上逐项核对 Ridge 拟合、置换顺序与向量化损失分数，最大差约 2.0×10^{-16} 。固定 $\alpha=1$ 代替原实验 RidgeCV；基础预测器、样本与评价器采用本文公共协议，故称原算法机制适配，不称复现原文全部实验。

作者辅助阈值函数在无解时返回最后一个有限候选。例如 $W=(1,2,3,4)$ 、 $q=.2$ 时，任何阈值都不满足 Knockoff+ 条件，原函数仍返回 4。本文按原文公式修正为 ∞ 并保留反例，不把软件错误归于原文数学定理，也不把纠错当作算法创新。

第四节 补充结果

本实验在全部 111 个公共真实案例上计算八种评分，并在相同 800 份 SCPL 模拟数据上追加 6,400 个方法案例。没有新增 800 份独立数据，也没有复用旧方法输出冒充新算法结果。Top-8/12 采用两个公共评价器，共 32 组真实预测；预测器与父实验的参考分数逐真实案例核对。

表 6-1 条件矩扩展的真实 Top-12 结果

方法	XGB-RMSE	TabM-RMSE	半样本 J	Nogueira
XGBoost-SHAP	1.8466	1.8571	0.7682	0.7439
TabM 置换	1.8458	1.8586	0.7288	0.6841
Deep Lasso	1.8468	1.8567	0.8394	0.8012
XGB-SKO-Ridge	1.8794	1.8669	0.4511	0.2696
XGB-SKO-非线性均值	1.8612	1.8722	0.3828	0.2228
XGB-SKO-尺度	1.8813	1.8731	0.3927	0.3007
XGB-SKO-均值尺度	1.8508	1.8654	0.4407	0.2568
TabM-SKO-Ridge	1.8996	1.9130	0.4397	0.3115
TabM-SKO-非线性均值	1.8837	1.9010	0.4224	0.3103
TabM-SKO-尺度	1.8793	1.9009	0.4713	0.3617
TabM-SKO-均值尺度	1.8965	1.9033	0.4099	0.3497




图 6-1 共同预测器下的真实预测与样本稳定性，误差与名单一致性分开评价

表 6-2 条件矩扩展的八场景原生发现

场景	方法	平均 FDP	MCSE	Power	发现数
全无效	XGB-SKO-Ridge	0.0300	0.0171	不定义	0.30
全无效	XGB-SKO-非线性均值	0.0400	0.0197	不定义	0.32
全无效	XGB-SKO-尺度	0.0200	0.0141	不定义	0.11
全无效	XGB-SKO-均值尺度	0.0500	0.0219	不定义	0.36
全无效	TabM-SKO-Ridge	0.0400	0.0197	不定义	0.28
全无效	TabM-SKO-非线性均值	0.0200	0.0141	不定义	0.10
全无效	TabM-SKO-尺度	0.0300	0.0171	不定义	0.22
全无效	TabM-SKO-均值尺度	0.0300	0.0171	不定义	0.20
线性稀疏	XGB-SKO-Ridge	0.1551	0.0184	1.0000	6.32
线性稀疏	XGB-SKO-非线性均值	0.1327	0.0169	1.0000	6.08
线性稀疏	XGB-SKO-尺度	0.1769	0.0184	1.0000	6.54
线性稀疏	XGB-SKO-均值尺度	0.1446	0.0166	1.0000	6.18
线性稀疏	TabM-SKO-Ridge	0.1799	0.0212	1.0000	6.83
线性稀疏	TabM-SKO-非线性均值	0.1830	0.0205	1.0000	6.77
线性稀疏	TabM-SKO-尺度	0.1786	0.0201	1.0000	6.68
线性稀疏	TabM-SKO-均值尺度	0.1990	0.0218	1.0000	7.08
强非线性	XGB-SKO-Ridge	0.0100	0.0050	0.1350	1.45
强非线性	XGB-SKO-非线性均值	0.1102	0.0142	0.8190	9.67
强非线性	XGB-SKO-尺度	0.0558	0.0111	0.4000	4.70
强非线性	XGB-SKO-均值尺度	0.1356	0.0149	0.9130	11.04
强非线性	TabM-SKO-Ridge	0.0183	0.0079	0.1290	1.52
强非线性	TabM-SKO-非线性均值	0.1125	0.0134	0.8560	10.01
强非线性	TabM-SKO-尺度	0.0351	0.0098	0.3200	3.66

第六章 双侧条件重建与条件矩扩展

场景	方法	平均 FDP	MCSE	Power	发现数
强非线性	TabM-SKO-均值尺度	0.1313	0.0151	0.8660	10.50
弱非线性	XGB-SKO-Ridge	0.0161	0.0069	0.0580	0.73
弱非线性	XGB-SKO-非线性均值	0.0885	0.0137	0.4540	5.57
弱非线性	XGB-SKO-尺度	0.0221	0.0071	0.1800	1.99
弱非线性	XGB-SKO-均值尺度	0.0967	0.0142	0.5700	6.95
弱非线性	TabM-SKO-Ridge	0.0278	0.0095	0.0740	0.92
弱非线性	TabM-SKO-非线性均值	0.1023	0.0150	0.4710	5.90
弱非线性	TabM-SKO-尺度	0.0360	0.0101	0.1060	1.40
弱非线性	TabM-SKO-均值尺度	0.1223	0.0151	0.5150	6.49
纯交互	XGB-SKO-Ridge	0.0210	0.0108	0.0190	0.41
纯交互	XGB-SKO-非线性均值	0.1603	0.0165	0.7950	10.17
纯交互	XGB-SKO-尺度	0.0049	0.0035	0.0090	0.12
纯交互	XGB-SKO-均值尺度	0.1559	0.0157	0.8110	10.26
纯交互	TabM-SKO-Ridge	0.0000	0.0000	0.0120	0.12
纯交互	TabM-SKO-非线性均值	0.1500	0.0146	0.9590	11.72
纯交互	TabM-SKO-尺度	0.0000	0.0000	0.0160	0.16
纯交互	TabM-SKO-均值尺度	0.1493	0.0145	0.9660	11.79
高相关线性	XGB-SKO-Ridge	0.1413	0.0167	0.6370	8.24
高相关线性	XGB-SKO-非线性均值	0.1514	0.0156	0.6620	8.48
高相关线性	XGB-SKO-尺度	0.1432	0.0154	0.6800	8.58
高相关线性	XGB-SKO-均值尺度	0.1481	0.0154	0.6470	8.29
高相关线性	TabM-SKO-Ridge	0.1541	0.0171	0.7970	10.28
高相关线性	TabM-SKO-非线性均值	0.1423	0.0158	0.7560	9.56
高相关线性	TabM-SKO-尺度	0.1608	0.0170	0.8030	10.42
高相关线性	TabM-SKO-均值尺度	0.1343	0.0162	0.7640	9.55
已知混合变换	XGB-SKO-Ridge	0.0050	0.0036	0.0420	0.47
已知混合变换	XGB-SKO-非线性均值	0.0883	0.0128	0.7160	8.26
已知混合变换	XGB-SKO-尺度	0.0312	0.0090	0.2440	2.83
已知混合变换	XGB-SKO-均值尺度	0.1248	0.0140	0.8670	10.35
已知混合变换	TabM-SKO-Ridge	0.0125	0.0060	0.0750	0.89
已知混合变换	TabM-SKO-非线性均值	0.1297	0.0137	0.8500	10.21
已知混合变换	TabM-SKO-尺度	0.0424	0.0106	0.3430	3.89
已知混合变换	TabM-SKO-均值尺度	0.1643	0.0138	0.8860	11.06
t 生成错误	XGB-SKO-Ridge	0.0076	0.0060	0.0280	0.38
t 生成错误	XGB-SKO-非线性均值	0.0809	0.0129	0.2380	3.07
t 生成错误	XGB-SKO-尺度	0.0152	0.0061	0.0370	0.47

场景	方法	平均 FDP	MCSE	Power	发现数
t 生成错误	XGB-SKO-均值尺度	0.1143	0.0161	0.3010	4.16
t 生成错误	TabM-SKO-Ridge	0.0215	0.0123	0.0190	0.37
t 生成错误	TabM-SKO-非线性均值	0.1147	0.0192	0.2200	3.44
t 生成错误	TabM-SKO-尺度	0.0205	0.0105	0.0250	0.48
t 生成错误	TabM-SKO-均值尺度	0.0999	0.0186	0.2000	3.13




图 6-2 八场景中的原生平均 FDP 和 Power，名义水平不代替有效性验证

预定主候选的 XGB 评价 RMSE 为 1.8965，同 TabM 的 Ridge 机制适配为 1.8996；其半样本参考 Jaccard 为 0.4099。相对 SHAP 的 RMSE 差为 0.0499，卖家簇 Bootstrap 点态 95% 区间为 [0.0308, 0.0697]。区间跨零时不能宣称已证实提升，也不能声称已证明等价。

强非线性下主候选 Power 为 0.8660，Ridge 适配为 0.1290；主候选平均 FDP 为 0.1313。平均 FDP 超过名义.20 的场景检查：所列场景未出现高于.20 的点估计，但有限模拟不证明总体控制。检出增多须与误选同时解释。条件尺度建模不自动产生交换有效性，任何经验失控都必须保留，不因其真实预测较好而隐去。

该实验补足了近期双侧条件重建的机制比较，但仅是固定参数、有限基函数的适配。当前没有把条件均值/尺度扩展称为已证明原创的新方法。

独立组件判断。强非线性中只用非线性均值的 Power 已为.856，联合尺度后为.866；纯交互中为.959 与.966。大部分检出改进来自非线性条件均值，而不是尺度项。联合项减非线性均值的配对差如下，Holm 校正限于同场景、同规则、

同指标的比较族，不能解释为跨所有场景筛选后的确认结论。

表 6-3 条件尺度相对非线性均值的检出增量

场景	加入尺度的 Power 差	95% 区间	Holm p
强非线性	0.0100	[-0.0240,0.0440]	0.561
弱非线性	0.0440	[-0.0083,0.0963]	0.09793
纯交互	0.0070	[-0.0029,0.0169]	0.3252
已知混合变换	0.0360	[0.0074,0.0646]	0.01401
高相关线性	0.0080	[-0.0140,0.0300]	1

联合 TabM 真实 RMSE 约 1.8965，SHAP 为 1.8466，误差差区间完全为正；参考 Jaccard 约.4099，也低于 SHAP 的.7682。联合方法没有形成真实应用优势。此外，未标准化 SCPL 随机对称 TabM 在强非线性、弱非线性和纯交互中的 Power 仍更高，因此不能把相对 Ridge 适配的巨大提高写成超越所有非线性方法。

条件重建扩展在何种机制下有收益，需要与同一预测器的 Ridge、非线性均值和尺度单独版本对比，而不是只与线性预测器比较。是否优于 SHAP 则只能在相同 K 的预测和模拟表中回答；原生 FDR 程序与没有原生阈值的 SHAP 不直接混比。

第七章 讨论、业务含义与局限

第一节 为什么没有全面优胜者

31 项指标中存在强代理和构成约束，增加网络复杂度不一定增加可识别信息。预测器可利用多个相似指标保持准确，却可能在抽样后交换它们的排名；高名单稳定性也可能来自强惩罚或机械并列。FDR 规则则允许证据不足时不作发现，这与固定展示容量存在真实冲突。

由此需要区分三种结果：预测器改善了响应拟合；评分改善了真变量相对假变量的可区分程度；生成器更接近有效联合分布。只有控制其他部分，才能把收益归因于具体改动。标准化失败、EntryPrune 刷新失败及生成器替换敏感性，都是这一分解的实证证据。

第二节 指标看板的使用边界

研究名单可作为后续看板试运行候选。展示 8 或 12 项需要结合维护成本，而不是对每一项附加“真实有效”的永久标签。应持续记录未来月份误差、缺失、变量替代和名单变动；没有新数据验证前，不把测试期点估计最优名单设为唯一生产默认。

具体解释应回到经营口径：交易规模指标提示下一期签收规模，履约和口碑指标反映当前可见状态，地域指标表达买家构成。指标被选中不说明人为改变它必然改变 GMV。业务原因解释仍需描述性拆解或因果设计。

第三节 有效性与计算限制

本研究仅有一个电商平台和三个测试月份，且测试已被探索查看；同卖家跨期相关破坏简单独立样本前提。生成器和条件矩估计都存在建模误差，缩尾、填补和静态快照也影响研究对象。真实数据未知支持集，不能直接估计真实 FDP。

不同实验的训练信息、早停、模拟场景和内部预算不同，因此按设计分表。共享预测器使评分消融更公平，但不能把联合训练耗时拆成各方法独立速度。基

础参数在真实开发期选定后迁移到模拟，不代表每场景充分调参后的性能上界。

条件矩适配统一按数值型变量使用残差重建，包含少数二元或占比指标；重建值可能离开原离散支持。本文没有实现原文所建议的分类概率重建分支，因此其真实结果和混合场景必须视为适配限制，不能用 oracle 连续变量结论掩盖。即使连续变量中，尺度模型也是稳定化代理而非一致性已获证明的条件方差估计。

当前没有完成 DeepPIG、GRIP2 原算法、HRT 或 dCRT 在公共协议下的完整比较，也没有第二真实数据集。文献名称新并不能代替这些缺口。全部已实测、失败和仅参考方法在独立档案登记，不能把“下载作者代码”统计为成功比较。

第四节 方法贡献的合理表述

可支持的贡献是一个具体可检验的评分对称化问题、性质证明、组件消融、条件重建扩展与完整负结果分析。尚不可支持的是已证明的原创优先权、估计生成器下的新 FDR 定理，以及电商真实数据上全面超越强基线。

论证应围绕“在何种前提下解决什么问题、在哪些场景失败”，而不是以网络规模或尝试数量证明创新。更广泛的文献逐公式比较、近期受控非线性基线和独立真实数据，是决定方法原型能否形成充分学位论文贡献的后续证据。

第八章 结论与后续研究

基础比较显示近期深度方法具有竞争力，但没有跨预测器、稳定性与模拟发现质量的一致冠军。模型内部机制改动中，Jacobian 具有局部稳定性价值，预算门、动态剪枝和序列损失的独立收益受限。负结果不应被更换指标或事后主方法遮盖。

交换对称成对损失满足明确的路径级符号翻转，并可在精确生成器与独立评分条件下使用已有 Knockoff 理论。非线性模拟中它相对匹配线性模型提高检出，但标准化常降低 Power，高相关线性构成反例。真实生成器失配限制了实际发现解释，MVR 敏感性改善预测也未提供可靠的稳定性优势。

双侧条件矩补充得到主候选真实 RMSE 1.8965、半样本 J 0.4099，强非线性 Power 0.8660 与平均 FDP 0.1313。它说明估计条件矩的收益与误选代价需要共同检查；作者阈值函数的纠错仅保证实现符合公式，不能补救条件模型失配。

后续优先进行三项工作：在未使用过的真实数据和时间窗口冻结验证；与近期非线性受控筛选算法按相同信息与预算比较；研究条件矩估计误差和生成失配对统计量符号及发现风险的影响。只有这些证据补足后，才能更明确判断方法贡献与适用范围。本文不预先承诺这些工作必然产生优势。

参考文献

- [1] Tibshirani R. Regression shrinkage and selection via the lasso[J]. Journal of the Royal Statistical Society, Series B, 58(1), 267-288, 1996. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>.
- [2] Zou H, Hastie T. Regularization and variable selection via the elastic net[J]. Journal of the Royal Statistical Society, Series B, 67(2), 301-320, 2005. <https://doi.org/10.1111/j.1467-9868.2005.00503.x>.
- [3] Meinshausen N, Bühlmann P. Stability selection[J]. Journal of the Royal Statistical Society, Series B, 72(4), 417-473, 2010. <https://doi.org/10.1111/j.1467-9868.2010.00740.x>.
- [4] Shah R D, Samworth R J. Variable selection with error control: another look at stability selection[J]. Journal of the Royal Statistical Society, Series B, 75(1), 55-80, 2013. <https://doi.org/10.1111/j.1467-9868.2011.01034.x>.
- [5] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. Proceedings of KDD, 785-794, 2016. <https://doi.org/10.1145/2939672.2939785>.
- [6] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[C]. Advances in Neural Information Processing Systems, 30, 2017. <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>.
- [7] Lundberg S M, Erion G, Chen H, et al. From local explanations to global understanding with explainable AI for trees[J]. Nature Machine Intelligence, 2, 56-67, 2020. <https://doi.org/10.1038/s42256-019-0138-9>.
- [8] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees[J]. Machine Learning, 63, 3-42, 2006. <https://doi.org/10.1007/s10994-006-6226-1>.

-
- [9] Kursa M B, Rudnicki W R. Feature Selection with the Boruta Package[J]. Journal of Statistical Software, 36(11), 1-13, 2010. <https://doi.org/10.18637/jss.v036.i11>.
- [10] Cherepanova V, Levin R, Somepalli G, et al. A Performance-Driven Benchmark for Feature Selection in Tabular Deep Learning[C]. NeurIPS Datasets and Benchmarks Track, 2023. <https://openreview.net/forum?id=v4PMCdSaAT>.
- [11] Ying W, Wang D, Chen H, Fu Y. Feature Selection as Deep Sequential Generative Learning[J]. ACM Transactions on Knowledge Discovery from Data, 18(9), Article 221, 2024. <https://doi.org/10.1145/3687485>.
- [12] Gorishniy Y, Kotelnikov A, Babenko A. TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling[C]. International Conference on Learning Representations, 2025. <https://openreview.net/forum?id=Sd4wYYOhmY>.
- [13] Zimmer F, Okanovic P, Hoefer T. EntryPrune: Neural Network Feature Selection using First Impressions[EB/OL]. arXiv:2410.02344v4, preprint, 2025. <https://arxiv.org/abs/2410.02344v4>.
- [14] Yamada Y, Lindenbaum O, Negahban S, Kluger Y. Feature Selection using Stochastic Gates[C]. Proceedings of Machine Learning Research, 119, 10648-10659, 2020. <https://proceedings.mlr.press/v119/yamada20a.html>.
- [15] Gregorova M, Kalousis A, Marchand-Maillet S. Structured Nonlinear Variable Selection[C]. Uncertainty in Artificial Intelligence, 2018. <https://auai.org/uai2018/proceedings/papers/17.pdf>.
- [16] Lu Y, Fan Y, Lv J, Noble W S. DeepPINK: reproducible feature selection in deep neural networks[C]. Advances in Neural Information Processing Systems, 2018. <https://arxiv.org/abs/1809.01185>.

-
- [17] Oh E, Lee H. DeepPIG: deep neural network architecture with pairwise connected layers and stochastic gates using knockoff frameworks for feature selection[J]. Scientific Reports, 14, Article 15582, 2024. <https://doi.org/10.1038/s41598-024-66061-6>.
- [18] Zou B J, Tian L. GRIP2: A Robust and Powerful Deep Knockoff Method for Feature Selection[EB/OL]. arXiv:2602.00218v1, preprint, 2026. <https://arxiv.org/abs/2602.00218v1>.
- [19] Shen H, Yan Y, Zhao Z. DeepDRK: Deep Dependency Regularized Knockoff for Feature Selection[C]. Advances in Neural Information Processing Systems, 2024. <https://openreview.net/forum?id=ibKpPabHVn>.
- [20] Hollmann N, Muller S, Purucker L, et al. Accurate predictions on small data with a tabular foundation model[J]. Nature, 637, 319-326, 2025. <https://doi.org/10.1038/s41586-024-08328-6>.
- [21] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing[J]. Journal of the Royal Statistical Society, Series B, 57(1), 289-300, 1995. <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>.
- [22] Barber R F, Candès E J. Controlling the false discovery rate via knockoffs[J]. The Annals of Statistics, 43(5), 2055-2085, 2015. <https://doi.org/10.1214/15-AOS1337>.
- [23] Candès E, Fan Y, Janson L, Lv J. Panning for gold: model-X knockoffs for high dimensional controlled variable selection[J]. Journal of the Royal Statistical Society, Series B, 80(3), 551-577, 2018. <https://doi.org/10.1111/rssb.12265>.
- [24] Spector A, Janson L. Powerful knockoffs via minimizing reconstructability[J]. The Annals of Statistics, 50(1), 252-276, 2022. <https://doi.org/10.1214/21-AOS2104>.

-
- [25] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for false discovery rate control[J]. Journal of the Royal Statistical Society, Series B, 86(1), 122-154, 2024. <https://doi.org/10.1093/jrsssb/qkad085>.
- [26] Wang R, Ramdas A. False discovery rate control with e-values[J]. Journal of the Royal Statistical Society, Series B, 84(3), 822-852, 2022. <https://doi.org/10.1111/rssb.12489>.
- [27] Blain A, Reyero Lobo A, Linhart J, Thirion B, Neuviat P. When knock-offs fail: diagnosing and fixing non-exchangeability of knockoffs[EB/OL]. arXiv:2407.06892, revised preprint, 2025. <https://arxiv.org/abs/2407.06892>.
- [28] Watson D S, Wright M N. Testing conditional independence in supervised learning algorithms[J]. Machine Learning, 110, 2107-2129, 2021. <https://doi.org/10.1007/s10994-021-06030-6>.
- [29] Reyero-Lobo A, Thirion B, Neuviat P. Semi-knockoffs: a model-agnostic conditional independence testing method with finite-sample guarantees[C]. International Conference on Machine Learning; arXiv:2601.23124v2, 2026. <https://arxiv.org/abs/2601.23124v2>.
- [30] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle dataset, 2018. <https://www.kaggle.com/datasets/olistbr/brazilian-e-commerce>.
- [31] Olist. Marketing Funnel by Olist[DB/OL]. Kaggle dataset, 2018. <https://www.kaggle.com/datasets/olistbr/marketing-funnel-olist>.
- [32] Nogueira S, Sechidis K, Brown G. On the Stability of Feature Selection Algorithms[J]. Journal of Machine Learning Research, 18(174), 1-54, 2018. <https://www.jmlr.org/papers/v18/17-514.html>.
- [33] Morris T P, White I R, Crowther M J. Using simulation studies to evaluate statistical methods[J]. Statistics in Medicine, 38(11), 2074-2102, 2019. <https://doi.org/10.1002/sim.8086>.

- [34] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. Journal of Multivariate Analysis, 88(2), 365-411, 2004.
[https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4).

附录 A 候选指标字典

表 8-1 31 项指标及观测范围

编号	中文含义	类型	观测范围	取值数	缺失率
1	平均商品价格	连续聚合量	0.850 至 6735.000	8101	0.00%
2	平均运费	连续聚合量	0.030 至 314.400	9396	0.00%
3	平均商品重量	连续聚合量	2.000 至 30000.000	5499	0.01%
4	平均商品长度	连续聚合量	8.000 至 105.000	2345	0.01%
5	平均商品高度	连续聚合量	2.000 至 105.000	2306	0.01%
6	平均商品宽度	连续聚合量	6.000 至 104.000	2239	0.01%
7	平均商品图片数	连续聚合量	1.000 至 19.000	928	1.66%
8	平均商品标题长度	连续聚合量	7.000 至 64.000	2229	1.66%
9	平均商品描述长度	连续聚合量	4.000 至 3992.000	7535	1.66%
10	平均支付分期期数	连续聚合量	1.000 至 24.000	1579	0.00%
11	平均支付序列数	连续聚合量	1.000 至 15.000	284	0.00%
12	信用卡支付占比	连续聚合量	0.000 至 1.000	1836	0.00%
13	Boleto 支付占比	连续聚合量	0.000 至 1.000	374	0.00%
14	代金券支付占比	连续聚合量	0.000 至 1.000	1690	0.00%
15	借记卡支付占比	连续聚合量	0.000 至 1.000	151	0.00%
16	月末可见平均评价	连续聚合量	1.000 至 5.000	382	26.68%
17	月末已送达平均天数	连续聚合量	1.115 至 29.304	10733	21.74%
18	月末已审核平均天数	连续聚合量	0.000 至 23.162	11290	0.61%
19	月末已承运平均准备天数	连续聚合量	0.001 至 24.190	12725	7.14%

第八章 参考文献

编号	中文含义	类型	观测范围	取值数	缺失率
20	月末已送达预计提前天数	连续聚合量	-13.236 至 139.397	10740	21.74%
21	购买件数	计数	1.000 至 358.000	153	0.00%
22	购买订单数	计数	1.000 至 271.000	139	0.00%
23	活跃品类数	计数	0.000 至 17.000	17	0.00%
24	独立顾客数	计数	1.000 至 268.000	140	0.00%
25	买家州数量	计数	1.000 至 22.000	22	0.00%
26	第一大买家州占比	连续聚合量	0.100 至 1.000	453	0.00%
27	跨州交易占比	连续聚合量	0.000 至 1.000	515	0.00%
28	平均买卖家距离	连续聚合量	0.000 至 3343.136	13684	0.43%
29	已观察卖家州频率	连续聚合量	0.000 至 0.605	230	0.00%
30	已成交营销来源频率	连续聚合量	0.000 至 0.344	41	0.00%
31	月末已匹配营销成交	二元	0.000 至 1.000	2	0.00%

附录 B 完整表与复现

表 8-2 SCPL 全部同预算评分结果，六个精确非零场景等权平均

方法	XGB 误差	TabM 误差	J	FDP@12	Power@12
评分集成对 Lasso	1.9488	1.9765	0.3569	0.5203	0.6590
线性预测器 + 标准化对称差	2.0784	2.0687	0.4046	0.4860	0.7002
XGBoost-SHAP	1.8466	1.8571	0.7682	0.2629	0.9678
XGBoost-置换	1.8478	1.8612	0.7853	0.2514	0.9817
TabM-置换	1.8458	1.8586	0.7288	0.2594	0.9720
Deep Lasso	1.8468	1.8567	0.8394	0.2678	0.9620
XGB-普通损失差	1.9286	1.9479	0.4237	0.2669	0.9630
XGB-中点对称差	1.9286	1.9479	0.4308	0.2719	0.9570
XGB-随机对称差	1.9286	1.9479	0.4300	0.2697	0.9597
XGB-标准化对称差	1.9323	1.9621	0.3387	0.3171	0.9028
TabM-普通损失差	2.0271	2.0294	0.3740	0.2728	0.9560
TabM-中点对称差	1.8577	1.8776	0.3934	0.2769	0.9510
TabM-随机对称差	1.8577	1.8776	0.3912	0.2739	0.9547
TabM-标准化对称差	2.0964	2.0886	0.3249	0.3214	0.8977

表 8-3 条件矩与共同对照的固定 K 模拟结果

方法	六场景 FDP@12	Power@12	共同模拟 RMSE
XGBoost-SHAP	0.2629	0.9678	0.9631
TabM-随机对称差	0.2739	0.9547	0.9643
TabM-标准化对称差	0.3214	0.8977	0.9732
XGB-SKO-Ridge	0.5064	0.6757	1.0480
XGB-SKO-非线性均值	0.3453	0.8690	0.9848
XGB-SKO-尺度	0.4629	0.7278	1.0275
XGB-SKO-均值尺度	0.3247	0.8937	0.9767
TabM-SKO-Ridge	0.4829	0.7038	1.0433
TabM-SKO-非线性均值	0.3140	0.9065	0.9758
TabM-SKO-尺度	0.4529	0.7398	1.0278
TabM-SKO-均值尺度	0.3090	0.9125	0.9733

表 8-4 $q=.10$ 敏感性，预定主候选

主候选	场景	平均 FDP	Power	发现数
TabM-标准化对称差	全无效	0.0100	不定义	0.11
TabM-标准化对称差	高相关线性	0.0477	0.1880	2.54
TabM-标准化对称差	线性稀疏	0.0167	0.0300	0.34
TabM-标准化对称差	t 生成错误	0.0325	0.0440	0.82
TabM-标准化对称差	已知混合变换	0.0602	0.3270	3.96
TabM-标准化对称差	强非线性	0.0607	0.2740	3.45
TabM-标准化对称差	弱非线性	0.0399	0.0900	1.37
TabM-标准化对称差	纯交互	0.0588	0.5260	5.96
TabM-SKO-均值尺度	全无效	0.0000	不定义	0.00
TabM-SKO-均值尺度	高相关线性	0.0542	0.3990	4.64
TabM-SKO-均值尺度	线性稀疏	0.0387	0.0700	0.79
TabM-SKO-均值尺度	t 生成错误	0.0109	0.0230	0.36
TabM-SKO-均值尺度	已知混合变换	0.0667	0.4760	5.55
TabM-SKO-均值尺度	强非线性	0.0479	0.4540	5.14
TabM-SKO-均值尺度	弱非线性	0.0223	0.0830	1.07
TabM-SKO-均值尺度	纯交互	0.0569	0.7340	8.08

表格均由案例 JSON 与逐行预测 CSV 生成。相同输入哈希、排名、两种原生阈值、模拟 FDP/Power、预测指标以及相同集合预测一致性逐项核对。模拟失败不丢弃，空集采用均值预测，不以零值填补未运行模型。源码初始和最终摘要、软件版本、作者代码及日志在工程中保留。

预测 CSV 的 float32 序列化后以 float64 复算可产生约 10^{-8} 量级差异，采用明确数值容差。系统矩阵乘法警告保留，并进行有限值与替代计算核验，不通过关闭警告隐藏失败。完整工程与正式六份 TeX/PDF 分开，签名和审批意见留空。

本文借助自动化计算和写作工具形成；作者与导师须复核统计论证、引文与署名，并遵守学校关于 AI 辅助和学术诚信的规定。