

上海财经大学

研究生申请学位论文开题报告表

姓名	吴优	学院	统计与数据科学学院
学号	2025213385	导师姓名	张吕欧
专业	应用统计	培养层次	专业硕士
同意开题		导师签字:	
论文题目	面向电商 GMV 监控的深度特征选择与稳定性评价研究		
开题时间	开题地点:		
与会专家姓名、 单位 (3-5 人)			
开题报告情况	专家主要意见:		
开题结果 (划 圈)	开题通过, 同意进入论文写作阶段。 / 开题未通过, 不同意进入论文写作阶段。 开题报告会专家组组长签名: 导师签名: 年 月 日		

注: 开题意见、结果与签名由相关教师和专家填写。附: 上海财经大学研究生学位论文开题报告书。

上海财经大学

研究生学位论文开题报告书

论文题目：面向电商 GMV 监控的
深度特征选择与稳定性评价研究

姓 名： 吴优

学 号： 2025213385

院系所： 统计与数据科学学院

专 业： 应用统计

培养层次： 专业硕士

导师姓名： 张吕欧

二〇二六年九月

1 选题背景与研究问题

电商经营看板包含交易、商品、支付、履约和市场覆盖等大量指标。研究拟在有限展示容量下选择值得持续监控的指标，并评价名单对卖家样本变化的敏感性。本文以本月 31 项指标与下一月签收确认商品金额的预测关系为评价基础，不将预测重要性解释为当期金额拆解或因果效应。

近期深度特征选择提供了输入梯度正则、序列子集搜索和参数高效集成等新工具，但其在真实电商面板上的增量价值仍需要与稀疏回归、树模型和 Knockoff 对照检验。研究不预设复杂方法必须胜出，而围绕信息保留、稳定性和误选边界建立统一评价。

2 文献依据与方法

Lasso 与 Elastic Net 提供可解释的稀疏基准 [1, 2]；稳定性选择与互补半样本为样本扰动设计提供依据 [3, 4]；Nogueira 指标用于机会校正稳定性 [5]。Model-X、MVR、多轮 e-value 与 e-BH 构成带有明确假设的 Knockoff 参照 [13, 14, 15, 16]。

深度候选包括 2023 年的 Deep Lasso、2024 年的 VTFS 与 DeepDRK，以及 2025 年的 TabM 和 TabPFN v2[18, 19, 21, 20, 22]。Deep Lasso 调用官方输入梯度惩罚；TabM 使用官方网络并附加验证置换排序；VTFS 使用官方 Transformer 骨干进行定额适配。DeepDRK 完成三种子训练后出现生成诊断警告；TabPFN 在完整样本上出现 MPS 内存错误，均不冒充完成全部比较。

表 1: 方法及完成范围

方法	文献年份	本研究输出/范围
Copula-MVR 聚合	2018/2022/2024	生成负对照、原生名单和排名； 诊断有警告
Elastic Net	2005	非零集合与系数排名
稳定性选择	2010/2013	Lasso 频率阈值与排名，经验适配
影子变量树	2006/2010	Extra Trees 影子比较，不是完整 Boruta
XGBoost-SHAP	2016/2017/2020	树模型解释排名
Deep Lasso	2023	官方输入梯度惩罚与 MLP 训练

方法	文献年份	本研究输出/范围
VTFS 定额适配	2024	官方 Transformer 骨干；固定预算和语料适配
TabM 置换	2025	官方集成网络；额外置换排名
DeepDRK 适配	2024	三种子训练和诊断后退出完整比较
TabPFN v2	2025	预训练模型；MPS 兼容失败
attention-like 过滤法	2024	仅文献核验，未计入训练结果

3 数据与信息时间

数据来自 Olist 电商与营销漏斗公开数据集 [24, 25]。十张原始表中包含 99,441 条订单和 112,650 条商品明细。支付、评价先按自然层级聚合，商品金额由明细价格求和，运费不计入目标，避免多对多连接放大金额。

物流与评价仅使用月末已发生的事件，营销成交按成交日期截断。最终得到 13,754 个卖家月、2,723 名卖家、18 个特征月份与 31 项指标，下一月零值率 17.8784%。主目标为下一月按真实签收月份确认的商品金额的 $\log(1+GMV)$ ，不是按购买月份回溯的最终送达金额。支付与元数据没有完整修订时间，其购买时可得性仍是工作假设。

表 2: 研究窗口

阶段	目标月份	行数	卖家数	用途
训练	2017-02 至 2017-12	6567	1694	预处理与模型拟合
调参	2018-01 至 2018-02	1831	1175	冻结配置
排序	2018-03 至 2018-04	1943	1219	名单、早停、开发选择
测试	2018-05 至 2018-07	3413	1680	仅评价

4 核心方法与公平原则

所有方法使用相同卖家抽样清单。30 组互补 50% 样本产生 60 个半样本，另运行 20 个 70% 和 20 个 80% 样本。同一卖家保留全部相应月份。主预算为 12 项，另比较 4、8、10 和 14 项；下游 XGBoost 与 TabM 配置对所有选择器一致。固定数据的 10 组种子试验与样本扰动结果分别报告。

Deep Lasso 优化预测损失及输入梯度组惩罚：

$$\mathcal{L}_{DL} = \mathcal{L}_B + \lambda \sum_j \|\partial \mathcal{L}_B / \partial X_{B,j}\|_2.$$

TabM 的 8 个集成成员分别计算训练损失，推断时平均；验证列置换增加的 MSE 作为重要性。VTFS 用 96 个随机子集效用训练编码器和解码器，在不超过 128 次查询内按预设 K 形成名单，明确保留随机语料回退与固定编号顺序的适配限制。

Knockoff 采用真假系数绝对值差 W，60 轮证据聚合后用 e-BH 生成原生名单。单轮 0.10、最终 0.20 和 高频入选是不同概念；强制 Top-K 集合不自动继承 FDR 保证。所有实际 FDR 声明还依赖生成有效性与依赖结构条件。

5 已完成的实证与模拟

八种方法各完成 111 个真实选择案例和 600 个模拟案例，形成 82 组统一预测产物。测试结果没有支持近期深度模型全面领先。

表 3: 主预算测试表现

选择方法	XGB-RMSE	TabM-RMSE	XGB-MAE	XGB-R ²	XGB-WAPE
Copula-MVR	1.8663	1.8945	1.3566	0.4894	0.5269
Elastic Net	1.8626	1.8737	1.3542	0.4914	0.5279
稳定性选择	1.8931	1.8840	1.3620	0.4746	0.5308
影子变量树	1.8606	1.8634	1.3494	0.4925	0.5281
XGBoost-SHAP	1.8464	1.8572	1.3442	0.5003	0.5276
Deep Lasso	1.8467	1.8600	1.3467	0.5001	0.5248
TabM-置换	1.8443	1.8597	1.3435	0.5014	0.5232

选择方法	XGB-RMSE	TabM-RMSE	XGB-MAE	XGB-R ²	XGB-WAPE
VTFS-定额适配	1.8625	1.8851	1.3592	0.4915	0.5312
全维基线	1.8649	1.8588	1.3404	0.4902	0.5232

TabM 置换与 Deep Lasso 在 XGBoost 评价器下接近最优，但在 TabM 评价器下 XGBoost-SHAP 仍很强。开发期选出的 VTFS 适配模型没有保持样本外优势，不在测试后更换主方法以制造胜出结论。

表 4: 样本稳定性

方法	50% 均值 [组级 95% 区间]	70% 均值	80% 均值	50% Nogueira
Copula-MVR	0.7355 [0.7131, 0.7578]	0.7508	0.8077	0.6798
Elastic Net	0.7244 [0.6979, 0.7509]	0.8385	0.9088	0.6185
稳定性选择	0.5827 [0.5614, 0.6041]	0.6619	0.7018	0.4788
影子变量树	0.9388 [0.9233, 0.9544]	0.9615	0.9923	0.9210
XGBoost-SHAP	0.7682 [0.7501, 0.7862]	0.8470	0.8220	0.7439
Deep Lasso	0.8230 [0.7962, 0.8498]	0.8868	0.7615	0.7754
TabM-置换	0.7505 [0.7196, 0.7813]	0.8780	0.8934	0.7304
VTFS-定额适配	0.4068 [0.3377, 0.4758]	0.4814	0.2972	0.2733

影子变量树在半样本名单一致性上突出；固定数据种子稳定性与更换卖家的稳定性不可混同。完整样本的 VTFS 最终名单与随机语料回退相同，不能将这次选择收益归功于深度解码器。

模拟包括六场景、每场景 100 次，已知真信号后分别评价原生名单和 Top-K 的 FDP 及 Power。固定 12 项且只有 5 项真信号时，FDP 至少为 7/12，不能据此混用原生错误率与容量约束。Copula-MVR 原生规则在六场景中的平均 FDP 范围为 0.0000 至 0.0549，平均 Power 范围为 0.0000 至 0.9960。这是当前有限场景、固定配置的经验结果；观察均值低于目标不能证明所有分布上的 FDR 控制，检出率低也必须与空名单和阈值约束结合解释。

6 可行性、限制与后续计划

数据处理、官方代码适配、重复实验与结果汇总均已实际完成，后续工作的重点转向外部验证与针对性方法改进。本文的应用统计工作是将时间可见性、相同样本扰动、双评价器、容量路径和生成诊断落实到同一研究任务，并明确它们分别回答的问题。

当前需要注意三项边界：公开数据静态快照不能完全还原实时可见性；三个月测试期不足以验证长期漂移；Copula-MVR 与本次 DeepDRK 均出现联合交换性诊断警告，真实数据不能无条件宣称 FDR 受控。

后续优先补充新的时间外数据；进一步研究重新调参后的全流程稳定性；对 VTFS 实施独立 K 优化与等查询预算随机搜索对照；对生成器开展卖家层诊断及独立训练；最后评估月度名单在周度业务预警中的可迁移性。这些扩展尚待验证，不计入当前完成结论。

参考文献

- [1] Tibshirani R. Regression shrinkage and selection via the lasso[J]. Journal of the Royal Statistical Society, Series B, 58(1), 267-288, 1996. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>.
- [2] Zou H, Hastie T. Regularization and variable selection via the elastic net[J]. Journal of the Royal Statistical Society, Series B, 67(2), 301-320, 2005. <https://doi.org/10.1111/j.1467-9868.2005.00503.x>.
- [3] Meinshausen N, Bühlmann P. Stability selection[J]. Journal of the Royal Statistical Society, Series B, 72(4), 417-473, 2010. <https://doi.org/10.1111/j.1467-9868.2010.00740.x>.
- [4] Shah R D, Samworth R J. Variable selection with error control: another look at stability selection[J]. Journal of the Royal Statistical Society, Series B, 75(1), 55-80, 2013. <https://doi.org/10.1111/j.1467-9868.2011.01034.x>.
- [5] Nogueira S, Sechidis K, Brown G. On the Stability of Feature Selection Algorithms[J]. Journal of Machine Learning Research, 18(174), 1-54, 2018. <https://www.jmlr.org/papers/v18/17-514.html>.
- [6] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. Proceedings of KDD, 785-794, 2016. <https://doi.org/10.1145/2939672.2939785>.
- [7] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[C]. Advances in Neural Information Processing Systems, 30, 2017. <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>.

- [8] Lundberg S M, Erion G, Chen H, et al. From local explanations to global understanding with explainable AI for trees[J]. *Nature Machine Intelligence*, 2, 56-67, 2020. <https://doi.org/10.1038/s42256-019-0138-9>.
- [9] Kursa M B, Rudnicki W R. Feature Selection with the Boruta Package[J]. *Journal of Statistical Software*, 36(11), 1-13, 2010. <https://doi.org/10.18637/jss.v036.i11>.
- [10] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees[J]. *Machine Learning*, 63, 3-42, 2006. <https://doi.org/10.1007/s10994-006-6226-1>.
- [11] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing[J]. *Journal of the Royal Statistical Society, Series B*, 57(1), 289-300, 1995. <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>.
- [12] Barber R F, Candès E J. Controlling the false discovery rate via knockoffs[J]. *The Annals of Statistics*, 43(5), 2055-2085, 2015. <https://doi.org/10.1214/15-AOS1337>.
- [13] Candès E, Fan Y, Janson L, Lv J. Panning for gold: model-X knockoffs for high dimensional controlled variable selection[J]. *Journal of the Royal Statistical Society, Series B*, 80(3), 551-577, 2018. <https://doi.org/10.1111/rssb.12265>.
- [14] Spector A, Janson L. Powerful knockoffs via minimizing reconstructability[J]. *The Annals of Statistics*, 50(1), 252-276, 2022. <https://doi.org/10.1214/21-AOS2104>.
- [15] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for false discovery rate control[J]. *Journal of the Royal Statistical Society, Series B*, 86(1), 122-154, 2024. <https://doi.org/10.1093/jrsssb/qkad085>.
- [16] Wang R, Ramdas A. False discovery rate control with e-values[J]. *Journal of the Royal Statistical Society, Series B*, 84(3), 822-852, 2022. <https://doi.org/10.1111/rssb.12489>.
- [17] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. *Journal of Multivariate Analysis*, 88(2), 365-411, 2004. [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4).
- [18] Cherepanova V, Levin R, Somepalli G, et al. A Performance-Driven Benchmark for Feature Selection in Tabular Deep Learning[C]. *NeurIPS Datasets and Benchmarks Track*, 2023. <https://openreview.net/forum?id=v4PMCdSaAT>.
- [19] Ying W, Wang D, Chen H, Fu Y. Feature Selection as Deep Sequential Generative Learning[J]. *ACM Transactions on Knowledge Discovery from Data*, 18(9), Article 221, 2024. <https://doi.org/10.1145/3687485>.

- [20] Gorishniy Y, Kotelnikov A, Babenko A. TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling[C]. International Conference on Learning Representations, 2025. <https://openreview.net/forum?id=Sd4wYYOhmY>.
- [21] Shen H, Yan Y, Zhao Z. DeepDRK: Deep Dependency Regularized Knockoff for Feature Selection[C]. Advances in Neural Information Processing Systems, 2024. <https://openreview.net/forum?id=ibKpPabHVn>.
- [22] Hollmann N, Muller S, Purucker L, et al. Accurate predictions on small data with a tabular foundation model[J]. Nature, 637, 319-326, 2025. <https://doi.org/10.1038/s41586-024-08328-6>.
- [23] Pham H, Tan Y, Singh T, Pavlopoulos V, Patnayakuni R. A multi-head attention-like feature selection approach for tabular data[J]. Knowledge-Based Systems, 301, 112250, 2024. <https://doi.org/10.1016/j.knosys.2024.112250>.
- [24] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle dataset, 2018. <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>.
- [25] Olist. Marketing Funnel by Olist[DB/OL]. Kaggle dataset, 2018. <https://www.kaggle.com/datasets/olistbr/marketing-funnel-olist>.
- [26] Morris T P, White I R, Crowther M J. Using simulation studies to evaluate statistical methods[J]. Statistics in Medicine, 38(11), 2074-2102, 2019. <https://doi.org/10.1002/sim.8086>.