



学校代码: 10272

学 号: 2025213385

上海财经大学

SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS

硕 士 学 位 论 文

MASTER DISSERTATION

(专 业 硕 士)

论文题目: 面向电商 **GMV** 监控的
深度特征选择与稳定性评价研究

培养院系: 统计与数据科学学院

论文类别: 应用统计硕士专业学位论文

论文作者: 吴优

指导教师: 张吕欧

完成日期: 2026 年 9 月

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本人的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名： 日期： 年 月 日

学位论文版权使用授权书 (硕士学位论文用)

本人完全了解上海财经大学关于收集、保存、使用学位论文的规定，即：按照有关要求提交学位论文的印刷本和电子版本。上海财经大学有权保留并向国家有关部门或机构送交本论文的复印件和扫描件，允许论文被查阅和借阅。本人授权上海财经大学可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

论文作者签名：	导师签名：
日期： 年 月 日	日期： 年 月 日

摘 要

电商经营看板通常同时展示交易、商品、支付、履约和地域等大量指标。指标间的相关性使信息重复，而有限的展示容量又要求管理者在预测信息、名单稳定性和误选风险之间进行权衡。深度特征选择能够表达非线性关系，但模型复杂度、验证集搜索和算法随机性可能使其在具体业务数据上的优势弱于公开基准中的表现。本文围绕下一月签收确认商品金额的监控，研究近期深度特征选择方法在统一评价条件下的适用性，并将固定数量的指标推荐与具有假设前提的错误发现率控制明确区分。

研究使用 Olist 公开的十张业务表，按照事件发生时间重建月末可见特征，得到 13,754 个卖家月观测、2,723 名卖家和 31 项候选指标。训练、调参、排序与测试阶段按目标月份划分，测试期为 2018 年 5 至 7 月。比较方法包括 Copula-MVR、Elastic Net、稳定性选择、影子变量树、XGBoost-SHAP、Deep Lasso、TabM 置换排序及 VTFS 定额适配。各方法共享 30 组互补半样本、20 组 70% 样本与 20 组 80% 样本，另设置 10 组固定数据算法随机性试验；在两个统一下游评价器中比较五种变量预算。六种已知真值的模拟场景各重复 100 次，用于分别评价原生名单和固定预算名单。

实际数据结果表明，复杂模型并不形成一致优势。在 12 项预算下，TabM 置换排序和 Deep Lasso 经统一 XGBoost 评价器得到的测试对数 RMSE 分别为 1.8443 和 1.8467，XGBoost-SHAP 为 1.8464；改用 TabM 评价器后，XGBoost-SHAP 为 1.8572，TabM 置换排序为 1.8597。开发期选中的 VTFS 适配模型在两种评价器下分别为 1.8625 和 1.8851，未保持开发集优势。50% 卖家抽样中，影子变量树与完整开发名单的平均 Jaccard 为 0.9388，Deep Lasso 为 0.8230，VTFS 适配模型为 0.4068。交换性诊断同时发现 Copula-MVR 和本次 DeepDRK 适配生成器存在联合分布失配，因而不对真实数据给出无条件 FDR 保证。

本文的应用价值在于形成按时间可见性构建数据、按相同样本扰动比较方

法、按展示容量评价信息保留、按诊断结果限定统计结论的研究流程。结果支持将近期深度模型纳入候选工具，但不支持以方法新颖或结构复杂替代样本外证据。指标名单应作为与目标口径、时间窗口和评价器相关的监控建议，而非因果归因或永久有效的准入结论。

关键词：电商经营监控；深度特征选择；表格深度学习；样本稳定性；错误发现率

Abstract

E-commerce monitoring systems contain many correlated indicators, while dashboard capacity is limited. This study evaluates recent deep feature selection methods for monitoring next-month delivered merchandise value, separating fixed-budget recommendations from error-controlled discoveries under explicit assumptions.

Ten public Olist tables are joined at their natural aggregation levels, and timestamped predictors are restricted to information available at the end of the feature month. The resulting panel contains 13,754 seller-month observations, 2,723 sellers, and 31 predictors. Training, tuning, ranking, and testing are separated by target month. Eight selectors share 30 complementary half-sample pairs, twenty 70-percent samples, twenty 80-percent samples, and ten algorithm-randomness batches. Five feature budgets are evaluated using common XGBoost and TabM predictors. Six simulation scenarios, each repeated 100 times, distinguish native selection rules from fixed-budget false discovery proportions and power.

At a budget of twelve features, TabM permutation ranking and Deep Lasso achieve test log-scale RMSE values of 1.8443 and 1.8467 with the XGBoost evaluator, compared with 1.8464 for XGBoost-SHAP. With the TabM evaluator, XGBoost-SHAP reaches 1.8572 and TabM permutation ranking reaches 1.8597. The development-selected VTFS adaptation does not retain its validation advantage. Under half-sampling, mean Jaccard agreement with the full development-data selection is 0.9388 for shadow trees, 0.8230 for Deep Lasso, and 0.4068 for the VTFS adaptation. Joint swap diagnostics raise warnings for both Copula-MVR and the adapted DeepDRK generator, precluding an unconditional real-data FDR

claim.

The study contributes an auditable application workflow rather than a new statistical theorem. Recent deep models provide useful alternatives, but increased complexity does not ensure consistently better prediction, stability, or discovery quality. Recommendations remain conditional on the outcome definition, observed time period, evaluation model, and implementation choices.

Keywords: e-commerce monitoring; deep feature selection; tabular deep learning; selection stability; false discovery rate

目 录

摘要	I
Abstract	III
第一章 绪论	1
1.1 研究背景	1
1.2 研究问题与范围	1
1.3 评价目标的多面性	2
1.4 研究思路	2
第二章 相关研究与方法依据	4
2.1 稀疏回归与重抽样选择	4
2.2 树模型与特征重要性	4
2.3 Knockoff 与错误发现率控制	5
2.4 近期深度方法	5
2.5 本文与既有工作的关系	6
第三章 数据来源与月末可见面板	8
3.1 数据来源及连接层级	8
3.2 信息时间与目标定义	8
3.3 样本人口与时间切分	9
3.4 候选指标及缺失值	10
3.5 训练期预处理	11
第四章 特征选择方法与实现	13
4.1 原生名单与固定预算名单	13
4.2 统计与树模型基线	13
4.3 Copula-MVR 与多轮证据聚合	14
4.4 Deep Lasso	15

4.5	TabM 与验证置换排序	16
4.6	VTFS 定额适配	16
4.7	DeepDRK 与未进入完整比较的候选	17
第五章	公平实验设计	18
5.1	时间分工与调参预算	18
5.2	公共卖家抽样	18
5.3	稳定性指标与区间	19
5.4	统一预测评价器	20
5.5	主选择规则与分析修订	20
第六章	实际数据结果	22
6.1	同预算预测表现	22
6.2	配对误差差异	22
6.3	样本稳定性与参考名单	24
6.4	算法随机性与样本扰动	25
6.5	容量路径与具体名单	26
6.6	局部消融与计算成本	28
第七章	已知真值模拟与生成诊断	31
7.1	模拟目标与数据生成	31
7.2	FDP、Power 与 Monte Carlo 误差	32
7.3	固定预算结果	32
7.4	原生名单结果	34
7.5	真实数据的联合交换性诊断	37
7.6	实验覆盖与不能推出的结论	38
第八章	讨论与结论	39
8.1	主要研究结论	39
8.2	对经营监控的启示	39

8.3 局限性	40
8.4 后续研究	41
参考文献	42
附录 A 变量字典	46
附录 B 实现差异与复现约定	48

第一章 绪论

第一节 研究背景

经营指标体系的建设不仅涉及“能够统计什么”，还涉及“应当持续观察什么”。电商平台从下单到签收的业务链条可产生订单数、商品价格、支付分期、运费、物流时效、评价和市场覆盖等指标。如果所有指标同时进入看板，管理者可能在相互重复的信号中反复切换，而难以识别真正需要跟踪的经营状态。另一方面，直接删除相关指标也存在风险：两个高度相关的变量可能在总体趋势上相似，却在不同卖家或不同时间阶段提供不同信息。

本文将有限容量看板的指标配置表述为特征选择问题。业务目标不是建立尽可能复杂的预测模型，而是在给定候选信息的条件下，找到能够较好保留下一期目标信息、并且对合理数据扰动不过度敏感的较小指标集合。预测任务为这一选择提供可检验的评价标准：若删除大量指标后样本外预测误差明显上升，说明压缩过程中损失了与目标有关的信息；若误差变化很小，则较小集合可能具有监控上的实用价值。

这一思路仍不能覆盖经营分析的全部含义。按州、品类或渠道拆分当期GMV，考察各部分对总量变化的会计贡献，属于描述性分解；观察某项指标是否有助于预测下一期GMV，属于预测性特征选择；判断改变某项业务策略将引起多少GMV变化，则属于因果推断。三者可以相互补充，但使用相同业务名称不意味着研究对象相同。

第二节 研究问题与范围

本文研究三个相互关联的问题。第一，近期深度特征选择方法在小到中等规模、混合分布且存在卖家内相关的电商面板上，能否在相同变量预算下保留更多预测信息？第二，改变参与分析的卖家后，不同方法的指标名单是否保持一致，固定数据的算法随机性与样本变化的影响有何区别？第三，在已知真值的模

拟和真实数据的生成诊断中，预测型排序与错误率控制型选择之间存在哪些不可混同的边界？

主分析单位为特征月有购买商品明细的卖家。目标为同一卖家下一自然月签收确认的商品金额，不含运费。本文使用“GMV”作为这一经营目标的简写，涉及具体金额口径时均指签收月确认金额。它既不等于下单时的预计成交金额，也不等于净收入、利润或扣除全部售后退款后的会计收入。公开数据没有提供覆盖所有修订的完整事件日志，因而研究不是生产环境实时账本的完整重放。

候选集合包含 31 项数值型经营特征。品类和州等原始分类字段经业务聚合形成品类数、州数量及占比，而非为每个分类枚举构造一个独立模型参数。因此，本文的“维度”主要指聚合后的经营指标，不是多维分析系统中所有可下钻的分类轴。研究范围限定为月度下一期监控，不将日度或周度效果视为已经验证的结论。

第三节 评价目标的多面性

“最好”的指标集合没有脱离任务的统一定义。最小预测误差偏向保留所有有用的弱信号；最小展示数量偏向较强的压缩；最高稳定性可能偏向重复选择少数强相关代理；控制错误发现率则允许在证据不足时不作发现。不同目标之间可能发生冲突。例如，一个总是返回固定名单的方法具有很高的形式稳定性，却未必包含目标信息；一个强制返回 12 项的程序也可能在只有 5 项真信号的场景中产生较高 FDP。

因此，本文不把多个指标任意加权成一个总分，也不以某一张最有利的结果表决定方法优劣。主预算预先设为 12 项，4、8、10 和 14 项作为容量路径；在相同下游预测器中比较误差，在相同卖家抽样中比较名单，在已知支持集的模拟中评价误选与检出。指标的单位、分母和适用条件分别报告。

第四节 研究思路

研究流程依次包括数据口径审计、方法实现与来源核验、时间分段调参、公共样本扰动、统一预测评价、已知真值模拟和结论边界诊断。数据处理首先解决

“信息何时可见”；外层抽样解决“是否受到相同的数据挑战”；下游评价器解决“名单信息与预测器能力是否混在一起”；原生名单与 Top-K 并列报告解决“控制误选和满足展示容量是否被当作同一件事”。

本文定位为应用统计研究，不提出新的 Knockoff 有效性定理，也不把公开模型的组合命名为新算法。方法适配的目的在于完成目标明确、可比较的业务实验。针对生成器、基础模型和序列选择器的失败或限制，均按其实际完成范围报告。这种设计允许研究得出“不存在全面优胜者”的结论，而不是预设某一种方法必须获胜。

第二章 相关研究与方法依据

第一节 稀疏回归与重抽样选择

Lasso 通过绝对值惩罚同时进行系数收缩与变量选择^[1]。在多个变量高度相关时，某个变量被选中而另一个被排除，可能主要体现同类信息的竞争，而非后者毫无价值。Elastic Net 加入平方惩罚，缓解相关变量下的解不稳定，并提供可解释的线性基准^[2]。这类方法的稀疏性由惩罚参数决定，但一般的交叉验证或时间验证选参并不直接保证发现集合的 FDR。

Meinshausen 与 Bühlmann 提出稳定性选择，通过反复子抽样统计变量入选频率^[3]。Shah 与 Samworth 进一步研究互补成对抽样下的错误控制^[4]。这些文献为样本扰动的设计提供依据，但其理论界需要特定选择规则与假设；仅仅采用“50% 样本”或“高频入选”并不能自动获得相同保证。本文将重抽样作为所有方法的外层评价工具，同时设置一个基于 Lasso 频率的经验稳定性选择基线。

Nogueira 等系统研究特征选择稳定性的定义与统计性质，指出集合大小会影响朴素稳定性指标^[5]。本文通过固定 K 降低数量混杂，并同时报告 Jaccard 与机会校正稳定性。外层评价的重点是名单对同一数据扰动的敏感程度，而不是使所有方法拥有相同的内部随机重复次数。

第二节 树模型与特征重要性

XGBoost 以加性树模型表达非线性与交互关系^[6]。SHAP 将模型预测分配到不同特征，TreeSHAP 针对树结构提供高效归因计算^[7,8]。对验证样本的绝对 SHAP 值取平均，可以得到全局重要性排名。然而，排名依赖已拟合模型、特征依赖结构和解释规则，不能直接解释为条件独立检验的显著性，也不是业务干预的因果效应。

影子变量方法通过打乱真实变量建立负对照。Boruta 是这一思想的代表实现^[9]，Extra Trees 则提供极端随机化的树集成^[10]。本文结合两者构造有限轮次

的影子变量树基线，使用真实重要性超过当轮最大影子重要性的频率排序。由于没有逐项实现 Boruta 的全部检验、决策和停止规则，正文将其称为“影子变量树”，不将其性能归属于完整 Boruta 原算法。

第三节 Knockoff 与错误发现率控制

Benjamini 与 Hochberg 提出 FDR 准则，将多重检验中的错误比例作为整体控制对象^[11]。Barber 与 Candès 提出 Knockoff 过滤器^[12]，Candès 等将其发展为 Model-X 框架^[13]。后者通过满足交换性条件的仿制变量，为真实变量提供具有可比性的负对照，从而利用灵活的统计量检验条件预测信息。

Spector 与 Janson 提出最小可重构性思想，说明单纯减小真假变量相关性未必带来高功效^[14]。Ren 与 Barber 利用 e-value 形式聚合多次 Knockoff 结果，以降低生成随机性对发现名单的影响^[15]；Wang 与 Ramdas 研究 e-BH 的 FDR 控制性质^[16]。这些方法的价值是明确错误控制对象及其条件，而不是保证任何数据、生成器和后处理方案都能获得有效结论。

本文的 Copula-MVR 先进行训练经验分布变换，再估计高斯联合结构。它可以改善偏态边际，但不能仅凭每列接近正态就证明联合高斯。协方差收缩用于提高数值稳定性^[17]，同样不能替代联合分布正确性。对于真实面板，联合交换性、组内依赖、经验变换及重复使用样本共同构成理论应用边界。

第四节 近期深度方法

Deep Lasso 出自 2023 年的表格深度特征选择基准研究^[18]。该方法对损失关于输入的梯度施加组稀疏惩罚，使网络训练与输入选择相联系。其新颖性不在于将普通 MLP 换一个名称，而在于输入梯度正则所定义的训练目标。本文直接调用官方正则函数，同时披露骨干网络和训练参数。

VTFS 将特征子集表示为序列，通过变分 Transformer 学习子集表示与效用，再在潜在空间中搜索新的序列^[19]。本文使用官方编码器与解码器，但把输出适配为固定容量的无重复特征顺序，并使用有限随机子集语料。这一改动适合比较不同 K，却使本实现不同于原文完整的自动停止与语料采集流程。相关

结果只归属于本文明确说明的定额适配，不能作为对原论文整体性能的复现结论。

TabM 是 2025 年提出的参数高效集成表格神经网络^[20]。多个成员共享主要权重，并保留成员特定参数，从而在较小参数增量下模拟集成。本研究使用官方软件包训练 TabM，再以验证集置换误差构造特征排名。置换步骤是额外的选择适配；TabM 本身既不是原生 FDR 程序，也不自动给出最终展示容量。

DeepDRK 使用 Transformer 生成器、多 Swapper 对抗训练与依赖正则构造 Knockoff^[21]。TabPFN v2 则以预训练基础模型处理小规模表格任务^[22]。两者均经过实际计算尝试，但前者在本次适配中触发生成诊断警告，后者出现 MPS 内存兼容错误。论文另外核验了一篇多头 attention-like 筛选论文^[23]；其方法被原文定义为过滤型，本文未将其冒充为已完成训练的深度网络。

表 2-1 候选方法、文献年代与本研究角色

方法	文献年份	本研究输出/范围
Copula-MVR 聚合	2018/2022/2024	生成负对照、原生名单和排名；诊断有警告
Elastic Net	2005	非零集合与系数排名
稳定性选择	2010/2013	Lasso 频率阈值与排名，经验适配
影子变量树	2006/2010	Extra Trees 影子比较，不是完整 Boruta
XGBoost-SHAP	2016/2017/2020	树模型解释排名
Deep Lasso	2023	官方输入梯度惩罚与 MLP 训练
VTFS 定额适配	2024	官方 Transformer 骨干；固定预算和语料适配
TabM 置换	2025	官方集成网络；额外置换排名
DeepDRK 适配	2024	三种子训练和诊断后退出完整比较
TabPFN v2	2025	预训练模型；MPS 兼容失败
attention-like 过滤法	2024	仅文献核验，未计入训练结果

第五节 本文与既有工作的关系

上述文献分别贡献了稀疏估计、集成预测、深度表示、子集搜索或错误控制机制。本文关注它们在同一实际任务中的可比较性，而非重新证明这些机制。

研究的具体工作是把数据可见性、展示预算、卖家层抽样、双评价器和原生错误率口径连接起来，并检验近期深度方法的收益是否能够同时体现在预测和名单稳定性上。

因此，文献发表较新仅决定候选范围，不能替代适用性验证。作者代码可获得也不意味着跨设备、跨任务适配毫无差异。本文对成功运行、适配后运行、诊断后退出和兼容失败四类情形分别记录，以避免把文献真实性、实现忠实度和本地实验效果混为一谈。

第三章 数据来源与月末可见面板

第一节 数据来源及连接层级

研究数据来自 Olist 公开电商交易数据集与营销漏斗数据集^[24,25]。实际读取订单、商品明细、支付、评价、商品、卖家、顾客、地理位置、营销合格线索及营销成交十张 CSV。订单表包含 99,441 条订单记录，商品明细表包含 112,650 条记录。多个商品明细、多个支付记录或多个评价记录可能对应同一订单，因此直接按订单编号展开连接会重复计算金额。

本文先在支付表中按订单汇总金额，并以支付金额加权计算分期期数；评价仅在时间可见的记录中按订单平均；地理数据按邮编前缀计算经纬度中位数。随后将订单信息连接到商品明细，再按卖家与月份汇总。支付和物流指标在卖家订单级去重后平均，避免同一订单因多件商品而重复加权；商品属性、件数及部分地域构成以商品明细为权重。两种聚合口径各自对应不同业务对象，不能笼统称为所有变量均“按订单平均”。

商品金额始终由商品明细价格求和，运费单列保存而不进入目标。全源表具有送达时间记录的商品金额对账合计为 13,220,895.11 巴西雷亚尔。该金额是数据连接的核验量，并非仅指最终研究面板所覆盖的卖家月目标之和。

第二节 信息时间与目标定义

设卖家为 s ，特征月份为 t ，月末信息截止点为下一月第一日。主目标定义为

$$G_{s,t+1} = \sum_{i: \text{seller}(i)=s, \text{deliverymonth}(i)=t+1} \text{price}_i, \quad Y_{s,t+1} = \log(1 + G_{s,t+1}).$$

使用对数尺度的原因是卖家金额存在长尾与零值；它使相对变化获得更多权重，并减轻少数大额观测对平方损失的支配。对数变换并不消除零值过程的特殊性，因此本文同时报告原金额尺度的 WAPE，作为补充而非替代。

物流特征只使用截止点之前已发生的审核、承运和送达事件。评价使用回答时间，而非仅使用订单购买月份。营销成交仅在成交日期早于截止点时进入特征，其来源频率也在当时已可见的成交记录中计算。卖家州频率以当时已经观察到购买活动的卖家为基数，不使用未来才出现的卖家扩充历史分母。

按全源表计数，时间遮蔽涉及 1,684 条审核记录、9,432 条承运记录、36,430 条送达时长记录和 47,439 条晚于截止点的评价记录。上述数字反映信息回溯风险的规模，但不能解读为相同数量的最终面板行被删除：一名卖家一个月可包含多条订单，并且部分指标仍能由当月其他可见记录计算。

支付记录与商品、卖家元数据缺少完整修订时间，地理表也不是逐月历史快照。本文只能将这些信息在购买时可得作为工作假设。对于无法从公开字段验证的历史可见性，不作完全消除信息泄漏的强声明。

第三节 样本人口与时间切分

特征月范围为 2017 年 1 月至 2018 年 6 月，共 18 个月。样本要求特征月存在购买商品明细，不先按最终订单状态过滤本月特征，以免将未来的最终交付状态提前用于样本选择。如果次月没有签收商品金额记录，则在当前分析人口中记为零。所得面板包含 13,754 行、2,723 名卖家，下一月目标为零的比例为 17.8784%。

这一人口定义排除了特征月没有购买明细的卖家，即使其下一月可能完成较早订单的签收。因此，结果适用于当前购买活跃卖家的下一期签收监控，不直接外推到平台全部注册卖家、所有无活跃月份或冷启动卖家。

表 3-1 按目标月份划分的数据窗口

阶段	目标月份	行数	卖家数	用途
训练	2017-02 至 2017-12	6567	1694	预处理与模型拟合
调参	2018-01 至 2018-02	1831	1175	冻结配置
排序	2018-03 至 2018-04	1943	1219	名单、早停、开发选择
测试	2018-05 至 2018-07	3413	1680	仅评价

训练阶段用于拟合预处理参数与模型；调参阶段选择冻结配置；排序阶段

用于计算验证重要性、早停或子集效用，并冻结主方法及紧凑预算；测试阶段仅用于评价。预测器最终在全部开发期目标上重拟合，但特征名单不读取测试目标。测试月份曾参与前期探索，因此这一时间留出不等于从未接触过的新外部确认样本。




图 3-1 研究面板覆盖的签收确认金额与对数目标分布

第四节 候选指标及缺失值

31 项指标涵盖价格运费、商品物理属性、商品展示内容、支付方式、月末可见口碑、履约时间、交易规模、地域覆盖与营销状态。商品品类被汇总为活跃品类数；顾客使用跨订单唯一顾客标识；市场集中度采用第一大买家州的商品明细占比。所有字段的观测范围、不同取值数与缺失比例列于附录。

月末可见评价的缺失比例为 26.6759%，已送达平均天数及预计提前天数的缺失比例为 21.7391%。这些缺失部分源于尚未发生相应事件，而非随机漏报。因此，中位数填补是一种共同预处理约定，不代表缺失机制可忽略。主比较不增加缺失指示器，以保持候选集合固定；后续可将“缺失意味着未完成”作为独立业务状态建模。

订单数、件数和独立顾客数具有明显概念重叠；信用卡与 Boletto 等支付占比也受到构成约束。相关变量的相互替代可能造成名单差异，却未必造成同等程度的预测损失。本文因此同时评价名单稳定性与下游误差，而不把不同名字的出现直接解释为业务关系根本改变。




图 3-2 候选经营指标的 Spearman 相关结构

第五节 训练期预处理

主预测预处理包括：对非负偏态均值及计数做预设对数变换；利用拟合窗口计算 1% 与 99% 分位缩尾点；以拟合窗口中位数填补缺失；按拟合窗口均值和标准差缩放。排序与测试数据只应用既定参数，不根据各自批次重新估计分位点或均值。

Copula-MVR 另使用训练经验 CDF 上的随机并列分位数。对于一个取值，首先在训练排序中确定相等值的左右端点，再在对应经验概率区间中放置固定种子的随机数，最后映射到标准正态分位数。这可使二元变量的并列值在概率区间内展开，但改变了变量表示；它不是证明原始二元变量存在可逆的高斯变换。

当前随机并列数按列和输入行位置生成。固定相同行顺序与同一前缀批次

时结果保持一致，但任意重新排列或分块后不具有逐行恒等不变性。复现要求保持规定的月、卖家排序。这一限制与“CDF 仅由训练数据估计”是两个不同问题，本文不将有限批次前缀校验表述为任意排列不变性证明。

第四章 特征选择方法与实现

第一节 原生名单与固定预算名单

记候选特征数为 $p = 31$ ，方法 m 输出重要性分数或顺序 π_m 。预算名单为

$$S_m(K) = \{\pi_m(1), \dots, \pi_m(K)\}.$$

其目标是满足固定展示容量。没有自然截断点的方法，如 SHAP、置换重要性和梯度排名，只输出这一类名单。具有自然稀疏或阈值规则的方法另外输出原生集合 $\hat{S}_m$ 。固定预算表与原生表分别评价，不把一个方法挑出的较少变量与另一方法固定挑出的较多变量直接用于总体胜负判断。

并列排名按方法可用的次级分数处理，如频率相同时比较平均系数或平均真实重要性；仍并列时按固定特征编号排序。这使结果可复现，却可能在信息不足时产生机械稳定性，故解释稳定性时需同时查看分数和并列情况。

第二节 统计与树模型基线

Elastic Net 最小化平方损失与混合惩罚：

$$\frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \left\{ \eta \|\beta\|_1 + \frac{1-\eta}{2} \|\beta\|_2^2 \right\}.$$

变量以绝对系数排名；绝对系数大于数值容差的变量形成经验原生集合。调参搜索 λ 与 η ，但比较过程中不根据测试误差重新挑选稀疏程度。

稳定性选择在每一个外层样本内部再做 20 组互补半样本，共 40 次 Lasso 拟合。变量系数非零的频率为主要分数，平均绝对系数用于打破并列；频率不低于 0.9 构成经验原生集合。外层抽样评价方法对样本变化的敏感性，内层抽样则属于该方法本身，二者不可替换。

影子变量树每次为各列独立打乱行顺序，拼接真假变量后拟合 Extra Trees。真实变量重要性超过最大影子重要性记为当轮胜出，8 轮胜出频率不低于 0.75

形成经验原生集合。该阈值是固定实现约定，不对应本文已经证明的 FDR 水平。

XGBoost-SHAP 以三个固定训练种子的验证期平均绝对 TreeSHAP 值排序，不设置原生显著性集合。SHAP 分数反映模型预测分解，而条件依赖变量间的贡献分配仍取决于模型与背景分布。

第三节 Copula-MVR 与多轮证据聚合

在训练变换后的空间估计均值 $\hat{\mu}$ 与收缩协方差 $\hat{\Sigma}$ 。MVR 选择满足正定约束的对角矩阵 S ，改善真假变量的可区分程度。在高斯近似下，条件生成式为

$$\tilde{Z} | Z \sim N\left(\hat{\mu} + (Z - \hat{\mu})(I - \hat{\Sigma}^{-1}S), 2S - S\hat{\Sigma}^{-1}S\right).$$

上式按行向量表示；其适用性依赖高斯联合近似，而不由边际正态化自动成立。理想 Model-X 要求交换任意特征对后联合分布不变，且仿制变量在给定真实变量后不额外利用响应：

$$(X, \tilde{X})_{\text{swap}(A)} \stackrel{d}{=} (X, \tilde{X}), \quad \tilde{X} \perp Y | X.$$

在真假拼接设计上拟合近似 Lasso 竞争模型，统计量为

$$W_j = |\hat{\beta}_j| - |\hat{\beta}_{j+p}|.$$

为减少高度相关情况下非唯一解造成的数值不对称，本实现采用 L1 比例 0.999、总惩罚 0.01 的 Elastic Net 近似，而非完全纯 Lasso。极小且对称的岭项只用于数值解的稳定；其改动在所有 Knockoff 竞争中保持一致。代码交换一个真假列对后的符号翻转误差约为 5.82×10^{-8} ，这是有限数值校验，不是对所有数据的数学证明。

单轮 Knockoff+ 阈值为

$$T_b = \min \left\{ t > 0 : \frac{1 + \#\{j : W_j^{(b)} \leq -t\}}{\#\{j : W_j^{(b)} \geq t\} \vee 1} \leq 0.10 \right\}.$$

没有满足条件的阈值时不作单轮发现。这里的 0.10 限制正负统计量数量之比，不是要求 $W_j > 0.10$ 。每轮构造

$$e_j^{(b)} = \frac{p \mathbf{1}\{W_j^{(b)} \geq T_b\}}{1 + \#\{k : W_k^{(b)} \leq -T_b\}}, \quad \bar{e}_j = \frac{1}{60} \sum_{b=1}^{60} e_j^{(b)}.$$

将平均证据分数从大到小排序，e-BH 在目标水平 0.20 下寻找满足 $\bar{e}_{(k)} \geq p/(0.20k)$ 的最大 k 。60 次是计算预算内的聚合次数，不是理论常数；单轮 0.10 与最终 0.20 是不同阶段的设置，也不等于 90% 的入选频率。

Knockoff 导出的证据分数可按整体的零假设期望预算讨论，并非必须逐项宣称每个分数都是单独有效的 e-value。在相应条件下， $\sum_{j \in H_0} E(\bar{e}_j) \leq p$ 与 e-BH 阈值可给出 FDR 界。这个推理仍依赖 Knockoff 有效性条件；经验生成器失配时不能只保留最后的 e-BH 公式而忽略前提。

第四节 Deep Lasso

Deep Lasso 骨干为两层 MLP，采用 ReLU、0.1 的 Dropout 和 AdamW。对于小批次损失 $\mathcal{L}_B$ ，输入梯度组惩罚写为

$$\mathcal{L}_{DL} = \mathcal{L}_B + \lambda \sum_{j=1}^p \left\| \frac{\partial \mathcal{L}_B}{\partial X_{B,j}} \right\|_2.$$

该惩罚直接调用作者发布的函数，其梯度需要二阶自动微分，因此统一使用 CPU 实现。每次拟合使用三个训练种子；排序期对输入损失梯度的平方和开方，再平均三个模型的分数。此排名强调网络误差对各输入的敏感性，而非稀疏线性系数，也不提供单个特征的显著性概率。

模型宽度、学习率与正则系数在 12 种配置中选择。最大训练 100 轮，验证损失连续 12 轮不改善则停止。本文另在冻结配置下将输入梯度惩罚设为零，使用同一完整样本与 60 个半样本进行局部消融。该消融回答当前正则项的边际作用，不等价于对普通 MLP 进行充分调参后的最优比较。

第五节 TabM 与验证置换排序

TabM 采用官方软件包实现，每个模型包含 8 个参数高效集成成员。训练时分别计算各成员的预测损失，而非先平均输出再只优化平均损失；推断时平均成员预测。外部再重复三个训练种子，以减少单次优化随机性。

对于特征 j ，在排序期打乱该列，并计算误差变化：

$$I_j = \frac{1}{R} \sum_{r=1}^R \left[\text{MSE}\{y_v, \hat{f}(X_v^{\text{perm}(j,r)})\} - \text{MSE}\{y_v, \hat{f}(X_v)\} \right],$$

其中每列置换 $R = 3$ 次。较大正值表示模型较依赖该特征。负值不被人为置零，在排序中保留。独立置换会打破特征间相关关系，因此重要性不能被解释为严格的条件独立检验。

TabM 同时承担统一下游评价器的角色。作为选择器时，它输出 31 项排序；作为评价器时，它只读取给定方法选出的 K 项特征重新训练。两种角色分开计算，避免把选择器自身更强的预测能力误当作所选名单更好。

第六节 VTFS 定额适配

VTFS 适配首先构造 96 个不同随机子集，包括完整特征集，再以固定 XGBoost 效用器计算排序期负 MSE。效用按语料中的最小值与最大值归一化，作为 Transformer 潜在表示的预测目标。每个训练轮次打乱子集内部顺序，联合优化效用预测、序列重建和 KL 项，权重分别为 0.8、0.2 和 0.001。

本文保留官方编码器和解码器，但进行了明确适配：不使用可选强化学习语料采集器；将设备操作移植到 CPU；解码时屏蔽终止符和已选特征，形成 31 项无重复顺序；按预设 Top-12 的排序期效用选择一条完整顺序。三个种子分别从四个高效用语料出发产生候选，同时保留八个高效用语料的回退顺序，总查询不超过 128 次。

发布代码中的重参数化使用常数 $\epsilon = 1$ 。本文保持该行为并予以记录，不将其描述为已经独立核验的标准随机 VAE 实现。模型真实完成了 Transformer 训练，但最终结果仍可能来自语料回退。若最终名单与回退名单相同，则不能将这

次结果的收益归功于深度解码器。

序列适配还存在预算限制：完整顺序按 $K=12$ 优化，不保证其前 4 项是独立优化的最优四项集合。回退子集以固定特征编号形成内部顺序，尤其可能影响小 K 截断。本文保留 K 路径以揭示这一限制，而不以测试误差重新排列特征。

第七节 DeepDRK 与未进入完整比较的候选

DeepDRK 适配采用 64 宽、两层、四头 Transformer 及两个 Swapper，生成器最大 200 轮，依据不使用响应的排序期交换损失保存检查点。按照公开方法进行依赖正则和行置换扰动，并额外接入 60 轮证据聚合。发布实现的逐列依赖函数在循环内部提前返回，本文修正为全列平均，并使用等价形式向量化；这项修正属于实现偏离，不能隐藏在“直接复现”措辞中。

三种子生成器均实际完成训练，但在交换性诊断中触发警告，因而没有继续全部外层稳定性和模拟。Copula-MVR 同样有诊断警告，不过作为预先设置的经验参照保留完整比较。二者都不获得真实数据 FDR 有效性的认可。完整运行范围不同意味着不能据此对 DeepDRK 与八个完整比较方法进行全面性能排名。

TabPFN 固定为对应 2025 年论文的 v2 软件版本，完整拟合窗口为 8,398 行。首次 MPS 内存估计不支持，设置显式节省内存后仍出现 29.95 GiB 缓冲区错误。本文未单独为该方法下采样，未将其他模型输出填入其结果，也未把运行失败解释为该论文方法在统计性能上较差。

第五章 公平实验设计

第一节 时间分工与调参预算

首先在训练期拟合、调参期评价，选择各方法的固定超参数。可调标准预测器通常使用 12 种不同配置；论文默认型或资源适配型方法使用已记录的固定配置，不按最终发现数选参。随后在训练加调参窗口拟合，并在排序窗口产生名单。外层子样本保持相同超参数，不在每一子样本重新搜索。

因此，本文考察的是“固定配置的选择程序对样本扰动的敏感性”，而不是包含重新调参在内的端到端流程稳定性。不同方法的内部训练次数与损失不同，无法通过机械设置相同 epoch 来保证等计算量。本设计统一数据、外层样本、变量预算、评价器和测试期，并披露搜索与运行成本；它不是严格等 FLOP 或等墙钟时间竞赛。

表 5-1 冻结配置与实际训练预算

方法	配置数	选定配置
Copula-MVR	1	60 轮；竞争惩罚 0.01
Elastic Net	12	$\alpha=0.001$, $l1_ratio=0.9$
稳定性选择	12	$\alpha=0.001$
影子变量树	12	$trees=240$, $leaf=8$
XGBoost-SHAP	12	$depth=4$, $lr=0.03$, $trees=280$
Deep Lasso	12	$width=64$, $layers=2$, $lr=0.003$, $regularization=1.0$
TabM-置换	12	$width=64$, $layers=3$, $lr=0.001$
VTFS-定额适配	1	$width=64$, $layers=2$, $lr=0.001$, $epochs=100$

第二节 公共卖家抽样

以开发期出现的卖家为抽样单位。每组随机排列所有开发卖家，并划分为互补 A、B 两半；共 30 组，得到 60 个约 50% 样本。同一卖家的所有开发期月份保留在同一半样本内。另设置 20 个 70% 样本与 20 个 80% 样本；相同组号的 70% 和 80% 样本来自同一随机排列的不同长度前缀。

所有方法读取相同卖家名单，不根据某方法的成功或表现重新抽样。每个案例记录拟合行和排序行的哈希，并跨方法核对。卖家层抽样保留了组内观测关系，避免把同一卖家的某些月份抽中、另一些月份独立删除；但它不是对面板依赖的全部统计修正，也不自动使生成器满足 Model-X 交换性。

固定数据的算法随机性另做 10 个种子批次。对于确定性的 Elastic Net，更换种子不应改变结果；对于 Knockoff，改变假变量生成种子；对于网络，改变初始化和优化种子；对于稳定性选择及影子树，改变其内部抽样或扰动种子。评价对象相同，但算法内部机制按各自定义保留。

第三节 稳定性指标与区间

名单相似性采用 Jaccard:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

主指标比较每个子样本名单与相同方法的完整开发样本名单。第二项指标直接比较同组互补半样本 A 与 B，减少完整样本参考名单本身特殊性的影响。第三项指标为 Nogueira 机会校正稳定性:

$$\hat{\Phi} = 1 - \frac{p^{-1} \sum_{j=1}^p \widehat{\text{Var}}(Z_{\cdot j})}{(\bar{k}/p)(1 - \bar{k}/p)},$$

其中 Z_{bj} 表示第 b 份名单是否选中特征 j ， $\bar{k}$ 为平均名单长度。该指标在本研究中作为描述性估计量，不将互补半样本当作独立重复套用原文独立样本的推断公式。

50% 样本的置信区间以 30 个组为单位：先平均同组 A、B 相对参考名单的 Jaccard，再计算组间标准误与 t 区间。70% 与 80% 分别使用 20 个组。方法间比较在同组内作差，而不以两个边际区间是否重叠判断差异。区间描述的是给定数据集的抽样敏感性，不能代表跨平台、跨年度的总体稳定性。

第四节 统一预测评价器

每条特征名单均交给固定配置的 XGBoost 和 TabM 评价器，使用相同目标与时间窗口。XGBoost 树数固定，先用排序期计算开发误差，再用全部开发数据重拟合。TabM 先在排序期确定最佳训练轮次，再以该轮次在全部开发数据上重新训练，不根据测试损失选择检查点。每个评价器均使用三个训练种子的平均预测。

报告对数 RMSE、对数 MAE、对数尺度 R^2 及原金额 WAPE：

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_i (Y_i - \hat{Y}_i)^2}, \quad \text{WAPE} = \frac{\sum_i |G_i - \max\{0, \exp(\hat{Y}_i) - 1\}|}{\sum_i G_i}.$$

由对数预测直接逆变换并不是条件平均金额的无偏估计，本文没有使用未经验证的偏差校正。因此，WAPE 只反映该逆变换规则下的金额误差，不据此声称最优收入预测。

测试区间采用 2,000 次配对卖家簇 Bootstrap。每次抽取卖家并保留其全部测试月份，同一抽样用于比较双方。主方法相对其他方法的差值统一定义为“主方法 RMSE 减对照 RMSE”，负值表示主方法误差较小。另给出一个固定 K、固定评价器内的 Bonferroni 分位区间；只有 2,000 次 Bootstrap 时尾部分位数精度有限，近零边界不作强结论。

测试期仅有三个月，卖家簇 Bootstrap 不能刻画宏观时间冲击或年度漂移的不确定性。所有区间均以这三个已观察月份为条件，既非长期经营保证，也不等于全体模型、预算、评价器和后续探索共同的错误率控制。

第五节 主选择规则与分析修订

开发集在主预算 12 下按统一 XGBoost 误差选择主方法；紧凑方案采用“在最优开发误差 1% 以内的最小 K”。规则在测试预测生成前保存，选出 VTFS 适配模型作为开发主选择、8 项作为紧凑方案。测试结果公布后不替换主方法，以免把测试期最优者重新包装为预先指定的胜者。

本地协议不是公开注册的确认性研究。执行过程中记录了设备移植、生成器缺陷修正、随机并列 CDF 修正、响应尺度修正及部分候选退出；原始结果按敏感性分析或失败记录保留。模拟中的 Elastic Net 和稳定性选择统一使用训练响应标准化后重跑，以匹配冻结惩罚的尺度；神经与 Knockoff 选择器内部标准化，树损失或子集效用采用相应尺度等变或归一化规则。补充消融在主结果计算后提出，应当按探索性证据解释。

第六章 实际数据结果

第一节 同预算预测表现

表 6-1 12 项预算下的统一测试评价

选择方法	XGB-RMSE	TabM-RMSE	XGB-MAE	XGB-R ²	XGB-WAPE
Copula-MVR	1.8663	1.8945	1.3566	0.4894	0.5269
Elastic Net	1.8626	1.8737	1.3542	0.4914	0.5279
稳定性选择	1.8931	1.8840	1.3620	0.4746	0.5308
影子变量树	1.8606	1.8634	1.3494	0.4925	0.5281
XGBoost-SHAP	1.8464	1.8572	1.3442	0.5003	0.5276
Deep Lasso	1.8467	1.8600	1.3467	0.5001	0.5248
TabM-置换	1.8443	1.8597	1.3435	0.5014	0.5232
VTFS-定额适配	1.8625	1.8851	1.3592	0.4915	0.5312
全维基线	1.8649	1.8588	1.3404	0.4902	0.5232

在 XGBoost 评价器下，TabM 置换排序取得 1.8443 的点估计，Deep Lasso 和 XGBoost-SHAP 分别为 1.8467 和 1.8464。这几项结果十分接近。相对 31 项基线 1.8649，保留 12 项能够在该评价器下取得较低误差，但这个比较不说明所删 19 项都不包含条件信息，也不说明三个方法彼此存在已经确认的显著差异。

更换为 TabM 评价器后，XGBoost-SHAP 的 RMSE 为 1.8572，Deep Lasso 与 TabM 置换分别为 1.8600 和 1.8597，全维基线为 1.8588。方法排名发生变化，表明一个名单是否有效与下游模型能否利用其信息有关。仅展示 XGBoost 评价器将夸大个别方法的优势；仅展示网络评价器也不能概括所有使用环境。

开发主选择 VTFS 适配模型的测试 RMSE 为 1.8625 和 1.8851，并未在测试期保持开发期优势。这一现象与序列模型在排序期反复评估子集有关，也可能受到任务规模、语料预算和适配方式的影响。现有结果不能区分各原因的贡献，但足以反对以开发期最优作为直接部署依据。

第二节 配对误差差异

第六章 实际数据结果




图 6-1 固定 12 项预算下的双评价器预测结果

表 6-2 开发主选择相对各方法的测试 RMSE 配对区间

评价器	对照	VTFS 减对照	95% 区间	同组多重比较区间
xgboost	Copula-MVR	-0.0038	[-0.0169, 0.0094]	[-0.0231, 0.0146]
xgboost	Elastic Net	-0.0001	[-0.0141, 0.0138]	[-0.0185, 0.0198]
xgboost	稳定性选择	-0.0306	[-0.0505, -0.0098]	[-0.0571, -0.0015]
xgboost	影子变量树	0.0019	[-0.0123, 0.0164]	[-0.0193, 0.0212]
xgboost	XGBoost-SHAP	0.0161	[0.0042, 0.0274]	[-0.0013, 0.0327]
xgboost	Deep Lasso	0.0158	[0.0031, 0.0276]	[-0.0012, 0.0333]
xgboost	TabM-置换	0.0182	[0.0047, 0.0308]	[0.0001, 0.0368]
xgboost	全维基线	-0.0024	[-0.0164, 0.0109]	[-0.0196, 0.0158]
tabm	Copula-MVR	-0.0094	[-0.0269, 0.0087]	[-0.0362, 0.0161]
tabm	Elastic Net	0.0114	[-0.0084, 0.0312]	[-0.0159, 0.0370]
tabm	稳定性选择	0.0010	[-0.0206, 0.0239]	[-0.0288, 0.0329]
tabm	影子变量树	0.0217	[0.0042, 0.0397]	[-0.0023, 0.0463]
tabm	XGBoost-SHAP	0.0279	[0.0107, 0.0454]	[0.0044, 0.0519]
tabm	Deep Lasso	0.0251	[0.0080, 0.0423]	[-0.0001, 0.0480]
tabm	TabM-置换	0.0254	[0.0081, 0.0422]	[0.0026, 0.0486]
tabm	全维基线	0.0263	[0.0087, 0.0444]	[0.0018, 0.0505]

在 XGBoost 评价器下，VTFS 与 Elastic Net 的点差约为 -0.0001 ，与 Copula-MVR 的点差约为 -0.0038 ，95% 配对区间均跨零。相对 TabM 置换，VTFS 点差约为 0.0182 ，方向不利于 VTFS；在当前多重比较分位区间中，下界

非常接近零，不宜夸大边界显著性。在 TabM 评价器下，VTFS 对若干对照的误差较高，开发选择没有形成稳健领先。

“区间跨零”不等于证明两方法等价。协议中的 1% 误差容忍度主要用于开发期紧凑方案，不自动成为经过正式等价检验的结论。尤其对于全维基线，只有在预先指定方向和容忍度、并用配对区间进行适当检验后，才可讨论非劣性；本文使用更保守的“点估计接近”或“未获得稳定优势”措辞。

第三节 样本稳定性与参考名单

表 6-3 Top-12 名单的样本稳定性

方法	50% 均值 [组级 95% 区间]	70% 均值	80% 均值	50% Nogueira
Copula-MVR	0.7355 [0.7131, 0.7578]	0.7508	0.8077	0.6798
Elastic Net	0.7244 [0.6979, 0.7509]	0.8385	0.9088	0.6185
稳定性选择	0.5827 [0.5614, 0.6041]	0.6619	0.7018	0.4788
影子变量树	0.9388 [0.9233, 0.9544]	0.9615	0.9923	0.9210
XGBoost-SHAP	0.7682 [0.7501, 0.7862]	0.8470	0.8220	0.7439
Deep Lasso	0.8230 [0.7962, 0.8498]	0.8868	0.7615	0.7754
TabM-置换	0.7505 [0.7196, 0.7813]	0.8780	0.8934	0.7304
VTFS-定额适配	0.4068 [0.3377, 0.4758]	0.4814	0.2972	0.2733

50% 卖家抽样下，影子变量树相对完整开发名单的平均 Jaccard 最高，为 0.9388；Deep Lasso 为 0.8230；XGBoost-SHAP 为 0.7682；TabM 置换为 0.7505；Copula-MVR 为 0.7355；Elastic Net 为 0.7244；稳定性选择为 0.5827；VTFS 适配为 0.4068。方法名称中的“稳定性选择”并不保证它在所有数据、惩罚参数和固定 K 下的 Jaccard 最高。

70% 和 80% 样本有助于观察名单在接近完整数据时的变化，但稳定性不必对抽样比例单调增加。例如，Deep Lasso 和 VTFS 在某些较大子样本中的相对参考 Jaccard 下降，而子样本之间仍可能更一致。这说明完整开发名单本身也可能是一份特殊名单。增加样本比例后的非单调结果不能被删除或以“异常”名义重抽。




图 6-2 相同卖家抽样下的名单稳定性及组级区间

表 6-4 互补半样本之间的 Top-12 一致性

方法	互补 Jaccard[95% 区间]	互补组数
Copula-MVR	0.6180 [0.5891, 0.6469]	30
Elastic Net	0.5318 [0.4936, 0.5700]	30
稳定性选择	0.4691 [0.4344, 0.5038]	30
影子变量树	0.8828 [0.8545, 0.9111]	30
XGBoost-SHAP	0.6557 [0.6241, 0.6874]	30
Deep Lasso	0.7381 [0.6961, 0.7801]	30
TabM-置换	0.6925 [0.6349, 0.7501]	30
VTFS-定额适配	0.4339 [0.3233, 0.5445]	30

互补 A/B 比较与 Nogueira 指标提供了不同参照：前者直接比较不重叠卖家集合，后者基于全部入选频率进行机会校正。若相对完整名单的 Jaccard 低，但 Nogueira 较高，说明多个子样本倾向于共同选择另一份名单，而非每次都完全随机。该区别对于判断参考名单是否具有代表性具有实际价值。

第四节 算法随机性与样本扰动

表 6-5 固定开发数据更换种子的 Top-12 一致性

方法	均值	最小值	最大值	种子批次
Copula-MVR	1.0000	1.0000	1.0000	10
Elastic Net	1.0000	1.0000	1.0000	10
稳定性选择	0.7824	0.7143	1.0000	10
影子变量树	1.0000	1.0000	1.0000	10

方法	均值	最小值	最大值	种子批次
XGBoost-SHAP	0.8769	0.8462	1.0000	10
Deep Lasso	0.8769	0.8462	1.0000	10
TabM-置换	0.9692	0.8462	1.0000	10
VTFS-定额适配	0.2935	0.2000	0.4118	10

固定数据的种子试验只能说明初始化、内部重抽样或 Knockoff 生成随机性带来的变动，不反映更换卖家后的鲁棒性。确定性方法的种子一致性为 1 是计算机制的结果，而非其泛化能力必然更好。随机方法通过多次训练或聚合可以减少种子敏感性，但不保证样本敏感性同步降低。

本文不将两类稳定性合并成一个百分数，也不把频繁出现的变量称为具有同等数值的“真实概率”。业务使用者应同时看到指标的入选频率、样本扰动结果和所用评价器，而不能仅凭一项接近 1 的算法一致性决定长期保留。

第五节 容量路径与具体名单

表 6-6 不同预算下的测试 RMSE

评价器	选择方法	K=4	K=8	K=10	K=12	K=14
xgboost	Copula-MVR	2.0532	1.8664	1.8648	1.8663	1.8646
xgboost	Elastic Net	2.0486	1.8652	1.8673	1.8626	1.8807
xgboost	稳定性选择	2.0405	1.8782	1.8967	1.8931	1.8913
xgboost	影子变量树	2.1338	1.8593	1.8562	1.8606	1.8469
xgboost	XGBoost-SHAP	2.0485	1.8454	1.8441	1.8464	1.8479
xgboost	Deep Lasso	1.8762	1.8555	1.8579	1.8467	1.8474
xgboost	TabM-置换	1.8681	1.8551	1.8566	1.8443	1.8467
xgboost	VTFS-定额适配	2.3854	1.8622	1.8614	1.8625	1.8608
tabm	Copula-MVR	2.0462	1.8933	1.8962	1.8945	1.8871
tabm	Elastic Net	2.0422	1.8959	1.8932	1.8737	1.8668
tabm	稳定性选择	2.0384	1.8868	1.8871	1.8840	1.8695
tabm	影子变量树	2.1353	1.8689	1.8647	1.8634	1.8602
tabm	XGBoost-SHAP	2.0421	1.8606	1.8556	1.8572	1.8590
tabm	Deep Lasso	1.8998	1.8625	1.8684	1.8600	1.8582
tabm	TabM-置换	1.8833	1.8633	1.8622	1.8597	1.8604
tabm	VTFS-定额适配	2.3959	1.8878	1.8811	1.8851	1.8788

把 K 从 12 减到 4，不同方法的信息损失差异较大。Deep Lasso 和 TabM 置换的小预算表现相对平稳，而 VTFS 的四项前缀明显较弱。这与其按 12 项优化一条完整序列、回退子集按固定编号排序的适配机制一致。不能据此断言原始 VTFS 自动停止算法也存在相同问题。

开发期紧凑选择为 VTFS 的 8 项方案，其 XGBoost 测试 RMSE 约为 1.8622，而 TabM 评价器下约为 1.8878。这一方案减少了展示数量，但仍未形成跨评价器优势。因此，本文保留其作为开发规则的实际输出，不把它无条件推荐为最终生产默认名单。




图 6-3 五种展示容量下的预测误差路径

表 6-7 各方法完整开发样本的前 12 项指标

方法	按顺序列出的前 12 项
Copula-MVR	平均商品价格；独立顾客数；购买订单数；购买件数；买家州数量；平均买卖家距离；月末已送达平均天数；平均商品重量；活跃品类数；月末已审核平均天数；跨州交易占比；平均商品标题长度
Elastic Net	独立顾客数；购买订单数；平均商品价格；第一大买家州占比；购买件数；平均买卖家距离；平均商品重量；月末已送达平均天数；买家州数量；跨州交易占比；月末可见平均评价；平均运费
稳定性选择	平均商品价格；第一大买家州占比；购买件数；平均买卖家距离；平均商品重量；月末已送达平均天数；跨州交易占比；月末可见平均评价；平均商品标题长度；已观察卖家州频率；活跃品类数；平均支付分期期数

第六章 实际数据结果

方法	按顺序列出的前 12 项
影子变量树	购买订单数；独立顾客数；买家州数量；购买件数；平均商品价格；第一大买家州占比；月末可见平均评价；月末已送达平均天数；月末已送达预计提前天数；平均支付分期期数；平均商品重量；平均运费
XGBoost-SHAP	独立顾客数；购买订单数；平均商品价格；买家州数量；月末已送达预计提前天数；月末已送达平均天数；月末可见平均评价；月末已承运平均准备天数；购买件数；平均商品标题长度；平均运费；平均商品重量
Deep Lasso	独立顾客数；购买订单数；平均商品价格；月末已送达平均天数；购买件数；第一大买家州占比；月末已送达预计提前天数；月末可见平均评价；买家州数量；平均买卖家距离；月末已承运平均准备天数；平均商品重量
TabM-置换	独立顾客数；平均商品价格；月末可见平均评价；月末已送达平均天数；购买订单数；月末已送达预计提前天数；购买件数；买家州数量；第一大买家州占比；平均商品重量；月末已承运平均准备天数；活跃品类数
VTFS-定额适配	平均商品价格；平均运费；平均支付序列数；代金券支付占比；月末已承运平均准备天数；月末已送达预计提前天数；独立顾客数；跨州交易占比；平均商品重量；平均商品长度；平均商品高度；平均商品宽度

名单中的价格、交易规模和部分履约指标具有直接业务含义，但入选并不意味着增加订单量、缩短时效等干预的因果效应已被识别。另一方面，未入选的支付或营销指标也不能被断言永久无效：其作用可能与低覆盖率、短观察窗口、代理变量和正则化共同有关。

完整开发样本中，Copula-MVR、Elastic Net、稳定性选择和影子变量树的原生集合分别包含 13、26、20 和 14 项。这些数目来自各自阈值或非零规则，不等于相同展示预算；Copula-MVR 的 13 项也不因使用 e-BH 就被自动认定为真实数据上有效的 FDR 确认集合。

第六节 局部消融与计算成本




图 6-4 相同 60 个半样本中各指标的 Top-12 入选频率

表 6-8 Deep Lasso 正则与 VTFS 解码候选的补充消融

检查项目	数值	解释范围
Deep Lasso 保留正则的半样本 Jaccard	0.8230 [0.7962, 0.8498]	固定配置
去掉正则的半样本 Jaccard	0.8182 [0.7852, 0.8511]	相同 60 半样本
保留减去掉正则的配对差	0.0049 [-0.0278, 0.0375]	30 个组，探索性
完整样本两种正则设置名单 Jaccard	0.8462	Top-12
VTFS 完整名单等于语料回退	是	不归功于深度解码
VTFS 半样本与回退相同的比例	0.6167	60 个半样本
VTFS 解码候选的平均开发效用增益	0.0359	标准化响应负 MSE，仅开发期

在完整开发样本中，VTFS 最终 Top-12 与高效用随机语料的回退名单相同，

解码候选相对回退名单的排序期效用增益为零。这不否认训练发生，而是说明本次最终名单不能被用来证明深度解码器贡献。半样本中的回退一致率和平均效用增益进一步报告在消融表中，但这些仍是排序期结果，不能代替独立测试。

Deep Lasso 局部消融只改变输入梯度正则，不重新调参，因此其结果反映特定配置下的作用。即使惩罚改善稳定性，也不能推广为任何 MLP 均会因该项惩罚受益；若差异很小，则应承认当前任务未充分体现这一组件优势。

本次保留正则与移除正则的平均半样本 Jaccard 分别为 0.8230 和 0.8182，配对差为 0.0049，95% 组级区间为 [-0.0278, 0.0375]。因此，当前局部消融没有给出明确的稳定性改善证据。不能把 Deep Lasso 整条流程表现较好，进一步推导为其中正则项已经被证明显著有效。

表 6-9 完整开发样本选择流程运行成本

方法	完整选择秒数	单网络参数量	三种子训练轮次
Copula-MVR	1.38	不适用	不适用
Elastic Net	0.17	不适用	不适用
稳定性选择	3.68	不适用	不适用
影子变量树	31.79	不适用	不适用
XGBoost-SHAP	1.47	不适用	不适用
Deep Lasso	1.80	6273	51/27/48
TabM-置换	19.61	15040	61/59/58
VTFS-定额适配	28.87	286305	100/100/100

运行时间来自同一台 Apple M4 Pro 计算机，部分任务并发执行；CPU 线程及设备策略记录于工程。表中时间具有工程参考价值，但并发竞争、库启动和缓存会影响墙钟计时，不能将其视为严格微基准。模型搜索、三个种子与内部负对照生成的成本均不相同，使用者需要把部署维护成本与预测收益共同考虑。

第七章 已知真值模拟与生成诊断

第一节 模拟目标与数据生成

按照模拟研究的目标、生成机制、估计对象、方法和性能指标原则组织实验^[26]。目标是观察已知支持集下的误选、检出和预测表现，而不是用人为信号替代真实业务结论。每个场景产生 2,000 行、31 列，训练、验证和测试分别为 1,200、400 和 400 行；100 次重复在所有方法之间共享。

连续潜变量采用 AR(1) 协方差 $\Sigma_{jk} = 0.65^{|j-k|}$ 。每隔三列做指数变换，末两列阈值二元化，信号从前 29 列中抽取。线性场景采用随机正负系数，非线性场景同时包含正弦、平方和两项交互；信号按该次样本的标准差缩放，再加入与预设信噪比对应的噪声。面板场景以每 10 行为一组，在误差中加入独立组效应，并保持训练、验证、测试组不交叉。

表 7-1 模拟场景

场景	真信号数	信噪比	重复
线性稀疏强信号	5	3.0	100
线性中信号	10	1.0	100
线性弱信号	10	0.3	100
线性较密信号	15	1.0	100
非线性独立误差	10	1.0	100
非线性组内相关	10	1.0	100

这些场景是人工控制的相关设计，不是对 Olist 真实联合分布的完整半参数复现。模拟配置沿用真实开发数据冻结参数，不对每个场景重新搜索最优超参数。因此，比较更接近固定选择流程的迁移表现，而非每种方法在各场景充分调参后的性能上界。训练响应尺度对有惩罚的线性方法统一标准化，避免信噪比变化同时改变惩罚的有效单位。

第二节 FDP、Power 与 Monte Carlo 误差

设真信号集合为 S^* ，一次重复的发现集合为 $\hat{S}$ ，定义

$$\text{FDP} = \frac{|\hat{S} \setminus S^*|}{|\hat{S}| \vee 1}, \quad \text{Power} = \frac{|\hat{S} \cap S^*|}{|S^*|}.$$

没有发现时 FDP 记为 0，Power 也为 0。平均 FDP 是给定模拟设计下 FDR 的 Monte Carlo 估计，不代表真实 Olist 数据中可直接观察的误选率。100 次重复的均值标准误由重复间标准差除以 10 计算；同时记录发现数和 FDP 超过 0.20 的比例，避免只用很少发现获得低 FDP 而忽略功效。

FDR 控制针对 FDP 的期望，不直接控制 $\Pr(\text{FDP} > 0.20)$ 。固定 K 时，FDP 与 Power 还存在确定关系：

$$\text{FDP} @ K = 1 - \frac{|S^*|}{K} \text{Power} @ K.$$

因此，两项指标不是完全独立的成功证据。若只有 5 项真信号而强制选择 12 项，即使全部真信号被找出，FDP 仍至少为 7/12。这样的结果不应被用于否定一个原本没有承诺固定预算 FDR 的方法。

第三节 固定预算结果

表 7-2 六场景 Top-12 的平均 FDP、Power 与检出不确定性

场景	方法	平均 FDP	Power	Power MCSE	共同 XGB-RMSE
线性稀疏强信号	Copula-MVR	0.5833	1.0000	0.0000	0.6386
线性稀疏强信号	Elastic Net	0.5833	1.0000	0.0000	0.6362
线性稀疏强信号	稳定性选择	0.5833	1.0000	0.0000	0.6359
线性稀疏强信号	影子变量树	0.5875	0.9900	0.0044	0.6396
线性稀疏强信号	XGBoost-SHAP	0.5833	1.0000	0.0000	0.6394
线性稀疏强信号	Deep Lasso	0.5833	1.0000	0.0000	0.6386
线性稀疏强信号	TabM-置换	0.5833	1.0000	0.0000	0.6371
线性稀疏强信号	VTFS-定额适配	0.6767	0.7760	0.0174	0.7125
线性中信号	Copula-MVR	0.1667	1.0000	0.0000	1.0729
线性中信号	Elastic Net	0.1667	1.0000	0.0000	1.0722

第七章 已知真值模拟与生成诊断

场景	方法	平均 FDP	Power	Power MCSE	共同 XGB-RMSE
线性中信号	稳定性选择	0.1675	0.9990	0.0010	1.0724
线性中信号	影子变量树	0.3292	0.8050	0.0076	1.0969
线性中信号	XGBoost-SHAP	0.1742	0.9910	0.0029	1.0737
线性中信号	Deep Lasso	0.1700	0.9960	0.0020	1.0724
线性中信号	TabM-置换	0.1692	0.9970	0.0022	1.0717
线性中信号	VTFS-定额适配	0.5325	0.5610	0.0134	1.1551
线性弱信号	Copula-MVR	0.1867	0.9760	0.0049	1.8829
线性弱信号	Elastic Net	0.1842	0.9790	0.0043	1.8826
线性弱信号	稳定性选择	0.2083	0.9500	0.0080	1.8847
线性弱信号	影子变量树	0.3583	0.7700	0.0093	1.9026
线性弱信号	XGBoost-SHAP	0.2208	0.9350	0.0070	1.8882
线性弱信号	Deep Lasso	0.2483	0.9020	0.0082	1.8876
线性弱信号	TabM-置换	0.2275	0.9270	0.0076	1.8856
线性弱信号	VTFS-定额适配	0.5400	0.5520	0.0117	1.9351
线性较密信号	Copula-MVR	0.0000	0.8000	0.0000	1.0985
线性较密信号	Elastic Net	0.0000	0.8000	0.0000	1.1016
线性较密信号	稳定性选择	0.0000	0.8000	0.0000	1.1020
线性较密信号	影子变量树	0.2033	0.6373	0.0067	1.1176
线性较密信号	XGBoost-SHAP	0.0225	0.7820	0.0034	1.0960
线性较密信号	Deep Lasso	0.0083	0.7933	0.0020	1.0941
线性较密信号	TabM-置换	0.0017	0.7987	0.0009	1.0964
线性较密信号	VTFS-定额适配	0.3942	0.4847	0.0090	1.1634
非线性独立误差	Copula-MVR	0.5125	0.5850	0.0127	1.2415
非线性独立误差	Elastic Net	0.5108	0.5870	0.0106	1.2329
非线性独立误差	稳定性选择	0.5325	0.5610	0.0125	1.2367
非线性独立误差	影子变量树	0.2642	0.8830	0.0082	1.1724
非线性独立误差	XGBoost-SHAP	0.1967	0.9640	0.0058	1.1704
非线性独立误差	Deep Lasso	0.3075	0.8310	0.0095	1.1740
非线性独立误差	TabM-置换	0.2975	0.8430	0.0098	1.1745
非线性独立误差	VTFS-定额适配	0.5125	0.5850	0.0104	1.2232
非线性组内相关	Copula-MVR	0.4817	0.6220	0.0125	1.2136
非线性组内相关	Elastic Net	0.5058	0.5930	0.0136	1.2089
非线性组内相关	稳定性选择	0.5383	0.5540	0.0134	1.2092
非线性组内相关	影子变量树	0.2742	0.8710	0.0090	1.1430
非线性组内相关	XGBoost-SHAP	0.1917	0.9700	0.0050	1.1420
非线性组内相关	Deep Lasso	0.2950	0.8460	0.0090	1.1459

场景	方法	平均 FDP	Power	Power MCSE	共同 XGB-RMSE
非线性组内相关	TabM-置换	0.3142	0.8230	0.0097	1.1467
非线性组内相关	VTFS-定额适配	0.5275	0.5670	0.0117	1.1972

固定预算表回答“同样拿到 12 个展示位置时，哪种方法覆盖更多真信号”。线性强信号、弱信号与非线性场景会改变方法相对表现；任何方法在某一场景的优势，都须限定在该生成机制和冻结配置下。真实交易特征的相关结构、可见性缺失及时间漂移并未被这些场景完全覆盖。

线性稀疏强信号场景中，Top-12 检出率最高的点估计为 1.0000（Copula-MVR、Deep Lasso、Elastic Net、稳定性选择、TabM-置换、XGBoost-SHAP）；线性中信号场景中，Top-12 检出率最高的点估计为 1.0000（Copula-MVR、Elastic Net）；线性弱信号场景中，Top-12 检出率最高的点估计为 0.9790（Elastic Net）；线性较密信号场景中，Top-12 检出率最高的点估计为 0.8000（Copula-MVR、Elastic Net、稳定性选择）；非线性独立误差场景中，Top-12 检出率最高的点估计为 0.9640（XGBoost-SHAP）；非线性组内相关场景中，Top-12 检出率最高的点估计为 0.9700（XGBoost-SHAP）。这些逐场景点排名未进行跨全部场景的多重比较推断。

非线性独立误差与组内相关场景中，XGBoost-SHAP 的 Top-12 Power 分别为 0.9640 和 0.9700，Deep Lasso 为 0.8310 和 0.8460，TabM 置换为 0.8430 和 0.8230。近期网络在这里优于若干线性排序，但仍未超过强树基准。线性场景则更有利于系数型排序；这种机制差异比单独给出一个跨场景平均冠军更有解释价值。

对于非线性响应，线性系数竞争可能遗漏以对称平方或高阶交互方式作用的变量；树模型和神经网络在机制上更有表达空间。但表达空间并不保证有限样本训练能够找到相应结构，尤其在验证搜索预算有限或噪声较大时。模拟结果因此用于揭示能力边界，而不是只作为某方法的宣传性补充。

第四节 原生名单结果

第七章 已知真值模拟与生成诊断




图 7-1 已知真值场景中的 Top-12 检出率与误选比例

表 7-3 原生选择规则的平均 FDP、Power 与发现数

场景	方法	平均 FDP	FDP MCSE	Power	发现数	FDP>0.20 比例
线性稀疏强信号	Copula-MVR	0.0000	0.0000	0.0000	0.00	0.0000
线性稀疏强信号	Elastic Net	0.8289	0.0008	1.0000	29.28	1.0000
线性稀疏强信号	稳定性选择	0.8224	0.0010	1.0000	28.24	1.0000
线性稀疏强信号	影子变量树	0.6852	0.0049	0.9980	16.24	1.0000
线性中信号	Copula-MVR	0.0549	0.0073	0.9800	10.45	0.0400
线性中信号	Elastic Net	0.6678	0.0011	1.0000	30.13	1.0000
线性中信号	稳定性选择	0.6691	0.0009	1.0000	30.24	1.0000
线性中信号	影子变量树	0.4771	0.0090	0.8850	17.40	0.9900
线性弱信号	Copula-MVR	0.0299	0.0057	0.3350	3.69	0.0200
线性弱信号	Elastic Net	0.6686	0.0010	1.0000	30.20	1.0000
线性弱信号	稳定性选择	0.6731	0.0007	1.0000	30.60	1.0000
线性弱信号	影子变量树	0.3573	0.0109	0.7610	12.10	0.9000
线性较密信号	Copula-MVR	0.0531	0.0053	0.9960	15.83	0.0000
线性较密信号	Elastic Net	0.5022	0.0014	1.0000	30.16	1.0000
线性较密信号	稳定性选择	0.5074	0.0012	1.0000	30.47	1.0000

第七章 已知真值模拟与生成诊断

场景	方法	平均 FDP	FDP MCSE	Power	发现数	FDP>0.20 比例
线性较密信号	影子变量树	0.3296	0.0088	0.7887	17.91	0.8900
非线性独立误差	Copula-MVR	0.0000	0.0000	0.0000	0.00	0.0000
非线性独立误差	Elastic Net	0.6724	0.0011	0.9890	30.20	1.0000
非线性独立误差	稳定性选择	0.6755	0.0008	0.9960	30.70	1.0000
非线性独立误差	影子变量树	0.2480	0.0110	0.8590	11.68	0.6300
非线性组内相关	Copula-MVR	0.0000	0.0000	0.0000	0.00	0.0000
非线性组内相关	Elastic Net	0.6727	0.0011	0.9900	30.26	1.0000
非线性组内相关	稳定性选择	0.6765	0.0011	0.9890	30.58	1.0000
非线性组内相关	影子变量树	0.2681	0.0096	0.8540	11.81	0.7500

原生表仅包含确实具有经验截断或稀疏输出的四类方法。Elastic Net 非零集合、稳定性选择频率阈值和影子变量树频率阈值都不是本文已经证明的 FDR 规则。Copula-MVR 则以 Knockoff/e-BH 构造为基础，但生成近似仍需检验。原生名单较少时的低平均 FDP 应结合 Power 和空名单频率理解。

Copula-MVR 原生规则在六场景中的平均 FDP 范围为 0.0000 至 0.0549，平均 Power 范围为 0.0000 至 0.9960。这是当前有限场景、固定配置的经验结果；观察均值低于目标不能证明所有分布上的 FDR 控制，检出率低也必须与空名单和阈值约束结合解释。

Copula-MVR 在稀疏强信号及两个非线性场景中，100 次重复均返回空原生名单，平均 FDP 和 Power 同时为零。这些零 FDP 不是高效筛选的证据。另一方面，Elastic Net 和经验稳定性选择的原生集合在若干场景接近全部 31 项，较高 Power 伴随较高 FDP；其原因包括从真实预测任务迁移的较弱惩罚，不能据此否定原稳定性选择文献在满足特定选择量约束时的理论。

在 $p = 31$ 且单轮水平 0.10 的设定中，即使没有负向超过阈值的统计量，也至少需要 10 个正向超过阈值的变量才能使 Knockoff+ 比例达标。对只有 5 个强信号的场景，这会造成保守性。60 轮聚合并不能凭空消除单轮阈值的离散约束，因此本研究不以“去随机化”替代对小 p 低功效的解释。




图 7-2 原生规则的平均 FDP 与 Power

第五节 真实数据的联合交换性诊断

诊断在不参与生成器拟合的排序期特征上进行。对于 25%、50% 和 100% 的特征对交换，将原始真假拼接行和交换行交给 Extra Trees 分类器；同一原始行与其交换版本成对进入诊断训练集或诊断测试集。若模型能稳定区分两者，则对联合交换性构成经验警告。

这里“不参与拟合”仅指没有用于梯度更新：DeepDRK 此前已用排序期的 X-only 损失选择检查点，因此诊断窗口并非完全独立的外部样本。这进一步限制了其形式检验含义。

表 7-4 生成器交换性诊断

生成器	平均边际 KS	25% AUC	50% AUC	100% AUC	状态
Copula-MVR	0.0575	0.7195	0.9367	0.9578	警告
DeepDRK 种子 11	0.3830	1.0000	1.0000	1.0000	警告
DeepDRK 种子 29	0.2443	1.0000	1.0000	1.0000	警告
DeepDRK 种子 47	0.4184	1.0000	1.0000	1.0000	警告

Copula-MVR 的平均边际 KS 约为 0.0575，但交换比例 25%、50%、100%

的 AUC 分别约为 0.7195、0.9367 和 0.9578。边际较为接近并未阻止联合分类器识别差异。三个 DeepDRK 生成器的 AUC 接近 1，平均边际 KS 也较高，表明当前适配存在明显分布失配。

诊断使用 199 次成对标签翻转， p 值最小分辨率为 0.005。其分割和翻转单位为观测行而非卖家，且只有三个固定交换比例，因此 p 值不是严格面板有效的全交换性检验。AUC 本身及其远离 0.5 的程度仍提供有用的工程警告，但未拒绝也不能证明交换性。本文据此限制实际 FDR 声明，而不将诊断解释为对相关原论文理论的普遍反证。




图 7-3 不同交换比例下的联合分类器 AUC

第六节 实验覆盖与不能推出的结论

八个完整比较方法各完成 111 个真实数据选择案例和 600 个模拟案例，合计 888 个真实案例与 4,800 个模拟案例；五种预算、两种评价器及公共全维基线共形成 82 组测试预测。DeepDRK 仅完成参考训练、生成诊断和该参考样本的下游竞争；TabPFN 保留运行失败；过滤型 attention-like 候选仅完成文献筛选。

计算覆盖完整只说明预设运行单元已经产生并通过一致性检查，不等于全部统计假设成立。模拟不存在业务真值，真实业务也不能直接计算 FDP。某方法在模拟中的平均 FDP 较低，不会修复它在 Olist 联合生成上的失配；某方法预测较好，也不因此获得条件独立发现或因果解释资格。

第八章 讨论与结论

第一节 主要研究结论

第一，在相同变量预算、时间窗口和评价器下，近期深度方法能够提供有竞争力的指标名单，但没有全面优胜者。TabM 置换排序和 Deep Lasso 在 XGBoost 评价器上接近最优；改用 TabM 评价器后，XGBoost-SHAP 仍具有很强的竞争力。结果支持把深度模型作为候选工具，不能支持以结构复杂程度代替选择质量。

第二，样本稳定性与预测表现不等价。影子变量树在半样本名单一致性方面突出，但并非所有预算和评价器下误差最低。Deep Lasso 的名单稳定性较高，而 TabM 置换的预测点估计较好。VTFS 适配模型既没有保持开发期预测优势，又对卖家样本变化较敏感，说明反复验证搜索与最终名单的泛化之间需要额外约束。

第三，错误率叙事必须以生成有效性为前提。Copula-MVR 的边际改善没有解决全部联合失配，DeepDRK 适配也未通过当前经验诊断。本文保留相关经验比较，但不把真实数据名单标为已经严格控制 20%FDR 的确认集合。固定 Top-K 名单不自动继承原生规则的理论保证。

第四，数据定义本身影响研究问题。签收月确认目标与购买月回溯目标的对数相关约为 0.7165，说明二者并非可互换口径。本期信息是否在月末可见、哪些卖家属于分析人口、零值究竟表示何种状态，都应先于算法性能解释。

第二节 对经营监控的启示

业务落地可分为候选、试运行和复核三个阶段。候选阶段保留透明且有明确时间口径的指标；试运行阶段根据看板容量选择 8 项或 12 项方案，同时记录名单来源和预测器；复核阶段使用新月份检查误差、缺失率及名单变化。对于仅由代理替代造成的小幅名单变化，可按业务概念组观察，而不必每次立即更换

看板字段。

本文不建议直接把开发期最优 VTFS 名单设为唯一默认方案。TabM 置换、Deep Lasso 和 XGBoost-SHAP 可进入后续时间外验证；在名单维护成本特别高的情形下，影子变量树值得作为稳定性参照。这些建议不是重新用测试集挑选一个“确认冠军”，而是由多项证据形成的后续验证方向。

对指标的使用仍应与描述性拆解结合。例如，订单数作为预测型监控特征能够提示下一期签收规模，但要解释当期 GMV 下降究竟来自哪些品类或地区，还需按原始品类、州或渠道进行金额分解。若进一步希望评估物流干预或营销策略效果，则需要自然实验、随机试验或具有识别假设的因果设计，不能直接读取模型重要性作为政策效应。

第三节 局限性

数据方面，研究仅覆盖一个公开平台和有限历史时期，分析人口不包括全部无活跃卖家月，静态快照的历史可见性无法完全核实。主目标是签收确认商品金额，不能覆盖退款、成本与利润。测试月份仅有三个月且曾参与前期探索，时间外确认强度有限。

方法方面，真实数据仅有 31 个候选维度，近期深度模型在高维冗余任务上的优势未必充分出现。各方法搜索空间、内部计算次数和适配程度不同；统一外层规则并不等于完全等算力。冻结参数的模拟研究也不能代表每个场景充分调参后的最佳性能。

推断方面，卖家簇 Bootstrap 只刻画固定测试月份下的卖家组成不确定性；生成诊断没有采用严格卖家层交换检验；经验 CDF、缩尾和缺失填补会改变原始特征的统计对象。多个探索性指标和后补消融增加了结果解读的自由度，本文通过保留冻结主选择、失败记录和并列表格减少选择性报告，但不能将其转化为外部注册的确认性证据。

第四节 后续研究

后续优先使用从未参与方法选择的新时间窗口与独立数据验证名单，而非继续围绕同一测试集增加模型。其次，在候选集合不变的条件下检验完整嵌套调参稳定性，区分参数选择与特征选择带来的波动。对于 VTFS，可单独实现按 K 优化的解码、与等查询预算随机搜索比较，并验证其训练部分确实贡献于样本外收益。

对于错误控制，可考虑更符合混合变量和卖家依赖结构的生成器、独立生成训练样本与卖家层诊断，再评价原生发现集合；在条件尚未满足时仍保留经验排序而不授予正式 FDR 标签。对于业务使用，可在新样本上研究按概念组聚合的稳定性，以及月度名单在周度预警中的适用性，但这些均属于待验证扩展，不是本文已完成结果。

参考文献

- [1] Tibshirani R. Regression shrinkage and selection via the lasso[J]. Journal of the Royal Statistical Society, Series B, 58(1), 267-288, 1996. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>.
- [2] Zou H, Hastie T. Regularization and variable selection via the elastic net[J]. Journal of the Royal Statistical Society, Series B, 67(2), 301-320, 2005. <https://doi.org/10.1111/j.1467-9868.2005.00503.x>.
- [3] Meinshausen N, Bühlmann P. Stability selection[J]. Journal of the Royal Statistical Society, Series B, 72(4), 417-473, 2010. <https://doi.org/10.1111/j.1467-9868.2010.00740.x>.
- [4] Shah R D, Samworth R J. Variable selection with error control: another look at stability selection[J]. Journal of the Royal Statistical Society, Series B, 75(1), 55-80, 2013. <https://doi.org/10.1111/j.1467-9868.2011.01034.x>.
- [5] Nogueira S, Sechidis K, Brown G. On the Stability of Feature Selection Algorithms[J]. Journal of Machine Learning Research, 18(174), 1-54, 2018. <https://www.jmlr.org/papers/v18/17-514.html>.
- [6] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. Proceedings of KDD, 785-794, 2016. <https://doi.org/10.1145/2939672.2939785>.
- [7] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[C]. Advances in Neural Information Processing Systems, 30, 2017. <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>.
- [8] Lundberg S M, Erion G, Chen H, et al. From local explanations to global understanding with explainable AI for trees[J]. Nature Machine Intelligence, 2, 56-67, 2020. <https://doi.org/10.1038/s42256-019-0138-9>.

- [9] Kursa M B, Rudnicki W R. Feature Selection with the Boruta Package[J]. Journal of Statistical Software, 36(11), 1-13, 2010. <https://doi.org/10.18637/jss.v036.i11>.
- [10] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees[J]. Machine Learning, 63, 3-42, 2006. <https://doi.org/10.1007/s10994-006-6226-1>.
- [11] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing[J]. Journal of the Royal Statistical Society, Series B, 57(1), 289-300, 1995. <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>.
- [12] Barber R F, Candès E J. Controlling the false discovery rate via knockoffs[J]. The Annals of Statistics, 43(5), 2055-2085, 2015. <https://doi.org/10.1214/15-AOS1337>.
- [13] Candès E, Fan Y, Janson L, Lv J. Panning for gold: model-X knockoffs for high dimensional controlled variable selection[J]. Journal of the Royal Statistical Society, Series B, 80(3), 551-577, 2018. <https://doi.org/10.1111/rssb.12265>.
- [14] Spector A, Janson L. Powerful knockoffs via minimizing reconstructability[J]. The Annals of Statistics, 50(1), 252-276, 2022. <https://doi.org/10.1214/21-AOS2104>.
- [15] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for false discovery rate control[J]. Journal of the Royal Statistical Society, Series B, 86(1), 122-154, 2024. <https://doi.org/10.1093/jrsssb/qkad085>.
- [16] Wang R, Ramdas A. False discovery rate control with e-values[J]. Journal of the Royal Statistical Society, Series B, 84(3), 822-852, 2022. <https://doi.org/10.1111/rssb.12489>.

- [17] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. Journal of Multivariate Analysis, 88(2), 365-411, 2004. [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4).
- [18] Cherepanova V, Levin R, Somepalli G, et al. A Performance-Driven Benchmark for Feature Selection in Tabular Deep Learning[C]. NeurIPS Datasets and Benchmarks Track, 2023. <https://openreview.net/forum?id=v4PMCdSaAT>.
- [19] Ying W, Wang D, Chen H, Fu Y. Feature Selection as Deep Sequential Generative Learning[J]. ACM Transactions on Knowledge Discovery from Data, 18(9), Article 221, 2024. <https://doi.org/10.1145/3687485>.
- [20] Gorishniy Y, Kotelnikov A, Babenko A. TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling[C]. International Conference on Learning Representations, 2025. <https://openreview.net/forum?id=Sd4wYYOhmY>.
- [21] Shen H, Yan Y, Zhao Z. DeepDRK: Deep Dependency Regularized Knockoff for Feature Selection[C]. Advances in Neural Information Processing Systems, 2024. <https://openreview.net/forum?id=ibKpPabHVn>.
- [22] Hollmann N, Muller S, Purucker L, et al. Accurate predictions on small data with a tabular foundation model[J]. Nature, 637, 319-326, 2025. <https://doi.org/10.1038/s41586-024-08328-6>.
- [23] Pham H, Tan Y, Singh T, Pavlopoulos V, Patnayakuni R. A multi-head attention-like feature selection approach for tabular data[J]. Knowledge-Based Systems, 301, 112250, 2024. <https://doi.org/10.1016/j.knosys.2024.112250>.
- [24] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle dataset, 2018. <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>.

- [25] Olist. Marketing Funnel by Olist[DB/OL]. Kaggle dataset, 2018. <https://www.kaggle.com/datasets/olistbr/marketing-funnel-olist>.
- [26] Morris T P, White I R, Crowther M J. Using simulation studies to evaluate statistical methods[J]. Statistics in Medicine, 38(11), 2074-2102, 2019. <https://doi.org/10.1002/sim.8086>.

附录 A 变量字典

下表范围为研究面板预处理之前的实际观测范围；均值类指标即使来源于整数记录，也通常是连续型聚合量。取值数是样本内不同数值的数量，不代表理论可取值总数。缺失值不计入取值数。

表 8-1 31 项候选指标的范围与缺失情况

编号	中文含义	类型	观测范围	取值数	缺失率
1	平均商品价格	连续聚合量	0.850 至 6735.000	8101	0.00%
2	平均运费	连续聚合量	0.030 至 314.400	9396	0.00%
3	平均商品重量	连续聚合量	2.000 至 30000.000	5499	0.01%
4	平均商品长度	连续聚合量	8.000 至 105.000	2345	0.01%
5	平均商品高度	连续聚合量	2.000 至 105.000	2306	0.01%
6	平均商品宽度	连续聚合量	6.000 至 104.000	2239	0.01%
7	平均商品图片数	连续聚合量	1.000 至 19.000	928	1.66%
8	平均商品标题长度	连续聚合量	7.000 至 64.000	2229	1.66%
9	平均商品描述长度	连续聚合量	4.000 至 3992.000	7535	1.66%
10	平均支付分期期数	连续聚合量	1.000 至 24.000	1579	0.00%
11	平均支付序列数	连续聚合量	1.000 至 15.000	284	0.00%
12	信用卡支付占比	连续聚合量	0.000 至 1.000	1836	0.00%
13	Boleto 支付占比	连续聚合量	0.000 至 1.000	374	0.00%
14	代金券支付占比	连续聚合量	0.000 至 1.000	1690	0.00%
15	借记卡支付占比	连续聚合量	0.000 至 1.000	151	0.00%
16	月末可见平均评价	连续聚合量	1.000 至 5.000	382	26.68%
17	月末已送达平均天数	连续聚合量	1.115 至 29.304	10733	21.74%
18	月末已审核平均天数	连续聚合量	0.000 至 23.162	11290	0.61%
19	月末已承运平均准备天数	连续聚合量	0.001 至 24.190	12725	7.14%

第八章 参考文献

编号	中文含义	类型	观测范围	取值数	缺失率
20	月末已送达预计提前天数	连续聚合量	-13.236 至 139.397	10740	21.74%
21	购买件数	计数	1.000 至 358.000	153	0.00%
22	购买订单数	计数	1.000 至 271.000	139	0.00%
23	活跃品类数	计数	0.000 至 17.000	17	0.00%
24	独立顾客数	计数	1.000 至 268.000	140	0.00%
25	买家州数量	计数	1.000 至 22.000	22	0.00%
26	第一大买家州占比	连续聚合量	0.100 至 1.000	453	0.00%
27	跨州交易占比	连续聚合量	0.000 至 1.000	515	0.00%
28	平均买卖家距离	连续聚合量	0.000 至 3343.136	13684	0.43%
29	已观察卖家州频率	连续聚合量	0.000 至 0.605	230	0.00%
30	已成交营销来源频率	连续聚合量	0.000 至 0.344	41	0.00%
31	月末已匹配营销成交	二元	0.000 至 1.000	2	0.00%

附录 B 实现差异与复现约定

表 8-2 原论文实现与本研究适配的对应关系

组件	来源	本研究差异
Deep Lasso	官方正则函数	自建两层 MLP，三种子，输入损失梯度排序
TabM	官方 0.0.3 软件包	8 成员；验证置换选择器另行附加
VTFS	官方编码器/解码器	随机语料、CPU、唯一 token、定额解码；保留 epsilon=1
DeepDRK	锁定官方 commit	64 宽 2 层；修正逐列提前返回；MPS；附加多轮聚合
Knockoff 竞争	对称系数差	L1 比例 0.999 的 Elastic Net 近似
稳定性选择	互补半样本思想	40 次 Lasso 与 0.9 经验阈值，无直接 PFER/FDR 声明
影子树	负对照与 Extra Trees	8 次、胜率 0.75，无完整 Boruta 复现声明
TabPFN v2	2.0.9 软件包	使用预训练权重；MPS 失败，未下采样补结果

官方来源的版本、压缩包摘要、软件包版本和协议摘要由工程清单保存。论文表格由案例级 JSON 与预测 CSV 生成，失败案例保留错误栈；计算修订前的中位秩结果和未统一线性响应尺度的模拟单独存档，不并入主结果。模型权重保存完整参考训练的网络状态，而非声称全部子样本均永久保留模型。

时间可见面板需从十张原始表重建；公共抽样名单由固定种子生成。CPU 浮点计算、软件版本和 MPS 实现差异仍可能造成极小数值变化，故复现应同时比较输入摘要、名单、训练轨迹和允许数值误差，而非只比较打印到四位小数的指标。

DeepDRK 与 TabPFN 退出不按零分处理，也不从方法登记中删除。参数、程序、样本和理论适用性是四个不同层次的可复核对象。复现材料使外部研究者可以定位结果的来源，但不能代替对科学问题及推断条件的独立判断。