

面向电商 GMV 监控的深度特征选择与稳定性评价研究

相同样本扰动、双评价器与真实负结果

吴优 2025213385

上海财经大学统计与数据科学学院
指导教师：张吕欧

2026 年 9 月



- 从 31 项经营指标中，选择值得持续监控的少量指标。
- 预测任务提供信息保留标准；稳定性反映名单对卖家变化的敏感性。
- 固定数量的推荐、原生错误控制和因果归因是不同问题。
- 不预设复杂深度模型一定优于统计或树模型。

方法	年份	出处/角色
Deep Lasso	2023	NeurIPS D&B; 输入梯度正则
VTFS	2024	ACM TKDD; 序列生成, 定额适配
DeepDRK	2024	NeurIPS; 深度 Knockoff 生成
TabM	2025	ICLR; 参数高效集成
TabPFN v2	2025	Nature; 预训练表格模型

- 对照: Copula-MVR、Elastic Net、稳定性选择、影子树、XGBoost-SHAP。

- 十张原始表：99,441 条订单，112,650 条商品明细。
- 13,754 个卖家月，2,723 名卖家，18 个特征月份。
- 候选指标 31 项；本月有购买明细的卖家进入分析。
- 下一月签收确认商品金额；不含运费，不等于利润或净收入。
- 下一月目标为零的比例为 17.8784%。

- 审核、承运、送达与评价按发生时间截断。
- 营销成交按成交日期截断；州频率使用当时已观察卖家。
- 支付、商品和卖家元数据缺少完整修订历史，仍有工作假设。
- 预测选择不等于按品类、地区拆分当期 GMV 的会计贡献。

阶段	目标月份	行数
训练	2017-02 至 2017-12	6,567
调参	2018-01 至 2018-02	1,831
排序	2018-03 至 2018-04	1,943
测试	2018-05 至 2018-07	3,413

- 测试前冻结主方法和 K；预测器在全部开发数据重拟合。
- 测试月份曾参与前期探索，不是全新外部确认样本。

- Deep Lasso: 训练时惩罚输入损失梯度, 再按梯度分数排序。
- TabM: 训练 8 成员共享权重网络, 再看验证集置换误差增量。
- VTFS: 从子集效用语料学习 Transformer 表示并搜索候选序列。
- 三者都实际训练, 但不自动获得 FDR 或因果解释。

$$\mathcal{L}_{\text{DL}} = \mathcal{L}_B + \lambda \sum_j \|\partial \mathcal{L}_B / \partial X_{B,j}\|_2$$

- 直接调用作者发布的正则函数，两层 MLP，三个训练种子。
- 验证早停；不使用测试集训练或选择检查点。
- 补充去掉正则的同样本消融，检验当前配置下的局部作用。

- 官方 2025 年参数高效集成网络，8 成员分别计算训练损失。
- 每列置换 3 次，以 MSE 增加量形成排名。
- 所有名单分别交给统一 XGBoost 与 TabM 重新预测。
- 双评价器用于识别名单收益是否依赖特定预测模型。

- 使用官方编码器、解码器；96 个随机子集语料。
- 固定预算唯一 token 解码；效用查询不超过 128 次。
- 保留公开代码中的常数重参数化，非完整原论文复现。
- 完整样本最终名单来自语料回退，本次收益不能归功于解码器。

- 30 组互补 50% 样本，共 60 个半样本；卖家全部月份共同保留。
- 20 个 70% 样本、20 个 80% 样本，共 100 个外层扰动。
- 另有 10 组固定数据的种子诊断，与样本稳定性分开。
- 比较 $K=4、8、10、12、14$ ；主预算预设 12。
- 50% 区间按 30 组计算，不把 60 个半样本视为独立。

- RMSE：保留的特征能否帮助下一期预测。
- Jaccard：名单名称是否一致；Nogueira 进行机会校正。
- FDP：发现中假变量的比例；Power：真变量被找到的比例。
- 真实业务没有已知真值，不能直接计算真实 FDP。
- 固定 12 项而只有 5 项真信号时，FDP 至少为 $7/12$ 。

同样 12 项：测试预测结果


选择方法	XGBoost RMSE	TabM RMSE
Copula-MVR	1.8663	1.8945
Elastic Net	1.8626	1.8737
稳定性选择	1.8931	1.8840
影子变量树	1.8606	1.8634
XGBoost-SHAP	1.8464	1.8572
Deep Lasso	1.8467	1.8600
TabM-置换	1.8443	1.8597
VTFS-定额适配	1.8625	1.8851
全维基线	1.8649	1.8588

开发主选择 VTFS 未保持优势；TabM、Deep Lasso 与树模型各有竞争力。

方法	50%	70%	80%
Copula-MVR	0.735	0.751	0.808
Elastic Net	0.724	0.838	0.909
稳定性选择	0.583	0.662	0.702
影子变量树	0.939	0.962	0.992
XGBoost-SHAP	0.768	0.847	0.822
Deep Lasso	0.823	0.887	0.762
TabM-置换	0.750	0.878	0.893
VTFS-定额适配	0.407	0.481	0.297

表中为相对完整开发名单的 Jaccard；稳定性不等于正确率。

展示容量：不能只看一条最有利结果




VTFS 按 K=12 优化顺序，其小 K 前缀不是独立优化结果。

Top-12 Power	SHAP	D.Lasso	TabM	VTFS
线性稀疏强信号	1.000	1.000	1.000	0.776
线性中信号	0.991	0.996	0.997	0.561
线性弱信号	0.935	0.902	0.927	0.552
线性较密信号	0.782	0.793	0.799	0.485
非线性独立误差	0.964	0.831	0.843	0.585
非线性组内相关	0.970	0.846	0.823	0.567

- 全部八方法共享生成数据；完整 FDP、Power 和原生名单见论文。
- 跨场景固定超参数，结果不代表各场景充分调参后的上界。

生成诊断：不能无条件宣称真实 FDR 受控



Copula-MVR 与 DeepDRK 均有联合失配警告；诊断不通过不等于反证原论文。

- VTFS 完整样本解码候选的开发效用增益为零，最终名单等于回退名单。
- Deep Lasso 保留/移除正则的半样本 Jaccard: 0.8230 / 0.8182; 仅为固定配置消融。
- DeepDRK 只完成参考训练与诊断; TabPFN 保留 MPS 失败记录。
- 失败方法不填零、不补造结果，也不声称完成全部公平比较。

- 没有全面优胜者，深度结构复杂不等于名单质量更高。
- 按新时间窗口验证 TabM、Deep Lasso 与强树基线。
- 加强按 K 独立优化、等查询预算随机搜索和嵌套调参比较。
- 研究混合变量与卖家依赖下的生成有效性，再讨论原生 FDR。
- 月度向周度迁移属于后续验证，不沿用未验证的多粒度结论。

- [1] Cherepanova V, Levin R, Somepalli G, et al.. A Performance-Driven Benchmark for Feature Selection in Tabular Deep Learning. NeurIPS Datasets and Benchmarks Track, 2023.
- [2] Ying W, Wang D, Chen H, Fu Y. Feature Selection as Deep Sequential Generative Learning. ACM Transactions on Knowledge Discovery from Data, 18(9), Article 221, 2024.
- [3] Gorishniy Y, Kotelnikov A, Babenko A. TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling. International Conference on Learning Representations, 2025.
- [4] Shen H, Yan Y, Zhao Z. DeepDRK: Deep Dependency Regularized Knockoff for Feature Selection. Advances in Neural Information Processing Systems, 2024.
- [5] Hollmann N, Muller S, Purucker L, et al.. Accurate predictions on small data with a tabular foundation model. Nature, 637, 319-326, 2025.
- [6] Candès E, Fan Y, Janson L, Lv J. Panning for gold: model-X knockoffs for high dimensional controlled variable selection. Journal of the Royal Statistical Society, Series B, 80(3), 551-577, 2018.
- [7] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for false discovery rate control. Journal of the Royal Statistical Society, Series B, 86(1), 122-154, 2024.
- [8] Wang R, Ramdas A. False discovery rate control with e-values. Journal of the Royal Statistical Society, Series B, 84(3), 822-852, 2022.
- [9] Meinshausen N, Bühlmann P. Stability selection. Journal of the Royal Statistical Society, Series B, 72(4), 417-473, 2010.
- [10] Shah R D, Samworth R J. Variable selection with error control: another look at stability selection. Journal of the Royal Statistical Society, Series B, 75(1), 55-80, 2013.
- [11] Nogueira S, Sechidis K, Brown G. On the Stability of Feature Selection Algorithms. Journal of Machine Learning Research, 18(174), 1-54, 2018.
- [12] Morris T P, White I R, Crowther M J. Using simulation studies to evaluate statistical methods. Statistics in Medicine, 38(11), 2074-2102, 2019.

完整 26 项来源及可访问链接见论文参考文献。