

面向电商 GMV 监控的深度特征选择与稳定性评价研究

1 研究摘要

电商经营看板通常同时展示交易、商品、支付、履约和地域等大量指标。指标间的相关性使信息重复，而有限的展示容量又要求管理者在预测信息、名单稳定性和误选风险之间进行权衡。深度特征选择能够表达非线性关系，但模型复杂度、验证集搜索和算法随机性可能使其在具体业务数据上的优势弱于公开基准中的表现。本文围绕下一月签收确认商品金额的监控，研究近期深度特征选择方法在统一评价条件下的适用性，并将固定数量的指标推荐与具有假设前提的错误发现率控制明确区分。

研究使用 Olist 公开的十张业务表，按照事件发生时间重建月末可见特征，得到 13,754 个卖家月观测、2,723 名卖家和 31 项候选指标。训练、调参、排序与测试阶段按目标月份划分，测试期为 2018 年 5 至 7 月。比较方法包括 Copula-MVR、Elastic Net、稳定性选择、影子变量树、XGBoost-SHAP、Deep Lasso、TabM 置换排序及 VTFS 定额适配。各方法共享 30 组互补半样本、20 组 70% 样本与 20 组 80% 样本，另设置 10 组固定数据算法随机性试验；在两个统一下游评价器中比较五种变量预算。六种已知真值的模拟场景各重复 100 次，用于分别评价原生名单和固定预算名单。

实际数据结果表明，复杂模型并不形成一致优势。在 12 项预算下，TabM 置换排序和 Deep Lasso 经统一 XGBoost 评价器得到的测试对数 RMSE 分别为 1.8443 和 1.8467，XGBoost-SHAP 为 1.8464；改用 TabM 评价器后，XGBoost-SHAP 为 1.8572，TabM 置换排序为 1.8597。开发期选中的 VTFS 适配模型在两种评价器下分别为 1.8625 和 1.8851，未保持开发集优势。50% 卖家抽样中，影子变量树与完整开发名单的平均 Jaccard 为 0.9388，Deep Lasso 为 0.8230，VTFS 适配模型为 0.4068。交换性诊断同时发现 Copula-MVR 和本次 DeepDRK 适配生成器存在联合分布失配，因而不对真实数据给出无条件 FDR 保证。

本文的应用价值在于形成按时间可见性构建数据、按相同样本扰动比较方法、按展示容量评价信息保留、按诊断结果限定统计结论的研究流程。结果支持将近期深度模型纳入候选工具，但不支持以方法新颖或结构复杂替代样本外证据。指标名单应作为与目标口径、时间窗口和评价器相关的监控建议，而非因果归因或永久有效的准入结论。

2 数据来源与月末可见面板

2.1 数据来源及连接层级

研究数据来自 Olist 公开电商交易数据集与营销漏斗数据集 [24, 25]。实际读取订单、商品明细、支付、评价、商品、卖家、顾客、地理位置、营销合格线索及营销成交十张 CSV。订单表包含 99,441 条订单记录，商品明细表包含 112,650 条记录。多个商品明细、多个支付记录或多个评价记录可能对应同一订单，因此直接按订单编号展开连接会重复计算金额。

本文先在支付表中按订单汇总金额，并以支付金额加权计算分期期数；评价仅在时间可见的记录中按订单平均；地理数据按邮编前缀计算经纬度中位数。随后将订单信息连接到商品明细，再按卖家与月份汇总。支付和物流指标在卖家订单级去重后平均，避免同一订单因多件商品而重复加权；商品属性、件数及部分地域构成以商品明细为权重。两种聚合口径各自对应不同业务对象，不能笼统称为所有变量均“按订单平均”。

商品金额始终由商品明细价格求和，运费单列保存而不进入目标。全源表具有送达时间记录的商品金额对账合计为 13,220,895.11 巴西雷亚尔。该金额是数据连接的核验量，并非仅指最终研究面板所覆盖的卖家月目标之和。

2.2 信息时间与目标定义

设卖家为 s ，特征月份为 t ，月末信息截止点为下一月第一日。主目标定义为

$$G_{s,t+1} = \sum_{i: \text{seller}(i)=s, \text{deliverymonth}(i)=t+1} \text{price}_i, \quad Y_{s,t+1} = \log(1 + G_{s,t+1}).$$

使用对数尺度的原因是卖家金额存在长尾与零值；它使相对变化获得更多权重，并减轻少数大额观测对平方损失的支配。对数变换并不消除零值过程的特殊性，因此本文同时报告原金额尺度的 WAPE，作为补充而非替代。

物流特征只使用截止点之前已发生的审核、承运和送达事件。评价使用回答时间，而非仅使用订单购买月份。营销成交仅在成交日期早于截止点时进入特征，其来源频率也在当时已可见的成交记录中计算。卖家州频率以当时已经观察到购买活动的卖家为基数，不使用未来才出现的卖家扩充历史分母。

按全源表计数，时间遮蔽涉及 1,684 条审核记录、9,432 条承运记录、36,430 条送达时长记录和 47,439 条晚于截止点的评价记录。上述数字反映信息回溯风险的规模，但不能解读为相同数量的最终面板行被删除：一名卖家一个月可包含多条订单，并且部分指标仍能由当月其他可见记录计算。

支付记录与商品、卖家元数据缺少完整修订时间，地理表也不是逐月历史快照。本文只能将这些信息在购买时可得作为工作假设。对于无法从公开字段验证的历史可见性，不作完全消除信息泄漏的强声明。

2.3 样本人口与时间切分

特征月范围为 2017 年 1 月至 2018 年 6 月，共 18 个月。样本要求特征月存在购买商品明细，不先按最终订单状态过滤本月特征，以免将未来的最终交付状态提前用于样本选择。如果次月没有签收商品金额记录，则在当前分析人口中记为零。所得面板包含 13,754 行、2,723 名卖家，下一月目标为零的比例为 17.8784%。

这一人口定义排除了特征月没有购买明细的卖家，即使其下一月可能完成较早订单的签收。因此，结果适用于当前购买活跃卖家的下一期签收监控，不直接外推到平台全部注册卖家、所有无活跃月份或冷启动卖家。

表 1: 按目标月份划分的数据窗口

阶段	目标月份	行数	卖家数	用途
训练	2017-02 至 2017-12	6567	1694	预处理与模型拟合
调参	2018-01 至 2018-02	1831	1175	冻结配置
排序	2018-03 至 2018-04	1943	1219	名单、早停、开发选择
测试	2018-05 至 2018-07	3413	1680	仅评价

训练阶段用于拟合预处理参数与模型；调参阶段选择冻结配置；排序阶段用于计算验证重要性、早停或子集效用，并冻结主方法及紧凑预算；测试阶段仅用于评价。预测器最终在全部开发期目标上重拟合，但特征名单不读取测试目标。测试月份曾参与前期探索，因此这一时间留出不等于从未接触过的新外部确认样本。

2.4 候选指标及缺失值

31 项指标涵盖价格运费、商品物理属性、商品展示内容、支付方式、月末可见口碑、履约时间、交易规模、地域覆盖与营销状态。商品品类被汇总为活跃品类数；顾客使用跨订单唯一顾客标识；市




图 1: 研究面板覆盖的签收确认金额与对数目标分布

场集中度采用第一大买家州的商品明细占比。所有字段的观测范围、不同取值数与缺失比例列于附录。

月末可见评价的缺失比例为 26.6759%，已送达平均天数及预计提前天数的缺失比例为 21.7391%。这些缺失部分源于尚未发生相应事件，而非随机漏报。因此，中位数填补是一种共同预处理约定，不代表缺失机制可忽略。主比较不增加缺失指示器，以保持候选集合固定；后续可将“缺失意味着未完成”作为独立业务状态建模。

订单数、件数和独立顾客数具有明显概念重叠；信用卡与 Boletto 等支付占比也受到构成约束。相关变量的相互替代可能造成名单差异，却未必造成同等程度的预测损失。本文因此同时评价名单稳定性与下游误差，而不把不同名字的出现直接解释为业务关系根本改变。

2.5 训练期预处理

主预测预处理包括：对非负偏态均值及计数做预设对数变换；利用拟合窗口计算 1% 与 99% 分位缩尾点；以拟合窗口中位数填补缺失；按拟合窗口均值和标准差缩放。排序与测试数据只应用既定参数，不根据各自批次重新估计分位点或均值。

Copula-MVR 另使用训练经验 CDF 上的随机并列分位数。对于一个取值，首先在训练排序中确定相等值的左右端点，再在对应经验概率区间中放置固定种子的随机数，最后映射到标准正态分位数。这可使二元变量的并列值在概率区间内展开，但改变了变量表示；它不是证明原始二元变量存在可逆的高斯变换。

当前随机并列数按列和输入行位置生成。固定相同行顺序与同一前缀批次时结果保持一致，但任意重新排列或分块后不具有逐行恒等不变性。复现要求保持规定的月、卖家排序。这一限制与“CDF 仅由训练数据估计”是两个不同问题，本文不将有限批次前缀校验表述为任意排列不变性证明。

3 公平实验设计

3.1 时间分工与调参预算

首先在训练期拟合、调参期评价，选择各方法的固定超参数。可调标准预测器通常使用 12 种不同配置；论文默认型或资源适配型方法使用已记录的固定配置，不按最终发现数选参。随后在训练加调参窗口拟合，并在排序窗口产生名单。外层子样本保持相同超参数，不在每一子样本重新搜索。

因此，本文考察的是“固定配置的选择程序对样本扰动的敏感性”，而不是包含重新调参在内的端到端流程稳定性。不同方法的内部训练次数与损失不同，无法通过机械设置相同 epoch 来保证等计算量。本设计统一数据、外层样本、变量预算、评价器和测试期，并披露搜索与运行成本；它不是严格等 FLOP 或等墙钟时间竞赛。




图 2: 候选经营指标的 Spearman 相关结构

表 2: 冻结配置与实际训练预算

方法	配置数	选定配置
Copula-MVR	1	60 轮; 竞争惩罚 0.01
Elastic Net	12	alpha=0.001, l1_ratio=0.9
稳定性选择	12	alpha=0.001
影子变量树	12	trees=240, leaf=8
XGBoost-SHAP	12	depth=4, lr=0.03, trees=280
Deep Lasso	12	width=64, layers=2, lr=0.003, regularization=1.0
TabM-置换	12	width=64, layers=3, lr=0.001
VTFS-定额适配	1	width=64, layers=2, lr=0.001, epochs=100

3.2 公共卖家抽样

以开发期出现的卖家为抽样单位。每组随机排列所有开发卖家，并划分为互补 A、B 两半；共 30 组，得到 60 个约 50% 样本。同一卖家的所有开发期月份保留在同一半样本内。另设置 20 个 70% 样本与 20 个 80% 样本；相同组号的 70% 和 80% 样本来自同一随机排列的不同长度前缀。

所有方法读取相同卖家名单，不根据某方法的成功或表现重新抽样。每个案例记录拟合行和排序行的哈希，并跨方法核对。卖家层抽样保留了组内观测关系，避免把同一卖家的某些月份抽中、另一些月份独立删除；但它不是对面板依赖的全部统计修正，也不自动使生成器满足 Model-X 交换性。

固定数据的算法随机性另做 10 个种子批次。对于确定性的 Elastic Net，更换种子不应改变结果；对于 Knockoff，改变假变量生成种子；对于网络，改变初始化和优化种子；对于稳定性选择及影子树，改变其内部抽样或扰动种子。评价对象相同，但算法内部机制按各自定义保留。

3.3 稳定性指标与区间

名单相似性采用 Jaccard:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

主指标比较每个子样本名单与相同方法的完整开发样本名单。第二项指标直接比较同组互补半样本 A 与 B，减少完整样本参考名单本身特殊性的影响。第三项指标为 Nogueira 机会校正稳定性:

$$\hat{\Phi} = 1 - \frac{p^{-1} \sum_{j=1}^p \widehat{\text{Var}}(Z_{\cdot j})}{(\bar{k}/p)(1 - \bar{k}/p)},$$

其中 Z_{bj} 表示第 b 份名单是否选中特征 j ， $\bar{k}$ 为平均名单长度。该指标在本研究中作为描述性估计量，不将互补半样本当作独立重复套用原文独立样本的推断公式。

50% 样本的置信区间以 30 个组为单位：先平均同组 A、B 相对参考名单的 Jaccard，再计算组间标准误与 t 区间。70% 与 80% 分别使用 20 个组。方法间比较在同组内作差，而不以两个边际区间是否重叠判断差异。区间描述的是给定数据集的抽样敏感性，不能代表跨平台、跨年度的总体稳定性。

3.4 统一预测评价器

每条特征名单均交给固定配置的 XGBoost 和 TabM 评价器，使用相同目标与时间窗口。XGBoost 树数固定，先用排序期计算开发误差，再用全部开发数据重拟合。TabM 先在排序期确定最佳训练轮次，再以该轮次在全部开发数据上重新训练，不根据测试损失选择检查点。每个评价器均使用三个训练种子的平均预测。

报告对数 RMSE、对数 MAE、对数尺度 R^2 及原金额 WAPE:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_i (Y_i - \hat{Y}_i)^2}, \quad \text{WAPE} = \frac{\sum_i |G_i - \max\{0, \exp(\hat{Y}_i) - 1\}|}{\sum_i G_i}.$$

由对数预测直接逆变换并不是条件平均金额的无偏估计，本文没有使用未经验证的偏差校正。因此，WAPE 只反映该逆变换规则下的金额误差，不据此声称最优收入预测。

测试区间采用 2,000 次配对卖家簇 Bootstrap。每次抽取卖家并保留其全部测试月份，同一抽样用于比较双方。主方法相对其他方法的差值统一定义为“主方法 RMSE 减对照 RMSE”，负值表示主方法误差较小。另给出一个固定 K、固定评价器内的 Bonferroni 分位区间；只有 2,000 次 Bootstrap 时尾部分位数精度有限，近零边界不作强结论。

测试期仅有三个月，卖家簇 Bootstrap 不能刻画宏观时间冲击或年度漂移的不确定性。所有区间均以这三个已观察月份为条件，既非长期经营保证，也不等于全体模型、预算、评价器和后续探索共同的错误率控制。

3.5 主选择规则与分析修订

开发集在主预算 12 下按统一 XGBoost 误差选择主方法；紧凑方案采用“在最优开发误差 1% 以内的最小 K”。规则在测试预测生成前保存，选出 VTFS 适配模型作为开发主选择、8 项作为紧凑方案。测试结果公布后不替换主方法，以免把测试期最优者重新包装为预先指定的胜者。

本地协议不是公开注册的确认性研究。执行过程中记录了设备移植、生成器缺陷修正、随机并列 CDF 修正、响应尺度修正及部分候选退出；原始结果按敏感性分析或失败记录保留。模拟中的 Elastic Net 和稳定性选择统一使用训练响应标准化后重跑，以匹配冻结惩罚的尺度；神经与 Knockoff 选择器内部标准化，树损失或子集效用采用相应尺度等变或归一化规则。补充消融在主结果计算后提出，应当按探索性证据解释。

4 实际数据结果

4.1 同预算预测表现

表 3: 12 项预算下的统一测试评价

选择方法	XGB-RMSE	TabM-RMSE	XGB-MAE	XGB- R^2	XGB-WAPE
Copula-MVR	1.8663	1.8945	1.3566	0.4894	0.5269
Elastic Net	1.8626	1.8737	1.3542	0.4914	0.5279
稳定性选择	1.8931	1.8840	1.3620	0.4746	0.5308
影子变量树	1.8606	1.8634	1.3494	0.4925	0.5281
XGBoost-SHAP	1.8464	1.8572	1.3442	0.5003	0.5276
Deep Lasso	1.8467	1.8600	1.3467	0.5001	0.5248
TabM-置换	1.8443	1.8597	1.3435	0.5014	0.5232
VTFS-定额适配	1.8625	1.8851	1.3592	0.4915	0.5312
全维基线	1.8649	1.8588	1.3404	0.4902	0.5232

在 XGBoost 评价器下，TabM 置换排序取得 1.8443 的点估计，Deep Lasso 和 XGBoost-SHAP 分别为 1.8467 和 1.8464。这几项结果十分接近。相对 31 项基线 1.8649，保留 12 项能够在该评价器下取得较低误差，但这个比较不说明所删 19 项都不包含条件信息，也不说明三个方法彼此存在已经确认的显著差异。




图 3: 固定 12 项预算下的双评价器预测结果

更换为 TabM 评价器后，XGBoost-SHAP 的 RMSE 为 1.8572，Deep Lasso 与 TabM 置换分别为 1.8600 和 1.8597，全维基线为 1.8588。方法排名发生变化，表明一个名单是否有效与下游模型能否利用其信息有关。仅展示 XGBoost 评价器将夸大个别方法的优势；仅展示网络评价器也不能概括所有使用环境。

开发主选择 VTFS 适配模型的测试 RMSE 为 1.8625 和 1.8851，并未在测试期保持开发期优势。这一现象与序列模型在排序期反复评估子集有关，也可能受到任务规模、语料预算和适配方式的影响。现有结果不能区分各原因的贡献，但足以反对以开发期最优作为直接部署依据。

4.2 配对误差差异

表 4: 开发主选择相对各方法的测试 RMSE 配对区间

评价器	对照	VTFS 减对照	95% 区间	同组多重比较区间
xgboost	Copula-MVR	-0.0038	[-0.0169, 0.0094]	[-0.0231, 0.0146]
xgboost	Elastic Net	-0.0001	[-0.0141, 0.0138]	[-0.0185, 0.0198]
xgboost	稳定性选择	-0.0306	[-0.0505, -0.0098]	[-0.0571, -0.0015]
xgboost	影子变量树	0.0019	[-0.0123, 0.0164]	[-0.0193, 0.0212]
xgboost	XGBoost-SHAP	0.0161	[0.0042, 0.0274]	[-0.0013, 0.0327]
xgboost	Deep Lasso	0.0158	[0.0031, 0.0276]	[-0.0012, 0.0333]
xgboost	TabM-置换	0.0182	[0.0047, 0.0308]	[0.0001, 0.0368]
xgboost	全维基线	-0.0024	[-0.0164, 0.0109]	[-0.0196, 0.0158]
tabm	Copula-MVR	-0.0094	[-0.0269, 0.0087]	[-0.0362, 0.0161]
tabm	Elastic Net	0.0114	[-0.0084, 0.0312]	[-0.0159, 0.0370]
tabm	稳定性选择	0.0010	[-0.0206, 0.0239]	[-0.0288, 0.0329]
tabm	影子变量树	0.0217	[0.0042, 0.0397]	[-0.0023, 0.0463]
tabm	XGBoost-SHAP	0.0279	[0.0107, 0.0454]	[0.0044, 0.0519]
tabm	Deep Lasso	0.0251	[0.0080, 0.0423]	[-0.0001, 0.0480]
tabm	TabM-置换	0.0254	[0.0081, 0.0422]	[0.0026, 0.0486]
tabm	全维基线	0.0263	[0.0087, 0.0444]	[0.0018, 0.0505]

在 XGBoost 评价器下，VTFS 与 Elastic Net 的点差约为 -0.0001，与 Copula-MVR 的点差约为 -0.0038，95% 配对区间均跨零。相对 TabM 置换，VTFS 点差约为 0.0182，方向不利于 VTFS；在




图 4: 相同卖家抽样下的名单稳定性及组级区间

当前多重比较分位区间中，下界非常接近零，不宜夸大边界显著性。在 TabM 评价器下，VTFS 对若干对照的误差较高，开发选择没有形成稳健领先。

“区间跨零”不等于证明两方法等价。协议中的 1% 误差容忍度主要用于开发期紧凑方案，不自动成为经过正式等价检验的结论。尤其对于全维基线，只有在预先指定方向和容忍度、并用配对区间进行适当检验后，才可讨论非劣性；本文使用更保守的“点估计接近”或“未获得稳定优势”措辞。

4.3 样本稳定性与参考名单

表 5: Top-12 名单的样本稳定性

方法	50% 均值 [组级 95% 区间]	70% 均值	80% 均值	50% Nogueira
Copula-MVR	0.7355 [0.7131, 0.7578]	0.7508	0.8077	0.6798
Elastic Net	0.7244 [0.6979, 0.7509]	0.8385	0.9088	0.6185
稳定性选择	0.5827 [0.5614, 0.6041]	0.6619	0.7018	0.4788
影子变量树	0.9388 [0.9233, 0.9544]	0.9615	0.9923	0.9210
XGBoost-SHAP	0.7682 [0.7501, 0.7862]	0.8470	0.8220	0.7439
Deep Lasso	0.8230 [0.7962, 0.8498]	0.8868	0.7615	0.7754
TabM-置换	0.7505 [0.7196, 0.7813]	0.8780	0.8934	0.7304
VTFS-定额适配	0.4068 [0.3377, 0.4758]	0.4814	0.2972	0.2733

50% 卖家抽样下，影子变量树相对完整开发名单的平均 Jaccard 最高，为 0.9388；Deep Lasso 为 0.8230；XGBoost-SHAP 为 0.7682；TabM 置换为 0.7505；Copula-MVR 为 0.7355；Elastic Net 为 0.7244；稳定性选择为 0.5827；VTFS 适配为 0.4068。方法名称中的“稳定性选择”并不保证它在所有数据、惩罚参数和固定 K 下的 Jaccard 最高。

70% 和 80% 样本有助于观察名单在接近完整数据时的变化，但稳定性不必对抽样比例单调增加。例如，Deep Lasso 和 VTFS 在某些较大子样本中的相对参考 Jaccard 下降，而子样本之间仍可能更一致。这说明完整开发名单本身也可能是一份特殊名单。增加样本比例后的非单调结果不能被删除或以“异常”名义重抽。

表 6: 互补半样本之间的 Top-12 一致性

方法	互补 Jaccard[95% 区间]	互补组数
Copula-MVR	0.6180 [0.5891, 0.6469]	30

方法	互补 Jaccard[95% 区间]	互补组数
Elastic Net	0.5318 [0.4936, 0.5700]	30
稳定性选择	0.4691 [0.4344, 0.5038]	30
影子变量树	0.8828 [0.8545, 0.9111]	30
XGBoost-SHAP	0.6557 [0.6241, 0.6874]	30
Deep Lasso	0.7381 [0.6961, 0.7801]	30
TabM-置换	0.6925 [0.6349, 0.7501]	30
VTFS-定额适配	0.4339 [0.3233, 0.5445]	30

互补 A/B 比较与 Nogueira 指标提供了不同参照：前者直接比较不重叠卖家集合，后者基于全部入选频率进行机会校正。若相对完整名单的 Jaccard 低，但 Nogueira 较高，说明多个子样本倾向于共同选择另一份名单，而非每次都完全随机。该区别对于判断参考名单是否具有代表性具有实际价值。

4.4 算法随机性与样本扰动

表 7: 固定开发数据更换种子的 Top-12 一致性

方法	均值	最小值	最大值	种子批次
Copula-MVR	1.0000	1.0000	1.0000	10
Elastic Net	1.0000	1.0000	1.0000	10
稳定性选择	0.7824	0.7143	1.0000	10
影子变量树	1.0000	1.0000	1.0000	10
XGBoost-SHAP	0.8769	0.8462	1.0000	10
Deep Lasso	0.8769	0.8462	1.0000	10
TabM-置换	0.9692	0.8462	1.0000	10
VTFS-定额适配	0.2935	0.2000	0.4118	10

固定数据的种子试验只能说明初始化、内部重抽样或 Knockoff 生成随机性带来的变动，不反映更换卖家后的鲁棒性。确定性方法的种子一致性为 1 是计算机制

的结果，而非其泛化能力必然更好。随机方法通过多次训练或聚合可以减少种子敏感性，但不保证样本敏感性同步降低。

本文不将两类稳定性合并成一个百分数，也不把频繁出现的变量称为具有同等数值的“真实概率”。业务使用者应同时看到指标的入选频率、样本扰动结果和所用评价器，而不能仅凭一项接近 1 的算法一致性决定长期保留。

4.5 容量路径与具体名单

表 8: 不同预算下的测试 RMSE

评价器	选择方法	K=4	K=8	K=10	K=12	K=14
xgboost	Copula-MVR	2.0532	1.8664	1.8648	1.8663	1.8646
xgboost	Elastic Net	2.0486	1.8652	1.8673	1.8626	1.8807
xgboost	稳定性选择	2.0405	1.8782	1.8967	1.8931	1.8913
xgboost	影子变量树	2.1338	1.8593	1.8562	1.8606	1.8469
xgboost	XGBoost-SHAP	2.0485	1.8454	1.8441	1.8464	1.8479
xgboost	Deep Lasso	1.8762	1.8555	1.8579	1.8467	1.8474
xgboost	TabM-置换	1.8681	1.8551	1.8566	1.8443	1.8467




图 5: 五种展示容量下的预测误差路径

评价器	选择方法	K=4	K=8	K=10	K=12	K=14
xgboost	VTFS-定额适配	2.3854	1.8622	1.8614	1.8625	1.8608
tabm	Copula-MVR	2.0462	1.8933	1.8962	1.8945	1.8871
tabm	Elastic Net	2.0422	1.8959	1.8932	1.8737	1.8668
tabm	稳定性选择	2.0384	1.8868	1.8871	1.8840	1.8695
tabm	影子变量树	2.1353	1.8689	1.8647	1.8634	1.8602
tabm	XGBoost-SHAP	2.0421	1.8606	1.8556	1.8572	1.8590
tabm	Deep Lasso	1.8998	1.8625	1.8684	1.8600	1.8582
tabm	TabM-置换	1.8833	1.8633	1.8622	1.8597	1.8604
tabm	VTFS-定额适配	2.3959	1.8878	1.8811	1.8851	1.8788

把 K 从 12 减到 4，不同方法的信息损失差异较大。Deep Lasso 和 TabM 置换的小预算表现相对平稳，而 VTFS 的四项前缀明显较弱。这与其按 12 项优化一条完整序列、回退子集按固定编号排序的适配机制一致。不能据此断言原始 VTFS 自动停止算法也存在相同问题。

开发期紧凑选择为 VTFS 的 8 项方案，其 XGBoost 测试 RMSE 约为 1.8622，而 TabM 评价器下约为 1.8878。这一方案减少了展示数量，但仍未形成跨评价器优势。因此，本文保留其作为开发规则的实际输出，不把它无条件推荐为最终生产默认名单。

表 9: 各方法完整开发样本的前 12 项指标

方法	按顺序列出的前 12 项
Copula-MVR	平均商品价格；独立顾客数；购买订单数；购买件数；买家州数量；平均买卖家距离；月末已送达平均天数；平均商品重量；活跃品类数；月末已审核平均天数；跨州交易占比；平均商品标题长度
Elastic Net	独立顾客数；购买订单数；平均商品价格；第一大买家州占比；购买件数；平均买卖家距离；平均商品重量；月末已送达平均天数；买家州数量；跨州交易占比；月末可见平均评价；平均运费
稳定性选择	平均商品价格；第一大买家州占比；购买件数；平均买卖家距离；平均商品重量；月末已送达平均天数；跨州交易占比；月末可见平均评价；平均商品标题长度；已观察卖家州频率；活跃品类数；平均支付分期期数

方法	按顺序列出的前 12 项
影子变量树	购买订单数；独立顾客数；买家州数量；购买件数；平均商品价格；第一大买家州占比；月末可见平均评价；月末已送达平均天数；月末已送达预计提前天数；平均支付分期期数；平均商品重量；平均运费
XGBoost-SHAP	独立顾客数；购买订单数；平均商品价格；买家州数量；月末已送达预计提前天数；月末已送达平均天数；月末可见平均评价；月末已承运平均准备天数；购买件数；平均商品标题长度；平均运费；平均商品重量
Deep Lasso	独立顾客数；购买订单数；平均商品价格；月末已送达平均天数；购买件数；第一大买家州占比；月末已送达预计提前天数；月末可见平均评价；买家州数量；平均买卖家距离；月末已承运平均准备天数；平均商品重量
TabM-置换	独立顾客数；平均商品价格；月末可见平均评价；月末已送达平均天数；购买订单数；月末已送达预计提前天数；购买件数；买家州数量；第一大买家州占比；平均商品重量；月末已承运平均准备天数；活跃品类数
VTFS-定额适配	平均商品价格；平均运费；平均支付序列数；代金券支付占比；月末已承运平均准备天数；月末已送达预计提前天数；独立顾客数；跨州交易占比；平均商品重量；平均商品长度；平均商品高度；平均商品宽度

名单中的价格、交易规模和部分履约指标具有直接业务含义，但入选并不意味着增加订单量、缩短时效等干预的因果效应已被识别。另一方面，未入选的支付或营销指标也不能被断言永久无效：其作用可能与低覆盖率、短观察窗口、代理变量和正则化共同有关。

完整开发样本中，Copula-MVR、Elastic Net、稳定性选择和影子变量树的原生集合分别包含 13、26、20 和 14 项。这些数目来自各自阈值或非零规则，不等于相同展示预算；Copula-MVR 的 13 项也不因使用 e-BH 就被自动认定为真实数据上有效的 FDR 确认集合。

4.6 局部消融与计算成本

表 10: Deep Lasso 正则与 VTFS 解码候选的补充消融

检查项目	数值	解释范围
Deep Lasso 保留正则的半样本 Jaccard	0.8230 [0.7962, 0.8498]	固定配置
去掉正则的半样本 Jaccard	0.8182 [0.7852, 0.8511]	相同 60 半样本
保留减去掉正则的配对差	0.0049 [-0.0278, 0.0375]	30 个组，探索性
完整样本两种正则设置名单 Jaccard	0.8462	Top-12
VTFS 完整名单等于语料回退	是	不归功于深度解码
VTFS 半样本与回退相同的比例	0.6167	60 个半样本
VTFS 解码候选的平均开发效用增益	0.0359	标准化响应负 MSE，仅开发期

在完整开发样本中，VTFS 最终 Top-12 与高效用随机语料的回退名单相同，解码候选相对回退名单的排序期效用增益为零。这不否认训练发生，而是说明本次最终名单不能被用来证明深度解码器贡献。半样本中的回退一致率和平均效用增益进一步报告在消融表中，但这些仍是排序期结果，不能代替独立测试。

Deep Lasso 局部消融只改变输入梯度正则，不重新调参，因此其结果反映特定配置下的作用。即使惩罚改善稳定性，也不能推广为任何 MLP 均会因该项惩罚受益；若差异很小，则应承认当前任务未充分体现这一组件优势。




图 6: 相同 60 个半样本中各指标的 Top-12 入选频率

本次保留正则与移除正则的平均半样本 Jaccard 分别为 0.8230 和 0.8182，配对差为 0.0049，95% 组级区间为 [-0.0278, 0.0375]。因此，当前局部消融没有给出明确的稳定性改善证据。不能把 Deep Lasso 整条流程表现较好，进一步推导为其中正则项已经被证明显著有效。

表 11: 完整开发样本选择流程运行成本

方法	完整选择秒数	单网络参数量	三种子训练轮次
Copula-MVR	1.38	不适用	不适用
Elastic Net	0.17	不适用	不适用
稳定性选择	3.68	不适用	不适用
影子变量树	31.79	不适用	不适用
XGBoost-SHAP	1.47	不适用	不适用
Deep Lasso	1.80	6273	51/27/48
TabM-置换	19.61	15040	61/59/58
VTFS-定额适配	28.87	286305	100/100/100

运行时间来自同一台 Apple M4 Pro 计算机，部分任务并发执行；CPU 线程及设备策略记录于工程。表中时间具有工程参考价值，但并发竞争、库启动和缓存会影响墙钟计时，不能将其视为严格微基准。模型搜索、三个种子与内部负对照生成的成本均不相同，使用者需要把部署维护成本与预测收益共同考虑。

5 讨论与结论

5.1 主要研究结论

第一，在相同变量预算、时间窗口和评价器下，近期深度方法能够提供有竞争力的指标名单，但没有全面优胜者。TabM 置换排序和 Deep Lasso 在 XGBoost 评价器上接近最优；改用 TabM 评价器后，XGBoost-SHAP 仍具有很强的竞争力。结果支持把深度模型作为候选工具，不能支持以结构复杂程度代替选择质量。

第二，样本稳定性与预测表现不等价。影子变量树在半样本名单一致性方面突出，但并非所有预算和评价器下误差最低。Deep Lasso 的名单稳定性较高，而 TabM 置换的预测点估计较好。VTFS 适配模型既没有保持开发期预测优势，又对卖家样本变化较敏感，说明反复验证搜索与最终名单的泛化之间需要额外约束。

第三，错误率叙事必须以生成有效性为前提。Copula-MVR 的边际改善没有解决全部联合失配，DeepDRK 适配也未通过当前经验诊断。本文保留相关经验比较，但不把真实数据名单标为已经严格控制 20%FDR 的确认集合。固定 Top-K 名单不自动继承原生规则的理论保证。

第四，数据定义本身影响研究问题。签收月确认目标与购买月回溯目标的对数相关约为 0.7165，说明二者并非可互换口径。本期信息是否在月末可见、哪些卖家属于分析人口、零值究竟表示何种状态，都应先于算法性能解释。

5.2 对经营监控的启示

业务落地可分为候选、试运行和复核三个阶段。候选阶段保留透明且有明确时间口径的指标；试运行阶段根据看板容量选择 8 项或 12 项方案，同时记录名单来源和预测器；复核阶段使用新月份检查误差、缺失率及名单变化。对于仅由代理替代造成的小幅名单变化，可按业务概念组观察，而不必每次立即更换看板字段。

本文不建议直接把开发期最优 VTFS 名单设为唯一默认方案。TabM 置换、Deep Lasso 和 XGBoost-SHAP 可进入后续时间外验证；在名单维护成本特别高的情形下，影子变量树值得作为稳定性参照。这些建议不是重新用测试集挑选一个“确认冠军”，而是由多项证据形成的后续验证方向。

对指标的使用仍应与描述性拆解结合。例如，订单数作为预测型监控特征能够提示下一期签收规模，但要解释当期 GMV 下降究竟来自哪些品类或地区，还需按原始品类、州或渠道进行金额分解。若进一步希望评估物流干预或营销策略效果，则需要自然实验、随机试验或具有识别假设的因果设计，不能直接读取模型重要性作为政策效应。

5.3 局限性

数据方面，研究仅覆盖一个公开平台和有限历史时期，分析人口不包括全部无活跃卖家月，静态快照的历史可见性无法完全核实。主目标是签收确认商品金额，不能覆盖退款、成本与利润。测试月份仅有三个月且曾参与前期探索，时间外确认强度有限。

方法方面，真实数据仅有 31 个候选维度，近期深度模型在高维冗余任务上的优势未必充分出现。各方法搜索空间、内部计算次数和适配程度不同；统一外层规则并不等于完全等算力。冻结参数的模拟研究也不能代表每个场景充分调参后的最佳性能。

推断方面，卖家簇 Bootstrap 只刻画固定测试月份下的卖家组成不确定性；生成诊断没有采用严格卖家层交换检验；经验 CDF、缩尾和缺失填补会改变原始特征的统计对象。多个探索性指标和后补消融增加了结果解读的自由度，本文通过保留冻结主选择、失败记录和并列表格减少选择性报告，但不能将其转化为外部注册的确认性证据。

5.4 后续研究

后续优先使用从未参与方法选择的新时间窗口与独立数据验证名单，而非继续围绕同一测试集增加模型。其次，在候选集合不变的条件下检验完整嵌套调参稳定性，区分参数选择与特征选择带来的波动。对于 VTFS，可单独实现按 K 优化的解码、与等查询预算随机搜索比较，并验证其训练部分确实贡献于样本外收益。

对于错误控制，可考虑更符合混合变量和卖家依赖结构的生成器、独立生成训练样本与卖家层诊断，再评价原生发现集合；在条件尚未满足时仍保留经验排序而不授予正式 FDR 标签。对于业务使用，可在新样本上研究按概念组聚合的稳定性，以及月度名单在周度预警中的适用性，但这些均属于待验证扩展，不是本文已完成结果。

参考文献

- [1] Tibshirani R. Regression shrinkage and selection via the lasso[J]. Journal of the Royal Statistical Society, Series B, 58(1), 267-288, 1996. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>.
- [2] Zou H, Hastie T. Regularization and variable selection via the elastic net[J]. Journal of the Royal Statistical Society, Series B, 67(2), 301-320, 2005. <https://doi.org/10.1111/j.1467-9868.2005.00503.x>.
- [3] Meinshausen N, Bühlmann P. Stability selection[J]. Journal of the Royal Statistical Society, Series B, 72(4), 417-473, 2010. <https://doi.org/10.1111/j.1467-9868.2010.00740.x>.
- [4] Shah R D, Samworth R J. Variable selection with error control: another look at stability selection[J]. Journal of the Royal Statistical Society, Series B, 75(1), 55-80, 2013. <https://doi.org/10.1111/j.1467-9868.2011.01034.x>.
- [5] Nogueira S, Sechidis K, Brown G. On the Stability of Feature Selection Algorithms[J]. Journal of Machine Learning Research, 18(174), 1-54, 2018. <https://www.jmlr.org/papers/v18/17-514.html>.

- [6] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. Proceedings of KDD, 785-794, 2016. <https://doi.org/10.1145/2939672.2939785>.
- [7] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[C]. Advances in Neural Information Processing Systems, 30, 2017. <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>.
- [8] Lundberg S M, Erion G, Chen H, et al. From local explanations to global understanding with explainable AI for trees[J]. Nature Machine Intelligence, 2, 56-67, 2020. <https://doi.org/10.1038/s42256-019-0138-9>.
- [9] Kursa M B, Rudnicki W R. Feature Selection with the Boruta Package[J]. Journal of Statistical Software, 36(11), 1-13, 2010. <https://doi.org/10.18637/jss.v036.i11>.
- [10] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees[J]. Machine Learning, 63, 3-42, 2006. <https://doi.org/10.1007/s10994-006-6226-1>.
- [11] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing[J]. Journal of the Royal Statistical Society, Series B, 57(1), 289-300, 1995. <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>.
- [12] Barber R F, Candès E J. Controlling the false discovery rate via knockoffs[J]. The Annals of Statistics, 43(5), 2055-2085, 2015. <https://doi.org/10.1214/15-AOS1337>.
- [13] Candès E, Fan Y, Janson L, Lv J. Panning for gold: model-X knockoffs for high dimensional controlled variable selection[J]. Journal of the Royal Statistical Society, Series B, 80(3), 551-577, 2018. <https://doi.org/10.1111/rssb.12265>.
- [14] Spector A, Janson L. Powerful knockoffs via minimizing reconstructability[J]. The Annals of Statistics, 50(1), 252-276, 2022. <https://doi.org/10.1214/21-AOS2104>.
- [15] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for false discovery rate control[J]. Journal of the Royal Statistical Society, Series B, 86(1), 122-154, 2024. <https://doi.org/10.1093/jrssb/qkad085>.
- [16] Wang R, Ramdas A. False discovery rate control with e-values[J]. Journal of the Royal Statistical Society, Series B, 84(3), 822-852, 2022. <https://doi.org/10.1111/rssb.12489>.
- [17] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. Journal of Multivariate Analysis, 88(2), 365-411, 2004. [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4).
- [18] Cherepanova V, Levin R, Somepalli G, et al. A Performance-Driven Benchmark for Feature Selection in Tabular Deep Learning[C]. NeurIPS Datasets and Benchmarks Track, 2023. <https://openreview.net/forum?id=v4PMCdSaAT>.
- [19] Ying W, Wang D, Chen H, Fu Y. Feature Selection as Deep Sequential Generative Learning[J]. ACM Transactions on Knowledge Discovery from Data, 18(9), Article 221, 2024. <https://doi.org/10.1145/3687485>.
- [20] Gorishniy Y, Kotelnikov A, Babenko A. TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling[C]. International Conference on Learning Representations, 2025. <https://openreview.net/forum?id=Sd4wYYOhmY>.

- [21] Shen H, Yan Y, Zhao Z. DeepDRK: Deep Dependency Regularized Knockoff for Feature Selection[C]. Advances in Neural Information Processing Systems, 2024. <https://openreview.net/forum?id=ibKpPabHVn>.
- [22] Hollmann N, Muller S, Purucker L, et al. Accurate predictions on small data with a tabular foundation model[J]. Nature, 637, 319-326, 2025. <https://doi.org/10.1038/s41586-024-08328-6>.
- [23] Pham H, Tan Y, Singh T, Pavlopoulos V, Patnayakuni R. A multi-head attention-like feature selection approach for tabular data[J]. Knowledge-Based Systems, 301, 112250, 2024. <https://doi.org/10.1016/j.knosys.2024.112250>.
- [24] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle dataset, 2018. <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>.
- [25] Olist. Marketing Funnel by Olist[DB/OL]. Kaggle dataset, 2018. <https://www.kaggle.com/datasets/olistbr/marketing-funnel-olist>.
- [26] Morris T P, White I R, Crowther M J. Using simulation studies to evaluate statistical methods[J]. Statistics in Medicine, 38(11), 2074-2102, 2019. <https://doi.org/10.1002/sim.8086>.