

面向电商经营指标筛选的非线性方法与交换对称损失研究

1 研究摘要

电商经营看板的指标选择需要同时考虑预测信息保留、名单维护成本与错误发现风险。相关指标之间的替代、响应的非线性和假变量生成失配，使“预测准确”“名单稳定”和“统计上可确认”成为不同问题。本文以卖家下一自然月签收确认商品金额为目标，在统一业务口径和评价条件下研究非线性特征选择，并构造固定预测器上的交换对称成对损失统计量。

研究使用 Olist 十张原始表，按月末已发生事件构建 13,754 个卖家月观测、2,723 名卖家和 31 项指标。基础比较覆盖稀疏回归、重抽样、树模型、Deep Lasso、TabM 与 VTFS 适配；机制实验进一步研究预测 Jacobian 正则、预算门、动态输入剪枝和固定容量序列损失。所有主比较共享卖家抽样，区分 30 组互补半样本、70% 及 80% 抽样和固定数据随机种子变化；下游预测使用共同 XGBoost 与 TabM，相同集合采用规范列顺序并共享预测。

交换对称损失通过不依赖真假命名的背景比较每个特征与 Knockoff 的预测损失。本文给出其完整符号翻转性质，并说明随机背景在精确生成器下的边际分布性质。800 份八场景模拟区分精确生成、全无效和错设条件；另外依据 Semi-knockoffs 的双侧条件重建思路，检验条件均值与条件尺度扩展。理论说明仅涉及统计量性质及已有定理的条件调用，不将估计生成器、估计条件矩或面板数据直接视为有限样本 FDR 受控。

实测没有显示复杂方法全面领先。基础规范 Top-12 比较中，XGBoost-SHAP 与 Deep Lasso 的 XGBoost 评价 RMSE 分别为 1.8466 与 1.8450；Jacobian 版本的半样本 Jaccard 为 0.8618，但其优势未同时覆盖互补稳定性和模拟发现质量。SCPL 预定标准化 TabM 版本在强非线性与纯交互场景的 Power 分别为 0.794 与 0.934，匹配线性对照分别为 0.087 与 0.003；未标准化版本却往往更强，高相关线性场景也存在明显反例。真实数据主生成器下 SCPL 表现较弱；事后 MVR 诊断改善预测但未形成稳定性优势。

条件矩补充中，预定 TabM 均值尺度版本的真实 Top-12 RMSE 为 1.8965，半样本 Jaccard 为 0.4099；强非线性原生 Power 为 0.8660，平均 FDP 为 0.1313。这些结果仍需结合估计条件重建的误选风险解释，不将局部检出增加直接写为有效错误控制。

研究结论支持将预测器能力、评分对称性、生成器有效性和业务适用性分开检验。本文形成了可复核的方法研究原型与负结果证据，但不主张新颖性优先权已经确立、真实 FDR 已经受控或任何方法无条件最优。

2 数据与公平实验设计

2.1 数据来源与自然连接层级

研究使用 Olist 电商与营销漏斗公开数据 [30, 31]。十张原始表涵盖订单、商品明细、支付、评价、商品、卖家、顾客、地理位置、营销线索与营销成交。订单表含 99,441 条记录，商品明细含 112,650 条记录。支付与评价先在订单层聚合，地理位置按邮编前缀取经纬度中位数，再按卖家月份汇总，避免多对多连接放大金额。

目标金额来自商品明细价格，不含运费。支付和物流指标在卖家订单层去重后平均，商品属性与部分地域指标按商品明细聚合，二者对应不同业务对象。全源表有送达时间的商品金额对账为 13,220,895.11 巴西雷亚尔，不能误称为最终面板目标总和。

2.2 月末可见性与目标

对于卖家 s 和特征月 t ，目标为

$$G_{s,t+1} = \sum_{i: \text{seller}(i)=s, \text{deliverymonth}(i)=t+1} \text{price}_i, \quad Y_{s,t+1} = \log(1 + G_{s,t+1}).$$

该定义按下一自然月签收确认，不是按购买月回溯最终送达金额，也不是净利润或扣除全部售后的会计收入。物流仅使用月末前发生的事件，评价按回答时间截断，营销按成交日期截断。支付、商品和卖家元数据缺少完整修订历史，其购买时可得性仍是工作假设，不能宣称完全还原生产实时账本。

分析人口是特征月有购买商品明细的卖家，不按未来最终送达状态过滤特征月。下一月无签收记录时目标记零。面板共 18 个特征月份、13,754 行、2,723 名卖家，目标零值率为 17.8784%。不直接外推到全部注册卖家或没有本月购买活动的冷启动人口。

2.3 时间分工与预处理

表 1: 训练、调参、评分与测试窗口

阶段	目标月份	行数	主要用途
训练	2017-02 至 2017-12	6567	预处理与基础拟合
调参	2018-01 至 2018-02	1831	选参数/轮次后重拟合
评分	2018-03 至 2018-04	1943	协议 A 可早停；协议 B 固定模型评分
测试	2018-05 至 2018-07	3413	仅评价；已经历探索

预处理包括预设偏态指标 $\log 1p$ 变换、拟合窗口 1% 和 99% 缩尾、训练中位数填补及标准化。各评价窗口只应用冻结参数。缺失可能意味着事件尚未发生，不应把中位数填补解释为已解决缺失机制。候选指标固定 31 项，不为某个方法单独增删变量。

本文包含两类训练协议。基础选择器及其模型内部机制允许排序期参与早停或子集效用；固定预测器损失研究严格限定 train/tune 决定基础模型，rank 只用于评分或已披露的条件重建。二者分别列示，不把同名模型在不同协议下的稳定性当成相同拟合结果。

2.4 样本扰动与稳定性

所有方法使用相同卖家清单：30 组互补 50% 样本、20 个 70% 样本、20 个 80% 样本；同一卖家所有月份共同保留。50% 样本有 60 份，但区间单位是 30 个互补组。另运行 10 组固定数据种子变化及一个完整参考，共 111 个案例。

对集合 A, B ，Jaccard 为 $|A \cap B| / |A \cup B|$ 。本文同时报告与完整参考名单的 Jaccard、互补两半直接比较的 Jaccard 及 Nogueira 机会校正稳定性 [32]。高参考稳定性不代表互补两半同样一致；固定数据更换随机种子也不代表对新卖家稳定。全空集合的形式一致性需结合空集比例解释。

2.5 预测与发现质量

主容量为 12 项，8 项为敏感性；规范化比较将选中列按固定编号排序，相同集合和评价器共享预测。所有名单分别交给共同 XGBoost 和 TabM 重拟合，在 3,413 行测试集评价 $\log$ 尺度 RMSE、MAE、 R^2 及金额尺度 WAPE。卖家簇 Bootstrap 重复 5,000 次，其区间只条件于已观察的三个测试月份和已拟合模型。

对于已知真支持集 S_0 ，

$$\text{FDP} = \frac{|\hat{S} \setminus S_0|}{|\hat{S}| \vee 1}, \quad \text{Power} = \frac{|\hat{S} \cap S_0|}{|S_0|}.$$

空发现集合 FDP 为 0；存在真信号时 Power 为 0；全无效场景 Power 不定义。固定 K 与原生名单分别报告。若真信号只有 5 个，Top-12 即使全部检出也至少误选 7 个，不能据此判定原生 FDR 失败。模拟设计、Monte Carlo 误差与配对比较参照规范化模拟研究原则 [33]。

2.6 实验组与证据权限

表 2: 各实验设计与覆盖，禁止跨设计直接混排

设计	训练/评分	实测规模	主要边界
A 基础与机制	排序期可用于早停/效用	8 基线 +10 改动；600 份模拟	固定配置适配，规范 Top8/12 复算
B SCPL	基础模型不见评分响应	14 评分；111 真实；800 模拟	oracle 与错设分开
B 生成敏感性	同 B，仅换 MVR	111 真实；30 组预测	看过参考结果后追加
B 条件矩	基础模型固定；条件模型使用评分响应	8 评分；111 真实；800 份复算	6,400 方法结果，非新数据

测试期已被多轮探索查看，本研究不将其称为独立确认数据。补充算法与生成器研究保留探索性质。没有采用所有实验中最好的 RMSE、另一实验的稳定性和第三实验的 FDP 拼成一个虚构“最优方法”。

3 基础选择器与模型机制改动

3.1 基础方法

Elastic Net 按绝对系数排序；稳定性选择在每个外层样本中再运行 20 组互补 Lasso，采用频率和平均系数打破并列；影子树进行 8 轮真实/打乱变量比较。其经验原生阈值都不是本文新证明的 FDR 规则。XGBoost-SHAP 使用三个模型的平均绝对贡献，TabM 以每列三次置换的误差增量排序。

Copula-MVR 在训练经验分布变换后估计收缩协方差 [34]，使用近似 Lasso 真假系数差，60 组假变量聚合 e-value，再按 e-BH 筛选。单轮 $q=.10$ 、最终 $q=.20$ 与频率 90% 是不同设置。该实现的真实联合分布诊断未通过，因此保留经验比较，不授予真实发现证书。

Deep Lasso 调用官方输入梯度惩罚，使用两层 MLP；TabM 使用官方 8 成员参数高效集成；VTFS 调用官方编码器解码器，但采用有限随机语料和无重复定额序列，公开实现中的常数重参数化行为被明确保留。完整参考名单来自语料回退时，不把收益归功于 Transformer 解码器。

3.2 从损失梯度到预测 Jacobian

对于平方损失，输入损失梯度同时包含预测器偏导与残差权重：

$$\frac{\partial(f(x) - y)^2}{\partial x_j} = 2(f(x) - y) \frac{\partial f(x)}{\partial x_j}.$$

较大残差可能放大某些观测对重要性的影响，因此检验预测 Jacobian 的稀疏惩罚及排名。消融包含同时改变训练与排名、只改变训练、只改变排名。该研究动机不是“复杂化一定更好”，并且函数偏导正则已有先行研究，不能把简单替换称为首创。

3.3 容量门、历史分数与序列效用

TabM 预算门把固定 K 约束引入输入训练，检验训练使用全部变量、最终只保留少量变量之间的差异。直通梯度只是一种有偏近似，不声称精确解决最优子集选择。

EntryPrune 回归适配使用动态输入层；刷新和环境波动惩罚针对历史高分可能被偶然噪声长期保留的问题。均值减标准差仅是算法分数，不是有效统计置信下界。VTFS 首先改为固定 K 语料，再加入成对效用差损失；预算纠正的收益不能归给后续损失。

3.4 真实结果与模拟发现质量

表 3: 模型机制比较，规范 Top-12 预测与六场景固定 K 模拟

方法	XGB 误差	TabM 误差	半样本 J	FDP@12	Power@12
Copula-MVR	1.8650	1.8967	0.7355	0.3218	0.8305
Elastic Net	1.8625	1.8806	0.7244	0.3251	0.8265
稳定性选择	1.8937	1.8885	0.5827	0.3383	0.8107
影子变量树	1.8611	1.8612	0.9388	0.3361	0.8261
XGBoost-SHAP	1.8466	1.8571	0.7682	0.2315	0.9403
Deep Lasso	1.8450	1.8594	0.8230	0.2687	0.8947
TabM-置换	1.8458	1.8586	0.7505	0.2656	0.8981
VTFS-定额适配	1.8622	1.8783	0.4068	0.5306	0.5876
Deep Lasso-Jacobian	1.8461	1.8600	0.8618	0.2657	0.8978
Jacobian 训练 + 原排名	1.8450	1.8594	0.7722	0.2686	0.8943
原 Deep Lasso+Jacobian 排名	1.8450	1.8594	0.8147	0.2656	0.8986
TabM-预算门	1.8450	1.8594	0.8071	0.2793	0.8826
EntryPrune-回归适配	1.8812	1.8744	0.6271	0.2869	0.8729
EntryPrune-刷新	2.0418	2.0350	0.4596	0.5203	0.6107
EntryPrune-环境波动惩罚	1.8706	1.8897	0.4498	0.5074	0.6263
VTFS-固定 K	1.8676	1.8921	0.4540	0.4593	0.6815
VTFS-固定 K+ 成对损失	1.8653	1.8949	0.4333	0.4531	0.6901
等预算随机子集搜索	1.8661	1.8926	0.4368	0.4911	0.6412

基础规范比较中，SHAP 和 Deep Lasso 的 XGBoost 评价 RMSE 分别为 1.8466 和 1.8450，相差很小。Jacobian 版本的参考 Jaccard 为 0.8618，父方法为 0.8230；但相对父方法的互补稳定性差区间跨零，模拟平均 FDP 变化也没有一致证据。相对 SHAP 的稳定性改善伴随较弱的模拟发现质量，属于权衡而非全面优势。

预算门提高了相对完整参考名单的 Jaccard，却没有同时提高互补稳定性，且模拟 FDP 增加。EntryPrune 刷新显著恶化真实预测和发现质量，波动惩罚未恢复强基线水平。固定 K 修正改善 VTFS 模拟检出，但实际预测未改善；新增成对损失的独立增量更小。

表 4: 关键配对差异与组件判断

改动减父方法	参考 J 差	互补 J 差	FDP 差	Power 差
Deep Lasso-Jacobian 减 Deep Lasso	0.0388	0.0155	-0.0031	0.0031
TabM-预算门减 TabM-置换	0.0566	-0.0448	0.0137	-0.0155
EntryPrune-刷新减 EntryPrune-回归适配	-0.1675	-0.1133	0.2333	-0.2622
VTFS-固定 K 减 VTFS-定额适配	0.0472	-0.0339	-0.0712	0.0939
VTFS-固定 K+ 成对损失减 VTFS-固定 K	-0.0208	0.0085	-0.0062	0.0086

只改变 Deep Lasso 排名的部分配置与原方法完整 Top-12 集合相同，因此规范化预测必须完全一致。任何未统一输入列顺序而产生的微小预测差都不能解释成选维改进。此前同月互补卖家梯度一致性探索最终选中 $\gamma=0$ ，其新增惩罚没有得到支持。

4 交换对称成对损失统计量

4.1 独立预测器与对称背景

将数据分为基础预测器训练 A、评分 B 和最终预测测试 C。基础模型 f_A 及预处理在 B 的响应被使用前冻结。对 B 内每个数值对定义 $L_{ij} = \min(X_{ij}, \tilde{X}_{ij})$ 、 $U_{ij} = \max(X_{ij}, \tilde{X}_{ij})$ 。四组 Bernoulli 掩码及其补掩码构成八个背景 $C^{(b)}$ ，每坐标从 L 或 U 选值，不依赖真假身份命名。

对第 j 个变量，将背景其他坐标保持不变，分别放入真实值和假值，计算

$$d_{ij} = \frac{1}{B} \sum_{b=1}^B \left[\ell\{Y_i, f_A(C_{i,-j}^{(b)}, \tilde{X}_{ij})\} - \ell\{Y_i, f_A(C_{i,-j}^{(b)}, X_{ij})\} \right].$$

先在卖家内平均，再对卖家平均形成 W_j 。标准化版本除以卖家均值标准误加 10^{-8} 。该标准化只用于排序，不是 t 检验。模拟中每行一个组。八个背景来自一组 Knockoff，不是八次独立假变量生成。

4.2 完整符号翻转性质

命题。固定预测器、预处理、掩码、分组和评分超参数，交换任意列对集合 S 后， $j \in S$ 的 W_j 反号， $j \notin S$ 的 W_j 保持不变。

证明。交换不改变任何 min/max，因此背景逐路径不变。未交换的 j 自身真假值不变，其两次预测输入不变。被交换的 j 两次预测输入互换，损失差反号。组内与组间均值保留反号；标准差在整体反号下不变，标准化版本也成立。证毕。

该命题不要求预测器正确拟合响应函数，但不保证 Power 或预测精度。中点 $(X + \tilde{X})/2$ 也具有交换不变性。普通真实背景在交换其他列后改变，不能直接满足这一完整性质。实际 TabM 的逐列及联合交换检查与代数检查一致。

4.3 随机背景边际与现有 FDR 结论

在独立同分布、精确逐坐标交换的 oracle 条件下，对掩码取平均，每个随机 min/max 背景的输入边际分布与 X 相同。给定真假数值，随机取 min/max 等价于随机取真实/假值，因此分布是所有交换子集的等权混合；每一交换子集下原侧向量均与 X 同分布。补掩码不会使各背景独立，中点背景一般也不具有这一边际性质。

上述性质只涉及输入分布，不保留背景与 Y 的原关联，不消除有限八背景误差；错设生成器下不能使用。另以十万行高斯数据核验协方差，并用显式 einsum 核对矩阵采样数值；数值检查不是数学证明或 Olist 合格证。

若 B 满足 Model-X 样本条件，条件于 A 的假变量精确交换、给定 X 后独立于 Y ，且统计量满足上述性质，可调用已有 Knockoff+ 结论：

$$T_q = \min \left\{ t > 0 : \frac{1 + \#\{j : W_j \leq -t\}}{\#\{j : W_j \geq t\} \vee 1} \leq q \right\}, \quad \hat{S} = \{j : W_j \geq T_q\}.$$

无解时 $T_q = \infty$ ，返回空集。本研究 $q=.20$ ， $q=.10$ 为敏感性。至少需要 $\lceil 1/q \rceil$ 个正发现才可能非空。Top-K 不继承该规则的 FDR 结论，真实同卖家跨期依赖与估计 Copula 也未满足全部 oracle 前提。

4.4 八场景模拟设计

表 5: 损失评分研究的模拟设置

场景	真信号	相关系数	信噪比	生成条件
全无效	0	0.6	不适用	已知精确
线性稀疏	5	0.6	2.0	已知精确
强非线性	10	0.6	2.0	已知精确
弱非线性	10	0.6	0.5	已知精确
纯交互	10	0.6	2.0	已知精确
高相关线性	10	0.9	2.0	已知精确
已知混合变换	10	0.6	2.0	已知精确
t 生成错误	10	0.6	2.0	故意错误

每份 $n=2000$ 、 $p=31$ ，前 1200 行用于基础模型，其中 1000/200 作训练与选轮次；400 行评分，400 行预测测试。七场景为精确高斯或已知变换后的高斯 Knockoff，t 场景故意使用错误高斯生成。响应信号尺度只由训练部分确定，真支持集不参与选参。成对 Lasso 仅在 400 行评分集拟合，因此另设同 1200 行训练的线性预测器对照。

4.5 模拟结果与机制反例

表 6: 原生 $q=.20$ 的场景结果，平均 FDP 与 Power

场景	方法	平均 FDP	FDP-MCSE	Power	发现数
全无效	匹配线性对称差	0.0100	0.0100	不定义	0.05
全无效	XGB-中点差	0.0600	0.0239	不定义	0.34
全无效	TabM-中点差	0.0500	0.0219	不定义	0.32
全无效	TabM-随机对称差	0.0300	0.0171	不定义	0.24
全无效	TabM-标准化对称差	0.0500	0.0219	不定义	0.35
线性稀疏	匹配线性对称差	0.1798	0.0182	1.0000	6.50
线性稀疏	XGB-中点差	0.1632	0.0196	1.0000	6.51
线性稀疏	TabM-中点差	0.2013	0.0213	1.0000	6.94
线性稀疏	TabM-随机对称差	0.1850	0.0219	1.0000	6.86
线性稀疏	TabM-标准化对称差	0.1955	0.0205	0.9700	6.73
强非线性	匹配线性对称差	0.0760	0.0169	0.0870	1.44
强非线性	XGB-中点差	0.1619	0.0135	0.9990	12.31
强非线性	TabM-中点差	0.1808	0.0151	0.9570	12.20
强非线性	TabM-随机对称差	0.1732	0.0155	0.9650	12.19
强非线性	TabM-标准化对称差	0.1668	0.0166	0.7940	10.26
弱非线性	匹配线性对称差	0.0742	0.0177	0.0750	1.39
弱非线性	XGB-中点差	0.1817	0.0156	0.9030	11.61
弱非线性	TabM-中点差	0.1823	0.0187	0.7580	10.34
弱非线性	TabM-随机对称差	0.1826	0.0174	0.7610	10.23
弱非线性	TabM-标准化对称差	0.1636	0.0189	0.4310	6.44
纯交互	匹配线性对称差	0.0155	0.0109	0.0030	0.13
纯交互	XGB-中点差	0.1471	0.0128	0.9310	11.25
纯交互	TabM-中点差	0.1565	0.0151	0.9980	12.31
纯交互	TabM-随机对称差	0.1545	0.0144	0.9970	12.22

场景	方法	平均 FDP	FDP-MCSE	Power	发现数
纯交互	TabM-标准化对称差	0.1528	0.0149	0.9340	11.58
高相关线性	匹配线性对称差	0.1746	0.0115	0.8590	10.75
高相关线性	XGB-中点差	0.1712	0.0163	0.7020	9.34
高相关线性	TabM-中点差	0.1617	0.0163	0.8440	10.87
高相关线性	TabM-随机对称差	0.1686	0.0163	0.8510	11.04
高相关线性	TabM-标准化对称差	0.1772	0.0197	0.5840	8.46
已知混合变换	匹配线性对称差	0.0903	0.0172	0.1750	2.56
已知混合变换	XGB-中点差	0.1750	0.0154	0.9940	12.56
已知混合变换	TabM-中点差	0.1612	0.0163	0.9640	12.10
已知混合变换	TabM-随机对称差	0.1518	0.0144	0.9630	11.78
已知混合变换	TabM-标准化对称差	0.1506	0.0146	0.8030	10.00
t 生成错误	匹配线性对称差	0.0755	0.0208	0.0370	1.00
t 生成错误	XGB-中点差	0.1382	0.0167	0.5090	6.80
t 生成错误	TabM-中点差	0.1390	0.0192	0.3710	5.02
t 生成错误	TabM-随机对称差	0.1551	0.0202	0.3970	5.52
t 生成错误	TabM-标准化对称差	0.1783	0.0228	0.2740	4.49

标准化 TabM 在强非线性、弱非线性、纯交互中明显提高相对匹配线性预测器的 Power，说明非线性表达确实有用。但未标准化 TabM 在强非线性下 Power 达到 0.965，高于预定标准化版本 0.794；高相关线性下主候选 0.584，低于线性对照 0.859。不能事后将更强消融改写为预定主方法，也不能把表达能力增益都归于对称化。

全无效场景主候选 100 次中 5 次非空，FDR 估计 .05，准确二项 95% 区间约 [.016,.113]；不是总体错误率恰等于 .05 的证明。t 错误下平均 FDP 即使低于目标也不能恢复理论保证。线性稀疏的 TabM 中点平均 FDP 略高于 .20，必须连同 Monte Carlo 误差保留。

4.6 真实数据及生成器敏感性

表 7: SCPL 同预算真实结果，两个生成器条件分别列示

生成条件	方法	XGB 误差	TabM 误差	J	Nogueira
等相关	XGBoost-SHAP	1.8466	1.8571	0.7682	0.7439
等相关	Deep Lasso	1.8468	1.8567	0.8394	0.8012
等相关	TabM-中点差	1.8577	1.8776	0.3934	0.2009
等相关	TabM-随机对称差	1.8577	1.8776	0.3912	0.1993
等相关	TabM-标准化对称差	2.0964	2.0886	0.3249	0.1248
MVR 追加	XGBoost-SHAP	1.8466	1.8571	0.7682	0.7439
MVR 追加	Deep Lasso	1.8468	1.8567	0.8394	0.8012
MVR 追加	TabM-中点差	1.8431	1.8575	0.4988	0.4509
MVR 追加	TabM-随机对称差	1.8630	1.8732	0.4874	0.4675
MVR 追加	TabM-标准化对称差	1.8493	1.8645	0.4696	0.3947

训练估计 Copula 的等相关 S 约 .00334，约 49.4% 真假值完全相同，评分信息很弱，完整参考原生规则均为空。主候选 Top-12 的 RMSE 为 2.0964、Jaccard 为 .3249，明显弱于 SHAP。不能以零发现的低 FDP 或形式稳定性美化这一结果。

事后参考样本 MVR 检查已看到预测变化后，再登记 111 例生成器敏感性分析。MVR 改善主候选 RMSE 至 1.8493，但 Jaccard 仅 .4696；中点 TabM 的 1.8431 虽低于 SHAP 1.8466，配对差 95% 区间 [-.0118,.0053] 包含零。该追加不是预先确认，MVR 也是既有生成器，不构成新发明。

表 8: 真实交换诊断, 按卖家隔离的分类 AUC

条件	25% 交换	50% 交换	100% 交换
等相关	0.9514	0.6470	0.8998
MVR 追加	0.8782	0.9139	0.9467

两套生成器均明显可区分交换前后联合样本。该 AUC 是工程诊断, 不是已校准的面板检验; 接近.5 也不能证明有效。原生发现数增加不能证明真实 FDR 正确。

5 双侧条件重建与条件矩扩展

5.1 原算法的目标

Semi-knockoffs 令 $\nu_j(X_{-j}) = E(X_j | X_{-j})$ 、 $\rho_j(X_{-j}, Y) = E(X_j | X_{-j}, Y)$ 。两侧分别重建特征并独立打乱残差, 比较共同预测器的损失。零假设下两个条件期望一致, 为 oracle 双侧对称提供依据。这些重建不是标准 Model-X 假变量, 不能与 SCPL 生成机制混称。

原文实践允许条件模型使用评分响应; 本研究明确将 rank 响应提供给条件重建, 不提供给基础预测器训练、早停或最终测试预测。条件于 Y 的拟合属于算法定义, 不是未披露的基础模型泄漏。估计模型可能过拟合并偏离零假设对称, 因此实际 FDR 需要单独检验。

5.2 条件均值与尺度的四种机制

线性条件均值可能无法表达平方效应中的方差信息。因此预先登记四种重建: 固定 Ridge 均值; 加入平方与响应交互的非线性均值; 线性均值加条件尺度; 非线性均值与条件尺度联合。每种分别接入同一批 XGBoost 和 TabM, 共八项评分, 主候选为 TabM 联合扩展。

非线性侧使用原输入及逐坐标平方, 条件于 Y 时再加 Y、Y² 及 Y 与其他特征的乘积。不声称这是通用深度条件分布估计。尺度模型对残差平方加稳定常数后取 log 并用相同基函数 Ridge 拟合, 指数预测相对残差方差截断在 [.05,20], 再开方; 这是一种条件尺度代理而非已证明无偏的方差估计。

$$\tilde{X}_{ij}^{(r)} = \hat{m}_{rj}(Z_{ri}) + \hat{s}_{rj}(Z_{ri}) \left\{ \frac{X_{\pi_r(i),j} - \hat{m}_{rj}(Z_{r,\pi_r(i)})}{\hat{s}_{rj}(Z_{r,\pi_r(i)})} \right\}, \quad r = 1, 2.$$

两侧使用相互独立的置换, 所有机制共享置换; 不使用 Y 的一侧 $Z_1 = X_{-j}$, 另一侧 $Z_2 = (X_{-j}, Y)$ 。统计量按行平均平方损失差, 不额外标准化。零假设下 oracle 均值及尺度一致时, 两侧残差抽样对称, 但估计均值尺度不会自动保持这一性质。这里不提出无条件的新 FDR 定理。

5.3 作者代码核验与实现差异

作者源码锁定 commit `ff51ec239529620300e92efd9988eb69490eb3ac`。在小型样本上逐项核对 Ridge 拟合、置换顺序与向量化损失分数, 最大差约 2.0×10^{-16} 。固定 $\alpha=1$ 代替原实验 RidgeCV; 基础预测器、样本与评价器采用本文公共协议, 故称原算法机制适配, 不称复现原文全部实验。

作者辅助阈值函数在无解时返回最后一个有限候选。例如 $W=(1,2,3,4)$ 、 $q=.2$ 时, 任何阈值都不满足 Knockoff+ 条件, 原函数仍返回 4。本文按原文公式修正为 ∞ 并保留反例, 不把软件错误归于原文数学定理, 也不把纠错当作算法创新。

5.4 补充结果

本实验在全部 111 个公共真实案例上计算八种评分, 并在相同 800 份 SCPL 模拟数据上追加 6,400 个方法案例。没有新增 800 份独立数据, 也没有复用旧方法输出冒充新算法结果。Top-8/12 采用两个




图 1: 共同预测器下的真实预测与样本稳定性，误差与名单一致性分开评价

公共评价器，共 32 组真实预测；预测器与父实验的参考分数逐真实案例核对。

表 9: 条件矩扩展的真实 Top-12 结果

方法	XGB-RMSE	TabM-RMSE	半样本 J	Nogueira
XGBoost-SHAP	1.8466	1.8571	0.7682	0.7439
TabM 置换	1.8458	1.8586	0.7288	0.6841
Deep Lasso	1.8468	1.8567	0.8394	0.8012
XGB-SKO-Ridge	1.8794	1.8669	0.4511	0.2696
XGB-SKO-非线性均值	1.8612	1.8722	0.3828	0.2228
XGB-SKO-尺度	1.8813	1.8731	0.3927	0.3007
XGB-SKO-均值尺度	1.8508	1.8654	0.4407	0.2568
TabM-SKO-Ridge	1.8996	1.9130	0.4397	0.3115
TabM-SKO-非线性均值	1.8837	1.9010	0.4224	0.3103
TabM-SKO-尺度	1.8793	1.9009	0.4713	0.3617
TabM-SKO-均值尺度	1.8965	1.9033	0.4099	0.3497

表 10: 条件矩扩展的八场景原生发现

场景	方法	平均 FDP	MCSE	Power	发现数
全无效	XGB-SKO-Ridge	0.0300	0.0171	不定义	0.30
全无效	XGB-SKO-非线性均值	0.0400	0.0197	不定义	0.32
全无效	XGB-SKO-尺度	0.0200	0.0141	不定义	0.11
全无效	XGB-SKO-均值尺度	0.0500	0.0219	不定义	0.36
全无效	TabM-SKO-Ridge	0.0400	0.0197	不定义	0.28
全无效	TabM-SKO-非线性均值	0.0200	0.0141	不定义	0.10
全无效	TabM-SKO-尺度	0.0300	0.0171	不定义	0.22
全无效	TabM-SKO-均值尺度	0.0300	0.0171	不定义	0.20
线性稀疏	XGB-SKO-Ridge	0.1551	0.0184	1.0000	6.32
线性稀疏	XGB-SKO-非线性均值	0.1327	0.0169	1.0000	6.08
线性稀疏	XGB-SKO-尺度	0.1769	0.0184	1.0000	6.54
线性稀疏	XGB-SKO-均值尺度	0.1446	0.0166	1.0000	6.18

场景	方法	平均 FDP	MCSE	Power	发现数
线性稀疏	TabM-SKO-Ridge	0.1799	0.0212	1.0000	6.83
线性稀疏	TabM-SKO-非线性均值	0.1830	0.0205	1.0000	6.77
线性稀疏	TabM-SKO-尺度	0.1786	0.0201	1.0000	6.68
线性稀疏	TabM-SKO-均值尺度	0.1990	0.0218	1.0000	7.08
强非线性	XGB-SKO-Ridge	0.0100	0.0050	0.1350	1.45
强非线性	XGB-SKO-非线性均值	0.1102	0.0142	0.8190	9.67
强非线性	XGB-SKO-尺度	0.0558	0.0111	0.4000	4.70
强非线性	XGB-SKO-均值尺度	0.1356	0.0149	0.9130	11.04
强非线性	TabM-SKO-Ridge	0.0183	0.0079	0.1290	1.52
强非线性	TabM-SKO-非线性均值	0.1125	0.0134	0.8560	10.01
强非线性	TabM-SKO-尺度	0.0351	0.0098	0.3200	3.66
强非线性	TabM-SKO-均值尺度	0.1313	0.0151	0.8660	10.50
弱非线性	XGB-SKO-Ridge	0.0161	0.0069	0.0580	0.73
弱非线性	XGB-SKO-非线性均值	0.0885	0.0137	0.4540	5.57
弱非线性	XGB-SKO-尺度	0.0221	0.0071	0.1800	1.99
弱非线性	XGB-SKO-均值尺度	0.0967	0.0142	0.5700	6.95
弱非线性	TabM-SKO-Ridge	0.0278	0.0095	0.0740	0.92
弱非线性	TabM-SKO-非线性均值	0.1023	0.0150	0.4710	5.90
弱非线性	TabM-SKO-尺度	0.0360	0.0101	0.1060	1.40
弱非线性	TabM-SKO-均值尺度	0.1223	0.0151	0.5150	6.49
纯交互	XGB-SKO-Ridge	0.0210	0.0108	0.0190	0.41
纯交互	XGB-SKO-非线性均值	0.1603	0.0165	0.7950	10.17
纯交互	XGB-SKO-尺度	0.0049	0.0035	0.0090	0.12
纯交互	XGB-SKO-均值尺度	0.1559	0.0157	0.8110	10.26
纯交互	TabM-SKO-Ridge	0.0000	0.0000	0.0120	0.12
纯交互	TabM-SKO-非线性均值	0.1500	0.0146	0.9590	11.72
纯交互	TabM-SKO-尺度	0.0000	0.0000	0.0160	0.16
纯交互	TabM-SKO-均值尺度	0.1493	0.0145	0.9660	11.79
高相关线性	XGB-SKO-Ridge	0.1413	0.0167	0.6370	8.24
高相关线性	XGB-SKO-非线性均值	0.1514	0.0156	0.6620	8.48
高相关线性	XGB-SKO-尺度	0.1432	0.0154	0.6800	8.58
高相关线性	XGB-SKO-均值尺度	0.1481	0.0154	0.6470	8.29
高相关线性	TabM-SKO-Ridge	0.1541	0.0171	0.7970	10.28
高相关线性	TabM-SKO-非线性均值	0.1423	0.0158	0.7560	9.56
高相关线性	TabM-SKO-尺度	0.1608	0.0170	0.8030	10.42
高相关线性	TabM-SKO-均值尺度	0.1343	0.0162	0.7640	9.55
已知混合变换	XGB-SKO-Ridge	0.0050	0.0036	0.0420	0.47
已知混合变换	XGB-SKO-非线性均值	0.0883	0.0128	0.7160	8.26
已知混合变换	XGB-SKO-尺度	0.0312	0.0090	0.2440	2.83
已知混合变换	XGB-SKO-均值尺度	0.1248	0.0140	0.8670	10.35
已知混合变换	TabM-SKO-Ridge	0.0125	0.0060	0.0750	0.89
已知混合变换	TabM-SKO-非线性均值	0.1297	0.0137	0.8500	10.21
已知混合变换	TabM-SKO-尺度	0.0424	0.0106	0.3430	3.89
已知混合变换	TabM-SKO-均值尺度	0.1643	0.0138	0.8860	11.06
t 生成错误	XGB-SKO-Ridge	0.0076	0.0060	0.0280	0.38
t 生成错误	XGB-SKO-非线性均值	0.0809	0.0129	0.2380	3.07
t 生成错误	XGB-SKO-尺度	0.0152	0.0061	0.0370	0.47
t 生成错误	XGB-SKO-均值尺度	0.1143	0.0161	0.3010	4.16




图 2: 八场景中的原生平均 FDP 和 Power，名义水平不代替有效性验证

场景	方法	平均 FDP	MCSE	Power	发现数
t 生成错误	TabM-SKO-Ridge	0.0215	0.0123	0.0190	0.37
t 生成错误	TabM-SKO-非线性均值	0.1147	0.0192	0.2200	3.44
t 生成错误	TabM-SKO-尺度	0.0205	0.0105	0.0250	0.48
t 生成错误	TabM-SKO-均值尺度	0.0999	0.0186	0.2000	3.13

预定主候选的 XGB 评价 RMSE 为 1.8965，同 TabM 的 Ridge 机制适配为 1.8996；其半样本参考 Jaccard 为 0.4099。相对 SHAP 的 RMSE 差为 0.0499，卖家簇 Bootstrap 点态 95% 区间为 [0.0308,0.0697]。区间跨零时不能宣称已证实提升，也不能声称已证明等价。

强非线性下主候选 Power 为 0.8660，Ridge 适配为 0.1290；主候选平均 FDP 为 0.1313。平均 FDP 超过名义.20 的场景检查：所列场景未出现高于.20 的点估计，但有限模拟不证明总体控制。检出增多须与误选同时解释。条件尺度建模不自动产生交换有效性，任何经验失控都必须保留，不因其真实预测较好而隐去。

该实验补足了近期双侧条件重建的机制比较，但仅是固定参数、有限基函数的适配。当前没有把条件均值/尺度扩展称为已证明原创的新方法。

独立组件判断。强非线性中只用非线性均值的 Power 已为.856，联合尺度后为.866；纯交互中为.959 与.966。大部分检出改进来自非线性条件均值，而不是尺度项。联合项减非线性均值的配对差如下，Holm 校正限于同场景、同规则、同指标的比较族，不能解释为跨所有场景筛选后的确认结论。

表 11: 条件尺度相对非线性均值的检出增量

场景	加入尺度的 Power 差	95% 区间	Holm p
强非线性	0.0100	[-0.0240,0.0440]	0.561
弱非线性	0.0440	[-0.0083,0.0963]	0.09793
纯交互	0.0070	[-0.0029,0.0169]	0.3252
已知混合变换	0.0360	[0.0074,0.0646]	0.01401
高相关线性	0.0080	[-0.0140,0.0300]	1

联合 TabM 真实 RMSE 约 1.8965，SHAP 为 1.8466，误差差区间完全为正；参考 Jaccard 约.4099，也低于 SHAP 的.7682。联合方法没有形成真实应用优势。此外，未标准化 SCPL 随机对称 TabM 在强非线性、弱非线性和纯交互中的 Power 仍更高，因此不能把相对 Ridge 适配的巨大提高写成超越所有非线性方法。

条件重建扩展在何种机制下有收益, 需要与同一预测器的 Ridge、非线性均值和尺度单独版本对比, 而不是只与线性预测器比较。是否优于 SHAP 则只能在相同 K 的预测和模拟表中回答; 原生 FDR 程序与没有原生阈值的 SHAP 不直接混比。

6 结论与后续研究

基础比较显示近期深度方法具有竞争力, 但没有跨预测器、稳定性与模拟发现质量的一致冠军。模型内部机制改动中, Jacobian 具有局部稳定性价值, 预算门、动态剪枝和序列损失的独立收益受限。负结果不应被更换指标或事后主方法遮盖。

交换对称成对损失满足明确的路径级符号翻转, 并可在精确生成器与独立评分条件下使用已有 Knockoff 理论。非线性模拟中它相对匹配线性模型提高检出, 但标准化常降低 Power, 高相关线性构成反例。真实生成器失配限制了实际发现解释, MVR 敏感性改善预测也未提供可靠的稳定性优势。

双侧条件矩补充得到主候选真实 RMSE 1.8965、半样本 J 0.4099, 强非线性 Power 0.8660 与平均 FDP 0.1313。它说明估计条件矩的收益与误选代价需要共同检查; 作者阈值函数的纠错仅保证实现符合公式, 不能补救条件模型失配。

后续优先进行三项工作: 在未使用过的真实数据和时间窗口冻结验证; 与近期非线性受控筛选算法按相同信息与预算比较; 研究条件矩估计误差和生成失配对统计量符号及发现风险的影响。只有这些证据补足后, 才能更明确判断方法贡献与适用范围。本文不预先承诺这些工作必然产生优势。

参考文献

- [1] Tibshirani R. Regression shrinkage and selection via the lasso[J]. Journal of the Royal Statistical Society, Series B, 58(1), 267-288, 1996. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>.
- [2] Zou H, Hastie T. Regularization and variable selection via the elastic net[J]. Journal of the Royal Statistical Society, Series B, 67(2), 301-320, 2005. <https://doi.org/10.1111/j.1467-9868.2005.00503.x>.
- [3] Meinshausen N, Bühlmann P. Stability selection[J]. Journal of the Royal Statistical Society, Series B, 72(4), 417-473, 2010. <https://doi.org/10.1111/j.1467-9868.2010.00740.x>.
- [4] Shah R D, Samworth R J. Variable selection with error control: another look at stability selection[J]. Journal of the Royal Statistical Society, Series B, 75(1), 55-80, 2013. <https://doi.org/10.1111/j.1467-9868.2011.01034.x>.
- [5] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. Proceedings of KDD, 785-794, 2016. <https://doi.org/10.1145/2939672.2939785>.
- [6] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[C]. Advances in Neural Information Processing Systems, 30, 2017. <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>.
- [7] Lundberg S M, Erion G, Chen H, et al. From local explanations to global understanding with explainable AI for trees[J]. Nature Machine Intelligence, 2, 56-67, 2020. <https://doi.org/10.1038/s42256-019-0138-9>.
- [8] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees[J]. Machine Learning, 63, 3-42, 2006. <https://doi.org/10.1007/s10994-006-6226-1>.
- [9] Kursa M B, Rudnicki W R. Feature Selection with the Boruta Package[J]. Journal of Statistical Software, 36(11), 1-13, 2010. <https://doi.org/10.18637/jss.v036.i11>.

- [10] Cherepanova V, Levin R, Somepalli G, et al. A Performance-Driven Benchmark for Feature Selection in Tabular Deep Learning[C]. NeurIPS Datasets and Benchmarks Track, 2023. <https://openreview.net/forum?id=v4PMCdSaAT>.
- [11] Ying W, Wang D, Chen H, Fu Y. Feature Selection as Deep Sequential Generative Learning[J]. ACM Transactions on Knowledge Discovery from Data, 18(9), Article 221, 2024. <https://doi.org/10.1145/3687485>.
- [12] Gorishniy Y, Kotelnikov A, Babenko A. TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling[C]. International Conference on Learning Representations, 2025. <https://openreview.net/forum?id=Sd4wYYOhmY>.
- [13] Zimmer F, Okanovic P, Hoefler T. EntryPrune: Neural Network Feature Selection using First Impressions[EB/OL]. arXiv:2410.02344v4, preprint, 2025. <https://arxiv.org/abs/2410.02344v4>.
- [14] Yamada Y, Lindenbaum O, Negahban S, Kluger Y. Feature Selection using Stochastic Gates[C]. Proceedings of Machine Learning Research, 119, 10648-10659, 2020. <https://proceedings.mlr.press/v119/yamada20a.html>.
- [15] Gregorova M, Kalousis A, Marchand-Maillet S. Structured Nonlinear Variable Selection[C]. Uncertainty in Artificial Intelligence, 2018. <https://auai.org/uai2018/proceedings/papers/17.pdf>.
- [16] Lu Y, Fan Y, Lv J, Noble W S. DeepPINK: reproducible feature selection in deep neural networks[C]. Advances in Neural Information Processing Systems, 2018. <https://arxiv.org/abs/1809.01185>.
- [17] Oh E, Lee H. DeepPIG: deep neural network architecture with pairwise connected layers and stochastic gates using knockoff frameworks for feature selection[J]. Scientific Reports, 14, Article 15582, 2024. <https://doi.org/10.1038/s41598-024-66061-6>.
- [18] Zou B J, Tian L. GRIP2: A Robust and Powerful Deep Knockoff Method for Feature Selection[EB/OL]. arXiv:2602.00218v1, preprint, 2026. <https://arxiv.org/abs/2602.00218v1>.
- [19] Shen H, Yan Y, Zhao Z. DeepDRK: Deep Dependency Regularized Knockoff for Feature Selection[C]. Advances in Neural Information Processing Systems, 2024. <https://openreview.net/forum?id=ibKpPabHVn>.
- [20] Hollmann N, Muller S, Purucker L, et al. Accurate predictions on small data with a tabular foundation model[J]. Nature, 637, 319-326, 2025. <https://doi.org/10.1038/s41586-024-08328-6>.
- [21] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing[J]. Journal of the Royal Statistical Society, Series B, 57(1), 289-300, 1995. <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>.
- [22] Barber R F, Candès E J. Controlling the false discovery rate via knockoffs[J]. The Annals of Statistics, 43(5), 2055-2085, 2015. <https://doi.org/10.1214/15-AOS1337>.
- [23] Candès E, Fan Y, Janson L, Lv J. Panning for gold: model-X knockoffs for high dimensional controlled variable selection[J]. Journal of the Royal Statistical Society, Series B, 80(3), 551-577, 2018. <https://doi.org/10.1111/rssb.12265>.
- [24] Spector A, Janson L. Powerful knockoffs via minimizing reconstructability[J]. The Annals of Statistics, 50(1), 252-276, 2022. <https://doi.org/10.1214/21-AOS2104>.

- [25] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for false discovery rate control[J]. Journal of the Royal Statistical Society, Series B, 86(1), 122-154, 2024. <https://doi.org/10.1093/jrsssb/qkad085>.
- [26] Wang R, Ramdas A. False discovery rate control with e-values[J]. Journal of the Royal Statistical Society, Series B, 84(3), 822-852, 2022. <https://doi.org/10.1111/rssb.12489>.
- [27] Blain A, Reyro Lobo A, Linhart J, Thirion B, Neuvial P. When knockoffs fail: diagnosing and fixing non-exchangeability of knockoffs[EB/OL]. arXiv:2407.06892, revised preprint, 2025. <https://arxiv.org/abs/2407.06892>.
- [28] Watson D S, Wright M N. Testing conditional independence in supervised learning algorithms[J]. Machine Learning, 110, 2107-2129, 2021. <https://doi.org/10.1007/s10994-021-06030-6>.
- [29] Reyro-Lobo A, Thirion B, Neuvial P. Semi-knockoffs: a model-agnostic conditional independence testing method with finite-sample guarantees[C]. International Conference on Machine Learning; arXiv:2601.23124v2, 2026. <https://arxiv.org/abs/2601.23124v2>.
- [30] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle dataset, 2018. <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>.
- [31] Olist. Marketing Funnel by Olist[DB/OL]. Kaggle dataset, 2018. <https://www.kaggle.com/datasets/olistbr/marketing-funnel-olist>.
- [32] Nogueira S, Sechidis K, Brown G. On the Stability of Feature Selection Algorithms[J]. Journal of Machine Learning Research, 18(174), 1-54, 2018. <https://www.jmlr.org/papers/v18/17-514.html>.
- [33] Morris T P, White I R, Crowther M J. Using simulation studies to evaluate statistical methods[J]. Statistics in Medicine, 38(11), 2074-2102, 2019. <https://doi.org/10.1002/sim.8086>.
- [34] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. Journal of Multivariate Analysis, 88(2), 365-411, 2004. [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4).