

Olist电商GMV维度选择研究

v1 极限精简版 · 数据、方法与模型方向

一、数据基础与研究任务

研究目标：用本月卖家经营特征预测次月GMV，并在控制其余候选变量后识别仍有增量信息的维度；核心不是普通重要性排序，而是在预设FDR水平下控制入选集合的假发现比例。

1. 原始数据与连接原则

数据来自Olist Brazilian E-Commerce Public Dataset和Marketing Funnel by Olist，共使用订单、商品明细、支付、评价、商品、卖家、顾客、地理、品类翻译与营销漏斗等11张CSV。连接前先按自然粒度聚合，避免商品明细×支付×评价形成多对多膨胀。

数据域	先聚合口径	主要用途
订单与商品明细	订单-卖家、卖家-月	GMV、件数、价格、运费、商品属性
支付与评价	先聚合到订单级	支付结构、分期、评价得分
顾客与地理	顾客唯一标识；邮编前缀经纬度中位数	独立顾客、州覆盖、跨州与距离
营销漏斗	线索映射到卖家后再入面板	营销来源与成交线索匹配

14,677 卖家-月观测	2,793 卖家	19 特征月份	12.342 百万雷亚尔GMV
------------------	-------------	------------	--------------------

2. 分析单位、目标与变量

- 样本期为2017-01至2018-07，仅保留已送达订单；处理后GMV与原始明细对账一致。
- 目标为 $Y_{s,t+1} = \log(1 + GMV_{s,t+1})$ ；次月无成交记0，零成交率25.86%。
- 构造32个候选维度，覆盖价格、商品、支付、口碑、履约、规模、地域和营销；零方差的申报月收入排除后，31项进入模型。
- 独立顾客按 customer_unique_id 去重；异常物流时长转缺失后在训练口径内插补。

任务边界：拒绝条件独立零假设只代表“包含增量预测信息”，不等于因果效应。

二、预处理与Copula-MVR Knockoff

稳健处理 1%/99%缩尾、偏态变换、中位数插补、标准化。	秩高斯 固定种子打散并列秩，将混合边际映射到近似正态空间。	协方差 Ledoit-Wolf收缩，降低高相关变量造成的病态估计。	MVR生成 最小化可重构性，逐轮生成与真实特征竞争的负对照。
---	---	---	--

1. 为什么使用秩高斯Copula

金额、计数、比例、二元变量和大量并列值不适合直接套用原始高斯。对第*j*列按随机化秩映射：

$$Z_{ij} = \Phi^{-1}[(r_{ij} - 0.5) / n]$$

该处理保留每列单调顺序，并用高斯Copula近似变量间依赖结构。它不是宣称原始变量服从正态分布，而是为二阶Model-X生成提供可计算空间。

2. MVR二阶Model-X生成

$$\tilde{X} | X \sim N\{X(I - \Sigma^{-1}S), 2S - S\Sigma^{-1}S\}$$

$\hat{\Sigma}$ 由Ledoit-Wolf估计，*S*由MVR准则确定。理想仿制变量需满足成对可交换性，并在给定*X*后不再包含*Y*的信息。每轮只重新抽取 $\tilde{X}$ ，不重新选择响应模型参数。

3. 生成质量诊断

0.013 Copula平均KS	0.200 原始高斯平均KS	0.027 协方差相对误差	0.033 交叉协方差非对称
----------------------------	--------------------------	-------------------------	--------------------------

诊断	判断内容	使用方式
边际KS	X_j 与 $\tilde{X}_j$ 的一维分布差异	比较Copula与原始高斯
协方差误差	仿制变量是否保留二阶依赖	检查整体矩阵保真
交叉对称性	$\text{Cov}(X, \tilde{X})$ 是否近似对称	检查交换性必要特征

Copula显著改善边际匹配，因此作为确认性主生成器；但较小KS和二阶误差不能证明全部高阶联合分布完全正确。

三、Lasso竞争、Knockoff+与e-value

1. 条件独立假设与反对称统计量

$$H_{0-j}: Y_{S,t+1} \perp X_{j,S,t} \mid X_{-j,S,t}$$

在联合设计矩阵 $[X, \tilde{X}]$ 上拟合Lasso，惩罚系数由首轮五折交叉验证确定，后续轮次固定。真实变量和仿制变量的系数绝对值之差为：

$$W_j = |\beta_j| - |\beta_{j+p}|$$

交换 X_j 与 $\tilde{X}_j$ 后 W_j 变号，满足Knockoff所需的反对称性；较大的正 W 表示真实变量稳定胜过负对照。

2. 单轮阈值与60轮去随机化

单轮Knockoff+ 按 $\alpha_{kn}=0.10$ 寻找正负 W 失衡阈值；使用“1+负向数”控制偏乐观选择。	重复60轮 不同随机种子重新生成 $\tilde{X}$ ，逐变量平均e-value，降低单次仿制随机性。
每轮e-value 入选变量获得与 $p/(1+负向数)$ 成比例的证据，未入选变量记0。	最终e-BH 在 $\alpha_{eBH}=0.20$ 下输出严格集合；单轮频率另作稳定性描述。

输出层	定义	是否承担FDR声明
严格确认集	60轮e-value平均后通过e-BH	是，在Model-X近似条件下
稳定候选集	单轮入选频率 $\geq 90\%$	否，只说明随机稳定性
预测解释层	XGBoost、SHAP、固定效应	否，用于交叉印证

3. 阈值与稳健性方向

0 FDR 0.10严格发现	14 FDR 0.20主发现	17 FDR 0.30严格发现	12 测试前独立选维
--------------------------	--------------------------	---------------------------	----------------------

稳健性情景还包括原始高斯生成器、同月GMV、次月客单价、截尾时间窗、XGBoost Knockoff及测试期前选维。稀疏模拟保留了去随机化e-BH功效为0.000的不利结果，说明低维少信号时Knockoff+存在离散门槛。

四、预测模型、SHAP与面板回归

1. 自然时间外预测设计

7,199 训练：2017-01至12	3,970 验证：2018-01至04	3,508 测试：2018-05至07	2.388 最佳测试RMSE(log)
-------------------------------	-------------------------------	-------------------------------	-------------------------------

模型与超参数只使用训练和验证期确定，测试期一次性评估。采用对数RMSE、MAE、 R^2 和原始GMV WAPE，兼顾重尾稳健性与金额解释。

模型方向	主要作用	解释边界
Ridge / Lasso	线性、正则化基线；观察平滑结构	系数受相关变量竞争影响
Extra Trees	非线性、交互与随机集成对照	重要性不等于显著性
XGBoost	主非线性预测器；缺失与交互适应	用时间外误差评价泛化
精简XGBoost	仅使用测试前Knockoff集合	检验选维后的预测保留度
MLP	神经网络表格预测对照	19个月不足以支持TFT

2. 时间外结果

模型	RMSE(log)	MAE(log)	R^2 (log)	WAPE
XGBoost	2.388	1.914	0.291	67.2%
Ridge	2.389	1.949	0.291	73.1%
Lasso	2.389	1.949	0.290	73.1%
ExtraTrees	2.390	1.914	0.290	65.9%
精简XGBoost	2.391	1.914	0.289	67.2%
MLP	2.429	1.947	0.267	74.5%
朴素基线	2.895	1.981	-0.042	79.2%

最佳模型为XGBoost，RMSE为2.388、 R^2 为0.291，较朴素基线下降17.5%。精简XGBoost接近全变量模型，说明测试前选出的变量保留了大部分预测信息。

3. 三种补充解释

- **TreeSHAP**：解释测试期XGBoost如何使用特征；前五项为成交订单数、独立顾客数、平均商品价格、平均审核至承运天数、买家州数量。
- **双向固定效应**：控制卖家不变异质性和共同月份冲击，标准误按卖家聚类；显著变量为平均审核至承运天数、Boleto支付占比、借记卡支付占比、信用卡支付占比。
- **证据分层**：Knockoff回答条件发现，SHAP回答模型依赖，固定效应回答卖家内关联，三者均不直接给出因果效应。

五、核心发现与方法结论

最终FDR水平0.20下，严格e-BH入选14项；其中10项的单轮入选频率至少90%。

经营规模 成交件数、成交订单数、活跃品类数、独立顾客数	商品与市场覆盖 平均商品高度、平均商品标题长度、平均商品描述长度、买家州数量、卖家所在州频率
价格成本 平均商品价格、平均运费	90%稳定候选 成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度
履约效率 平均下单至送达天数、平均审核至承运天数、平均预计提前送达天数	

1. 结果如何使用

证据等级	变量	建议用途
一级 监控	成交订单数、平均商品价格、独立顾客数、买家州数量、平均审核至承运天数、平均运费、平均预计提前送达天数、平均商品标题长度、卖家所在州频率、平均商品描述长度	首页趋势、异常预警
二级 诊断	成交件数、活跃品类数、平均商品高度、平均下单至送达天数	异常后的商品、履约与地域定位
专题 分析	支付、评价、距离、营销等未严格入选变量	专项研究与实验候选

2. 方法方向总结

- 统计主线：自然粒度聚合 → 前瞻目标 → Copula-MVR Knockoff → Lasso反对称W → 60轮e-value → e-BH。
- 机器学习主线：时间外XGBoost预测 + TreeSHAP解释；只承担预测验证，不替代FDR推断。
- 面板主线：双向固定效应提供卖家内关联证据，仍需实验或准实验确认可干预效果。

主要局限：卖家-月存在组内相关；Copula只近似高阶依赖；缺少曝光、库存、促销和竞争变量；19个月限制长序列模型；低维稀疏场景下Knockoff+可能保守。

复现：随机种子20260823；面板SHA-256：7212bf462a8b23ba6455bed5fe7354481b43d3e3a0f633a13ced1a97c3046a1e；完整代码、逐轮W、结果表和图位于“论文/v1”。

核心方法文献：Barber & Candès (2015)；Candès et al. (2018)；Spector & Janson (2022)；Ren & Barber (2024)；Lundberg & Lee (2017)。