

面向电商GMV监控的可控错误发现维度选择 研究

Olist实证研究精简介绍版（v1）

学校：【待填写】

学院：【待填写】

专业：【待填写】

研究生：【待填写】

指导教师：【待填写】

二〇二六年八月

目录

- 摘要
- 第1章 研究背景与问题
 - 1.1 研究背景
 - 1.2 研究问题
 - 1.3 研究思路
- 第2章 数据与研究设计
 - 2.1 数据来源与样本
 - 2.2 目标变量
 - 2.3 候选维度
 - 2.4 描述统计
- 第3章 方法
 - 3.1 Copula Model-X Knockoff
 - 3.2 竞争统计量与e-value
 - 3.3 预测与解释
- 第4章 核心实证结果
 - 4.1 Knockoff生成质量
 - 4.2 主变量选择
 - 4.3 阈值与时间稳健性
 - 4.4 时间外预测
 - 4.5 SHAP与固定效应
 - 4.6 模拟校准的边界
- 第5章 看板应用建议
 - 5.1 三级维度治理
 - 5.2 展示方式
 - 5.3 从预测到实验
- 第6章 结论与局限
 - 6.1 主要结论
 - 6.2 研究贡献
 - 6.3 主要局限
 - 6.4 后续方向
- 参考文献
- 版本说明

摘要

电商经营看板通常同时包含价格、交易规模、供给、支付、履约、口碑、地域和营销等大量维度。若仅依据相关系数、单变量显著性或机器学习重要性筛选字段，容易把高度相关的代理变量重复当作独立发现，也无法约束入选指标中的假发现比例。本文使用 Olist 巴西电商公开数据，构建卖家-月份面板，并以次月 $\log(1+GMV)$ 为目标，研究哪些本月经营维度在控制其他候选信息后仍具有增量预测价值。

研究在各原始表的自然粒度上先聚合再连接，避免商品明细、支付和评价多对多连接造成 GMV 重复计算。最终样本覆盖 2017-01 至 2018-07，包含 14,677 个卖家-月、2,793 个卖家和 19 个月，已送达商品 GMV 合计 12.342 百万巴西雷亚尔。共构造 32 个候选维度，其中申报月收入因零方差排除，31 个变量进入分析。

方法上，本文采用随机化秩高斯 Copula、Ledoit-Wolf 收缩协方差和 MVR 二阶 Model-X Knockoff，并以 Lasso 真变量与仿制变量系数差构造统计量。主分析重复生成 60 组 Knockoff，设置最终 $\alpha_{eBH}=0.20$ 、单轮 $\alpha_{kn}=0.10$ ，通过 e-value 聚合与 e-BH 控制错误发现率。结果显示，Copula 生成器平均边际 KS 距离为 0.013，显著低于原始高斯基线的 0.200。严格 e-BH 入选 14 个维度：成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度、平均商品高度、卖家所在州频率、平均商品描述长度、平均下单至送达天数。

时间外测试中，最佳模型为 XGBoost，对数尺度 RMSE 为 2.388，较直接使用本月 GMV 的朴素基线下降 17.5%。SHAP 结果与 Knockoff 在交易规模、价格、履约和市场覆盖维度形成交叉证据。本文据此提出“一级监控、二级诊断、专题分析”的看板分层方案，同时强调所有结果属于条件预测关系，不直接代表因果效应。

关键词： 电商 GMV；Model-X Knockoff；错误发现率；e-value；XGBoost；可解释机器学习

第1章 研究背景与问题

1.1 研究背景

数字平台能够完整记录订单、商品、顾客、支付、履约和评价过程，但指标数量也会随业务扩张持续增加。一个 GMV 看板可能同时展示订单数、件数、顾客数、均价、运费、品类、支付方式、物流时长、评价和地域覆盖。大量字段并列展示会产生三类问题：

1. 订单数、件数和顾客数等高度相关变量重复表达经营规模；
2. 逐项显著性检验会随候选变量增多而累积误报；
3. 机器学习重要性可以排序，却不能直接说明入选集合中可能有多少错误发现。

错误发现率（False Discovery Rate, FDR）定义为全部发现中错误发现比例的期望：

$$\text{FDR} = \mathbb{E} \left[\frac{V}{R \vee 1} \right],$$

其中 V 是错误发现数， R 是总发现数。FDR 允许在整体错误比例受控的前提下保留较多有效信号，适合需要兼顾探索效率与结果可信度的指标治理。

1.2 研究问题

本文的核心问题是：在本月可观测的卖家经营信息中，哪些维度在控制其余候选变量后，仍包含次月 GMV 的增量预测信息，并值得进入常驻看板？

相应的 Model-X 零假设为：

$$H_{0j}: Y_{s,t+1} \perp X_{j,s,t} \mid X_{-j,s,t}.$$

拒绝零假设表示变量具有条件预测信息，不表示人为改变该变量一定会改变 GMV。全文将预测发现、机器学习解释和因果结论严格区分。

1.3 研究思路

研究包括四个步骤：

1. 在订单、商品明细、支付、评价、地理和营销等自然粒度上分别聚合，构造卖家-月面板；
2. 使用 Copula-MVR Model-X Knockoff 生成负对照变量，通过重复 Knockoff 和 e-BH 控制 FDR；
3. 使用 Ridge、Lasso、Extra Trees、XGBoost 和 MLP 进行自然时间外预测；
4. 结合 SHAP、双向固定效应和稳健性分析，将结果转化为看板分层建议。

第2章 数据与研究设计

2.1 数据来源与样本

数据来自 Olist Brazilian E-Commerce Public Dataset 和 Marketing Funnel by Olist，共使用订单、商品明细、支付、评价、商品、卖家、顾客、地理、品类翻译及营销漏斗 11 张 CSV。原始订单为 99,441 笔，商品明细为 112,650 行；主分析只保留已送达订单。

支付表和评价表可能一单多行，不能直接与商品明细连接。本文先把支付方式、支付金额和评价聚合到订单级，再聚合到卖家-月；地理表先按邮编前缀取经纬度中位数；商品明细按卖家-月汇总 GMV、价格、运费和商品属性。该流程使处理后 GMV 与原始已送达商品明细逐笔对账一致。

顾客数量使用 `customer_unique_id` 去重，而非订单级 `customer_id`。不合理的负物流时长和明显超界时间设为缺失，随后在模型训练样本中以中位数插补。

最终面板包含 14,677 个卖家-月、2,793 个卖家和 19 个月。样本 GMV 为 12.342 百万雷亚尔，次月零成交观测占 25.86%。




图2-1 Olist主分析期月度GMV

2.2 目标变量

主目标定义为：

$$Y_{s,t+1} = \log(1 + \text{GMV}_{s,t+1}).$$

若卖家本月有交易而次月没有已送达订单，则次月 GMV 记为零。使用次月目标可以避免同月件数、订单数和均价对同月 GMV 的机械解释，更符合经营预警场景。

2.3 候选维度

32 个候选维度覆盖以下类别：

- 价格与运费：平均商品价格、平均运费；
- 商品结构：重量、长宽高、图片数、标题和描述长度；
- 支付：分期数、支付序列数及四类支付方式占比；
- 口碑与履约：评价、审核时长、承运时长、送达时长和预计提前量；
- 经营规模：件数、订单数、品类数和独立顾客数；
- 地域覆盖：买家州数量、第一大州占比、跨州比例和平均距离；
- 卖家与营销：卖家州频率、营销来源及是否匹配营销成交。

申报月收入在分析面板中恒为零，因此在查看响应结果前按零方差规则排除，最终 31 个变量进入模型。最大特征缺失率为 1.49%。

2.4 描述统计

表2-1 关键变量描述统计

变量	N	缺失率	均值	标准差	中位数	Spearman相关
平均商品价格	14677	0.00%	158.080	258.195	90.256	0.201
平均运费	14677	0.00%	22.586	18.367	17.696	0.094
平均评价得分	14653	0.16%	4.162	0.960	4.400	-0.121
平均下单至送达天数	14674	0.02%	12.748	8.174	11.262	0.074
平均审核至承运天数	14600	0.52%	3.015	3.431	2.032	-0.018
成交件数	14677	0.00%	7.000	14.798	3.000	0.550
成交订单数	14677	0.00%	6.206	12.948	2.000	0.572
活跃品类数	14677	0.00%	1.480	1.114	1.000	0.331
独立顾客数	14677	0.00%	6.173	12.850	2.000	0.572
买家州数量	14677	0.00%	2.959	2.747	2.000	0.551
跨州交易占比	14677	0.00%	0.674	0.357	0.750	-0.081
平均卖家-买家距离	14617	0.41%	626.901	460.658	534.101	0.088

边际相关显示，订单数、独立顾客数、件数和市场覆盖与次月 GMV 相关较高，但边际相关不能区分独立信息与相关代理，因此只作为描述。

第3章 方法

3.1 Copula Model-X Knockoff

Model-X Knockoff 为每个真实变量 X_j 构造仿制变量 $\tilde{X}_j$ 。理想仿制变量满足成对可交换性，并在给定真实特征后不再包含响应信息：

$$(X, \tilde{X})_{\text{swap}(S)} \stackrel{d}{=} (X, \tilde{X}), \quad \tilde{X} \perp Y | X.$$

Olist 变量同时包含金额、计数、比例、二元值和大量并列值。本文先对连续变量进行 1% 与 99% 分位缩尾、偏态变换、中位数插补和标准化，再使用固定随机种子打散并列秩，并映射为近似标准正态：

$$Z_{ij} = \Phi^{-1}\left(\frac{r_{ij} - 0.5}{n}\right).$$

随后使用 Ledoit-Wolf 收缩协方差与 MVR 准则生成二阶 Knockoff。与直接假定原始变量服从高斯分布相比，Copula 方法更适合混合边际，同时保留了明确的诊断指标。

3.2 竞争统计量与e-value

将真实变量和仿制变量共同输入 Lasso，构造：

$$W_j = |\hat{\beta}_j| - |\hat{\beta}_{j+p}|.$$

若真实变量显著胜过仿制变量， W_j 较大且为正。每次 Knockoff 按 $\alpha_{\text{kn}}=0.10$ 计算 Knockoff+ 阈值，并转换为 e-value：

$$e_j^{(m)} = p \frac{\mathbf{1}\{W_j^{(m)} \geq T^{(m)}\}}{1 + \sum_k \mathbf{1}\{W_k^{(m)} \leq -T^{(m)}\}}.$$

主分析重复 60 次，对 e-value 取平均后，在 $\alpha_{\text{eBH}}=0.20$ 下实施 e-BH。最终 FDR 水平与单轮阈值分开设置，遵循去随机化 Knockoff 的推荐方案。

本文还报告单轮入选频率。严格 e-BH 集合承担 FDR 声明，频率至少 90% 的集合只描述生成稳定性，二者不能混用。

3.3 预测与解释

按自然月份划分训练、验证和测试集：

- 训练期：2017-01 至 2017-12，7,199 行；
- 验证期：2018-01 至 2018-04，3,970 行；
- 测试期：2018-05 至 2018-07，3,508 行。

比较模型包括朴素本月 GMV、Ridge、Lasso、Extra Trees、XGBoost、MLP 以及只使用测试期前 Knockoff 入选变量的 XGBoost。评价指标为对数 RMSE、MAE、 R^2 和原始金

额 WAPE。XGBoost 使用 TreeSHAP 解释测试期预测。

由于单卖家最多只有 19 个特征月份，且多数序列更短，本文没有强行使用参数量较大的 TFT，而使用 XGBoost 和 MLP 完成非线性 AI 验证。

第4章 核心实证结果

4.1 Knockoff生成质量

Copula 生成器的平均边际 KS 距离为 0.013，最大值为 0.037，协方差相对误差为 0.027，交叉协方差非对称度为 0.033。原始高斯基线平均边际 KS 为 0.200。Copula 的边际误差明显较小，因此主结果采用 Copula-MVR。

4.2 主变量选择

在 $\alpha_{eBH}=0.20$ 、 $\alpha_{kn}=0.10$ 下，严格入选 14 个变量：成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度、平均商品高度、卖家所在州频率、平均商品描述长度、平均下单至送达天数。

表4-1 严格e-BH入选变量

变量	平均W	单轮入选频率	平均e-value
成交订单数	0.144	95.0%	28.675
平均商品价格	0.142	95.0%	28.675
独立顾客数	0.140	95.0%	28.675
成交件数	0.117	95.0%	28.675
买家州数量	0.097	95.0%	28.675
平均审核至承运天数	0.053	95.0%	28.675
平均运费	0.027	95.0%	28.675
活跃品类数	0.023	95.0%	28.675
平均预计提前送达天数	0.021	95.0%	28.675
平均商品标题长度	0.022	91.7%	27.642
平均商品高度	0.013	80.0%	24.025
卖家所在州频率	0.014	76.7%	22.992
平均商品描述长度	0.009	50.0%	14.725
平均下单至送达天数	0.007	41.7%	12.142

其中 10 个变量的单轮入选频率达到至少 90%：成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度。严格集合与稳定集合可能不同，因为 e-BH 使用每轮负向统计量数量加权，而 90% 频率只是人为设置的描述阈值。




图4-1 主分析平均e-value

严格变量可归为四组：

1. 经营规模：订单数、件数、独立顾客数、活跃品类数；
2. 价格成本：平均商品价格、平均运费；
3. 履约：审核至承运、下单至送达和预计提前量；
4. 商品与覆盖：标题、描述、商品高度、买家州数量和卖家州频率。

这些结果表明，次月 GMV 既有经营规模延续，也包含价格带、履约状态、商品结构和市场覆盖的条件信息。

4.3 阈值与时间稳健性

表4-2 不同FDR水平的严格结果

最终FDR水平	单轮水平	严格入选数	严格入选变量
0.10	0.05	0	无
0.20（主分析）	0.10	14	成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度、平均商品高度、卖家所在州频率、平均商品描述长度、平均下单至送达天数
0.30	0.15	17	平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均商品描述长度、平均支付序列数、借记卡支付占比、平均下单至送达天数、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、第一大买家州占比、卖家所在州频率

在更严格的 0.10 水平下，严格发现为 0 项；在 0.30 水平下为 17 项。测试期开始前样本独立选出的 12 个变量为：平均商品价格、平均商品标题长度、平均商品描述长度、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、第一大买家州占比、卖家所在州频率。该集合用于精简 XGBoost，避免测试数据进入变量筛选。

4.4 时间外预测

表4-3 时间外测试性能

模型	测试N	RMSE(log)	MAE(log)	R2(log)	WAPE
XGBoost	3508	2.388	1.914	0.291	67.2%
Ridge	3508	2.389	1.949	0.291	73.1%
Lasso	3508	2.389	1.949	0.290	73.1%
ExtraTrees	3508	2.390	1.914	0.290	65.9%
XGBoost-Knockoff-selected	3508	2.391	1.914	0.289	67.2%
MLP	3508	2.429	1.947	0.267	74.5%
Naive-current-GMV	3508	2.895	1.981	-0.042	79.2%

最佳模型为 XGBoost，测试集对数 RMSE 为 2.388、 R^2 为 0.291。朴素基线 RMSE 为 2.895，最佳模型下降 17.5%。Ridge、Lasso、Extra Trees 和 XGBoost 表现接近，说明主要可预测结构较平滑，复杂模型没有形成压倒性优势。




图4-2 时间外预测模型比较

4.5 SHAP与固定效应

SHAP 前五项为成交订单数、独立顾客数、平均商品价格、平均审核至承运天数、买家州数量。Knockoff 严格集合与 SHAP 前十项的交集为成交订单数、平均商品价格、独立顾客数、买家州数量、平均审核至承运天数、平均运费、平均预计提前送达天数、平均商品标题长度、卖家所在州频率、平均商品描述长度，可作为优先监控候选；其余严格项目为成交件数、活跃品类数、平均商品高度、平均下单至送达天数，更适合二级诊断。




图4-3 XGBoost SHAP重要性

双向固定效应控制卖家和月份效应，标准误按卖家聚类。5% 水平显著的动态变量为平均审核至承运天数、Boleto支付占比、借记卡支付占比、信用卡支付占比。固定效应只能提供同一卖家随时间变化的关联证据，仍可能受到促销、曝光、库存和竞争等遗漏因素影响。

4.6 模拟校准的边界

模拟在真实特征矩阵上设置 5 个真信号。去随机化 e-BH 的平均 FDP 为 0.000、平均功效为 0.000；单轮 Knockoff+ 的平均 FDP 为 0.197、平均功效为 1.000。

聚合程序在该稀疏模拟中零功效，原因是 $p=31$ 、 $\alpha_{kn}=0.10$ 时 Knockoff+ 存在离散门槛，只有 5 个真信号很难在不引入假发现的情况下达到阈值。这一结果说明方法在低维、极稀疏任务中可能保守。本文保留该不利结果，而不通过事后调参制造非空发现。

第5章 看板应用建议

5.1 三级维度治理

一级监控层优先包含成交订单数、平均商品价格、独立顾客数、买家州数量、平均审核至承运天数、平均运费、平均预计提前送达天数、平均商品标题长度、卖家所在州频率、平均商品描述长度。这些变量同时获得严格 e-BH 与 XGBoost 预测解释支持，适合在首页展示趋势和异常。

二级诊断层包含成交件数、活跃品类数、平均商品高度、平均下单至送达天数。这些变量通过严格 e-BH，但预测排序相对靠后，适合在一级指标异常后用于定位商品结构、内容、履约和地域问题。

专题分析层包含未进入严格集合、但具有明确业务用途的支付、评价、距离和营销变量。未入选不等于永远无用，只表示在当前候选集和次月 GMV 目标下缺乏足够条件证据。

5.2 展示方式

看板不应把所有入选变量平铺成卡片，而应按经营问题组织：

- 交易规模模块：订单数、件数和独立顾客数；
- 价格成本模块：平均商品价格和平均运费；
- 履约模块：承运准备、送达时长和承诺偏差；
- 供给内容模块：品类数、标题与描述；
- 市场覆盖模块：买家州数量和地域基准。

每个模块保留一个主要状态指标和少量下钻指标，以减少代理变量重复展示。

5.3 从预测到实验

订单数和顾客数首先是经营状态变量，不能把“提高订单数”写成可执行因果建议。履约时长、商品内容和运费策略更接近可干预变量，但仍需 A/B 实验、分层实验或准实验确认。Knockoff 的作用是缩小候选范围，不是替代因果识别。

第6章 结论与局限

6.1 主要结论

本文使用 Olist 全量公开数据构建了 14,677 个卖家-月观测，并以次月 GMV 为前瞻目标。随机化秩高斯 Copula 显著改善了混合变量的 Knockoff 边际匹配。主分析在最终 FDR 水平 0.20 下严格入选 14 个维度，覆盖经营规模、价格、履约、商品内容和市场覆盖。

时间外测试中，XGBoost 的 RMSE 为 2.388，较朴素基线改善 17.5%。Knockoff、SHAP、预测误差和固定效应构成互补证据，其中只有预先设定的 e-BH 程序承担 FDR 声明。

6.2 研究贡献

第一，将 FDR 控制引入电商看板维度治理。第二，采用自然粒度聚合和次月目标，规避多表膨胀与同月定义泄漏。第三，明确区分严格发现、随机稳定性、预测解释和因果结论。第四，保留完整代码、每轮 W 统计量、结果表和随机种子，支持复核。

6.3 主要局限

1. 公开数据缺少曝光、广告、库存、促销和竞争强度；
2. 卖家-月面板存在同一卖家内部相关，标准 Model-X 独立条件只能近似满足；
3. Copula 二阶方法不能保证刻画全部高阶和尾部依赖；
4. 只有 19 个特征月份，不适合复杂长序列深度模型；
5. 固定效应与 SHAP 不能替代随机实验；
6. 低维稀疏场景下 Knockoff+ 可能因离散阈值而功效不足。

6.4 后续方向

未来可在更长企业面板上使用滚动 Knockoff 和在线 e-value；按交易、履约、商品和地域定义 group knockoff；开发并严格诊断现代 Deep Knockoff；在更长序列中比较 TFT 与其他时序模型；对可行动变量开展实验和因果机器学习分析。

参考文献

- [1] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing[J]. *Journal of the Royal Statistical Society: Series B*, 1995, 57(1): 289-300.
- [2] Barber R F, Candès E J. Controlling the false discovery rate via knockoffs[J]. *The Annals of Statistics*, 2015, 43(5): 2055-2085.
- [3] Candès E, Fan Y, Janson L, Lv J. Panning for gold: Model-X knockoffs for high-dimensional controlled variable selection[J]. *Journal of the Royal Statistical Society: Series B*, 2018, 80(3): 551-577.
- [4] Romano Y, Sesia M, Candès E. Deep knockoffs[J]. *Journal of the American Statistical Association*, 2020, 115(532): 1861-1872.
- [5] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for false discovery rate control[J]. *Journal of the Royal Statistical Society Series B*, 2024, 86(1): 122-154.
- [6] Wang R, Ramdas A. False discovery rate control with e-values[J]. *Journal of the Royal Statistical Society Series B*, 2022, 84(3): 822-852.
- [7] Tibshirani R. Regression shrinkage and selection via the lasso[J]. *Journal of the Royal Statistical Society: Series B*, 1996, 58(1): 267-288.
- [8] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. *Journal of Multivariate Analysis*, 2004, 88(2): 365-411.
- [9] Spector A, Janson L. Powerful knockoffs via minimizing reconstructability[J]. *The Annals of Statistics*, 2022, 50(1): 252-276.
- [10] Breiman L. Random forests[J]. *Machine Learning*, 2001, 45: 5-32.
- [11] Chen T, Guestrin C. XGBoost: a scalable tree boosting system[C]//*Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016: 785-794.
- [12] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]//*Advances in Neural Information Processing Systems*. 2017, 30.
- [13] Lim B, Arik S Ö, Loeff N, Pfister T. Temporal fusion transformers for interpretable multi-horizon time series forecasting[J]. *International Journal of Forecasting*, 2021, 37(4): 1748-1764.
- [14] Wooldridge J M. *Econometric analysis of cross section and panel data*[M]. 2nd ed. Cambridge, MA: MIT Press, 2010.
- [15] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle, 2018.

[16] Olist. Marketing Funnel by Olist[DB/OL]. Kaggle, 2018.

版本说明

本文件为 v1 精简介绍版，所有数字与完整论文使用同一面板和同一组模型结果。完整论文、代码、结果表、图和运行日志位于 论文/v1。封面身份信息需按实际情况填写。