

Olist电商GMV维度选择研究

v3 极限精简版 · 参数K控制选择数量与模型默认推荐

一、数据基础与问题定义

主问题：32个候选维度经FDR 0.20得到14项后，如何让用户自主选择保留数量？V3增加参数 $K \in [1,14]$ ，按验证集模型贡献排序，并自动推荐默认K。

1. 数据来源、时间与分析单位

使用Olist订单、商品明细、支付、评价、商品、卖家、顾客、地理、品类翻译和营销漏斗等11张CSV。支付与评价先聚合到订单级，地理先到邮编前缀，商品明细再聚合为卖家×月，避免多对多连接重复计算GMV。

数据模块	关键处理	生成信息
交易与商品	已送达订单；订单-卖家后聚合	GMV、件数、订单、价格、运费、品类
支付与口碑	多行先合并到订单级	支付占比、分期、评价
顾客与空间	unique_id去重；Haversine距离	顾客数、州覆盖、跨州与距离
营销漏斗	线索-卖家映射	来源频率、营销成交标识

14,677

卖家-月观测

2,793

卖家

19

月份

12.342

百万雷亚尔GMV

2. 时间口径与预测目标

- 样本期：2017-01至2018-07；本月特征预测次月 $\log(1+GMV)$ ，避免同月定义泄漏。
- 次月无已送达订单记0，零成交率25.86%；最终面板哈希固定，V1/V2/V3共用同一输入。

3. 全部32个候选维度

价格成本 (2)

平均商品价格、平均运费

商品物理与内容 (7)

平均商品重量、平均商品长度、平均商品高度、平均商品宽度、平均商品图片数、平均商品标题长度、平均商品描述长度

支付结构 (6)

平均支付分期期数、平均支付序列数、信用卡支付占比、Boleto支付占比、代金券支付占比、借记卡支付占比

口碑与履约 (5)

平均评价得分、平均下单至送达天数、平均下单至审核天数、平均审核至承运天数、平均预计提前送达天数

经营规模 (4)

成交件数、成交订单数、活跃品类数、独立顾客数

地域覆盖 (4)

买家州数量、第一大买家州占比、跨州交易占比、平均卖家-买家距离

卖家与营销 (3)

卖家所在州频率、营销来源频率、是否匹配营销成交线索

构造后排除 (1)

申报月收入对数：面板内零方差，未进入31维模型

进入模型：31项。研究识别的是控制其他维度后的条件预测信息，不把选维、SHAP或固定效应直接解释为因果效应。

两类样本量需区分：横截面联合分布学习有14,677行，可训练深度Knockoff；单卖家时间序列最多19个月，不足以可靠训练TFT。

二、确认性主线：Copula-Lasso-eBH

预处理 缩尾、偏态变换、插补、标准化、随机化并列秩。	负对照 秩高斯Copula + Ledoit-Wolf协方差 + MVR。	竞争统计量 [X, $\tilde{X}$]上Lasso，计算真实与仿制系数差。	FDR控制 60轮Knockoff转e-value，最终执行e-BH。
--------------------------------------	---	---	---

1. Model-X生成与Lasso反对称性

$Z_{ij} = \Phi^{-1}[(r_{ij} - 0.5)/n]$	$W_j = \beta_j - \beta_{j+p} $
--	-----------------------------------

秩高斯处理混合、偏态、离散和大量并列边际；MVR降低X被 $\tilde{X}$ 重构的程度。

交换 X_j 和 $\tilde{X}_j$ 后 W_j 变号；惩罚系数首轮交叉验证后固定。

$$H_0: Y_{s,t+1} \perp X_{j,s,t} \mid X_{-j,s,t}$$

2. 去随机化与证据权限

步骤	设定	输出解释
单轮Knockoff+	$\alpha_{kn}=0.10$	用正负W失衡确定阈值
重复生成	60个随机种子	每轮入选转换为e-value并平均
最终e-BH	$\alpha_{eBH}=0.20$	严格集合承担FDR声明
稳定频率	单轮频率 $\geq 90\%$	只描述复现性，不等于FDR控制

3. 基线生成诊断与阈值路径

0.013 V1 Copula平均KS	0.200 原始高斯平均KS	14 FDR 0.20严格发现	10 90%稳定候选
-------------------------------	--------------------------	---------------------------	----------------------

最终e-BH水平	固定单轮水平	严格入选数
0.10	0.10	0
0.15	0.10	12
0.20	0.10	14
0.30	0.10	16
0.40	0.10	17

主方法在0.20水平严格入选14项：成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度、平均商品高度、卖家所在州频率、平均商品描述长度、平均下单至送达天数

其中单轮频率 $\geq 90\%$ 的10项：成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度

V3控制参数：K可取1至14；K=4为极简、K=8为均衡、K=10为模型默认、K=14为完整确认集。

固定同一组e-value，仅改变最终e-BH水平用于风险敏感性展示；确认性主结论仍是预先设定的0.20水平。

三、深度Knockoff生成与交换性准入

1. 生成器结构

$$\tilde{X} = G\theta(X, \varepsilon), \quad \varepsilon \sim N(0, I)$$

噪声条件生成器输入31维真实特征与同维高斯噪声，使用4层、宽度192的全连接网络，LayerNorm + GELU，输出经tanh限制极端值；AdamW训练，正式配置最多90轮。

2. 训练目标：同时约束边际与联合交换

Swap-aware MMD 训练时随机交换20%、50%、80%特征，压低原始与交换联合分布差异。	可重构性 将平均真伪成对相关推向约0.50，避免生成器复制X。
矩结构 约束边际、均值、方差、协方差和交叉协方差对称性。	经验边际校准 只使用X的经验分位数，不读取Y；可修正边际，不能保证联合交换。

3. 验证子集多指标诊断

方法	平均KS	协方差误差	交叉非对称	真伪相关	swap AUC
Copula-MVR	0.026	0.081	0.094	0.512	0.788
深度生成（原始）	0.212	0.105	0.145	0.508	0.990
深度生成（校准）	0.016	0.160	0.187	0.555	0.922

- 诊断包括KS、协方差误差、交叉非对称、真伪相关、90%/95%覆盖率、10%—100% swap下的RBF-MMD和Extra Trees分类器两样本检验。
- 边际校准后平均KS为0.016，但swap分类器平均AUC为0.922，仍能识别联合分布差异。
- 预设联合准入结论：未通过预设联合交换性诊断，不作FDR声明。

深度生成分支形式上入选11项：平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均下单至送达天数、平均审核至承运天数、平均预计提前送达天数、成交件数、活跃品类数、独立顾客数、第一大买家州占比

方法结论：“每一列看起来相同”不足以证明联合交换性。失败分支形式上得到的选择结果不进入FDR结论；验证子集参与早停、全体X参与边际校准，也使外部复核仍有必要。

四、深度重要性与表格预测模型

1. 配对竞争MLP：在有效Copula Knockoff上计算W

$$\text{pair}_j = X_j \cdot a_j + \tilde{X}_j \cdot \tilde{a}_j \quad ; \quad W_j = |a_j|d_j - |\tilde{a}_j|d_j$$

真实与仿制变量使用对称配对权重，共享同一后续网络和第一隐藏层下游范数 d_j 。每轮随机交换成对输入位置后再映射回真实方向，削弱列位置偏好；正式实验重复20次。

检查项	正式结果	解释
交换反对称性	最大误差0.000e+00	通过
0.20水平c-BH	0项：无	非线性稳健性分支
结论权限	不替代Copula-Lasso主线	优化随机性与重复数有限

2. 残差表格MLP与时间外预测

输入31维特征，宽度128，3个Residual Block，LayerNorm + GELU + Dropout，AdamW优化；训练、验证、测试月份与V1完全相同。该模型检验深层表格表示能否提升泛化，不承担FDR推断。

模型	RMSE(log)	MAE(log)	R2(log)	WAPE
K=4极简	2.388	1.918	0.291	66.7%
K=8均衡	2.389	1.921	0.290	66.5%
K=10默认	2.385	1.922	0.293	66.9%
K=14完整	2.384	1.915	0.294	67.2%
全31维XGBoost	2.388	1.914	0.291	67.2%
残差MLP	2.414	1.927	0.276	71.8%
朴素基线	2.895	1.981	-0.042	79.2%

全31维XGBoost测试RMSE为2.388；默认K=10模型为2.385，相对变化-0.097%。默认值只使用验证集确定。

3. 各AI模型在论文中的分工

模型	回答的问题	是否承担FDR声明
深度生成器	能否学习有效联合负对照	否，本次准入失败
配对竞争MLP	是否存在非线性真伪竞争信号	补充证据
XGBoost / 残差MLP	次月GMV时间外预测能力	否，仅预测验证
TreeSHAP	XGBoost如何使用变量	否，仅模型解释

测试期前独立Knockoff选出的12项：平均商品价格、平均商品标题长度、平均商品描述长度、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、第一大买家州占比、卖家所在州频率

TreeSHAP前10项：成交订单数、独立顾客数、平均商品价格、平均审核至承运天数、买家州数量、平均预计提前送达天数、平均商品标题长度、卖家所在州频率、平均运费、平均商品描述长度

双向固定效应5%显著的4项：信用卡支付占比、Boleto支付占比、借记卡支付占比、平均审核至承运天数

五、可控K路径与默认推荐

14项仍是正式FDR确认池；用户通过K选择前K项。系统按“累计验证贡献 $\geq 90\%$ 且验证RMSE距最优 $\leq 0.5\%$ ”推荐K=10。

K=4 极简

独立顾客数、成交订单数、平均商品价格、平均审核至承运天数

K=8 均衡

独立顾客数、成交订单数、平均商品价格、平均审核至承运天数、平均预计提前送达天数、买家州数量、平均下单至送达天数、成交件数

K=10 默认

独立顾客数、成交订单数、平均商品价格、平均审核至承运天数、平均预计提前送达天数、买家州数量、平均下单至送达天数、成交件数、平均运费、平均商品标题长度

K=14 完整

成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度、平均商品高度、卖家所在州频率、平均商品描述长度、平均下单至送达天数

1. 五层证据结构

层级	方法	正式结论
确认层	Copula-MVR + Lasso + 60轮e-value	14项严格发现
生成诊断层	深度Knockoff + 多指标swap检验	拒绝深度生成分支
非线性重要性层	Copula Knockoff + 配对MLP	反对称性通过，0项严格发现
预测解释层	XGBoost、残差MLP、SHAP、固定效应	XGBoost泛化最优
参数化展示层	验证SHAP排序 + 参数K	用户选数量，默认K=10

结论权限：14项仍是正式FDR确认集；任意K对应展示子集，不新增FDR声明。深度生成的11项因生成器失败不采纳；配对MLP为0项。

2. 面向后续研究的模型方向

- 生成模型：优先尝试显式离散似然、条件normalizing flow或diffusion，减少事后边际校准，并预留独立测试集做交换性准入。
- 重要性模型：增加配对MLP重复数、样本分割与交叉拟合；继续用结构约束和数值测试保证反对称性。
- 预测模型：在更长企业面板上再比较TFT、N-BEATS等序列模型；当前19个月不宜强行上长序列架构。
- 因果方向：对履约、内容和价格策略开展A/B实验、准实验或双重机器学习，不能把预测发现直接当干预收益。

最重要的V3结论：用户可自主设置K；模型默认推荐K=10，测试RMSE相对全维变化-0.097%。统计确认与展示数量必须分层表达。

复现：随机种子20260823；PyTorch 2.8.0；面板SHA-256：7212bf462a8b23ba6455bed5fe7354481b43d3e3a0f633a13ced1a97c3046a1e；材料位于“论文/v1”“论文/v2”“论文/v3”。

核心文献：Candès et al. (2018)；Romano et al. (2020)；Spector & Janson (2022)；Ren & Barber (2024)；Shen et al. (2024)。