

# 面向电商GMV监控的可控错误发现维度选择研究

Olist可控参数维度选择精简介绍版（v3）

学校：【待填写】

学院：【待填写】

专业：【待填写】

研究生：【待填写】

指导教师：【待填写】

二〇二六年八月

# 目录

- 摘要
- 第1章 研究背景与问题
  - 1.1 研究背景
  - 1.2 研究问题
  - 1.3 研究思路
- 第2章 数据与研究设计
  - 2.1 数据来源与样本
  - 2.2 目标变量
  - 2.3 候选维度
  - 2.4 描述统计
- 第3章 方法
  - 3.1 Copula Model-X Knockoff
  - 3.2 竞争统计量与e-value
  - 3.3 预测与解释
  - 3.4 V2深度学习扩展
  - 3.5 V3参数化选择规则
- 第4章 核心实证结果
  - 4.1 Knockoff生成质量
  - 4.2 主变量选择
  - 4.3 阈值与时间稳健性
  - 4.4 时间外预测
  - 4.5 深度重要性与事后路径
  - 4.6 V3可调维度路径
  - 4.7 SHAP与固定效应
  - 4.8 模拟校准的边界
- 第5章 看板应用建议
  - 5.1 三级维度治理
  - 5.2 展示方式
  - 5.3 从预测到实验
- 第6章 结论与局限
  - 6.1 主要结论
  - 6.2 研究贡献

- 6.3 主要局限
  - 6.4 后续方向
- 参考文献
- 版本说明

## 摘要

电商经营看板通常同时包含价格、交易规模、供给、支付、履约、口碑、地域和营销等大量维度。若仅依据相关系数、单变量显著性或机器学习重要性筛选字段，容易把高度相关的代理变量重复当作独立发现，也无法约束入选指标中的假发现比例。本文使用 Olist 巴西电商公开数据，构建卖家-月份面板，并以次月  $\log(1+GMV)$  为目标，研究哪些本月经度在控制其他候选信息后仍具有增量预测价值。

研究在各原始表的自然粒度上先聚合再连接，避免商品明细、支付和评价多对多连接造成 GMV 重复计算。最终样本覆盖 2017-01 至 2018-07，包含 14,677 个卖家-月、2,793 个卖家和 19 个月，已送达商品 GMV 合计 12.342 百万巴西雷亚尔。共构造 32 个候选维度，其中申报月收入因零方差排除，31 个变量进入分析。

方法上，本文采用随机化秩高斯 Copula、Ledoit-Wolf 收缩协方差和 MVR 二阶 Model-X Knockoff，并以 Lasso 真变量与仿制变量系数差构造统计量。主分析重复生成 60 组 Knockoff，设置最终  $\alpha_{eBH}=0.20$ 、单轮  $\alpha_{kn}=0.10$ ，通过 e-value 聚合与 e-BH 控制错误发现率。结果显示，Copula 生成器平均边际 KS 距离为 0.013，显著低于原始高斯基线的 0.200。严格 e-BH 入选 14 个维度：成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度、平均商品高度、卖家所在州频率、平均商品描述长度、平均下单至送达天数。

V2 进一步实跑噪声条件深度 Knockoff、配对竞争 MLP 和残差表格 MLP。深度生成器边际校准后的平均 KS 为 0.016，但 swap 分类器 AUC 为 0.922，未通过预设联合交换性门槛，因此该分支不作 FDR 声明。配对 MLP 的反对称性最大误差为  $0.000e+00$ ；残差 MLP 的时间外 RMSE 为 2.414。V2 由此把深度生成、生成诊断、深度重要性和预测验证分开，保留失败结果而不扩大结论。

V3 不改变上述 14 项正式发现，而是增加参数  $K \in [1, 14]$ ：在确认集内按验证集 TreeSHAP 贡献排序，用户选择前  $K$  项。系统提供  $K=4$  极简、 $K=8$  均衡、 $K=14$  完整等档位，并按“累计贡献  $\geq 90\%$ 、验证 RMSE 距最优  $\leq 0.5\%$ ”推荐默认  $K=10$ 。默认模型测试 RMSE 为 2.385，相对全维模型变化 -0.097%。

时间外测试中，最佳模型为 XGBoost，对数尺度 RMSE 为 2.388，较直接使用本月 GMV 的朴素基线下降 17.5%。SHAP 结果与 Knockoff 在交易规模、价格、履约和市场覆盖维度形成交叉证据。本文据此提出“一级监控、二级诊断、专题分析”的看板分层方案，同时强调所有结果属于条件预测关系，不直接代表因果效应。

关键词： 电商 GMV；Model-X Knockoff；错误发现率；可控参数；维度选择路径；XGBoost

# 第1章 研究背景与问题

## 1.1 研究背景

数字平台能够完整记录订单、商品、顾客、支付、履约和评价过程，但指标数量也会随业务扩张持续增加。一个 GMV 看板可能同时展示订单数、件数、顾客数、均价、运费、品类、支付方式、物流时长、评价和地域覆盖。大量字段并列展示会产生三类问题：

1. 订单数、件数和顾客数等高度相关变量重复表达经营规模；
2. 逐项显著性检验会随候选变量增多而累积误报；
3. 机器学习重要性可以排序，却不能直接说明入选集合中可能有多少错误发现。

错误发现率（False Discovery Rate, FDR）定义为全部发现中错误发现比例的期望：

$$\text{FDR} = \mathbb{E} \left[ \frac{V}{R \vee 1} \right],$$

其中  $V$  是错误发现数， $R$  是总发现数。FDR 允许在整体错误比例受控的前提下保留较多有效信号，适合需要兼顾探索效率与结果可信度的指标治理。

## 1.2 研究问题

本文的核心问题是：在本月可观测的卖家经营信息中，哪些维度在控制其余候选变量后，仍包含次月 GMV 的增量预测信息，并值得进入常驻看板？

相应的 Model-X 零假设为：

$$H_{0j}: Y_{s,t+1} \perp X_{j,s,t} \mid X_{-j,s,t}.$$

拒绝零假设表示变量具有条件预测信息，不表示人为改变该变量一定会改变 GMV。全文将预测发现、机器学习解释和因果结论严格区分。

## 1.3 研究思路

研究包括四个步骤：

1. 在订单、商品明细、支付、评价、地理和营销等自然粒度上分别聚合，构造卖家-月面板；
2. 使用 Copula-MVR Model-X Knockoff 生成负对照变量，通过重复 Knockoff 和 e-BH 控制 FDR；
3. 使用 Ridge、Lasso、Extra Trees、XGBoost 和 MLP 进行自然时间外预测；
4. 结合 SHAP、双向固定效应和稳健性分析，将结果转化为看板分层建议。

## 第2章 数据与研究设计

### 2.1 数据来源与样本

数据来自 Olist Brazilian E-Commerce Public Dataset 和 Marketing Funnel by Olist，共使用订单、商品明细、支付、评价、商品、卖家、顾客、地理、品类翻译及营销漏斗 11 张 CSV。原始订单为 99,441 笔，商品明细为 112,650 行；主分析只保留已送达订单。

支付表和评价表可能一单多行，不能直接与商品明细连接。本文先把支付方式、支付金额和评价聚合到订单级，再聚合到卖家-月；地理表先按邮编前缀取经纬度中位数；商品明细按卖家-月汇总 GMV、价格、运费和商品属性。该流程使处理后 GMV 与原始已送达商品明细逐笔对账一致。

顾客数量使用 `customer_unique_id` 去重，而非订单级 `customer_id`。不合理的负物流时长和明显超界时间设为缺失，随后在模型训练样本中以中位数插补。

最终面板包含 14,677 个卖家-月、2,793 个卖家和 19 个月。样本 GMV 为 12.342 百万雷亚尔，次月零成交观测占 25.86%。




图2-1 Olist主分析期月度GMV

### 2.2 目标变量

主目标定义为：

$$Y_{s,t+1} = \log(1 + \text{GMV}_{s,t+1}).$$

若卖家本月有交易而次月没有已送达订单，则次月 GMV 记为零。使用次月目标可以避免同月件数、订单数和均价对同月 GMV 的机械解释，更符合经营预警场景。

## 2.3 候选维度

32 个候选维度覆盖以下类别：

- 价格与运费：平均商品价格、平均运费；
- 商品结构：重量、长宽高、图片数、标题和描述长度；
- 支付：分期数、支付序列数及四类支付方式占比；
- 口碑与履约：评价、审核时长、承运时长、送达时长和预计提前量；
- 经营规模：件数、订单数、品类数和独立顾客数；
- 地域覆盖：买家州数量、第一大州占比、跨州比例和平均距离；
- 卖家与营销：卖家州频率、营销来源及是否匹配营销成交。

申报月收入在分析面板中恒为零，因此在查看响应结果前按零方差规则排除，最终 31 个变量进入模型。最大特征缺失率为 1.49%。

## 2.4 描述统计

表2-1 关键变量描述统计

| 变量        | N     | 缺失率   | 均值      | 标准差     | 中位数     | Spearman相关 |
|-----------|-------|-------|---------|---------|---------|------------|
| 平均商品价格    | 14677 | 0.00% | 158.080 | 258.195 | 90.256  | 0.201      |
| 平均运费      | 14677 | 0.00% | 22.586  | 18.367  | 17.696  | 0.094      |
| 平均评价得分    | 14653 | 0.16% | 4.162   | 0.960   | 4.400   | -0.121     |
| 平均下单至送达天数 | 14674 | 0.02% | 12.748  | 8.174   | 11.262  | 0.074      |
| 平均审核至承运天数 | 14600 | 0.52% | 3.015   | 3.431   | 2.032   | -0.018     |
| 成交件数      | 14677 | 0.00% | 7.000   | 14.798  | 3.000   | 0.550      |
| 成交订单数     | 14677 | 0.00% | 6.206   | 12.948  | 2.000   | 0.572      |
| 活跃品类数     | 14677 | 0.00% | 1.480   | 1.114   | 1.000   | 0.331      |
| 独立顾客数     | 14677 | 0.00% | 6.173   | 12.850  | 2.000   | 0.572      |
| 买家州数量     | 14677 | 0.00% | 2.959   | 2.747   | 2.000   | 0.551      |
| 跨州交易占比    | 14677 | 0.00% | 0.674   | 0.357   | 0.750   | -0.081     |
| 平均卖家-买家距离 | 14617 | 0.41% | 626.901 | 460.658 | 534.101 | 0.088      |

边际相关显示，订单数、独立顾客数、件数和市场覆盖与次月 GMV 相关较高，但边际相关不能区分独立信息与相关代理，因此只作为描述。

## 第3章 方法

### 3.1 Copula Model-X Knockoff

Model-X Knockoff 为每个真实变量  $X_j$  构造仿制变量  $\tilde{X}_j$ 。理想仿制变量满足成对可交换性，并在给定真实特征后不再包含响应信息：

$$(X, \tilde{X})_{\text{swap}(S)} \stackrel{d}{=} (X, \tilde{X}), \quad \tilde{X} \perp Y | X.$$

Olist 变量同时包含金额、计数、比例、二元值和大量并列值。本文先对连续变量进行 1% 与 99% 分位缩尾、偏态变换、中位数插补和标准化，再使用固定随机种子打散并列秩，并映射为近似标准正态：

$$Z_{ij} = \Phi^{-1}\left(\frac{r_{ij} - 0.5}{n}\right).$$

随后使用 Ledoit-Wolf 收缩协方差与 MVR 准则生成二阶 Knockoff。与直接假定原始变量服从高斯分布相比，Copula 方法更适合混合边际，同时保留了明确的诊断指标。

### 3.2 竞争统计量与e-value

将真实变量和仿制变量共同输入 Lasso，构造：

$$W_j = |\hat{\beta}_j| - |\hat{\beta}_{j+p}|.$$

若真实变量显著胜过仿制变量， $W_j$  较大且为正。每次 Knockoff 按  $\alpha_{\text{kn}}=0.10$  计算 Knockoff+ 阈值，并转换为 e-value：

$$e_j^{(m)} = p \frac{\mathbf{1}\{W_j^{(m)} \geq T^{(m)}\}}{1 + \sum_k \mathbf{1}\{W_k^{(m)} \leq -T^{(m)}\}}.$$

主分析重复 60 次，对 e-value 取平均后，在  $\alpha_{\text{eBH}}=0.20$  下实施 e-BH。最终 FDR 水平与单轮阈值分开设置，遵循去随机化 Knockoff 的推荐方案。

本文还报告单轮入选频率。严格 e-BH 集合承担 FDR 声明，频率至少 90% 的集合只描述生成稳定性，二者不能混用。

### 3.3 预测与解释

按自然月份划分训练、验证和测试集：

- 训练期：2017-01 至 2017-12，7,199 行；
- 验证期：2018-01 至 2018-04，3,970 行；
- 测试期：2018-05 至 2018-07，3,508 行。

比较模型包括朴素本月 GMV、Ridge、Lasso、Extra Trees、XGBoost、MLP 以及只使用测试期前 Knockoff 入选变量的 XGBoost。评价指标为对数 RMSE、MAE、 $R^2$  和原始金

额 WAPE。XGBoost 使用 TreeSHAP 解释测试期预测。

由于单卖家最多只有 19 个特征月份，且多数序列更短，本文没有强行使用参数量较大的 TFT，而使用 XGBoost、传统 MLP 和残差表格 MLP 完成非线性 AI 验证。

### 3.4 V2深度学习扩展

深度生成器以真实特征和同维高斯噪声为输入，使用 4 层宽度 192 的 LayerNorm-GELU 网络生成仿制变量。训练损失联合 20%、50%、80% swap 比例的混合 RBF-MMD、边际、协方差、交叉协方差和可重构性。保留集同时报告 KS、覆盖率、相关误差、MMD permutation test 与分类器两样本检验。

配对竞争 MLP 使用对称输入层和共享下游范数构造  $W_j$ ，保证交换  $(X_j, \tilde{X}_j)$  后统计量变号；正式实验重复 20 次。预测分支新增 3 个残差块的 PyTorch 表格 MLP，与 V1 模型使用完全相同的自然月份切分。

### 3.5 V3参数化选择规则

第一阶段保留 FDR 0.20 下的14项确认池；第二阶段按训练期模型在验证集上的SHAP 贡献排序；第三阶段由参数K截取前K项。测试集不参与排序或默认K选择。参数K控制展示长度，不被表述为新的FDR结果。

## 第4章 核心实证结果

### 4.1 Knockoff生成质量

Copula 生成器的平均边际 KS 距离为 0.013，最大值为 0.037，协方差相对误差为 0.027，交叉协方差非对称度为 0.033。原始高斯基线平均边际 KS 为 0.200。Copula 的边际误差明显较小，因此主结果采用 Copula-MVR。

表4-1 V2多指标生成诊断

| 方法              | 平均KS  | 协方差误差 | 交叉非对称 | 平均真伪相关 | 90%覆盖率 | swap分类AUC |
|-----------------|-------|-------|-------|--------|--------|-----------|
| Copula-MVR      | 0.026 | 0.081 | 0.094 | 0.512  | 89.8%  | 0.788     |
| 原始高斯-MVR        | 0.200 | 0.072 | 0.080 | 0.700  | 92.7%  | 0.973     |
| 深度生成器<br>(原始)   | 0.212 | 0.105 | 0.145 | 0.508  | 92.0%  | 0.990     |
| 深度生成器<br>(边际校准) | 0.016 | 0.160 | 0.187 | 0.555  | 93.9%  | 0.922     |

表中统一采用 V2 的 20% 验证子集，故 Copula KS 与 V1 全样本口径略有差异。深度生成器的平均 KS 经校准降至 0.016，但协方差误差为 0.160、swap 分类器 AUC 为 0.922。按预设规则判定为“未通过预设联合交换性诊断，不作FDR声明”。这说明边际一致不能替代联合交换性。

### 4.2 主变量选择

在  $\alpha_{eBH}=0.20$ 、 $\alpha_{kn}=0.10$  下，严格入选 14 个变量：成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度、平均商品高度、卖家所在州频率、平均商品描述长度、平均下单至送达天数。

表4-2 严格c-BH入选变量

| 变量         | 平均W   | 单轮入选频率 | 平均e-value |
|------------|-------|--------|-----------|
| 成交订单数      | 0.144 | 95.0%  | 28.675    |
| 平均商品价格     | 0.142 | 95.0%  | 28.675    |
| 独立顾客数      | 0.140 | 95.0%  | 28.675    |
| 成交件数       | 0.117 | 95.0%  | 28.675    |
| 买家州数量      | 0.097 | 95.0%  | 28.675    |
| 平均审核至承运天数  | 0.053 | 95.0%  | 28.675    |
| 平均运费       | 0.027 | 95.0%  | 28.675    |
| 活跃品类数      | 0.023 | 95.0%  | 28.675    |
| 平均预计提前送达天数 | 0.021 | 95.0%  | 28.675    |
| 平均商品标题长度   | 0.022 | 91.7%  | 27.642    |
| 平均商品高度     | 0.013 | 80.0%  | 24.025    |
| 卖家所在州频率    | 0.014 | 76.7%  | 22.992    |
| 平均商品描述长度   | 0.009 | 50.0%  | 14.725    |
| 平均下单至送达天数  | 0.007 | 41.7%  | 12.142    |

其中 10 个变量的单轮入选频率达到至少 90%：成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度。严格集合与稳定集合可能不同，因为 c-BH 使用每轮负向统计量数量加权，而 90% 频率只是人为设置的描述阈值。




图4-1 主分析平均e-value

严格变量可归为四组：

1. 经营规模：订单数、件数、独立顾客数、活跃品类数；
2. 价格成本：平均商品价格、平均运费；
3. 履约：审核至承运、下单至送达和预计提前量；
4. 商品与覆盖：标题、描述、商品高度、买家州数量和卖家州频率。

这些结果表明，次月 GMV 既有经营规模延续，也包含价格带、履约状态、商品结构和市场覆盖的条件信息。

## 4.3 阈值与时间稳健性

表4-3 不同FDR水平的严格结果

| 最终FDR水平   | 单轮水平 | 严格入选数 | 严格入选变量                                                                                                                            |
|-----------|------|-------|-----------------------------------------------------------------------------------------------------------------------------------|
| 0.10      | 0.05 | 0     | 无                                                                                                                                 |
| 0.20（主分析） | 0.10 | 14    | 成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度、平均商品高度、卖家所在州频率、平均商品描述长度、平均下单至送达天数                          |
| 0.30      | 0.15 | 17    | 平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均商品描述长度、平均支付序列数、借记卡支付占比、平均下单至送达天数、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、第一大买家州占比、卖家所在州频率 |

在更严格的 0.10 水平下，严格发现为 0 项；在 0.30 水平下为 17 项。测试期开始前样本独立选出的 12 个变量为：平均商品价格、平均商品标题长度、平均商品描述长度、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、第一大买家州占比、卖家所在州频率。该集合用于精简 XGBoost，避免测试数据进入变量筛选。

## 4.4 时间外预测

表4-4 时间外测试性能

| 模型                        | 测试N  | RMSE(log) | MAE(log) | R2     | WAPE  |
|---------------------------|------|-----------|----------|--------|-------|
| XGBoost                   | 3508 | 2.388     | 1.914    | 0.291  | 67.2% |
| Ridge                     | 3508 | 2.389     | 1.949    | 0.291  | 73.1% |
| Lasso                     | 3508 | 2.389     | 1.949    | 0.290  | 73.1% |
| ExtraTrees                | 3508 | 2.390     | 1.914    | 0.290  | 65.9% |
| XGBoost-Knockoff-selected | 3508 | 2.391     | 1.914    | 0.289  | 67.2% |
| MLP                       | 3508 | 2.429     | 1.947    | 0.267  | 74.5% |
| Naive-current-GMV         | 3508 | 2.895     | 1.981    | -0.042 | 79.2% |
| PyTorch-Residual-MLP      | 3508 | 2.414     | 1.927    | 0.276  | 71.8% |

最佳模型为 XGBoost，测试集对数 RMSE 为 2.388、 $R^2$  为 0.291。残差 MLP 的 RMSE 为 2.414、 $R^2$  为 0.276，较 XGBoost 高 1.1%，未形成预测增益。复杂模型没有形成压倒性优势。




图4-2 V2时间外预测模型比较

## 4.5 深度重要性与事后路径

配对 MLP 的反对称性测试结论为“通过”，0.20 水平得到 0 项：无。它使用通过诊断的 Copula Knockoff，作为非线性稳健性证据，不替代预先指定的 Copula-Lasso 主结果。

固定 V1 的 60 轮 e-value 后，仅改变最终 e-BH 阈值得到：

| 最终e-BH水平 | 固定单轮水平 | 入选数 | 入选变量                                                                                                                      |
|----------|--------|-----|---------------------------------------------------------------------------------------------------------------------------|
| 0.05     | 0.100  | 0   | 无                                                                                                                         |
| 0.10     | 0.100  | 0   | 无                                                                                                                         |
| 0.15     | 0.100  | 12  | 平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、卖家所在州频率                                     |
| 0.20     | 0.100  | 14  | 平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均商品描述长度、平均下单至送达天数、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、卖家所在州频率                  |
| 0.25     | 0.100  | 15  | 平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均商品描述长度、平均下单至送达天数、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、第一大买家州占比、卖家所在州频率         |
| 0.30     | 0.100  | 16  | 平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均商品描述长度、平均支付序列数、平均下单至送达天数、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、第一大买家州占比、卖家所在州频率 |

| 最终c-BH水平 | 固定单轮水平 | 入选数 | 入选变量                                                                                                                              |
|----------|--------|-----|-----------------------------------------------------------------------------------------------------------------------------------|
| 0.35     | 0.100  | 17  | 平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均商品描述长度、平均支付序列数、借记卡支付占比、平均下单至送达天数、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、第一大买家州占比、卖家所在州频率 |
| 0.40     | 0.100  | 17  | 平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均商品描述长度、平均支付序列数、借记卡支付占比、平均下单至送达天数、平均审核至承运天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、第一大买家州占比、卖家所在州频率 |

## 4.6 V3可调维度路径

表4-5 默认K=10的维度及证据

| 排序 | 维度             | 单轮频率  | 平均e-value | 模型排名 | 贡献占比  | 累计贡献  | 入选依据                     |
|----|----------------|-------|-----------|------|-------|-------|--------------------------|
| 1  | 独立顾客数          | 95.0% | 28.675    | 1    | 30.0% | 30.0% | e-BH通过；<br>按验证SHAP<br>排序 |
| 2  | 成交订单数          | 95.0% | 28.675    | 2    | 20.8% | 50.8% | e-BH通过；<br>按验证SHAP<br>排序 |
| 3  | 平均商品价格         | 95.0% | 28.675    | 3    | 15.2% | 66.1% | e-BH通过；<br>按验证SHAP<br>排序 |
| 4  | 平均审核至<br>承运天数  | 95.0% | 28.675    | 4    | 6.0%  | 72.1% | e-BH通过；<br>按验证SHAP<br>排序 |
| 5  | 平均预计提前<br>送达天数 | 95.0% | 28.675    | 5    | 5.3%  | 77.4% | e-BH通过；<br>按验证SHAP<br>排序 |
| 6  | 买家州数量          | 95.0% | 28.675    | 6    | 3.5%  | 80.9% | e-BH通过；<br>按验证SHAP<br>排序 |
| 7  | 平均下单至<br>送达天数  | 41.7% | 12.142    | 7    | 3.4%  | 84.3% | e-BH通过；<br>按验证SHAP<br>排序 |
| 8  | 成交件数           | 95.0% | 28.675    | 8    | 2.8%  | 87.1% | e-BH通过；<br>按验证SHAP<br>排序 |
| 9  | 平均运费           | 95.0% | 28.675    | 9    | 2.8%  | 89.9% | e-BH通过；<br>按验证SHAP<br>排序 |
| 10 | 平均商品标题<br>长度   | 91.7% | 27.642    | 10   | 2.7%  | 92.6% | e-BH通过；<br>按验证SHAP<br>排序 |

默认维度为独立顾客数、成交订单数、平均商品价格、平均审核至承运天数、平均预计提前送达天数、买家州数量、平均下单至送达天数、成交件数、平均运费、平均商品标题长度。正式14项中未进入默认层的4项为平均商品高度、平均商品描述长度、活跃品类数、卖家所在州频率。

表4-6 K=4、8、默认值与14的选择路径

| 档位    | K  | 累计贡献   | 验证RMSE | 测试RMSE | 所选维度                                                                                                    |
|-------|----|--------|--------|--------|---------------------------------------------------------------------------------------------------------|
| 极简    | 4  | 72.1%  | 2.335  | 2.388  | 独立顾客数、成交订单数、平均商品价格、平均审核至承运天数                                                                            |
| 均衡    | 8  | 87.1%  | 2.341  | 2.389  | 独立顾客数、成交订单数、平均商品价格、平均审核至承运天数、平均预计提前送达天数、买家州数量、平均下单至送达天数、成件数                                             |
| 默认推荐  | 10 | 92.6%  | 2.343  | 2.385  | 独立顾客数、成交订单数、平均商品价格、平均审核至承运天数、平均预计提前送达天数、买家州数量、平均下单至送达天数、成件数、平均运费、平均商品标题长度                               |
| 完整确认集 | 14 | 100.0% | 2.343  | 2.384  | 独立顾客数、成交订单数、平均商品价格、平均审核至承运天数、平均预计提前送达天数、买家州数量、平均下单至送达天数、成件数、平均运费、平均商品标题长度、平均商品高度、平均商品描述长度、卖家所在州频率、活跃品类数 |

默认K=10的RMSE为2.385，全维模型为2.388，相对变化-0.097%。用户可根据页面容量选择K，不必重新调整FDR水平。

## 4.7 SHAP与固定效应

SHAP 前五项为成交订单数、独立顾客数、平均商品价格、平均审核至承运天数、买家州数量。Knockoff 严格集合与 SHAP 前十项的交集为成交订单数、平均商品价格、独立顾客数、买家州数量、平均审核至承运天数、平均运费、平均预计提前送达天数、平均商品标题长度、卖家所在州频率、平均商品描述长度，可作为优先监控候选；其余严格项目为成交件数、活跃品类数、平均商品高度、平均下单至送达天数，更适合二级诊断。




图4-3 XGBoost SHAP重要性

双向固定效应控制卖家和月份效应，标准误按卖家聚类。5% 水平显著的动态变量为平均审核至承运天数、Boleto支付占比、借记卡支付占比、信用卡支付占比。固定效应只能提供同一卖家随时间变化的关联证据，仍可能受到促销、曝光、库存和竞争等遗漏因素影响。

## 4.8 模拟校准的边界

模拟在真实特征矩阵上设置 5 个真信号。去随机化 e-BH 的平均 FDP 为 0.000、平均功效为 0.000；单轮 Knockoff+ 的平均 FDP 为 0.197、平均功效为 1.000。

聚合程序在该稀疏模拟中零功效，原因是  $p=31$ 、 $\alpha_{kn}=0.10$  时 Knockoff+ 存在离散门槛，只有 5 个真信号很难在不引入假发现的情况下达到阈值。这一结果说明方法在低维、极稀疏任务中可能保守。本文保留该不利结果，而不通过事后调参制造非空发现。

## 第5章 看板应用建议

### 5.1 三级维度治理

一级监控层默认采用K=10：独立顾客数、成交订单数、平均商品价格、平均审核至承运天数、平均预计提前送达天数、买家州数量、平均下单至送达天数、成交件数、平均运费、平均商品标题长度；也可切换K=4极简、K=8均衡或K=14完整。

二级诊断层包含确认集内未进入短名单的6项：平均商品高度、平均商品描述长度、活跃品类数、卖家所在州频率。

专题分析层包含未进入严格集合、但具有明确业务用途的支付、评价、距离和营销变量。未入选不等于永远无用，只表示在当前候选集和次月GMV目标下缺乏足够条件证据。

### 5.2 展示方式

看板不应把所有入选变量平铺成卡片，而应按经营问题组织：

- 交易规模模块：订单数、件数和独立顾客数；
- 价格成本模块：平均商品价格和平均运费；
- 履约模块：承运准备、送达时长和承诺偏差；
- 供给内容模块：品类数、标题与描述；
- 市场覆盖模块：买家州数量和地域基准。

每个模块保留一个主要状态指标和少量下钻指标，以减少代理变量重复展示。

### 5.3 从预测到实验

订单数和顾客数首先是经营状态变量，不能把“提高订单数”写成可执行因果建议。履约时长、商品内容和运费策略更接近可干预变量，但仍需A/B实验、分层实验或准实验确认。Knockoff的作用是缩小候选范围，不是替代因果识别。

## 第6章 结论与局限

### 6.1 主要结论

本文使用 Olist 全量公开数据构建了 14,677 个卖家-月观测，并以次月 GMV 为前瞻目标。随机化秩高斯 Copula 显著改善了混合变量的 Knockoff 边际匹配。主分析在最终 FDR 水平 0.20 下严格入选 14 个维度，覆盖经营规模、价格、履约、商品内容和市场覆盖。

时间外测试中，XGBoost 的 RMSE 为 2.388，较朴素基线改善 17.5%。Knockoff、SHAP、预测误差和固定效应构成互补证据，其中只有预先设定的 e-BH 程序承担 FDR 声明。

### 6.2 研究贡献

第一，将 FDR 控制引入电商看板维度治理。第二，采用自然粒度聚合和次月目标，规避多表膨胀与同月定义泄漏。第三，明确区分严格发现、深度生成准入、随机稳定性、预测解释和因果结论。第四，以反对称性测试约束深度重要性。第五，保留失败生成器、完整代码、每轮 W、结果表和随机种子，支持复核。

### 6.3 主要局限

1. 公开数据缺少曝光、广告、库存、促销和竞争强度；
2. 卖家-月面板存在同一卖家内部相关，标准 Model-X 独立条件只能近似满足；
3. Copula 二阶方法不能保证刻画全部高阶和尾部依赖，深度生成器则未通过联合交换性准入；
4. 只有 19 个特征月份，不适合复杂长序列深度模型；
5. 固定效应与 SHAP 不能替代随机实验；
6. 低维稀疏场景下 Knockoff+ 可能因离散阈值而功效不足。

### 6.4 后续方向

未来可在更长企业面板上使用滚动 Knockoff 和在线 e-value；按交易、履约、商品和地域定义 group knockoff；使用离散似然、normalizing flow 或 diffusion 改进深度生成；在更长序列中比较 TFT；对可行动变量开展实验和因果机器学习分析。

## 参考文献

- [1] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing[J]. Journal of the Royal Statistical Society: Series B, 1995, 57(1): 289-300.
- [2] Barber R F, Candès E J. Controlling the false discovery rate via knockoffs[J]. The Annals of Statistics, 2015, 43(5): 2055-2085.
- [3] Candès E, Fan Y, Janson L, Lv J. Panning for gold: Model-X knockoffs for high-dimensional controlled variable selection[J]. Journal of the Royal Statistical Society: Series B, 2018, 80(3): 551-577.
- [4] Romano Y, Sesia M, Candès E. Deep knockoffs[J]. Journal of the American Statistical Association, 2020, 115(532): 1861-1872.
- [5] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for false discovery rate control[J]. Journal of the Royal Statistical Society Series B, 2024, 86(1): 122-154.
- [6] Wang R, Ramdas A. False discovery rate control with e-values[J]. Journal of the Royal Statistical Society Series B, 2022, 84(3): 822-852.
- [7] Tibshirani R. Regression shrinkage and selection via the lasso[J]. Journal of the Royal Statistical Society: Series B, 1996, 58(1): 267-288.
- [8] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. Journal of Multivariate Analysis, 2004, 88(2): 365-411.
- [9] Spector A, Janson L. Powerful knockoffs via minimizing reconstructability[J]. The Annals of Statistics, 2022, 50(1): 252-276.
- [10] Breiman L. Random forests[J]. Machine Learning, 2001, 45: 5-32.
- [11] Chen T, Guestrin C. XGBoost: a scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016: 785-794.
- [12] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]//Advances in Neural Information Processing Systems. 2017, 30.
- [13] Lim B, Arik S Ö, Loeff N, Pfister T. Temporal fusion transformers for interpretable multi-horizon time series forecasting[J]. International Journal of Forecasting, 2021, 37(4): 1748-1764.
- [14] Wooldridge J M. Econometric analysis of cross section and panel data[M]. 2nd ed. Cambridge, MA: MIT Press, 2010.
- [15] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle, 2018.

- [16] Olist. Marketing Funnel by Olist[DB/OL]. Kaggle, 2018.
- [17] Sudarshan M, Tansey W, Ranganath R. Deep direct likelihood knockoffs[C]//NeurIPS. 2020.
- [18] Shen A, Yan Y, Zhao P. Deep dependency regularized knockoff for controlling false discovery rates[C]//ICLR. 2024.
- [19] Hollmann N, Müller S, Purucker L, et al. Accurate predictions on small data with a tabular foundation model[J]. Nature, 2025, 637(8045): 319-326.

## 版本说明

本文件为 v3 精简介绍版。V3 完整继承 V1/V2 结果，并新增K=1至14的选择路径、模型默认K和各档真实时间外预测。