

Olist电商GMV维度选择研究

v4 极限精简版 · 聚类、组级、深度核与轨迹重要性

一、保留主线与V4升级目标

不推倒V3：仍以32项构造、31项建模、Copula-MVR + Lasso + 60轮 ϵ -value、FDR 0.20下14项确认集为主线；默认K=10仍用于展示。V4只针对已知软肋增加稳健性和诊断。

14,677 卖家-月	2,793 卖家	19 月份	14 主线确认维度
-----------------------	--------------------	-----------------	---------------------

1. V3五个软肋与V4对应方法

软肋	V4方法	作用
卖家-月组内相关	卖家均值/离差分层Knockoff	区分跨卖家与卖家内信号
共线代理稀释	十二业务组Group Knockoff	在业务组层控制FDR
深度生成联合失败	DDLK式最坏swap目标	直接攻击最坏交换子集
固定MMD功效不足	训练/检验分离的深度核MMD	提高两样本检验功效
配对MLP功效为0	GRIP2式二维正则轨迹积分	聚合不同正则几何

2. 两处严谨性修正

- 经验边际校准只在生成器80%训练子集拟合，再应用到验证集。
- 深度核199次置换的p值下限为0.005；分类器99次置换下限为0.010，按离散分辨率解释。

结论权限：新增分支均为稳健性/诊断；只有原Copula-Lasso主线承担0.20 FDR声明。

二、聚类分层与组级Knockoff

1. 卖家均值一离差分解

$$X_{st} = \bar{X}_s + (X_{st} - \bar{X}_s)$$

卖家间层使用2,793个卖家均值；卖家内层使用14,677行离差并排除零方差静态项。两个层级分别构造Copula-MVR并重复40轮。

层级	q=.20严格数	严格集合
卖家间均值层	16	平均商品价格、平均运费、平均商品标题长度、平均支付序列数、代金券支付占比、借记卡支付占比、平均下单至送达天数、平均下单至审核天数、平均预计提前送达天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、跨州交易占比、平均卖家-买家距离
卖家内离差层	0	无

0.20水平：卖家间层16项，卖家内层0项。主信号主要来自卖家长期经营位置差异。

2. 十二业务组

交易与商品

价格成本、商品物理、商品内容、交易规模

履约与市场

履约、市场集中度、市场覆盖

支付与口碑

支付过程、支付方式、口碑

卖家侧

卖家地域、营销

最终水平	严格组数	业务组
0.20	0	无
0.30	10	价格成本、商品物理属性、商品内容、支付过程、支付方式、履约、交易规模、市场集中度、市场覆盖、卖家地域

仅12组时，0.20水平Knockoff+离散门槛较强而无严格发现；0.30水平出现10组：价格成本、商品物理属性、商品内容、支付过程、支付方式、履约、交易规模、市场集中度、市场覆盖、卖家地域。

逐变量结果回答“哪个指标”，组级结果回答“哪类信息”；0.30组级结果属于更宽松敏感性分析。

三、最坏swap生成与深度核诊断

1. DDLK式最坏交换目标

每批次用Gumbel-logistic软掩码搜索可区分性最大的swap子集，生成器最小化最坏swap-MMD、边际、协方差、交叉对称与可重构性损失。边际映射仅用训练子集拟合。

2. 三类生成器诊断

方法	平均KS	深度核拒绝率	分类AUC
Copula-MVR	0.026	0%	0.777
V2深度（训练校准）	0.018	100%	0.902
V4最坏swap	0.019	100%	0.937

- Copula-MVR：深度核MMD在5个比例均不拒绝；分类器AUC均值0.777。
- V2训练集校准：平均KS 0.018，深度核5/5拒绝，AUC 0.902。
- V4最坏swap：平均KS 0.019，深度核5/5拒绝，AUC 0.937。

V4最坏swap生成器结论：未通过，不作FDR声明。

3. 诊断矛盾如何收口

固定RBF-MMD对V2/V4深度分支仍多不拒绝；学习核后全部比例拒绝，并与分类器一致。说明V3的矛盾来自固定核功效不足，而不是分类器“误报”。

检验	置换数	最小p值	论文写法
RBF/深度核MMD	199	0.005	≤ 0.005
分类器标签置换	99	0.010	≤ 0.010

深度分支形式上选出的维度为平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均下单至送达天数、平均审核至承运天数、平均预计提前送达天数、成文件数、活跃品类数、独立顾客数、第一大买家州占比，但生成器准入失败，因此全部只作诊断。

四、GRIP2式轨迹重要性与V3参数K

1. 二维正则轨迹聚合

$$W_j = \text{mean}_t \lambda(|a_j|d_j - |\tilde{a}_j|d_j)$$

在4个L1强度×4个组正则强度上循环采样，沿优化轨迹累计配对第一层活跃度。20轮Copula Knockoff独立训练；交换测试最大误差0.000e+00。

维度	平均W	q=.20频率	q=.30入选
平均商品价格	0.708	20%	是
平均审核至承运天数	0.345	20%	是
独立顾客数	0.302	20%	是
成交订单数	0.250	20%	是
成交件数	0.235	20%	是
平均商品标题长度	0.226	20%	否
买家州数量	0.114	10%	否
卖家所在州频率	0.103	20%	否
平均预计提前送达天数	0.098	10%	否
平均支付序列数	0.088	10%	否

GRIP2式结果：0.20水平0项；0.30水平5项——平均商品价格、平均审核至承运天数、成交件数、成交订单数、独立顾客数。

2. 与V2配对MLP比较

方法	反对称	q=0.20	q=0.30
V2单正则配对MLP	通过	0项	0项
V4轨迹聚合	通过	0项	5项

3. 参数K保持不变

V3的 $K \in [1,14]$ 展示路径继续保留：K=4极简、K=8均衡、默认K=10、K=14完整。V4新增方法未获得足够主水平证据，因此不改写排序池。

轨迹聚合提高了0.30水平功效，但主水平0.20仍无发现，不能包装为“深度方法已胜出”。

五、V4结论与答辩口径

V4没有推翻14项确认集，也没有放宽深度准入；其贡献是把组内相关、共线代理和诊断功效从“局限”升级为真实实验。

1. 结果权限总表

层级	真实结果	可作何种结论
V1确认主线	q=0.20严格14项	唯一正式逐变量FDR集合
聚类分层	between 16； within 0	主信号层级来源
组级Knockoff	q=.20为0组； q=.30为10组	业务模块敏感性
最坏swap生成	深度核与分类器均拒绝	不作FDR声明
GRIP2式重要性	q=.20为0项； q=.30为5项	非线性敏感性
参数K	默认K=10，RMSE 2.385	只控制展示数量

2. 关键解释

- 卖家内层0项说明当前数据更适合跨卖家风险分层，不足以支持卖家自身短期变化的严格发现。
- 组级0.20无发现不等于业务组无信息，而是12组与Knockoff+“+1”项造成离散门槛。
- 最坏swap训练没有通过准入，证明更强训练目标仍不能替代独立诊断。
- 深度核与分类器的一致拒绝，使联合交换性判据比V3更自治。

最终建议：继续使用V1确认集和V3参数K；V4聚类、组级和深度结果作为稳健性标签。若获得更长面板，再重点验证卖家内动态与在线e-value。

复现：随机种子20260823；PyTorch 2.8.0；面板SHA-256：7212bf462a8b23ba6455bed5fe7354481b43d3e3a0f633a13ced1a97c3046a1e；结果位于“论文/v4/results”。

新增文献：Bacci et al. (2026) clustered knockoffs；Liu et al. (2020) deep-kernel MMD；Dai & Barber (2016) group knockoff。