

电商GMV多粒度受控维度选择研究

方法与结果摘要 · 统一基准、组件消融与多粒度稳健性

一、问题、数据与粒度决策

研究问题：在31个候选经营维度中，筛选对下一期GMV仍有增量预测信息的少数指标，并控制入选集合的预期误选比例。

31 实际建模维度	14 月度q=.20确认项	33,190 卖家-周观测	11 月周共同项
---------------------	-------------------------	-------------------------	--------------------

1. 原始数据与面板构造

使用Olist订单、商品明细、支付、评价、商品、卖家、顾客、地理和营销漏斗全量CSV。支付与评价先聚合至订单级，再与商品明细连接，避免多对多连接造成GMV膨胀；独立顾客按customer_unique_id去重。

口径	面板行	期间数	下一期零值率	严格入选
月度主分析	14,677	19月	25.9%	14项
周度稳健性	33,190	83周	40.5%	18项

2. 为什么仍以月度为主

- 月度单元汇集更多订单，零成交率25.86%，较适合大量低频卖家。
- 周度时间点更多，但下一周零成交率40.5%，单订单周和共线代理更多。
- 日度会进一步放大零膨胀、星期效应和偶发订单噪声，不适合作为本数据主线。

结论：月度承担确认性主分析；周度只检验结论是否依赖时间聚合粒度。

二、月周统一统计流程

1. 前瞻目标

$$Y_{s,t+1} = \log(1 + GMV_{s,t+1})$$

用本月预测次月、用本周预测下一周。若当前期活跃而下一期无已送达订单，则目标标记为零。同月GMV只作为机械关系对照，不作为主目标。

2. Model-X Knockoff

1. 1%/99%缩尾、偏态变换、中位数插补与标准化；
2. 随机化秩高斯Copula处理连续、计数、比例、二元及并列值；
3. Ledoit-Wolf协方差与MVR准则生成每个变量的负对照；
4. Lasso真实/仿制系数竞争： $W_j = |\beta_j| - |\hat{\beta}_j|$ ；
5. 重复60轮，聚合e-value后用e-BH控制最终FDR。

$$\alpha_{kn}=0.10; \alpha_{eBH}=0.20; \text{重复} M=60$$

3. 周度完整重跑内容

生成与目标

Copula、高斯、同周GMV、下一周AOV、截尾期

结构稳健性

卖家间/内、12业务组、GRIP2式轨迹

模型统计量

Lasso与XGBoost Knockoff

外推验证

Ridge、Lasso、Extra Trees、XGBoost、MLP

4. 推断边界

Knockoff拒绝的是“给定其余维度后不再含预测信息”的条件零假设，不代表因果效应。周度分析采用最终已送达订单按购买周回溯归属；物流和评价在周末未必可见，因此不是严格在线部署模拟。

参数K基于月度14项确认池：K=4极简、K=8均衡、默认K=10、K=14完整。周度18项不改变该确认池。

三、月度与周度选择结果

1. 周度主分析

Copula平均边际KS=0.012，明显低于原始高斯0.234。q=.10为0项；q=.20入选18项，其中13项的单轮频率至少90%。

周度18项：平均商品价格、平均运费、平均商品重量、平均商品高度、平均商品宽度、平均商品图片数、平均商品标题长度、Boleto支付占比、平均审核至承运天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、第一大买家州占比、卖家所在州频率、营销来源频率、是否匹配营销成交线索

2. 跨粒度交集

类别	数量	变量
月周共同	11	平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均审核至承运天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、卖家所在州频率
仅月度	3	平均商品描述长度、平均下单至送达天数、平均预计提前送达天数
仅周度	7	平均商品重量、平均商品宽度、平均商品图片数、Boleto支付占比、第一大买家州占比、营销来源频率、是否匹配营销成交线索

跨粒度核心11项：平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均审核至承运天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、卖家所在州频率

进一步满足周度频率≥90%的10项：平均商品价格、平均运费、平均商品标题长度、平均审核至承运天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、卖家所在州频率。

3. 差异如何解释

- 月度特有3项：平均商品描述长度、平均下单至送达天数、平均预计提前送达天数，更偏慢变化的履约和内容信号。
- 周度特有7项：平均商品重量、平均商品宽度、平均商品图片数、Boleto支付占比、第一大买家州占比、营销来源频率、是否匹配营销成交线索，更易受单周商品组合、支付和营销构成波动影响。
- Jaccard=0.524代表中等重合，不支持“两个粒度完全相同”，也不支持“月度结论失效”。

18项是周度条件下的稳健性集合；论文正式确认集为月度14项，默认展示使用月度K=10。

四、统一基准、消融与已知真值模拟

1. 相同12项预算的真实数据比较

方法	主集重合	稳定性	RMSE
去随机化Knockoff	12/12	0.855	2.392
Elastic Net	10/12	0.873	2.390
稳定性选择	10/12	0.814	2.390
影子变量树模型	10/12	0.832	2.387
XGBoost-SHAP	8/12	0.686	2.383

所有方法只用测试期前数据选维，再输入同一XGBoost。XGBoost-SHAP的RMSE=2.383最低；去随机化Knockoff为2.392。30组相同70%卖家子样本下，Elastic Net与Knockoff的平均稳定性分别为0.873和0.855，差异区间包含0。预测最优与稳定受控准入不是同一目标。

2. 关键组件消融

设定	M	严格数	主集Jaccard
equicorrelated	30	12	0.857
M=1	1	12	0.857
M=60	60	14	1.000
原始高斯-MVR-Lasso	40	12	0.733
Copula-MVR-XGBoost	25	0	0.000

只有M=60与正式14项集合完全一致；原始高斯、替代S矩阵和XGBoost竞争统计量均改变结果，说明组件选择具有可测量影响。

3. 20轮已知真值模拟

方法	平均FDP	FDP>.20	Power
去随机化Knockoff	0.054	10%	1.000
单次Knockoff	0.145	35%	1.000
Elastic Net	0.644	100%	1.000
稳定性选择	0.090	5%	1.000
影子变量树模型	0.566	100%	1.000

去随机化Knockoff平均FDP=0.054，低于单次Knockoff的0.145；二者Power均为1.000。稳定性选择表现较好，但不具有相同的Model-X有限样本目标保证。

五、研究结论与论文口径

结论不是“Knockoff所有指标最优”，而是其预测误差接近最优、统一子抽样稳定性与Elastic Net相近，并提供明确FDR目标解释；周度结果进一步限定了跨粒度适用范围。

1. 最终证据分层

层级	结果	用途
月度确认层	q=.20严格14项	论文正式逐变量集合
参数展示层	默认K=10	控制首页维度数量
跨粒度核心	11项	月周共同证据
周度稳健层	q=.20严格18项	短期监测候选
卖家内动态	月度与周度均0项	不作严格动态声明
公平基准层	12项统一预算	区分预测、稳定与FDR

2. 实际看板建议

- 月度首页继续使用K参数，默认K=10；季度滚动复核FDR集合。
- 周度预警优先展示跨粒度且周度高稳定的10项，不把7项周度特有变量直接升级。
- 订单数、件数、顾客数属于状态变量；履约、内容、价格等可行动项仍需实验确认。
- 上线前按真实可见时间重构物流和评价特征，并进行滚动时间外回测。

3. 核心限制

Olist仅覆盖约19个月；面板存在组内相关；Copula只近似高阶联合分布；20轮模拟和基线阈值不足以建立普遍方法排序；所有结果属于预测关联而非因果识别。

答辩一句话：统一基准说明SHAP预测略优，Elastic Net与Knockoff的样本稳定性相近；Knockoff的额外价值是目标FDR解释，消融与模拟则说明各组件的作用和边界。

复现：随机种子20260823；周度面板SHA-256：bef6bd6f902d076de1e3dcda5234acf02163ba8d650e34c43b2d7972b22a48ff；完整计算保留每轮统计量和机器可读结果。
文稿：2026年9月；完整论文包含方法推导、实证分析、稳健性检验和研究边界。