

基于去随机化Model-X Knockoff的电商 GMV多粒度受控维度选择研究

去随机化Model-X Knockoff、参数化展示与周度稳健性

学校：【待填写】

学院：【待填写】

专业：【待填写】

研究生：吴优

学号：2025213385

指导教师：张吕欧

二〇二六年九月

目录

- [摘要](#)
- [第1章 研究问题](#)
- [第2章 数据与研究设计](#)
- [第3章 方法](#)
 - [3.1 去随机化Model-X Knockoff](#)
 - [3.2 参数 \$K\$ 与预测验证](#)
 - [3.3 结构与非线性稳健性](#)
 - [3.4 基准比较与组件消融](#)
- [第4章 月度实证结果](#)
 - [4.1 确认集合](#)
 - [4.2 参数化展示与预测](#)
 - [4.3 结构与深度结果](#)
 - [4.4 统一基准、消融与模拟](#)
- [第5章 周度稳健性与应用](#)
 - [5.1 周度选择结果](#)
 - [5.2 月周交集](#)
 - [5.3 周度模型与结构检验](#)
 - [5.4 看板治理建议](#)
- [第6章 结论与展望](#)
- [参考文献](#)

摘要

本文研究电商经营看板中的维度准入问题：在多个相关候选指标中，筛选对下一期GMV仍有增量预测信息的变量，并控制入选集合的目标错误发现率。研究使用Olist全量公开数据，在自然粒度上聚合订单、商品明细、支付、评价、商品、卖家、顾客、地理和营销信息，分别形成14,677个卖家-月和33,190个卖家-周观测。32项候选维度中，一项因零方差排除，31项进入分析。

本文使用随机化秩高斯Copula、Ledoit-Wolf收缩协方差和MVR准则生成Model-X Knockoff，以Lasso真实变量与仿制变量系数差构造统计量。主分析重复60轮，设置单轮 $\alpha_{kn}=0.10$ 、最终 $\alpha_{eBH}=0.20$ ，经e-value聚合和e-BH形成确认集合。在确认集合内，训练期XGBoost与验证集TreeSHAP构成参数K的展示路径。卖家均值—离差分层、业务组Knockoff、深度联合交换性诊断、轨迹重要性、固定效应和周度完整重跑用于检验稳健性。研究还在统一选维窗口、12项预算、预测器和测试期下比较五种方法，并对边际变换、S矩阵、统计量和重复次数进行消融。

月度主分析入选14项，其中10项的单轮频率不低于90%。模型默认推荐 $K=10$ ，测试RMSE为2.385。同预算基准中，XGBoost-SHAP的测试RMSE最低，为2.383；去随机化Knockoff为2.392。在30组配对的70%卖家子样本中，Elastic Net和去随机化Knockoff的平均集合稳定性分别为0.873和0.855，两者差异区间包含0。20轮模拟中，去随机化与单次Knockoff的平均FDP分别为0.054和0.145。周度分析入选18项，与月度集合共同入选11项，Jaccard=0.524。结果支持月度承担确认性选择，周度承担粒度稳健性和短期预警。全部结果属于条件预测信息，不作因果解释。

关键词： 电商GMV；Model-X Knockoff；错误发现率；多粒度面板；可解释机器学习

第1章 研究问题

电商平台能够记录从获客、下单、支付到履约和评价的完整链路，但指标数量随业务扩张持续增加。订单数、件数和顾客数等变量高度相关；逐项显著性检验会累积误报；机器学习重要性虽然能够排序，却不能直接控制发现集合中的错误比例。

本文将研究问题定义为：给定卖家本期31项经营维度，哪些变量在控制其余候选信息后仍包含下一期GMV的增量预测信息，并值得进入持续监控体系。相应的条件零假设为

$$H_{0j}: Y_{s,t+1} \perp X_{j,s,t} \mid X_{-j,s,t}.$$

本文完成五项工作：构造可对账的月度和周度卖家面板；建立去随机化Model-X Knockoff选择流程；在确认集合内建立参数 K 的展示路径；通过面板分层、业务组、深度诊断和跨粒度重跑检验结论边界；通过统一预算基准、组件消融和已知真值模拟区分预测精度、选择稳定性与错误率控制。

第2章 数据与研究设计

数据来自Olist Brazilian E-Commerce Public Dataset和Marketing Funnel by Olist。支付与评价先聚合到订单级，地理信息先按邮编前缀聚合，再与商品明细连接，从而避免多对多连接造成GMV重复计算。独立顾客数使用customer_unique_id去重。

表2-1 月度与周度口径

口径	面板行	卖家	期间数	目标零值率	q=.20入选	研究角色
月度主分析	14677	2793	19	25.9%	14	确认性主结论
周度稳健性	33190	2834	83	40.5%	18	粒度稳健性补充

月度主目标为次月 $\log(1+GMV)$ ，周度目标为下一周 $\log(1+GMV)$ 。若卖家当前期活跃而下一期没有已送达订单，则目标标记为零。月度目标零值率为25.86%，周度为40.5%。下一期目标避免订单数、件数和价格对同周期GMV的机械解释。

31项建模变量覆盖价格成本、商品物理属性、内容、支付、评价、履约、交易规模、市场覆盖、卖家地域和营销。月度预测按2017年训练、2018年1月至4月验证、2018年5月至7月测试；周度预测使用相同自然时间边界。




图2-1 月度GMV变化




图2-2 周度GMV变化

第3章 方法

3.1 去随机化Model-X Knockoff

连续变量先进行分位缩尾、偏态变换、中位数插补和标准化，再通过随机化秩高斯变换处理离散值和并列值。使用Ledoit-Wolf协方差与MVR准则生成二阶Knockoff，将真实变量与仿制变量共同输入Lasso：

$$W_j = |\widehat{\beta}_j| - |\widehat{\beta}_{j+p}|.$$

每轮以 $\alpha_{kn} = 0.10$ 计算Knockoff+阈值并形成e-value，60轮平均后在 $\alpha_{eBH} = 0.20$ 下实施e-BH。单轮频率只描述随机稳定性，不等同于正式FDR保证。

3.2 参数K与预测验证

月度确认集合先由e-BH固定，再按训练期XGBoost在验证集上的平均绝对TreeSHAP排序。参数K截取前K项。默认值取累计验证贡献不低于90%、且验证RMSE距最优值不超过0.5%的最小K。测试集只用于最终评价。

3.3 结构与非线性稳健性

卖家均值一离差分层用于区分长期卖家差异和同一卖家的动态变化。31项变量进一步划为12个业务组，按组内真实与仿制系数的 L_2 范数差实施Group Knockoff。

深度生成器使用多比例swap-MMD、边际和协方差等联合损失。生成器是否有效由边际KS、协方差误差、深度核MMD和分类器检验共同决定。未通过准入的生成器不进入FDR结论。轨迹重要性在二维正则网格上累计配对竞争结果，并单独验证交换反对称性。

3.4 基准比较与组件消融

所有方法只使用2018年4月及以前数据选维，以12项为统一预算，再将各自集合输入相同参数的XGBoost并在2018年5月至7月测试。比较方法包括去随机化Knockoff、Elastic Net、稳定性选择、影子变量树模型和XGBoost-SHAP。集合稳定性使用30组完全相同的70%卖家子样本配对评估，Knockoff在每个子样本内聚合60轮。组件消融分别替换Copula边际、MVR/SDP/等相关S矩阵、Lasso/XGBoost统计量以及1至60轮聚合；真实协方差模拟报告FDP、Power和发现数。

第4章 月度实证结果

4.1 确认集合

Copula生成器平均边际KS为0.013，低于原始高斯的0.200。在最终FDR水平0.20下，月度主分析入选14项：成交订单数、平均商品价格、独立顾客数、成交件数、买家州数量、平均审核至承运天数、平均运费、活跃品类数、平均预计提前送达天数、平均商品标题长度、平均商品高度、卖家所在州频率、平均商品描述长度、平均下单至送达天数。

表4-1 月度严格入选变量

变量	平均W	单轮入选频率	平均e-value
成交订单数	0.144	95.0%	28.675
平均商品价格	0.142	95.0%	28.675
独立顾客数	0.140	95.0%	28.675
成交件数	0.117	95.0%	28.675
买家州数量	0.097	95.0%	28.675
平均审核至承运天数	0.053	95.0%	28.675
平均运费	0.027	95.0%	28.675
活跃品类数	0.023	95.0%	28.675
平均预计提前送达天数	0.021	95.0%	28.675
平均商品标题长度	0.022	91.7%	27.642
平均商品高度	0.013	80.0%	24.025
卖家所在州频率	0.014	76.7%	22.992
平均商品描述长度	0.009	50.0%	14.725
平均下单至送达天数	0.007	41.7%	12.142




图4-1 月度主分析平均e-value

4.2 参数化展示与预测

默认 $K = 10$ 的维度为独立顾客数、成交订单数、平均商品价格、平均审核至承运天数、平均预计提前送达天数、买家州数量、平均下单至送达天数、成交件数、平均运费、平均商品标题长度。默认模型测试RMSE为2.385，全31维XGBoost为2.388，相对变化-0.097%。

表4-2 代表性K档位

档位	K	累计贡献	验证RMSE	测试RMSE
极简	4	72.1%	2.335	2.388
均衡	8	87.1%	2.341	2.389
默认推荐	10	92.6%	2.343	2.385
完整确认集	14	100.0%	2.343	2.384

月度时间外最佳模型为XGBoost，RMSE为2.388，较朴素基线改善17.5%。SHAP前五项为成交订单数、独立顾客数、平均商品价格、平均审核至承运天数、买家州数量，与Knockoff共同支持交易规模、价格、履约和市场覆盖等信息。

4.3 结构与深度结果

卖家间层在0.20水平入选16项，卖家内层为0项。十二业务组在0.20水平入选0组，在0.30水平入选10组。轨迹统计量在0.20水平入选0项，在0.30水平入选5项。

表4-3 生成器联合诊断

方法	平均KS	协方差误差	深度核拒绝率	分类AUC
Copula-MVR	0.026	0.091	0%	0.777
基础深度生成器（训练集校准）	0.018	0.166	100%	0.902
最坏swap深度生成器（训练集校准）	0.019	0.188	100%	0.937

深度生成器的边际KS较小，但深度核MMD和分类器仍能区分交换样本，因此不作FDR声明。该负结果说明联合交换性必须独立验证，不能由模型复杂度或单一边际指标替代。

4.4 统一基准、消融与模拟

表4-4 同预算方法比较

方法	与主集重合	重抽样稳定性	测试RMSE
去随机化Knockoff	12/12	0.855	2.392
Elastic Net	10/12	0.873	2.390
稳定性选择	10/12	0.814	2.390
影子变量树模型	10/12	0.832	2.387
XGBoost-SHAP	8/12	0.686	2.383

XGBoost-SHAP的测试RMSE最低，为2.383；去随机化Knockoff为2.392。统一子抽样下，Elastic Net、去随机化Knockoff和XGBoost-SHAP的平均稳定性分别为0.873、0.855和0.686。Elastic Net与Knockoff差异较小且置信区间重叠，预测最优与稳定受控选择是不同目标。

表4-5 关键组件消融

消融	设定	M	严格数	与主集Jaccard
S矩阵	mvr	30	16	0.875
S矩阵	sdp	30	16	0.765
S矩阵	equicorrelated	30	12	0.857
重复次数	M=1	1	12	0.857
重复次数	M=10	10	15	0.933
重复次数	M=60	60	14	1.000
边际与统计量	原始高斯-MVR-Lasso	40	12	0.733
边际与统计量	Copula-MVR-XGBoost	25	0	0.000

重复次数由1增至60时，严格发现数依次发生变化，只有60轮与正式14项集合完全一致。原始高斯边际与替代S矩阵均改变集合；XGBoost竞争统计量在当前设定下没有严格发现。

表4-6 已知真值模拟

方法	平均FDP	FDP>0.20概率	平均Power	平均发现数
去随机化Knockoff	0.054	10.0%	1.000	10.65
单次Knockoff	0.145	35.0%	1.000	12.05
Elastic Net	0.644	100.0%	1.000	28.15
稳定性选择	0.090	5.0%	1.000	11.05
影子变量树模型	0.566	100.0%	1.000	23.10

去随机化Knockoff平均FDP为0.054，低于单次Knockoff的0.145，二者Power均为1.000。Elastic Net和影子变量树模型的高Power伴随较高FDP；稳定性选择在当前场景表现较好，但不具有相同的Model-X有限样本目标保证。

第5章 周度稳健性与应用

5.1 周度选择结果

周度Copula平均边际KS为0.012，原始高斯为0.234。在0.20水平，周度入选18项，其中13项单轮频率不低于90%。

表5-1 周度严格入选变量

维度	平均W	单轮频率	平均e-value	月度同时入选
独立顾客数	0.1546	100.0%	30.742	是
成交订单数	0.1391	100.0%	30.742	是
平均商品价格	0.0925	100.0%	30.742	是
成交件数	0.0859	100.0%	30.742	是
买家州数量	0.0837	100.0%	30.742	是
活跃品类数	0.0305	100.0%	30.742	是
平均审核至承运天数	0.0299	100.0%	30.742	是
平均运费	0.0299	100.0%	30.742	是
第一大买家州占比	0.0220	100.0%	30.742	否
平均商品标题长度	0.0167	100.0%	30.742	是
平均商品宽度	0.0173	98.3%	30.225	否
是否匹配营销成交线索	0.0118	95.0%	29.192	否
卖家所在州频率	0.0099	91.7%	28.158	是
营销来源频率	0.0088	85.0%	26.092	否
Boleto支付占比	0.0086	85.0%	26.092	否
平均商品图片数	0.0058	58.3%	17.825	否
平均商品高度	0.0041	41.7%	12.658	是
平均商品重量	0.0039	36.7%	11.108	否

5.2 月周交集

月度14项和周度18项共同入选11项，Jaccard=0.524。共同集合为平均商品价格、平均运费、平均商品高度、平均商品标题长度、平均审核至承运天数、成交件数、成交订单数、活跃品类数、独立顾客数、买家州数量、卖家所在州频率。月度特有3项为平均商品描述长度、平均下单至送达天数、平均预计提前送达天数；周度特有7项为平均商品重量、平均商品宽度、平均商品图片数、Boleto支付占比、第一大买家州占比、营销来源频率、是否匹配营销成交线索。




图5-1 月度与周度入选频率

交集集中于交易规模、价格、承运准备、商品标题和市场覆盖。月度特有项更偏慢变化的履约与内容信息；周度特有项更易受单周商品组合、支付和营销构成波动影响。周度特有变量只进入观察层。

5.3 周度模型与结构检验

表5-2 周度时间外预测

模型	测试N	RMSE(log)	MAE(log)	R2	WAPE
Extra Trees	7515	2.416	2.146	0.254	78.0%
XGBoost	7515	2.420	2.160	0.251	79.6%
XGBoost（周度18项）	7515	2.421	2.157	0.251	79.2%
Lasso	7515	2.433	2.189	0.244	82.7%
Ridge	7515	2.434	2.185	0.243	82.8%
MLP	7515	2.443	2.167	0.238	81.0%
本周GMV朴素基线	7515	3.401	2.600	-0.478	110.8%

最佳模型Extra Trees的RMSE为2.416；周度18项XGBoost的RMSE为2.421，相对全31维模型变化0.02%。

周度卖家间层入选12项，卖家内层为0项；Group Knockoff在0.20水平入选10组；轨迹统计量在0.20水平为0项。提高时间频率未恢复卖家内严格发现，短序列和零膨胀仍限制动态识别。

5.4 看板治理建议

月度层承担统计确认和参数 K 展示，周度层承担短期异常监测。月周共同11项可标记为跨粒度核心，其中周度高稳定的10项优先用于预警。看板按交易规模、价格成本、履约、供给内容和市场覆盖组织，每个模块保留一个主要状态指标和少量下钻指标。

实际周度部署必须按字段真实可见时间重构物流和评价特征。Knockoff、SHAP和固定效应均识别预测关系；对履约、内容和价格策略的可行动建议仍需随机实验或准实验确认。

第6章 结论与展望

本文构建了受控确认、参数化展示和多粒度复核组成的GMV维度选择框架。月度主分析在0.20水平形成14项确认集合，默认 $K = 10$ 在压缩展示数量的同时保留预测性能。周度分析形成18项集合，与月度共同入选11项；周度入选集合的XGBoost RMSE为2.421。月度降低低频噪声，适合正式确认；周度增加时间点，适合作为稳健性和短期预警。

研究的主要贡献包括：以多轮e-value聚合降低Knockoff随机性；将统计确认与参数 K 展示分离；通过面板分层、业务组、深度联合诊断和周度重跑明确结论边界；用统一信息窗口、变量预算、预测器和测试期完成公平基准，并以组件消融说明主流程各环节的作用。主要限制包括公开数据缺少曝光、库存和促销信息，面板存在组内相关，深度生成器未通过联合准入，周度回溯口径不等同于实时部署，20轮模拟不足以覆盖所有稀疏度与相关结构。

后续研究可在更长企业面板上使用滚动Knockoff和在线e-value，采用显式离散似然或条件生成模型改善联合分布，并对可行动变量开展实验或因果机器学习分析。

参考文献

- [1] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing[J]. *Journal of the Royal Statistical Society: Series B*, 1995, 57(1): 289-300.
- [2] Barber R F, Candès E J. Controlling the false discovery rate via knockoffs[J]. *The Annals of Statistics*, 2015, 43(5): 2055-2085.
- [3] Candès E, Fan Y, Janson L, Lv J. Panning for gold: Model-X knockoffs for high-dimensional controlled variable selection[J]. *Journal of the Royal Statistical Society: Series B*, 2018, 80(3): 551-577.
- [4] Romano Y, Sesia M, Candès E. Deep knockoffs[J]. *Journal of the American Statistical Association*, 2020, 115(532): 1861-1872.
- [5] Ren Z, Barber R F. Derandomised knockoffs: leveraging e-values for false discovery rate control[J]. *Journal of the Royal Statistical Society Series B*, 2024, 86(1): 122-154.
- [6] Wang R, Ramdas A. False discovery rate control with e-values[J]. *Journal of the Royal Statistical Society Series B*, 2022, 84(3): 822-852.
- [7] Tibshirani R. Regression shrinkage and selection via the lasso[J]. *Journal of the Royal Statistical Society: Series B*, 1996, 58(1): 267-288.
- [8] Zou H, Hastie T. Regularization and variable selection via the elastic net[J]. *Journal of the Royal Statistical Society: Series B*, 2005, 67(2): 301-320.
- [9] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. *Journal of Multivariate Analysis*, 2004, 88(2): 365-411.
- [10] Spector A, Janson L. Powerful knockoffs via minimizing reconstructability[J]. *The Annals of Statistics*, 2022, 50(1): 252-276.
- [11] Breiman L. Random forests[J]. *Machine Learning*, 2001, 45: 5-32.
- [12] Friedman J H. Greedy function approximation: a gradient boosting machine[J]. *The Annals of Statistics*, 2001, 29(5): 1189-1232.
- [13] Chen T, Guestrin C. XGBoost: a scalable tree boosting system[C]//*Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016: 785-794.
- [14] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]//*Advances in Neural Information Processing Systems*. 2017, 30.
- [15] Lim B, Arik S Ö, Loeff N, Pfister T. Temporal fusion transformers for interpretable multi-horizon time series forecasting[J]. *International Journal of Forecasting*, 2021, 37(4): 1748-1764.
- [16] Hastie T, Tibshirani R, Friedman J. *The elements of statistical learning*[M]. 2nd ed. New York: Springer, 2009.
- [17] Wooldridge J M. *Econometric analysis of cross section and panel data*[M]. 2nd ed. Cambridge, MA: MIT Press, 2010.
- [18] Arellano M. Computing robust standard errors for within-groups estimators[J]. *Oxford Bulletin of Economics and Statistics*, 1987, 49(4): 431-434.
- [19] Varian H R. Big data: new tricks for econometrics[J]. *Journal of Economic Perspectives*, 2014, 28(2): 3-28.
- [20] Mullainathan S, Spiess J. Machine learning: an applied econometric approach[J]. *Journal of Economic Perspectives*, 2017, 31(2): 87-106.
- [21] Molnar C. *Interpretable machine learning*[M/OL]. 2nd ed. 2022. <https://christophm.github.io/interpretable-ml-book/>.
- [22] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: machine learning in Python[J]. *Journal of Machine Learning Research*, 2011, 12: 2825-2830.
- [23] McKinney W. Data structures for statistical computing in Python[C]//*Proceedings of the 9th Python in Science Conference*. 2010: 56-61.
- [24] Harris C R, Millman K J, van der Walt S J, et al. Array programming with NumPy[J]. *Nature*, 2020, 585: 357-362.
- [25] Virtanen P, Gommers R, Oliphant T E, et al. SciPy 1.0: fundamental algorithms for scientific computing in Python[J]. *Nature Methods*, 2020, 17: 261-272.
- [26] Seabold S, Perktold J. Statsmodels: econometric and statistical modeling with Python[C]//*Proceedings of the 9th Python in Science Conference*. 2010: 92-96.

- [27] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle, 2018. <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>.
- [28] Olist. Marketing Funnel by Olist[DB/OL]. Kaggle, 2018. <https://www.kaggle.com/datasets/olistbr/marketing-funnel-olist>.
- [29] Little R J A, Rubin D B. Statistical analysis with missing data[M]. 3rd ed. Hoboken: Wiley, 2019.
- [30] Hyndman R J, Athanasopoulos G. Forecasting: principles and practice[M/OL]. 3rd ed. Melbourne: OTexts, 2021.
- [31] Meinshausen N, Bühlmann P. Stability selection[J]. Journal of the Royal Statistical Society: Series B, 2010, 72(4): 417-473.
- [32] Vovk V, Wang R. E-values: calibration, combination and applications[J]. The Annals of Statistics, 2021, 49(3): 1736-1754.
- [33] Sudarshan M, Tansey W, Ranganath R. Deep direct likelihood knockoffs[C]//Advances in Neural Information Processing Systems. 2020, 33: 5036-5046.
- [34] Shen A, Yan Y, Zhao P. Deep dependency regularized knockoff for controlling false discovery rates[C]//International Conference on Learning Representations. 2024.
- [35] Zhu Z, Fan Y, Kong Y, Lv J, Sun F. DeepLINK: deep learning inference using knockoffs with applications to genomics[J]. Proceedings of the National Academy of Sciences, 2021, 118(36): e2104683118.
- [36] Hollmann N, Müller S, Purucker L, et al. Accurate predictions on small data with a tabular foundation model[J]. Nature, 2025, 637(8045): 319-326.
- [37] Borisov V, Leemann T, Seßler K, et al. Deep neural networks and tabular data: a survey[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024, 35(6): 7499-7519.
- [38] Hansen L, Manzo M, Regier J. Normalizing flows for knockoff-free controlled feature selection[C]//Advances in Neural Information Processing Systems. 2022, 35.
- [39] Fischer L, Sechidis K. Choosing the nominal level post-hoc with knockoffs using e-values[EB/OL]. arXiv:2511.11166, 2025.
- [40] PyTorch Contributors. PyTorch 2.8 documentation[EB/OL]. 2025. <https://pytorch.org/docs/2.8/>.
- [41] Sawaya K. Provable FDR control for deep feature selection: deep MLPs and beyond[EB/OL]. arXiv:2512.04696, 2025.
- [42] Zou B J, Tian L. GRIP2: a robust and powerful deep knockoff method for feature selection[EB/OL]. arXiv:2602.00218, 2026.
- [43] Bacci S, Grilli L, Rampichini C. Variable selection via knockoffs for clustered data[EB/OL]. arXiv:2602.19398, 2026.
- [44] Liu F, Xu W, Lu J, Zhang G, Gretton A, Sutherland D J. Learning deep kernels for non-parametric two-sample tests[C]//Proceedings of the 37th International Conference on Machine Learning. 2020: 6316-6326.
- [45] Dai R, Barber R F. The knockoff filter for FDR control in group-sparse and multitask regression[C]//Proceedings of the 33rd International Conference on Machine Learning. 2016: 1851-1859.